

分类号	
学校代码	10700
学 号	2210221265

西安理工大学

硕士学位论文

(专业学位)

考虑机器人学习和实际装配场景的复杂动态人机协作任务分配

冯俊伟

专业类别: 机械硕士

工程领域: 机械工程

指导教师: 王雯 教授 高志强 副教授

企业导师: 颜长峰 高级工程师

申请日期: 2024 年 6 月

论文题目：考虑机器人学习和实际装配场景的复杂动态人机协作任务分配

学科名称：机械工程

研 究 生：冯俊伟

签 名：

指导教师：王雯 教授

签 名：

高志强 副教授

签 名：

企业导师：颜长峰 高级工程师

签 名：

摘 要

任务分配作为人机协作装配领域的研究热点，旨在实现操作者与机器人装配任务的最优分配。目前，任务分配模型大多适用于流水线生产，装配场景因素简单，人机协作程度较低；模型仅考虑静态分配过程，通常忽略机器人状态和实际装配场景的影响，获得的分配结果无法进行动态调整，可能造成资源分配不合理；同时，随着协作机器人的发展，机器人具有自主感知、自主决策、自主执行以及自主学习能力，传统模型难以充分发挥机器人自身能力，造成资源浪费。

针对以上问题，本文基于传统任务复杂度分配模型，重点探究复杂动态装配过程的任务分配实现方法。

面向复杂动态装配过程的人机协作任务分配方法研究。考虑动态分配过程中操作者意图、机器人能力变化和实际装配场景因素影响，提出一种复杂动态装配任务分配流程。通过设计提示词对预训练模型 GPT（Generative Pre-trained Transformer）进行微调，实现对装配任务细化，从而获得与机器人能力相匹配的动作序列，结合动态分配流程，实现装配任务动作级别的分配；基于传统复杂度任务分配模型，改进任务复杂度评价流程，细化任务评价结果，对评价存疑的任务进行在线装配仿真验证，并考虑机器人能力变化的影响，更新任务评价集合；设计机器人在线插空学习策略，以实现机器人能力的在线更新。以简单产品装配为例，通过本文提出的复杂动态任务分配流程，实现在人机协作动态过程中的动作级别任务分配，为实现动态任务分配的提供一种思路。

基于深度强化学习的复杂轴孔装配仿真研究。针对不同孔位姿的复杂轴孔装配问题，在 Gazebo 仿真环境下，基于 Soft Actor-Critic(SAC) 深度强化学习算法，构建统一的算法环境，包括状态空间、动作空间、奖励函数等；采用相同算法环境分别对垂直和倾斜轴孔装配模型进行强化学习训练，并对训练获得的两个装配模型进行不同直径和间隙的轴孔

装配仿真测试，其装配成功率分别达到 97%和 98%。针对不同孔型的轴孔装配问题，利用原有垂直装配模型实现对不同边长和间隙方形轴孔装配的仿真测试，表明了装配模型具有一定的鲁棒性和泛化性。针对复杂动态任务分配对在线仿真验证和在线插空学习的需求，设计了在线装配仿真场景创建流程，实现了实际场景到仿真场景的映射，并验证了分段强化学习提升机器人能力的可行性。

机器人自主轴孔装配实验。为验证在线装配仿真场景创建及强化学习仿真模型迁移的可行性，搭建 Sawyer 机器人实际装配场景。通过机器视觉和点云识别定位获取装配对象信息，搭建仿真场景，加载倾斜轴孔装配模型，完成在线装配仿真。并将仿真获得的机器人关节角序列输出给 Sawyer 机器人执行，借助孔的导向特性，最终实现对直径 50mm、间隙 0.1mm、倾角 30°的斜孔装配。

关键词：动态任务分配；任务复杂度；深度强化学习；轴孔装配

Title: CONSIDER COMPLEX AND DYNAMIC HUMAN-ROBOT COLLABORATIVE TASK ASSIGNMENT FOR ROBOT LEARNING AND REAL-WORLD ASSEMBLY SCENARIOS

Major: Mechanical Engineering

Name: Junwei Feng

Signature: 

Supervisor: Prof. Wen WANG

Signature: 

Associate prof. Zhiqiang GAO

Signature: 

Senior Engineer. Changfeng YAN

Signature: 

Abstract

Task allocation, as a research hotspot in the field of human-robot collaborative assembly, aims primarily at achieving the optimal distribution of assembly tasks between humans and robots. Currently, most task allocation models are designed for assembly line production with simple assembly scenario factors and a low degree of human-robot collaboration; they only consider the static allocation process and often overlook the impact of robot states and actual assembly scenarios. Consequently, the outcomes of task allocation cannot be dynamically adjusted, which may lead to unreasonable resource distribution. Moreover, with the development of collaborative robots that possess capabilities of autonomous perception, decision-making, execution, and learning, traditional models fail to fully leverage the robots' inherent abilities, resulting in resource wastage.

Addressing the issues mentioned above, this paper focuses on exploring methods for task allocation implementation during complex dynamic assembly processes, based on traditional task complexity allocation models.

Research on human-machine collaborative task allocation methods for complex dynamic assembly processes. Taking into consideration the influences of operator's intent, variation in robot capabilities, and actual assembly scenario factors in dynamic allocation processes, a complex dynamic assembly task allocation process is proposed. By designing prompt words to fine-tune the pre-trained model GPT (Generative Pretrained Transformer), the assembly tasks are refined to obtain an action sequence that matches the robot's capabilities. In combination with the dynamic allocation process, it allows task allocation at the level of assembly actions. Based on traditional complexity task allocation models, the complexity evaluation process is improved and the evaluation results of tasks are refined. For tasks whose evaluations are questionable, online assembly simulation verification is conducted, and considering the impact of changes in robot capabilities, the evaluation set for tasks is updated. A strategy for the robot's online idle learning is designed to realize the online update of robot capabilities. Using simple product assembly as

an example, the complex dynamic task allocation process proposed in this paper achieves task allocation at the action level in the dynamic process of human-machine collaboration, providing an approach for implementing dynamic task allocation.

Research on complex shaft-hole assembly simulation based on deep reinforcement learning. Addressing the complex shaft-hole assembly issue for holes with varying poses, a unified algorithmic environment was constructed in the Gazebo simulation setting, grounded on deep reinforcement learning algorithms. This environment includes elements such as state space, action space, and reward function. Using this consistent algorithmic context, both vertical and inclined shaft-hole assembly models were trained through reinforcement learning. These trained models were then subjected to simulation tests for assembling shaft-holes with varying diameters and clearances, achieving assembly success rates of 97% and 98%, respectively. Regarding the shaft-hole assembly challenge with different hole shapes, the existing vertical assembly model was tested for the assembly of square shaft-holes with different side lengths and clearances, indicating a certain level of robustness and generalizability of the assembly model. To meet the demands for online simulation verification and gap learning in complex dynamic task allocation, an online assembly simulation scenario creation process was designed, achieving the mapping from real scenes to simulation scenarios, and validating the feasibility of incremental reinforcement learning to enhance robot capabilities.

Autonomous robot shaft-hole assembly experiment. To verify the feasibility of creating online assembly simulation scenarios and transferring reinforcement learning simulation models, an actual assembly scene using a Sawyer robot was constructed. By utilizing machine vision and point cloud recognition for positioning, information about the assembly objects was acquired. A simulation environment was then set up, and an inclined shaft-hole assembly model was loaded to complete the online assembly simulation. The robot joint angle sequence derived from the simulation was output to the Sawyer robot for execution. With the help of the hole's guidance feature, the assembly of an inclined hole with a diameter of 50 mm, clearance of 0.1 mm, and an inclination angle of 30° was ultimately achieved.

Keywords: Dynamic task allocation; Task complexity; Deep reinforcement learning; Shaft-hole assembly

目 录

1 绪论.....	1
1.1 研究背景和意义.....	1
1.2 国内外研究现状.....	2
1.2.1 装配任务分配研究.....	2
1.2.2 强化学习轴孔装配研究.....	5
1.3 主要研究内容和论文章节安排	7
2 面向复杂动态装配过程的人机协作任务分配方法研究	9
2.1 任务复杂度影响因素和量化方法	9
2.1.1 零部件自身属性.....	10
2.1.2 装配和连接.....	10
2.1.3 安全设计因素.....	11
2.1.4 任务复杂度计算.....	11
2.2 基于复杂度的动态任务分配模型构建	13
2.2.1 模型假设.....	13
2.2.2 复杂动态装配任务分配流程.....	13
2.2.3 装配任务顺序以及选取.....	15
2.2.4 改进任务复杂度评价流程.....	21
2.2.5 信息数字化.....	25
2.3 基于动态任务分配模型的减速器装配任务分配	26
2.4 本章小结.....	28
3 基于深度强化学习的复杂轴孔装配仿真	29
3.1 SAC 算法基本原理.....	29
3.1.1 强化学习算法基本原理.....	29
3.1.2 深度强化学习 SAC 算法原理	31
3.2 轴孔装配强化学习算法环境设计	35
3.2.1 仿真平台简介.....	36
3.2.2 Sawyer 机器人运动学建模.....	36
3.2.3 状态空间.....	41
3.2.4 动作空间.....	42
3.2.5 奖励函数.....	42
3.2.6 终止函数.....	43
3.2.7 环境初始化.....	43
3.2.8 算法训练整体流程.....	44
3.3 轴孔装配仿真训练及测试	45

3.3.1 强化学习模型参数.....	45
3.3.2 仿真装配训练.....	46
3.3.3 仿真装配测试.....	48
3.4 在线搭建仿真场景.....	51
3.4.1 离线建库.....	52
3.4.2 离线仿真场景搭建.....	53
3.4.3 在线仿真场景创建.....	53
3.4.4 在线插空学习测试.....	54
3.5 本章小结.....	55
4 机器人轴孔自主装配实验	57
4.1 机器人装配场景搭建.....	57
4.2 相机标定.....	58
4.2.1 Kinectv2 相机标定	58
4.2.2 手眼标定.....	60
4.3 点云识别与定位.....	61
4.3.1 点云预处理.....	61
4.3.2 离线构建 CAD 模型点云库	63
4.3.3 点云识别.....	64
4.3.4 点云定位.....	65
4.4 轴孔装配仿真实验.....	67
4.5 机器人轴孔装配实验.....	68
4.6 本章小结.....	70
5 结论与展望.....	71
5.1 结论.....	71
5.2 展望.....	72
参考文献.....	73

1 绪论

1.1 研究背景和意义

随着科学技术和市场经济发展,企业竞争愈加激烈,市场消费者对产品服务个性化的需求日益增强,要求制造业企业必须具备个性化定制和柔性制造能力^[1-4]。装配是产品制造过程的关键环节之一,在实际生产过程中,操作者具有较高的主观能动性,能够灵活处理装配过程中突发情况,具有可靠执行复杂构件装配、处理简单临时任务以及灵活执行任务的优势。但若将装配任务都交由操作者完成,容易造成操作者身心上的疲劳,导致操作者可靠性降低进而影响装配的质量和效率。机器人则具有可执行高危任务、生产效率高、稳定性强、精度高、重复活动精度高等特点。将机器人引入装配系统中,能够加快生产速度,提高效率,降低成本。当然引入机器人的目的是使得机器人与操作者高效协同工作并非完全取代操作者,因此提出人机协作概念。人机协作所指的是:人类和协作式智能机器人在没有安全栅栏的狭小工作空间内共同完成某项任务。在人机协作场景中,操作者和机器人共同协作装配产品。在我国,人机协作已列入《智能制造 2025》和《新一代人工智能发展规划》的重点扶持项目,并成为目前国内智能机器人发展的一个主要趋势^[5]。

根据机器人与操作者交互水平可以将人机协作程度分为以下类别:

1. 机器人与操作者处于不同时间不同空间执行不同装配任务。
2. 操作者与机器人处于同一时间不同空间执行任务,通常为工业机器人独自执行任务,特点为机器人交互感知能力低,为保证操作者安全需要进行安全隔离。
3. 处于不同时间同一空间,机器人具有一定的感知交互能力,能够单独执行一部分任务,机器人常为辅助完成任务。
4. 处于同一时间同一空间,机器人具有较高的智能化,人机交互非常密集且深入,能够实现与操作者的动态配合,本文重点研究同时空的协作装配问题。

人机协作作为制造业升级转型的重要抓手,其研究方向众多,如人机协作任务分配、意图识别^[6]、安全设计^[7]和仿真规划^[8]等,其中任务分配问题是人机协作领域的研究热点之一。

其主要目的是明确哪些任务适合人操作,哪些任务适合机器进行操作。传统方法中,操作者与机器人之间的任务分配是通过人类直觉完成的,没有任何结构化的模型可用。同时由专家或工人直觉进行的任务分配,受主观影响大,往往并非最优分配方法,对资源分配和任务完成的质量效率都有巨大影响。此外,制造业在应对市场环境变化时,必须主动适应生产需求的变化,满足小批量、个性化定制需求,对于生产线的布局的调整也会更加频繁,传统分配方式将面临繁重的工作量,耗时长且效率低下,无法满足快速变化的装配任务需求^[9]。因此,在人机协作装配过程中,面对复杂多变的装配任务和装配场景,如何

充分发挥机器人与人两者自身优势，尽可能做到将资源充分利用是生产过程中所追求的。对于任务分配问题的研究则成为实现这一目标的重要途径之一，任务分配的核心问题为如何将任务自身属性、机器人自身属性和人的特点相结合，将任务交于适合的对象完成，最终达到对装配资源的整合和合理分配，进而提升装配效率质量。

到目前为止，关于人机协作中任务分配问题已经开展了一些研究，大致可分为基于数据驱动和基于知识驱动两种分配方法^[10]。基于数据驱动模型是指依赖于大量数据的分析和处理，以从数据中提取模式、趋势和见解，从而指导决策和行动的方法。这种方法通常使用机器学习、数据挖掘和统计分析等技术。基于知识的任务分配模型是指根据专家知识或规则来分配任务和指导决策的方法，例如专家系统、规则设计或复杂度模型等。在任务分配模型搭建时仍存在以下几个问题：

1. 在模型构建过程中，通常假设操作者和机器人能够在理想工作环境中执行所分配的任务并采集相关属性信息。模型忽视了在实际生产中，机器人和人由于各自特性以及现实场景的限制，可能无法完成由模型直接分配的任务，进而影响任务分配的优化效果和装配质量。

2. 多数现有的研究仅考虑静态任务分配，即在装配任务执行前完成任务分配，并不考虑实际工作环境对任务执行的影响。但在人机协作程度高的装配场景中操作者与机器人在同时空下进行协作装配，装配场景中信息复杂多变，任务分配模型需要适用于复杂动态执行过程，因此需要考虑实际装配场景对分配结果的影响。此外，分配结果固定性将导致装配对象的执行任务具有重复性和单一性。考虑到操作者自身特点，可能会降低操作者的工作效率和质量。

3. 近年来，人工智能技术的快速发展，智能机器人已成为产业升级的重要组成部分，并在人机协作中扮演着重要角色。与传统机器人相比，智能机器人具备更强的自主学习能力，能够在初始能力的基础上，针对某特定问题通过实际操作增长知识和技能。然而，现有的研究大多只根据机器人初始能力进行一次性任务分配，而没有将智能机器人通过自主学习逐渐增长的能力充分运用到任务分配当中，未能充分发挥智能机器人的价值，造成了资源的浪费。这说明在生产过程中还有很大的改进和提升空间。

为了解决上述问题，本文致力于研究在装配任务动态执行过程中的任务分配策略，深入考虑各种装配场景对机器人执行任务能力的影响。同时，本文还将探讨机器人的自我学习能力如何影响装配任务的分配，尝试量化机器人能力，以确保机器人的能力得到充分利用，最终实现智能化的任务分配。

1.2 国内外研究现状

1.2.1 装配任务分配研究

任务分配作为人机协作领域的研究热点之一，目前已有许多国内外学者在这一领域开展了研究，并取得了显著成绩。任务分配问题被应用到各个领域当中，如无人机组协作

战^[11-13]、服务机器人以及产品装配等。对于装配任务分配方法的研究方法大致包括为基于知识驱动、数据驱动以及二者融合驱动。

(1) 知识驱动模型

基于知识的模型的主要目的是利用专家知识、规则或先验信息来指导任务执行、决策制定或问题求解。

基于任务复杂度分配模型作为常见的知识驱动模型，Samy 等人^[14]提出一种装配复杂性评价模型。模型将产品组装复杂度定义为个别零件/子装配件包含的物理属性在手工或自动装配过程中导致操作和插入困难的程度。这种方法考虑了不同零件的装配属性以及它们的数量和种类，并对汽车活塞和一组三插脚电插头装配任务进行复杂度分析。Liu^[15]给出主观任务复杂度和任务难度的定义分别为任务执行者感知到的复杂度和任务执行者在执行任务时感到的困难程度，并提出一种遵循一个任务-组件-因素-维度框架来概念化复杂性，搭建任务评价模型。赵洪乐^[16]从信息熵视角出发，给出装配中静态复杂度与动态复杂性概念，同时描述了在装配系统执行过程中，各装配资源实际状态需要的信息量。在装配方面，Ahmad 等人^[17]研究量化了与组件的安装可能性和装配顺序相关的装配复杂度。这个度量非常适合考虑详细的装配任务和产品，但并未主要关注于整体装配流程。周伟明^[18]通过分析装配过程中操作的行为过程，搭建装配工位复杂度分析模型，并应用于分析任务复杂度与操作者装配失误的关联，模型仅考虑任务复杂性对于操作人员的影响，并未深入考虑装配过程中人机协作因素。Lamon^[19]在任务复杂度的基础上引入了操作者灵活性以及任务压力指标对装配任务进行评估，通过操作者灵活性属性考虑了不同装配人员的操作喜好，为确保人机装配任务分配均匀提出任务压力概念，设计整体装配成本函数用于完成任务分配工作。张凯^[10]通过构建任务复杂度评价模型，将任务属性作为模型输入，输出评价结果作为初次的任务分配结果，对于操作者与机器人都能完成的任务进行仿真装配验证机器人执行任务的可行性，对初次评价结果进行更新获得最终分配结果。

此外，也有学者提出了许多基于其他理论的知识驱动模型，Marsden 等人^[20]提出让“利益相关者”对系统的目的描述达成一致的理念，将改进 HTN(Hierarchical task analysis)原理应用于操作者与机器人任务分配问题中，提出一系列任务分配的标准，以考虑它们对工作满意度、人为错误、注意力、工作负载、生产力和成本效益可能产生的影响。Ranz^[21]提出了一种通过考虑人和机器人的实际能力来决定任务分配的方法，通过能力与某一特定任务的给定要求相匹配，以确定最大一致性作为分配决策的基础，从而提高工作质量。陈志贤^[22]通过对传统 HTN 模型改进，提出经验信息抽象提取框架，实现基于经验对同类型多场景任务规划问题进行自主规划。

上述知识驱动的任务分配模型仍存在一些问题。基于已有的知识库或规则集来构建的分配模型的模型泛化性差，在新环境中或未知场景时，模型的任务分配或决策结果可能无法适用，需要不断更新知识或规则。此外，构建模型准确性依赖于领域专家或知识工作

者的经验和专业知识,当专家知识不完善或不准确,可能会导致模型的性能下降或决策的不准确性,基于知识驱动的分配模型通常应用于静态任务分配中。

(2) 数据驱动

随着机器学习智能算法以及人机协作其他领域研究发展,有研究学者尝试将智能算法引入到任务分配研究领域并有一些显著成果。

有学者将人机协作任务分配问题简化为最优路径搜索问题, Shao 等人^[23]首次在分层任务网络(HTN)规划中引入了蒙特卡洛树搜索(Monte Carlo Tree Search, MCTS)技术,提出了 MCTS-HTN 算法,并将其与 SHOP 规划算法整合,构造了 SHOP-m 算法,能够实现动态最优任务分配路径决策。Hari^[24]提出用于解决任务分配、排序和调度问题(Task Allocation, Sequencing and Scheduling Problem, TASSP)的近似算法。算法通过对单一旅行商问题拓展,旨在找到每个机器人访问目标的序列,并与人类操作员一起执行目标上的任务,以确保每个目标正好被某个机器人访问一次,满足调度约束,且任何机器人的最大任务时间最小,并通过对 11 个目标,3 个机器人和 1 个人类操作员的场景进行算法验证。

为保障装配系统中操作者的可靠性,还有学者将人因工程领域研究引入任务分配模型。李吉轩^[25]提出了考虑成本-时间-难度多目标的动态任务评价模型,通过对实时场景的检测和装配工序识别,采用 Mediapipe 疲劳度检测算法实现操作者疲劳度计算,并通过改进的人工蜂群算法实现装配任务的分配。夏青云^[26]提出一种面向人-外肢体装配任务分配模型,将操作者身心疲劳程度作为模型约束条件,采用改进 NSGA-II 算法实现任务分配,此外通过改进人工势场法,实现机器人装配过程中自主避障的路径规划。

也有学者将人机协作中其他研究方向内容与任务分配问题相融合, Cramer^[27]提出一种基于人类意图的装配任务规划模型,模型通过提前采用反向切割集算法自动构造装配顺序 And/or 图,在获取到操作者装配意图后,构建隐马尔可夫决策模型进行任务规划,实现机器人与操作者高效相互协作。王艺宸^[28]提出人机协作装配过程中的数字孪生框架,通过遗传算法实现对装配任务的分配,并通过相机标定机器人控制与映射实现仿真环境的虚实映射,最终实现装配过程中完整映射-实时同步-迭代优化的闭环。熊志华^[29]则是将任务分配问题转化为强化学习训练问题,环境状态空间设计为四通道的帧图,其中包含编号、任务类型、执行时间以及执行单元,动作空间为分配的任务和执行对象,并以获取最短任务时长作为训练模型,完成任务分配。Adu-Bredu 等人^[30]以及 Garrett 等人^[31]设计了在线规划和操作系统来完成厨房家务工作。尽管重新规划是为了应对突发事件,但在实践中其成功率并不令人满意,尤其是在有高实时性要求的情况下。Lee^[32]将人机协作领域中意图预测以及任务分配研究内容联合起来,提出了一种考虑人机协作(HRC)和人类行为预测(HBP)的拆卸任务规划算法。通过装配任务移动距离以及耗时来预测操作者下一步执行动作,根据装配任务顺序设计任务序列规划器,实现根据操作者工作动态分配任务。

基于数据驱动模型需要大量的历史经验数据来确保模型输出的准确性,尤其为深度学习,模型准确率受训练数据质量影响,当数据出现错误、缺失或偏差时,模型输出结

果将受其影响。此外，对于数据生成的模型一般具有可解释性差的问题，难以对模型深层原理进行分析。

(3) 混合驱动

由于知识驱动与数据驱动各自具有优缺点，有研究学者尝试将两者进行融合应用于任务分配方法的研究中。Hasan^[33]基于装配任务复杂性评价方法，将装配任务中任务作为节点，根据复杂性构建二叉树形结构，通过层次聚类方法计算节点之间相似性，并根据相似性实现产品分类，从产品级别进行分配，但并未给出任务分配过程中具体机器人与操作者分工情况。Bruno^[34]基于专家任务分类数据提前训练二叉分类树，将任务分为操作者执行、机器人执行以及二者都可执行，模型输入任务属性，根据分类结果设置任务分配规则，但模型并未考虑实际机器人与操作者自身能力问题，使得模型缺少泛化性。Mateus^[35]提出了一种分析装配任务优先级的算法，以联络矩阵、碰撞矩阵以及基础部件和子装配体内容作为输入，识别子装配体及其组成部件的装配优先级，并生成优化后的装配任务顺序。Parsa^[36]提出了一种基于人机协作的拆解规划方法，首先通过任务零部件属性参数评价对人机协作任务进行分类，然后构建 And/or 图表示拆解顺序，最终通过改进的遗传算法实现任务分配。Elen^[37]通过构建 And/Or Graph (AOG)实现装配任务在线分配，在每个装配步骤中将任务属性作为输入，模型输出下一个任务以及分配对象，通过计算每个关节运动执行过程中的动力磨损值 $Vi(t)$ ，来评估关节层面的人体工效学风险，评估的结果在下次分配前将作为更新 AOG 的成本。梁人升^[38]引入人因工程学中的心理以及生理疲劳因素作为约束条件用于任务分配数学模型搭建，模型通过量化任务复杂性和人工因素来计算任务匹配度，并设计搜索算法实现高效和最大化匹配度的分配方案。

以上学者多从客观或主观的角度实现对分配模型的构建，但构建的多数分配模型仅适用于任务执行前，鲜有考虑在人机协作动态执行过程中，真实装配场景对任务分配结果的影响。与理想环境下的装配相比，真实场景中的信息要更为复杂多变。在理想环境中进行的任务分配，可能会因为实际场景中设备、工具以及装配环境等因素限制，导致机器人与操作者无法有效执行操作。因此，有必要分析动态协作过程中，机器人在复杂实际装配环境下执行任务的可行性。

此外，协作机器人学习能力对任务分配结果的准确性影响巨大。具备学习能力的协作机器人可以根据持续积累的经验和反馈进行调整和改进。协作机器人能够更好地适应不同的装配任务，并在面对新的挑战时做出更加灵活的反应，若任务分配模型仅基于机器人初始能力进行任务分配，模型分配结果会偏于保守，不能充分发挥机器人能力，从而造成资源浪费。

1.2.2 强化学习轴孔装配研究

轴孔装配作为装配过程中的常规操作，其自动化水平直接决定了装配效率和质量。针对轴孔装配任务，研究机器人自主装配方法有助于推动机器人在装配行业中的应用。尤其

是对于那些精度要求极高以及形态复杂的部件来说,实现高效而可靠的轴孔装配仍面临着众多技术难题。对于轴孔装配方法研究已有很多研究成果,其中包括基于力学反馈^[39]、路径规划算法^[40]、模仿学习^[41]以及视觉与力学相结合^[42]的研究方法等。在深度学习盛行之后,许多学者开始探索将强化学习与传统装配方法相结合,以进一步提高装配任务的效率和准确性。装配过程中,机器人应用强化学习优点是能够进行自主学习如何执行装配任务,属于无监督学习,不需要大量先验数据,机器人能够从与环境不断交互过程中获取经验,并根据奖励函数的信息调整行为,逐步提高任务执行的效率和准确性。

2019年,Xu等人^[43]将强化学习技术应用于机器人自动装配多轴孔的挑战中。通过构建强化学习环境,成功对双轴插孔装配任务进行了仿真测试并验证其有效性。Zou等人^[44]设计出了一种模糊 Q-learning 可变阻抗控制器。其核心目标在于训练机器人掌握在轴销插孔装配任务中的顺应性行为,增强其在不确定环境下的应变能力。Khader等人^[45]在研究中将变阻抗控制(Variable Impedance Control, VIC)与强化学习相结合,采用交叉熵(Cross Entropy)方法对采样分布进行优化。这一方法旨在解决强化学习在全时稳定性方面存在的问题,为实现更稳定、可靠的强化学习过程提供思路。Hou等人^[46]采用了一种创新的分层强化学习策略,通过构建一个基于阻抗作用空间的框架,有效地解决了复杂多样的轴销插孔装配任务,从而为复杂装配过程提供了新的解决方案。鄢智超^[47]提出了一种可变旋转参数的多轴孔装配强化学习方法,基本思想为实时计算装配零件的位姿变化进行机器人姿态调整,通过分析力学与姿态变换关系并结合强化学习 DDPG 算法,实现对多轴孔的高效装配。

为提高强化学习模型轴孔装配收敛速度,Zhang等人^[48]采用对抗性逆强化学习方法,通过分析众多轴销插孔装配的示范数据,获得其奖励函数。这一方法显著提升了学习模型在不同装配任务间的迁移能力,增强了机器学习模型的适应性和灵活性。Yu等人^[49]提出了一种由用户示范的运动规划强化学习方法,收集了专家对多个装配任务的运动示范,然后提取和表示运动示范中的知识,并构建了强化学习模型,使用提取的知识优化运动规划策略。Hou等人^[50]提出了一种基于模糊逻辑驱动的强化学习方法,其中模糊逻辑系统由预测状态控制,以映射机器人控制器的阻抗参数。将先验知识作为人工的模糊逻辑,进而构建强化学习的动作空间。Quan^[51]提出一种基于模型的策略预测方法,创建 DNN 神经网络以经验回放池内实际数据为训练数据,创建预测数据经验池,用以增加强化学习训练集的大小,提高数据效率并加速学习阶段。Li等人^[52]通过多核最大均值差异(MK-MMD)方法计算先验数据与目标数据之间的特征距离,选取相似先验知识添加进强化学习经验库中用于算法训练,提升收敛速度,并采用 PPO 算法应用于不同类型轴孔装配实验中实现经验数据迁移学习。

也有学者拓展传统单一轴孔装配问题,尝试研究给出装配整体方案。苟小虎^[53]针对装配流程中零件识别、定位以及装配的关键问题提出综合解决方案。通过运用 YOLOv3 算法实现对轴孔精确识别,构建 Sawyer 机器人的抓取场景,采用 RRT-connect 算法完成零件

抓取,并搭建 SAC 强化学习算法环境,实现轴孔精密装配。闫少凡^[54]通过离线构建模型点云库方法与场景点云进行匹配配准,实现对场景中的轴孔识别与定位,并基于 TD3 强化学习算法环境搭建和轴孔装配模型训练,最终将获取到轴孔位姿信息输入训练模型实现 Sawyer 机器人轴孔装配。

上述关于将强化学习应用于轴孔装配的研究,多为提升算法性能以实现高效的轴孔装配,鲜有针对复杂轴孔装配场景适用性问题的研究。随着产品个性化和定制化需求日益增强,不同行业、不同产品的轴孔装配场景可能存在着较大的差异性。在产品装配过程中,可能会存在不同孔径、孔型和倾斜角度等的特殊装配需求,使得传统单一装配模型无法满足实际装配需求。因此,为满足个性化定制产品的装配需求,有必要对提升模型装配场景的泛化性进行深入研究。

针对上述问题,本文考虑机器人学习和实际装配场景因素,设计在线场景搭建框架和任务更新集合,构建动态任务分配模型,最终实现在机器人能力提升过程中完成任务分配。此外,搭建不同孔位姿轴孔装配的强化学习环境,提升机器人执行轴孔装配的适应性。

1.3 主要研究内容和论文章节安排

本课题研究的主要目的是提出一种动态任务分配模型,考虑实际装配场景以及机器人自主学习对于任务分配结果的影响。基于复杂性任务评价模型,从充分发挥协作功能角度出发,设计动态任务分配流程,细化复杂性评价结果,根据仿真结果更新任务评价。针对复杂轴孔装配问题,在 Gazebo 仿真环境搭建 Sawyer 机器人强化学习环境,并进行轴孔装配仿真测试。同时,为实现在动态任务分配流程中考虑实际装配场景以及机器人学习的影响,提出一种在线搭建仿真场景框架,以实现对实际装配场景的在线搭建。该框架主要应用于机器人仿真测试与自主学习过程。最后,进行综合实验进行仿真装配验证和分析。

第 1 章 绪论。阐明本文的研究背景与意义,分析人机协作背景下任务分配问题和生产过程中常见的轴孔装配问题的研究现状,并进行归纳总结。针对存在问题明确本文研究的必要性和重要性,最后给出研究内容和章节安排。

第 2 章 面向复杂动态装配过程的人机协作任务分配方法研究。基于传统任务复杂度分配模型,提出复杂动态装配任务分配流程。引入操作者意图作为分配模型的输入,改进传统任务复杂度评价流程,细化评价结果,对存疑任务需要进行在线仿真验证,设计任务评价集合用于更新任务评价结果;设计软件界面实现装配任务信息数字化处理,构建任务分解提示词对预训练模型 GPT 进行微调,以获取动作级别任务顺序;此外,为避免资源浪费,当机器人无法辅助装配时,进行插空学习。通过对钢笔以及减速器部分的装配任务进行分析,展示了模型如何有效的应用。

第 3 章 基于深度强化学习的复杂轴孔装配仿真。对比分析两种强化学习算法 TD3 与 SAC 的算法原理和更新过程,选择适用的算法 SAC;为增强强化学习模型泛化能力,设计基于 Gazebo 中 Sawyer 机器人装配的强化学习环境,包含奖励函数、状态空间以及动

作空间的设计；基于设计的算法环境训练垂直和斜度为 30 度的轴孔装配模型，通过装配仿真测试来验证算法环境的鲁棒性；设计在线仿真场景搭建框架，包括离线建库、离线仿真场景搭建以及在线仿真场景搭建三部分，实现在线搭建 Gazebo 仿真场景。此外，设计测试实验对机器人插空学习实现机器人能力增长的可行性进行验证。

第 4 章 机器人轴孔自主装配实验。为验证所提出的在线搭建仿真场景可行性，在实际场景中搭建装配环境，对 Kinectv2 深度相机进行标定，并采集场景点云；采用场景点云与模型点云匹配配准方法实现轴孔识别和定位，离线搭建模型点云库，进行场景点云预处理，基于点云全局特征实现零部件的识别，基于点云初定位与 ICP 算法实现零部件的定位；在线搭建仿真环境并集合强化学习算法进行仿真装配，并将仿真结果迁移到实际机器人装配中，实现机器人轴孔装配。

第 5 章 总结与展望，对本文研究成果进行总结，给出主要结论，并对其中不足之处进行分析和展望。

本文技术路线如图 1-1 所示

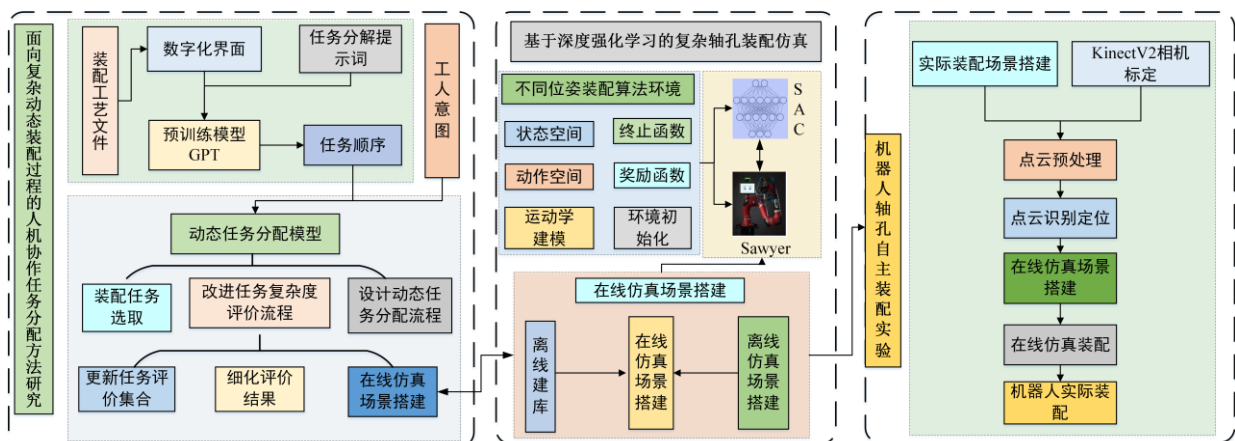


图 1-1 研究技术路线

Fig. 1-1 Studies the technical route

2 面向复杂动态装配过程的人机协作任务分配方法研究

在高度人机协作的装配场景中,操作者与机器人处于同时空进行协作装配,装配系统中装配资源的实际状态信息处于动态变化中,使得装配场景的状态复杂多变。针对复杂动态的装配场景,依据现有研究所提出的静态任务分配模型,任务将被分配至不同操作对象,但由于无法预测实际任务需求,可能导致资源利用的不平衡:一部分操作对象面临资源过载情况,而另一部分则处于资源匮乏状态。同时由于静态分配策略不考虑如资源故障或任务执行顺序变动等执行期间的变化,其在动态环境中的表现通常不尽人意。当任务量或类型发生变化时,静态策略的适应性不足,且重新分配任务可能需大量人工干预,无法满足小批量定制化产品的生产需求。此外,随着科学技术发展,传统生产线上的工业机器人正在逐渐被智能协作机器人所替代。协作机器人具有自主感知、自主决策、自主执行以及自主学习能力,可以直接与人类操作者协同工作,不需要设置安全围栏。协作机器人的自主学习能力对提高其效率和适应性至关重要,这使得机器人可以在不断变化的工作环境中更好地发挥作用。在传统的任务分配模型中,分配决策主要基于机器人的初始能力,这导致了随着机器人能力的增强,模型的分配结果可能限制了机器人潜在的性能发挥,造成资源浪费。

此外,根据产品装配工艺文件可以获取产品的初步装配任务顺序。操作者由于具有较高的主观能动性,可以轻易的理解装配任务顺序,但对于机器人而言无法直接理解装配任务内容,导致机器人无法完成任务。因此,本文首先采用预训练模型 GPT 将装配任务分解成机器人可执行的基本动作序列。然后,基于传统任务复杂度分配模型,深入研究分析现有的工业装配案例从中提炼出关键任务分配要素。遵循人机协作理念,在装配系统中结合人类意图,考虑机器人能力提升对分配结果影响,改进任务复杂度评价流程,设计动态任务分配流程,使模型能够解决动态分配问题。

2.1 任务复杂度影响因素和量化方法

人机协作场景中,每个装配任务的复杂度(难易程度)与多种影响因素有关。其中,零部件的自身属性、任务装配和连接的方式以及安全设计等^[55],是评价装配任务复杂度的关键因素,这些因素影响着分配模型的设计和最终评价结果。

1. 零部件自身属性

在执行装配任务时,零部件的自身属性对于装配过程的顺利进行以及最终产品的性能和可靠性起着决定性作用。机器人执行装配任务的难易程度受到零部件的尺寸、形状、质量、对环境变化的适应能力(稳定性)及表面处理敏感性等多种因素的显著影响。

2. 装配和连接的方式

在人机协作过程中,产品装配和连接的方式直接影响机器人实现装配动作的难易程度。装配可细分为装配插入方向,插入阻力。以及插入次数等。连接则考虑常见的粘合、

铆接、弯曲和拧紧等。

3. 安全设计因素

为确保机器人在操作过程中的安全性，有必要将安全因素作为复杂度分配模型构建的考虑因素，主要考虑装配过程中是否会发生碰撞和是否涉及锋利工具。以上因素是人机协作复杂度模型评价的组成部分，如图 2-1 所示。




图 2-1 人机协作复杂度评价组成因素

Fig.2-1 Components of Human-Robot Collaboration Complexity Evaluation

2.1.1 零部件自身属性

在零部件自身属性中，零部件的特征尺寸是指末端执行器的抓取尺寸，对任务复杂性有直接影响，当零部件尺寸超出执行器的抓取范围或过小以至于需特殊夹具时，操作难度增加；同时零部件的几何形状，尤其是个性化和复杂的形状，也会影响抓取的位置和姿态，提高对夹持器设计的要求，增加任务复杂性；此外，装配中的重型零部件增加了系统惯性，从而增加了损坏和安全风险；自身属性中的环境稳定性指机器人在振动、温湿度变化等干扰下保持性能的能力，是评估系统稳定性的关键指标；零部件表面灵敏度，如对腐蚀、划伤、温度变化的反应，将影响装配操作的复杂度。

装配零件自身属性的复杂度可通过式（2-1）进行计算：

$$L_{self} = \frac{\sum_{j_s}^{j_s} self}{j_s} \times 100\% \quad (2-1)$$

其中， L_{self} 为零部件复杂度得分， j_s 为零部件相关属性个性。

2.1.2 装配和连接

在装配连接评价因素中，精确定位零部件位置对机器人和操作人员至关重要。操作人员能够灵活适应位置和姿态的变化，而机器人依赖于传感器和算法复杂实现位置识别和动作

规划, 在已知环境中机器人操作较为简单, 但在未知环境中自主感知和决策的难度增加; 装配过程中, 分层安装原则通过自上而下的顺序减少装配步骤, 降低了操作复杂度, 提高了垂直和水平装配的效率与精度; 同时, 机器人在执行配合精度高的任务时, 会受到明显装配阻力, 对机器人自身自动化程度提出更高要求; 此外, 压紧操作需要机器人传感器系统的协同工作过, 尤其在单臂机器人中可能需要工具或人工辅助, 而操作者则能更简单高效地进行此操作。根据以上信息, 零件的安装复杂度可通过式 (2-2) 进行计算:

$$L_{con} = \frac{\sum_1^{j_c} con}{j_c} \times 100\% \quad (2-2)$$

其中, L_{con} 为零部件安装复杂度得分, j_c 为零部件相关属性个性。

实际装配中, 为实现零件之间的连接, 通常会使用拧紧、弯曲、粘合和铆接等操作。其中螺栓连接是最基本的连接方式, 机器人可以通过使用特殊工具实现预定的扭矩和进程自动拧紧螺栓, 所以机器人适合完成基本的拧紧工作。粘合则需要对机器人进行实现编程和调试, 以实现材料的加工和处理, 弯曲和铆接需要添加力传感器配合实现。

零件的连接方式复杂度可通过式 (2-3) 进行计算:

$$L_{join} = \frac{\sum_1^{j_j} join}{j_j} \times 100\% \quad (2-3)$$

其中, L_{join} 为零部件连接方式复杂度得分, j_j 为零部件相关属性个性。

2.1.3 安全设计因素

在人机协作的装配中, 确保操作安全是设计的核心, 目的是保护操作环境中的人员、设备和产品。安全风险主要来自处理锋利工具和设备, 以及操作员、机器人和零部件之间的潜在碰撞。为保障安全, 机器人利用视觉传感器准确识别零部件和操作者的位置, 并运用算法精确计算安全的运动路径, 在处理锋利物件时, 机器人应实时监控并调整其与操作员的相对位置, 采取适当的避让和减速行动以避免碰撞。对于高风险任务, 应优先考虑人工操作, 以减少机器人的使用。零件的安全因素复杂度可通过式 (2-4) 进行计算:

$$L_{safe} = \frac{\sum_1^{j_s} safe}{j_s} \times 100\% \quad (2-4)$$

式中, L_{safe} 为零部件安全因素复杂度得分, j_s 为零部件相关属性个性。

2.1.4 任务复杂度计算

结合上述介绍的传统任务复杂度评价因素的具体情况, 结合实际装配情况^[10]建立复杂度评价表格, 如表 2-1 所示。

表 2-1 任务分配中复杂度评价
Table 2-1 Complexity Evaluation in Task Assignment.

复杂度评价表格					
零部件自身属性	特征尺寸	无需夹具	需要夹具	轨迹干涉	超出最大尺寸
		1	0.6	0.3	0
	自身质量	<1kg	1~3kg	3~8kg	>8kg
		1	0.6	0.3	0
	几何形状	二指夹持器	三指夹持器	四指夹持器	最好手扶
		1	0.6	0.3	0
	系统稳定性	稳定	强力动荡	低力动荡	动荡
		1	0.6	0.3	0
	表面灵敏度	表面无要求	强力损坏	低力损坏	敏感表面
		1	0.6	0.3	0
安装连接	零件状态	已知位置和姿态		已知位置不知姿态	未知位置和姿态
		1		0.6	0.3
	执行次数	任务执行 1 次		任务执行 2~4 次	任务执行 4 次以上
		1		0.6	0.3
	装配方向	垂直安装		水平安装	
		1		0.5	
	压紧需求	不需要		需要	
		1		0.5	
	装配阻力	无需用力	轻力	中等力量	需要按压
		1	0.6	0.3	0
	连接方式	拧紧或无需连接	弯曲	粘合	铆接
		1	0.6	0.3	0
安全因素	碰撞	可增强安全		可消除风险	频繁碰撞
		1		0.6	0.3
	锋利工具	可增强安全		可消除风险	受伤可能性大
		1		0.6	0.3

根据上面各评价因素的的计算公式和评价表格，最终可根据式（2-5）进行装配任务的复杂度的计算：

$$L = \frac{\sum_{j_l}^j L}{j_l} \times 100\% \quad (2-5)$$

其中, L 为零部件装配复杂度得分, j_l 为零部件相关属性个性。

2.2 基于复杂度的动态任务分配模型构建

2.2.1 模型假设

本研究旨在探讨人机协作中的任务分配问题, 重点关注如何构建一个适用于复杂动态装配场景下的任务分配模型。假设在协作程度高的实际装配场景当中, 操作者与协作机器人在相同时空环境中协同工作, 且在装配任务开始执行前操作者与机器人已知产品装配所需执行的任务或动作序列。此外, 为使得机器人更好地理解操作者动作, 模型引入操作者的操作意图。其主要的假设内容为:

- (1) 装配过程中不存在缺少零部件情况, 且所使用的零部件尺寸、形状、质量都符合装配工艺要求;
- (2) 协作机器人和操作者所需的装备工具和设备齐全, 并能够正常工作, 不存在损坏问题;
- (3) 装配任务强度适当, 在操作过程中操作者并不会因操作时长原因导致可靠性降低, 假设保持最佳状态;
- (4) 不考虑特殊装配环境条件, 装配操作者和机器人在舒适工作环境下进行工作;
- (5) 在同一时刻, 机器人和操作者只能执行一项工作, 且不能中断;
- (6) 任务分配结果最终必须由操作者或机器人来完成;
- (7) 不考虑多产品之间混合装配情况, 仅考虑单一产品的装配问题;
- (8) 装配场景中操作者的下一时刻意图已经准确获取到。

2.2.2 复杂动态装配任务分配流程

如图 2-2 所示, 为本文设计的复杂任务动态分配整体流程。在装配过程中, 根据装配工艺手册, 机器人和操作者可以获取到初步的装配任务顺序。然而, 由于工艺手册内容是面向操作者制定, 其中对于装配任务描述较为模糊, 通常包含多个装配子任务, 且不包含具体作业动作、顺序以及工具等细节, 机器人无法直接执行一系列装配子任务。因此, 本文引入大语言模型 GPT 对工艺手册中装配任务进一步细化, 通过将机器人基本能力以及参数信息作为输入, 并对大语言模型进行特定任务的微调训练, 使其能够将任务分解成机器人能够执行的基本动作或前置任务的序列组合, 获取到分解后产品装配动作顺序。

本文从充分发挥人机协作过程中的协作特性角度出发, 在装配任务的分配过程中, 引入操作者意图^[32]。并将操作者意图作为当前任务, 机器人优先考虑辅助操作者完成当前装配任务。同时, 本文改进传统复杂度评价流程, 将当前任务属性作为输入, 结合任务复杂度计算公式 2-4, 最终评价是否能够当完成当前任务。如果能够完成当前任务则交由机器

人执行装配,以辅助操作者完成当前任务。此外,为避免操作者频繁变换装配顺序,增加操作者操作难度,本文设计当机器人执行当前任务时,操作者进行调整休息,缓解装配疲劳,保证操作者装配的可靠性。

当机器人评价自身无法协助操作者完成当前任务时,依据装配任务顺序选择其他并行的待装配任务。将其任务属性输入到改进的任务复杂度评价流程,根据评价结果判定机器人能否执行。当机器人前两种情况都无法执行时,为避免装配系统资源浪费,机器人进行插空学习。机器人在等待装配任务完成期间,通过强化学习训练,机器人提升自身能力。在此过程中,操作者装配意图周期性输入系统,以检测操作者意图是否发生变化。当检测到意图发生变化时,意味操作者执行任务发生改变,则会重新将操作者装配意图以及装配顺序作为输入。此外,当机器人执行完当前任务或待装配任务时,需要判断操作者意图是否发生变化,并重新选取当前任务,选取具体内容详见 2.2.3 节。




图 2-2 复杂装配任务动态分配流程

Fig.2-2 Dynamic assignment process for complex assembly tasks

图 2-2 中, a_1 、 a_2 、 a_3 为机器人三种动作状态,分别为辅助完成当前任务、辅助完成待装配任务以及插空学习状态。插空学习是通过在线仿真场景搭建方法,当机器人无法辅助完成工作时,在线搭建之前装配失败任务的仿真场景,并对其进行仿真装配训练,具体内容详见 3.4 节与 2.2.4 节。

操作者与机器人的协作装配流程如图 2-3,图中包含操作者、机器人和装配任务顺序。其中装配任务由 P_1 到 P_n 子任务组成。 T_1 到 T_n 时刻进行零部件装配,期间某一时刻操作者执行某一任务,机器人根据动态任务分配模型结果执行操作。如图 2-3 所示,在 T_1 时刻,操作者装配意图为 P_1 任务,机器人通过任务分配模型选择辅助操作者完成当前任务 P_1 任务,操作者休息调整;在 T_2 时刻,操作者意图为 P_2 任务,机器人评价为无法完成 P_2 ,执行待装配任务 P_3 ;在 T_3 时刻,操作者意图为 P_4 任务,机器人辅助完成 P_4 任务;在 T_4 时刻,机器人完成当前任务以及待装配任务,进行插空学习,操作者完成 P_5 任务。




图 2-3 人机协作装配流程

Fig.2-3 Overall Process of Human-Robot Collaboration

2.2.3 装配任务顺序以及选取

装配任务顺序可分为装配任务、工序、工步和动作级别，如图 2-4 所示，任务级别指不同产品间的装配任务顺序，工序级别为某一装配产品根据装配工艺文件确定的装配任务顺序，工步级别则是操作者根据操作经验对工序级别任务进行划分得到的任务顺序，动作级别则为工序级别中某一工步执行所需要的装配操作。




图 2-4 装配任务顺序类别

Fig.2-4 Assembly Task Sequence Categories

(1) 装配工序、工步任务顺序

根据产品装配工艺文件信息,可以初步获取装配任务顺序。在此基础上,借助预训练模型 GPT,将工序、工步任务分解到动作级别。构建任务节点并设置节点属性,其中节点信息包含动作名称、上级工序、工步名称、复杂度各项评价属性、执行次数、评价结果以及机器人执行成功率等,并使用链式存储方式将装配信息数字化存储,根据装配任务顺序采用邻接链表法生成任务顺序图,节点与邻接链表如图 2-5 所示。链式存储是一种数据结构存储方式,它使用节点(Node)来存储数据,并通过指针(或引用)将这些节点连接起来,形成链表(Linked List)。节点是链表中的基本单元,它包含两部分信息:数据域和指针域。数据域用于存储节点所持有的数据。数据可以是任意类型,例如整数、浮点数、字符串等,甚至可以是复杂的自定义数据结构。指针域用于存储指向下一个节点(或上一个节点)的指针(或引用),可以轻松地执行插入、删除和移动操作,而无需移动其他节点。邻接表法(Adjacency List)是一种用于表示图的数据结构,它通过使用链式存储的方式来表示图中的顶点及其相邻的顶点。




图 2-5 任务节点属性(左)以及邻接链表架构(右)

Fig.2-5 Attributes of Task Nodes (Left) and Adjacency List Architecture (Right)

(2) GPT 任务细分

预训练模型 GPT 是一种基于 Transformer 架构的大语言模型,由 OpenAI 公司提出并开发。它的基本工作原理是通过大规模的文本数据集进行预训练,通过自监督学习的方式,尝试预测文本序列中下一个词的可能性,针对用户的特定任务需要进行微调,以完成各种自然语言处理(Natural Language Processing, NLP)任务。微调是指将预训练的模型加载到特定的任务上,并在带标签的数据集上进行额外的训练,即需要针对特定任务进行特定提示词工程,以适应特定的任务要求。这使得 GPT 在各种 NLP 任务上表现良好,例如文本分类、命名实体识别、情感分析等。

严谨高效的提示词工程设计有助于预训练模型输出效果准确性,可以依据以下设计原则进行设计^[56]。

a. 清晰表达任务目标

对于任务的表述不应该不明确或者模棱两可,应该强调的是在微调过程中需要给出清晰且明确的指示^[57]。详细的任务描述应该包含任务组成的各个元素,包括任务目标、输入输出格式,以及任务限制条件信息,例如“给出一份清明假期活动调查问卷问题,希望

生成相关问题简要，注意问题不应多余 30 个，内容应涉及时间、人物以及地点等信息”。明确的任务描述帮助 GPT 更有效的理解目标，并达到预期输出效果。

b. 分解成简单、详细的子任务

对于复杂任务可以尝试将任务分解成简单且详细的子任务，进而 GPT 实现逐步完成任务最终解决问题。可以通过设计带有编号形式列出分解后的子任务，例如“通过执行以下连续任务达到目标效果：1...;2...;3...”。通过分解复杂任务的形式，GPT 可以通过解决容易的子任务，最终取得处理复杂任务的理想输出。

c. 进行示例演示

预训练模型 GPT 能够实现从上下文学习中，为得到更好的输出效果，可以提供少量的理想输入输出的任务示例。少量的示例帮助 GPT 学习输入输出之间的语义映射，无需对参数进行调整，在实际应用中，通过提供高质量示例，GPT 模型能够更快地学习并提高其解决问题的能力。

d. 合适的表示格式

GPT 是通过数据集上预训练得到的模型，利用一些特殊提示格式有助于 GPT 更好地理解指令，例如 Open AI 官方文档中，可以通过符号###或者""作为停止符用来分割指令和上下文。由于 GPT 为 Open AI 研发应用，因此 GPT 对于英文任务执行效果表现要优于其他语言。

根据上面所述的设计原则进行本文任务分解提示词的提示词设计，模型的主要任务是将输入的任务细化到动作级别。首先，将机器人基本情况输入给 GPT 模型，包括自由度、有效载荷、臂展、末端执行器以及自身基本能力等信息。此外，需要明确机器人能够执行的基本动作，这些操作与完成装配任务时操作者的基本操作^[58]类似，通常包括：定位、紧固、压配、调整、固定、夹紧、密封、填充、搬运和抓取。然后，结合机器人自身能力，设计机器人基本操作包含：夹爪打开、夹爪闭合、查找动作、等待动作、重置动作、移动以及旋转动作，并对每个动作的基本原理和目标进行阐述。最后，设置模型输入输出的格式，确定模型输出限制条件，以减速器端盖装配为示例，完成任务分解的提示词构建。表 2-2 为所设计的任务分解提示词。

表 2-2 任务分解提示词

Table 2-2 Task breakdown prompts.

任务分解提示词	
1.任务目标	假设是一个七关节的 Sawyer 机器人处理器，主要职能是对操作者输入的任务进行动作划分。
2.机器人基本属性	机器人末端执行器为二指夹爪，本体自重 19kg，臂展范围为 1260mm，有效负载 4kg，重复定位精度为正负 0.1mm，装配场景中有扳手、螺丝刀、扭力扳手等常见装配工具。

表 2-2(续):

任务分解提示词	
3.机器人基本能力	现在预先设置一些机器人能够实现的动作: 1.夹爪闭合动作: 主要功能是机器人通过夹爪闭合实现抓取物体与机器人的连接可以实现后续的物体移动操作, 不需要任务信息。 2.移动动作: 主要是机器人通过自身的运动求解实现机器人的位置移动到指定的位置的功能, 需要的任务信息是移动目标点的名称。 3.夹爪打开动作: 主要是机器人在抓取完成, 并通过机器人的移动实现对物体的移动后, 物体到达指定位置与机器人实现脱离功能, 不需要任务信息。 4.等待动作: 主要是机器人原地待命静止的操作, 不需要输入信息。 5.重置动作: 主要是机器人实现自身姿态重置, 恢复到初始状态, 不需要输入信息。 6.查找动作: 主要是机器人通过视觉点云等技术实现对场景中目标物体的寻找功能, 任务信息是需要查找的名称。 7. 插入动作: 主要是机器人抓取零部件后, 将抓取到的零部件插入到待装配零部件。 8.旋转动作: 主要是抓取零部件在装配过程中需要进行旋转操作。
4.输入输出格式	对于机器人助手来说, 当输入“任务:”开头时, 需要对“:”后面的任务进行分解。首先判断是否需要工具辅助, 如果需要输出装配相应的工具, 并结合预先设置的动作进行分解, 获取动作需要的信息, 参照下方案例输出格式输出, 并禁止使用未预先定义的动作。此外, 不需要对任务需求进行过多的修饰, 统一采用一个名称表述, 查找动作可以有多个任务需求。
5.示例	输入任务: 装配减速器端盖 输出: 执行任务: 装配工具扳手+查找动作 + 移动动作(减速器端盖) + 夹爪闭合动作 + 移动动作(装配位置)+ 插入动作 + 旋转动作 + 夹爪打开动作 步骤: 执行查找动作, 查找“减速器端盖”和“装配位置”, 任务需求: “减速器端盖”、“装配位置”。 执行移动动作, 移动到“减速器端盖”的位置, 任务需求: “减速器端盖”。 执行夹爪闭合动作, 抓取“减速器端盖”。 执行移动动作, 将夹爪带着“减速器端盖”移动至“装配位置”, 任务需求: “装配位置”。 执行插入动作, 将抓取到的减速器端盖插入到待装配零部件。 执行旋转动作, 根据装配需求对减速器端盖进行旋转操作。 执行夹爪打开动作, 完成减速器端盖的装配, 释放夹爪。

对装配螺栓任务进行分解测试，输出结果如表 2-3。

表 2-3 装配螺栓示例

Table 2-3 Assembly Bolt Example.

输入：	“装配螺栓”
输出：	执行任务：装配工具扳手 + 查找动作 + 移动动作(螺栓)+ 夹爪闭合动作 + 移动动作(装配位置)+ 插入动作 + 旋转动作 + 夹爪打开动作 步骤： 装配工具：扳手； 执行查找动作，查找物品“螺栓”和“装配位置”，任务需求：“螺栓”、“装配位置”； 执行移动动作，移动到“螺栓”的位置，任务需求：“螺栓”； 执行夹爪闭合动作，抓取“螺栓”； 执行移动动作，将夹爪带着“螺栓”移动至“装配位置”，任务需求：“装配位置”； 执行插入动作，将抓取到的螺栓插入到待装配零部件； 执行旋转动作，根据装配需求对螺栓进行旋转操作； 执行夹爪打开动作，完成螺栓的装配，释放夹爪。

在提示词设计完成后，人工训练 GPT3.5 模型，并提出错误信息反馈以提升模型输出准确性。通过对 100 个不同的任务进行分解测试，以评估模型分解准确性并判断模型的实用性。此外，通过设计的 GPT 模型进行任务分解，当模型判断任务包含多个操作动作时，对当前任务进行细分，生成相应动作节点，并插入到邻接链表中。否则选取其他任务进行分解，当所有任务完成分解后，得到装配任务顺序链表。

(3) 任务选取

本文采用拓扑排序方法进行任务选取，拓扑排序常用于任务调度和编译器优化等场景。拓扑排序是一种对有向无环图(Directed Acyclic Graph, DAG)进行的排序算法，特点是将图中的节点按照其依赖关系进行线性排序，使图中的每一条有向边从排序后的序列前节点遍历到最后一个节点。在 DAG 中不存在环路，并且图中节点有先后顺序。一个有向图由一组结顶点和一组有向边组成。顶点表示图中的节点，有向边表示节点之间的依赖关系。在拓扑排序中，入度和出度指当前节点引入节点的个数和指向节点的个数，表示当前节点需要多少个前置条件和当前节点为多少个节点的前置条件，将选取入度为 0 的任务节点，即无前置条件的节点任务，可分为当前任务和待装配任务选取。如图 2-6 所示为有向图，其中节点 1 为节点 2 的前置条件，节点 1 入度为 0，出度为 2。




图 2-6 任务顺序有向图

Fig.2-6 Task sequence directed graph

本文根据圆柱齿轮减速器的装配工艺文件，人工完成其装配任务的确定，内容如表 2-4 所示：

表 2-4 减速器装配任务表
Table 2-4 Reducer assembly task table

装配工序名称	装配工步名称
1.低速轴部件装配	1 齿轮装配
	2 齿轮套筒装配
	3 轴承装配
2.中间轴部件装配	4 齿轮装配
	5 齿轮套筒装配
	6 轴承装配
3.高速轴部件装配	7 轴承装配
4.整机装配	8 基座装配
	9 低速轴装配
	10 轴承套筒装配
	11 轴承端盖装配
	12 中间轴装配
	13 轴承套筒装配
	14 轴承端盖装配
	15 高速轴装配
	16 轴承套筒装配
	17 轴承端盖装配
	18 上箱体装配
	19 油标装配
	20 油塞装配
	21 视孔盖装配
	22 透气塞装配

获取到减速器装配的工序和工步任务顺序表 2-4 后,根据其装配任务之间的依赖关系(包括顺序和并行等),构建任务的邻接链表,如图 2-7 所示。




图 2-7 减速器装配工步任务邻接链表图

Fig.2-7 Reducer assembly step task adjacency linked list diagram

在装配过程中的某时刻,如果机器人通过任务复杂度评价流程判断无法完成当前任务,则需要通过构建的邻接链表获取当前任务的相关信息,包括可执行的并行待装配任务信息。考虑操作者的后续操作意图不确定性,为避免装配出现混乱,待装配任务选择并行的待装配任务,即选取并行且入度为 0 的任务节点。

如图 2-8 所示,某一时刻,节点任务 4 已完成,当前任务为 5,下一任务为 6,并行任务为 1 和任务 7。当前任务 5 无法完成时,根据拓扑排序的原理,随机选取入度为 0 的节点任务 1 和 7。




图 2-8 待装配任务选取案例

Fig.2-8 Example of selected assembly task

当操作者装配意图发生改变或机器人执行完任务后,需要更新当前任务,并剔除当前任务的前置任务节点,例如图 2-8 中节点任务 4 被剔除。在装配过程中,如果操作者装配意图发生变化,则意味操作者的装配任务随之发生改变。当机器人完成操作后,如果操作者意图未发生变化,选取完成任务的顺序相邻任务为当前任务。否则,基于假设条件中的优先相互协助原则,将变化后的操作者装配意图更新当前任务。

2.2.4 改进任务复杂度评价流程

根据图 2-2 所示,当获取完装配任务评价属性后,需要对任务进行复杂度评价。对传统任务复杂度评价流程进行改进,设计任务评价流程,如图 2-9 所示。首先,创建并初始化任务评价集合,集合中记录任务名称以及任务复杂度评价结果和执行成功率。然后,将获取到的装配任务属性,根据上面建立的复杂度评价表 2-1 以及复杂度计算公式(2-4),计

算复杂度评价数值。最后，对评价结果细化，将装配任务分为不可执行任务、存疑任务和可执行任务。其中，不可执行任务考虑任务复杂度过高，不能交由机器人完成。对存疑任务，需要在线搭建仿真场景，机器人进行装配仿真，以验证任务的可行性。若仿真装配失败，则评价为不可执行任务；若仿真成功则评价为可执行任务，并更新装配任务执行成功率。对于评价为可执行的任务，则直接交由机器人完成。

为了对存疑任务的可执行性进行验证，需要进行在线仿真装配。本文通过将实际装配场景映射到仿真环境中，更真实地模拟实际装配过程中的各种因素和挑战，并有助于预测潜在的风险和问题，从而提升分配结果的实用性和可靠性。为实现实际装配场景到仿真环境的映射，需要对装配场景零部件的位姿信息进行提取并保存，以便后续搭建在线仿真场景，进行机器人仿真装配测试和在线插空学习，关于在线仿真场景搭建的具体方法详见 3.4 章节。此外，在插空学习状态下，协作机器人自身能力将不断增强，因此需要更新任务评价集合，以使分配结果与机器人能力提升相适应。




图 2-9 改进的任务复杂度评价流程

Fig.2-9 Improved task complexity evaluation process

(1) 细化评价结果

输入任务属性通过复杂度评价表 2-1 计算任务复杂度评价数值，并根据以下条件对评价结果进行细分。当评价数值大于阈值某邻域范围且小于阈值时，认为任务较为复杂，不建议机器人完成；当评价数值小于阈值某邻域范围且大于阈值时，则认定任务能够勉强被

机器人完成。对于评价结果为不建议或勉强执行的任务，统一标记为存疑任务，需要在线搭建仿真环境并进行仿真验证；若评价数值超过阈值某邻域范围时，判断机器人具备顺利完成任务的能力；评价数值小于阈值某邻域范围，机器人操作执行任务风险过大，不能交由机器人完成。细化结果如表 2-5 所示，其中 a 为阈值，邻域为 ± 0.15 ， a 为 $0.7^{[10]}$ 。

表 2-5 任务评价结果

Table 2-5 Task Evaluation Results.

任务评价结果				
评价结果	不可执行	不建议完成	勉强完成	可执行
评价数值	$0 \sim a - 0.15$	$a - 0.15 \sim a$	$a \sim a + 0.15$	$a + 0.15 \sim 1.0$

(2) 更新任务评价集合

由于机器人自主学习能力，机器人在不断执行任务过程中，自身能力的不断提升，需要更新任务评价集合，以确保评价体系与机器人当前能力相匹配。

首先，依据前文细化评价结果，将任务的评价结果分为不可执行、存疑和可执行，构建评价结果集合并按照评分数值进行升序排列。当存疑任务实际成功执行率达到 90%，则认为机器人能力提升足以完成该任务，并将该任务移至可执行任务集合中。在后续评价任务时，取任务集合评价结果与复杂度模型评价结果中的最大值 $\text{Max}(\text{集合}, \text{模型})$ 作为任务最终的评价结果，其中模型评价结果是指利用评价表格 2-1 得出的评估结果。任务更新流程如图 2-10 所示，图中显示某时刻不可执行、存疑和可执行集合都含有 4 个任务。同时，从不可执行任务集合中选择集合中评分最高任务，并将其归入存疑任务集合中。随着机器人的能力增强，可执行任务越多，不可执行任务减少。




图 2-10 更新任务评价集合

Fig.2-10 Update the task evaluation collection

由于减速器装配任务过于复杂，同时鉴于减速器某一工步的装配情况过于单一，缺乏足够的代表性，本文以钢笔的装配为例子，装配钢笔任务包含装配笔尖、笔帽和按钮 3 个步骤，并分别表示为任务 1、2、3，本文将笔尖和按钮安装作为并行任务，并通过 GPT 实

现 3 个任务的分解，如图 2-11 所示。




图 2-11 钢笔装配任务分解

Fig.2-11 Pen assembly task breakdown

其中装配意图输入为动作级别，然后给出动态分配结果，如表 2-6 所示。

表 2-6 钢笔装配动态分配结果

Table 2-6 Pen assembly dynamically assigns results.

时间	装配意图	操作者	机器人	当前任务	备注(w:插空学习)
T0	1.1	1.1	2.1	1.1	机器人无法完成 1.1，执行待装配 2.1
T1	1.1	1.1	2.2	2.2	装配意图未变，当前任务为 2.2
T2	1.2	1.2	2.2	1.2	装配意图改变，当前任务为 1.2
T3	1.3		1.3	1.3	机器人评价能够执行当前任务并执行 1.3
T4	1.4	1.4	2.3	1.4	机器人无法完成 1.4 执行待装配 2.3
T5	1.5	1.5	2.3	1.5	机器人继续执行 2.3
T6	1.5	1.5	w	1.5	机器人无法执行 1.5 和 2.4，等待并插空学习直至意图发生变化
T7	1.6		1.6	1.6	意图发生改变，并机器人执行 1.6
T8	2.4	2.4	3.1	2.4	机器人无法完成 2.4 执行 3.1
T9	2.5		2.5	2.5	机器人执行当前任务
T10	2.6	2.6	3.2	2.6	机器人无法完成当前任务 2.6，执行 3.2
T11	3.3	3.3	w	3.3	机器人评价无法完成 3.3，等待并插空学习
T12	3.4		3.4	3.4	机器人执行当前任务 3.4
T13	3.5	3.5	w	3.5	机器人评价无法完成 3.5，等待并插空学习
T14	3.6		3.6	3.6	机器人执行当前任务 3.6
T15				完成装配	

根据表 2-6, 给出钢笔装配的参与者与机器人协作装配过程甘特图, 如图 2-12, 可以看出, 机器人与参与者能够进行高效的协作装配。




图 2-12 钢笔装配任务分配甘特图

Fig.2-12 Gantt chart of pen assembly task assignments

2.2.5 信息数字化

为方便将工艺文件中的装配顺序以及装配任务的基本属性数字化处理, 基于搭建的复杂度评价表格, 通过 QT 软件进行界面设计, QT 是一个跨平台的 C++ 库, 用于开发图形用户界面 (GUI) 应用程序、嵌入式设备和其他跨平台软件。它提供了丰富的组件和工具, 使开发者能够快速构建各种功能强大的应用程序。采用 QT 提供的 QSQLITE 数据库将任务信息保存, 数据库设计包括任务名称、自身属性、装配连接、安全属性、复杂度数值、后置任务以及评价结果, 界面如图 2-13 所示。



图 2-13 装配任务属性数字化界面

Fig.2-13 Digital interface for assembly task properties

2.3 基于动态任务分配模型的减速器装配任务分配

本文以二级减速器装配为例，给出零部件参数，如表 2-7

表 2-7 二级减速器零部件参数

Table 2-7 Parameters of secondary reducer parts.

装配名称	重量/kg	尺寸 cm	材料
1.1 齿轮装配	16.79	直径 28.2	45
1.2 齿轮套筒装配	0.134	外径 9	Q235
1.3 轴承装配	0.501	外径 9	
2.1 齿轮装配	11.787	直径 27.8	45
2.2 齿轮套筒装配	0.125	外径 8	Q235
2.3 轴承装配	0.39	外径 8	
3.1 轴承装配	0.21	外径 6.2	
4.1 基座装配	60	73*30*22	HT150
4.2 低速轴装配	23.615	抓取尺寸 $\Phi 5.4$	
4.3 轴承套筒装配	0.128	外径 9	Q235
4.4 轴承端盖装配	1.043	大端外径 13	Q235
4.5 中间轴装配	18.292	抓取尺寸 33	
4.6 轴承套筒装配	0.113	外径 8	Q235
4.7 轴承端盖装配	0.902	大端外径 12	Q235
4.8 高速轴装配	3.51	抓取尺寸 $\Phi 4.4$	
4.9 轴承套筒装配	0.074	外径 6.2	45
4.10 轴承端盖装配	0.351	大端外径 9	Q235
4.11 上箱体装配	41.313	73*30*25	HT150
4.12 油标装配	0.084	直径 2.4	Q235
4.13 油塞装配	0.118	直径 1.8	
4.14 视孔盖装配	0.786	18*14*0.4	Q235
4.15 透气塞装配	0.037	直径 2.2	Q235

本文对减速器装配中各个任务中移动和旋转动作评价，评价以及部分分配结果如表 2-8 所示。

表 2-8 减速器装配任务评价结果
Table 2-8 Evaluation results of reducer assembly tasks.

装配名称	动作	复杂度数值	评价结果（存疑任务、可执行任务、不可执行任务）
1.1 齿轮装配	移动	0.72667	存疑任务
	插入	0.698889	存疑任务
1.2 齿轮套筒装配	移动	0.914444	可执行任务
	插入	0.886667	可执行任务
1.3 轴承装配	移动	0.713333	存疑任务
	插入	0.741111	存疑任务
2.1 齿轮装配	移动	0.66	存疑任务
	插入	0.632222	存疑任务
2.2 齿轮套筒装配	移动	0.861111	可执行任务
	插入	0.833333	存疑任务
2.3 轴承装配	移动	0.833333	存疑任务
	插入	0.805556	存疑任务
3.1 轴承装配	移动	0.861111	存疑任务
	插入	0.833333	存疑任务
4.1 基座装配	移动	0.385556	不可执行任务
	插入		
4.2 低速轴装配	移动	0.553333	存疑任务
	插入	0.525556	不可执行任务
4.3 轴承套筒装配	移动	0.861111	可执行任务
	插入	0.805556	存疑任务
4.4 轴承端盖装配	移动	0.765556	存疑任务
	插入	0.793333	存疑任务
4.5 中间轴装配	移动	0.447778	不可执行任务
	插入	0.42	不可执行任务
4.6 轴承套筒装配	移动	0.741111	存疑任务
	插入	0.713333	存疑任务
4.7 轴承端盖装配	移动	0.726667	存疑任务

表 2-8(续):

装配名称	动作	复杂度数值	评价结果（存疑任务、可执行任务、不可执行任务）
4.7 轴承端盖装配	插入	0.754444	存疑任务
4.8 高速轴装配	移动	0.593333	存疑任务
	插入	0.543333	不可执行任务
4.9 轴承套筒装配	移动	0.91444	可执行任务
	插入	0.886667	可执行任务
4.10 轴承端盖装配	移动	0.794444	可执行任务
	插入	0.744444	存疑任务
4.11 上箱体装配	移动	0.42	不可执行任务
	插入	0.38	不可执行任务
4.12 油标装配	移动	0.90111	可执行任务
	插入	0.851111	可执行任务
4.13 油塞装配	移动	0.886667	可执行任务
	插入	0.82	存疑任务
4.14 视孔盖装配	移动	0.807778	存疑任务
	插入	0.741111	存疑任务
4.15 透气塞装配	移动	0.886667	可执行任务
	插入	0.858889	可执行任务

根据表 2-8 评价结果可以看出,在二级减速器装配过程中,多数任务对于机器人而言存在一定难度,需要进一步机器人仿真装配对可行性进行评价。

2.4 本章小结

本章将实际场景信息、机器人自主学习能力及任务复杂度紧密结合起来,基于传统任务复杂度模型,提出了动态任务分配流程,引入操作者意图,改进任务复杂度评价流程,细分任务评价结果,对存疑任务需要在线搭建仿真场景并进行仿真装配;设计任务评价集合用于任务评价结果更新;GPT 细分装配任务顺序到动作序列级别;同时,当机器人无法完成任务时进行插空学习,最终实现机器人在动态过程中的任务分配。以钢笔装配和减速器装配为例,展示了该模型在动态人机协作过程中如何有效地应用,实现装配任务的高质量分配。本章为人机协作中动态任务分配问题提供了一种新解决方案,提高了任务分配结果的实用性和可靠性。

3 基于深度强化学习的复杂轴孔装配仿真

根据第 2 章改进的任务复杂度评价流程,可知在人机动态协作过程中,为充分考虑实际装配场景的影响,需要对存疑任务在线搭建实际装配场景,并进行仿真装配来验证机器人执行任务的可行性。轴孔装配作为实际装配中一个典型场景,众多产品的装配过程都涉及轴孔装配原理。目前,已有研究将深度强化学习应用于轴孔装配场景当中,实现了轴孔精密装配。然而,现有的研究大多数针对简单垂直轴孔装配问题。而在复杂的装配场景中,轴孔具有多样化特点,不仅包含垂直装配,还包括斜孔装配以及不同孔型等特殊装配问题。传统深度强化学习装配模型在处理复杂装配场景时通常需要重新搭建算法环境,因而缺少泛化性和鲁棒性。当面对市场需求向小批量个性化定制任务转变时,频繁的人工调整算法参数,将增加整体装配成本,难以满足市场需求。此外,现有模型大多仅靠考虑简单装配场景,在复杂装配场景中,模型的有效性会受到限制。在进行实际轴孔装配时,装配场景中零部件的形状和位姿会直接影响机器人轴孔装配的可行性。因此,同样需要在线搭建实际装配场景进行仿真验证其可行性。

针对以上存在问题,本章提出一种在线搭建仿真场景方法,以实现从实际场景到仿真环境的映射,进而完成机器人装配的仿真场景搭建。在搭建的场景中,实现机器人在线仿真装配测试以及在线插空学习;同时,针对复杂装配场景下不同孔位姿的轴孔装配问题,基于 SAC 算法,搭建 Sawyer 机器人的强化学习环境。并在机器人操作系统 ROS 集成的 Gazebo 仿真环境中,对 Sawyer 机器人进行仿真装配验证。最后,设计测试实验对第 2 章中插空学习状态下,机器人能力增长的可行性验证。

3.1 SAC 算法基本原理

3.1.1 强化学习算法基本原理

如图 3-1 所示,强化学习^[59]训练过程为智能体在与环境的交互过程中生成并执行动作,环境状态转移到下一状态并对智能体执行当前动作进行评价,智能体不断迭代交互更新自身决策网络,提升自身能力最终实现最佳的决策效果。




图 3-1 强化学习交互基本原理

Fig.3-1 Fundamentals of reinforcement learning interactions

强化学习由环境状态 S_t 到 S_{t+1} 需要经过智能体策略函数 $\pi(a_t | s_t)$ 生成动作并随机抽样选取动作 a_t ，智能体执行当前动作 a_t ，并通过状态转移分布函数 $P(s_{t+1} | s_t, a_t)$ ，环境转移至下一环境 S_{t+1} ，并由环境进行动作评价给出当前动作奖励 r_t ，马尔科夫决策过程^[60]如图 3-2 所示。




图 3-2 马尔科夫决策过程

Fig.3-2 Markov decision-making process

其中，策略函数 $\pi(a_t | s_t)$ 为当前状态 S_t 在智能体执行动作 a_t 的概率函数。状态转移分布函数 $P(s_{t+1} | s_t, a_t)$ 为在智能体执行动作 a_t 后，由当前状态 S_t 转变为 S_{t+1} 的概率。

在强化学习过程中智能体不断与环境交互学习，计算智能体在强化学习的一个回合中从初始状态到最终状态的累计奖励，最终实现在一个回合过程中的累计奖励达到最大化。在某一状态下，为确保当前状态对于累计奖励的影响最大，引入折扣因子 γ ，故累计奖励又称累计折扣奖励，如式 (3-1) 所示

$$R_t = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} \cdots + \gamma^{k-1} r_{t+k} = \sum_{k=0}^{\infty} \gamma^{k-1} r_{t+k} \quad (3-1)$$

其中， R_t 为累计奖励， r_t 奖励，折扣因子 $0 \leq \gamma \leq 1$ ，折扣因子越大，表明智能体越重视长期奖励，越小则表明越重视当前奖励。

根据强化学习中智能体学习的目标，可以分为基于价值和基于策略的强化学习。基于价值的强化学习主要目标为学习状态价值函数或动作价值函数，通过最大化价值函数实现最优决策。基于策略的强化学习则是智能体追求在累计奖励最大化的时的动作概率，并根据概率选择动作，即输入是状态，输出直接是动作或动作概率。

为解决在实际问题中求解价值函数 V 过程中模型状态转移概率未知，使用时序差分法^[61]通过与环境不断的交互过程中获取的经验，以实际获取的奖励来逼近更加准确的价值函数。如图 3-3 所示，当前状态的潜在价值 $V(s_t)$ 可以由执行完动作 a_t 后的下一个状态的潜在价值 $V(s_{t+1})$ 加上执行动作后获得的实际奖励 r_t 表示。




图 3-3 时序差分法

Fig.3-3 Timing difference method

估算状态价值函数的公式如下：

$$V(s_t) \leftarrow V(s_t) + \alpha \left[\underbrace{r_t + \gamma V(s_{t+1})}_{\text{target}} - V(s_t) \right] \quad (3-2)$$

其中， $r_t + \gamma V(s_{t+1}) - V(s_t)$ 为时序差分误差 TD error， α 为学习率，控制更新幅度，数值越大则更新的幅度越大。除了可以估算状态价值函数，同样也可以对于动作价值函数进行估算，如式 (3-3)，即也是 Q-learning^[62] 的算法原理。

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha (r_{t+1} + \lambda \max_{a_{t+1}} Q(s_{t+1}, a_{t+1}) - Q(s_t, a_t)) \quad (3-3)$$

不同于上述的价值强化学习算法，基于策略的强化学习算法并不是间接的优化值函数，而是使用神经网络代替策略函数并直接优化策略函数，模型输入为状态输出为动作或动作概率，而不是输出价值。策略梯度算法(PG Policy Gradient)^[63]可以适用于不确定环境和连续动作空间场景，算法目标函数为：

$$L(\theta) = \max \mathbb{E} (r_t + \lambda r_{t+1} + \lambda^2 r_{t+2} \cdots + \lambda^{k-1} r_{t+k} \mid \pi(a \mid s, \theta)) \quad (3-4)$$

其中， θ 为决策网络参数，算法目标为实现尽可能最大化回报，当执行动作回报奖励越高则动作被选择的概率越高，回报奖励越低，概率越低。

对上述目标函数公式进行求梯度，并对参数进行反向传播更新。

$$\nabla_{\theta} L(\theta) = \mathbb{E} (\nabla_{\theta} \log \pi_{\theta}(s, a) Q_{\pi\theta}(s, a)) \quad (3-5)$$

$$\theta \leftarrow \theta + \alpha \nabla_{\theta} L(\theta) \quad (3-6)$$

3.1.2 深度强化学习 SAC 算法原理

(1) 常见算法

常见的基于价值的深度强化学习算法 DQN^[64]，是一种采用神经网络近似 Q-learning 中状态动作价值函数的强化学习算法，神经网络表示为 $Q(s, a, \theta)$ ，其中输入为在特定状态下执行特定的动作 (s, a) ，输出为潜在价值 $Q(s, a)$ ， θ 为神经网络参数。由上式可知 Q-learning 目标函数，将其中价值函数 Q 替换为神经网络 $Q(s, a, \theta)$ ，可知目标函数：

$$Q(s, a, \theta) = r + \underbrace{\lambda \max_{a'} Q(s', a', \theta)}_{\text{target}} \quad (3-7)$$

DQN 算法中使用经验回放和固定 Q 目标来稳定训练过程。在训练过程中，算法会将智能体过去的经验进行打包放进经验池中，一般一次经验格式 (s, a, r, s') ，通常会设置经验池大小，经验池达到一定比例或放满时，智能体从经验池中随机抽取小批量经验进行训练。经验回放的方法可以降低经验数据间的相关性，提高样本的利用率，减少训练过程中的方差。DQN 的流程图如图 3-4 所示。




图 3-4 DQN 流程图

Fig.3-4 DQN flowchart

此外，为解决基于策略梯度的算法在更新过程中效率低下问题，引入 AC(Actor-Critic) [65] 算法，AC 算法能够实现单步更新，收敛速度要快。AC 算法结合策略梯度算法和值函数估计方法，同时学习一个策略函数 Actor 和一个值函数 Critic，策略函数用于选择动作，值函数用于评价当前动作执行后的好坏。其中 Critic 又称评论家，本质为 Q 网络，用于估计当前状态下执行当前动作后的潜在价值即潜在的累计奖励。Actor 又称行动者或演员，主要目的学习策略函数，输入为状态 s ，输出为动作 a ，Actor-Critic 的关系如图 3-5 所示。




图 3-5 AC 流程图

Fig.3-5 AC flowchart

由于在强化学习过程中，对 Q 函数值的估计处理时，会选择最大化 Q 值来代替 $v(s')$ 进行评估，通常会造成估计高于真实的最大化 Q 值，累计误差会导致算法很难收敛。为解决此问题结合 DQN 和 DDPG [66]（深度确定性策略梯度算法）特点提出 TD3 [67] 算法。

DDPG 引入经验回访池，将智能体在与环境交互过程中的经验以 (S_t, a_t, r_t, S_{t+1}) 的形式进行一组数据的存储。在网络更新时从经验池中随机选取几组经验完成更新，减小数据之间的联系。TD3算法在 DDPG 算法基础上，引入 DQN 算法原理，设立两个独立的 Q 网络，即 Q_1 和 Q_2 ，分别用于估计状态-动作对的值函数，原理如图 3-6 所示。




图 3-6 TD3 流程图

Fig.3-6 TD3 flowchart

由图 3-7 可知，在训练过程中，使用两个 Q 网络来估计目标值，并且选择目标 Q 值较小的网络来计算目标值，这样可以减少过估计的风险。此外，由于确定性策略算法存在过度拟合问题和函数逼近误差问题，在更新 Critic 网络时影响智能体学习目标，导致估计值偏大不准确。TD3 算法目标策略噪声和目标策略平滑的技术，在选择目标动作时，添加噪声来提高探索性；同时，采用目标策略平滑来减少目标策略的方差，使得目标动作更加稳定。

(2) SAC

常见强化学习算法以累计奖励数值最大化为学习目标，并根据上面的介绍可知，DDPG 算法当学习到最优决策后策略函数区域一种决策结果，动作空间探索性较差，易造成局部最优，且策略与 Q 值相互耦合，使其性能不稳定，受超参数设计的影响收敛速度，TD3 算法则是在 Actor 网络输出结果中添加噪音实现探索不同输出动作。SAC^[68] 算法是一种用于解决连续动作空间中的离线 (off-policy) 强化学习问题的随机策略算法。SAC 算法学习除了追求累计奖励数值最大化的基本目标，还要求策略网络 (policy net) 的每一次输出的动作 (action) 的熵 (entropy) 最大，其目的是为通过最大化策略的熵来促进智能体与环境交互过程中探索和学习多样化的策略。

针对于本文的机器臂运动控制来说，SAC 算法引入动作熵最大化可以实现在训练过程中机械臂尽可能的探索不同运动轨迹进而选择最优决策。相比之下，TD3 算法过度依赖贪婪策略，可能导致算法陷入局部最优解而无法跳出，且 TD3 算法可能对动作空间的噪声敏感，需要对超参数进行优化调整才能获得良好的性能，故本文选用 SAC 算法。

SAC 的目标函数如式(3-8)所示：

$$J(\pi) = \arg \max_{\pi} \mathbb{E}_{(s_t, a_t) \sim \rho_{\pi}} \left[\underbrace{\sum_t R(s_t, a_t)}_{\text{reward}} + \alpha \underbrace{H(\pi(\cdot | s_t))}_{\text{entropy}} \right] \quad (3-8)$$

其中, $R(s_t, a_t)$ 为 s_t 状态下执行动作 a_t 后的奖励值, α 为熵的系数, 用于调整熵值权重, $H(\pi(\cdot | s_t))$ 为策略的熵, $\pi(\cdot | s_t)$ 为策略函数或动作分布概率。对于策略来说, 熵^[69]越高表示策略越随机越不稳定, 即在给定状态下采取不同动作的概率更加均匀。熵值权重 α 用于平衡累计奖励最大化和动作熵最大化, 当对于策略比较完善的状态空间时, 权重应当减小, 反之则应增大。

在某些情况下, 策略网络得出的动作值可能会超出系统实际可接受的范围。例如, 在控制机械臂时, 每个关节都有其运动范围限制。如果输出的动作值超出了这些范围, 机械臂将无法达到下一个有效状态。此外, 为了控制机械臂的速度和加速度, 在设计动作时通常会采用增量方式, 而不是直接指定角度。这可以避免机械臂在移动时产生过大的速度或加速度。本文使用激活函数来约束输出动作值在合理的范围内, 选择双曲正切 ($\tanh$) 激活函数, 其输出范围在 -1 到 1 之间, 保持了机械臂动作的平滑性和连续性, 如式(3-9)

$$\begin{aligned} u_t &= \mu_t + \varepsilon_t \odot \exp(\log \sigma_t) \\ a_t &= \tanh(u_t) \end{aligned} \quad (3-9)$$

其中, μ_t 为策略网络输出的平均值, σ_t 为策略网络输出的误差

SAC 网络参数更新流程如图 3-7 所示, 本文 SAC 网络架构由 2 个 Q critic 网络、2 个 V critic 和 1 个 Actor 组成。




图 3-7 SAC 网络参数更新流程图

Fig.3-7 Flow chart of SAC network parameter update

SAC 算法伪代码为表 3-1 所示。

表 3-1 SAC 伪代码
Tab.3-1 SAC Algorithmic Pseudocode

SAC 算法伪代码

1. 初始化 V critic 值网络 ϕ_1, ϕ_2 与 Q Critic 网络 Q_1, Q_2 ，策略网络 Actor π_θ
 2. 初始化回放经验池 D ，初始化学习率 α ，目标网络更新率 τ ，折扣因子 γ ，奖励缩放因子 α
 3. for eps=1 to M do
 4. 初始化状态
 5. for step=1 to N do
 6. 根据策略网络选择动作并添加噪声

$$a_t = f_\phi(\epsilon t; s_t) = f_\phi^\mu(s_t) + \epsilon_t \odot f_\phi^\sigma(s_t);$$
 7. 智能体执行动作后会返回新的状态 s' ，奖励值 r ；
 8. 将 (s_t, a_t, r_t, s_{t+1}) 存入经验池 D ；
 9. 使用以下公式计算目标 Q 值函数：

$$Q_{tar}(r, s') = r + \lambda \left(\min_{j=1,2} \{Q_{tar,j}(s', \tilde{a}')\} - \alpha \log \pi_\theta(\tilde{a}' | s') \right)$$
 10. 梯度下降更新 Q 网络：

$$\nabla_{\phi_j} \frac{1}{|B|} \sum (Q_{\phi_j}(s, a) - Q_{tar}(r, s', d))^2$$
 11. 梯度下降更新策略网络：

$$\nabla_{\phi_j} \frac{1}{|B|} \sum \left(\min_{j=1,2} \{Q_{\phi_j}(s, \tilde{a}_\theta(s, \xi))\} - \alpha \log \pi_\theta(\tilde{a}_\theta(s, \xi) | s) \right)$$
 12. 更新目标网络：

$$\begin{aligned} \phi_{tar,j} &\leftarrow \rho \phi_j + (1 - \rho) \phi_{tar,j}, j = 1, 2 \\ \pi'_\theta &\leftarrow \rho \pi_\theta + (1 - \rho) \pi' \end{aligned}$$
 - Endfor
 - Endfor
-

3.2 轴孔装配强化学习算法环境设计

强化学习的环境是指智能体与实际作用交互的世界，包括交互过程中包含的所有事物、条件和规则。智能体通过执行决策的动作来改变环境状态，并根据环境的反馈来学习状态-动作映射的优化策略。环境可以为连续的，也可以为离散的，通常包含动作空间 (Action Space)、状态空间 (State Space)、奖励函数 (Reward Function)、环境初始化 (Reset) 和终止条件 (Termination Condition) 等信息。对于本章，智能体为 Sawyer 协作机器人。机器人根据装配任务及环境状态进行决策规划并执行动作。随着环境状态的转移，借助设计的环境奖励反馈机制，利用前文提到的 SAC 深度强化学习算法，学习从状态空间到动作空间的最优映射策略。

3.2.1 仿真平台简介

ROS (Robot Operating System) 是由斯坦福大学开发的一款开源机器人操作系统平台,旨在提供用于模拟机器人行为、测试算法、开发控制软件等的工具或环境,平台依赖于 Linux 操作系统。ROS 包含一系列用于搭建机器人的相关库和工具,如 Gazebo、Rviz、Tf 等。其中 Gazebo 使用高精度的物理引擎,可以实现机器人在仿真环境中的轨迹规划、动力学分析以及碰撞预测等方面的测试和验证。此外,机器人的相关信息可以通过提供的可视化界面获取到,同样也提供多种传感器的模拟,包括深度相机、激光雷达和摄像头等。综合上述 Gazebo 优点,选择基于 Gazebo 作为机器人强化学习的仿真平台。

Sawyer 机器人是由美国机器人公司 Rethink Robotics 开发的一款 7 关节的协作机器人。它设计用于与人类共同工作,拥有许多先进的功能和特性,使其在灵活性和安全性方面非常适合在制造业等领域中应用。Sawyer 机器人搭载 Sawyer SDK 软件开发工具包,用户可以结合 SDK 中提供的接口程序和驱动程序,实现机器人在仿真场景中的运动控制,并应用于机器人的强化学习环境构建中。

基于 Gazebo 搭建的机器人轴孔装配的仿真环境如图 3-8 所示。




图 3-8 Gazebo 仿真场景

Fig.3-8 Gazebo simulation scenario

3.2.2 Sawyer 机器人运动学建模

在机器人强化学习过程中,算法模型需要获取机器人在仿真场景中位姿信息,并将其作为环境状态信息的一部分。因此,需要对机器人运动学建模进行研究。运动学建模是指构建机器人运动的数学模型,应用于机器人的仿真、规划和控制当中,使得机器人能够实现准确运动。Sawyer 机器人作为一款 7 自由度的协作机器人,相较于传统 6 自由度机器人具有额外的自由度,机器人具有更高的灵活性和精度,同时运动控制更为复杂。为减小机器人正解计算误差,采用改进的 D-H 法^[70]对机器人进行正运动学求解,并通过牛顿-拉夫逊法实现逆运动学求解。

(1) 正运动学求解

机器人的正运动学求解是指根据机器人的关节位置（关节角度）、关节速度等信息，计算末端执行器（末端效应器）的位置和姿态。正运动学求解是机器人运动学中的一个基本问题，其结果可以用于机器人的轨迹规划、路径规划以及控制算法的设计等应用。

根据 Sawyer 机器人基本构型，采用标准 D-H 法进行正运动学求解。其基本原理为将机器人的每个连杆之间的相对运动关系抽象为连接参数，从而描述整个机器人的运动学模型。如图 3-9 为标准 D-H 法示意图。




图 3-9 标准 D-H 建模

Fig.3-9 Standard D-H modeling

其中， α_i 为绕着 X_i 轴，从 Z_{i-1} 到 Z_i 的旋转角度； a_i 为沿着 X_i 轴，从 Z_{i-1} 到 Z_i 的距离； θ_i 为绕着 Z_{i-1} 轴，从 X_{i-1} 到 X_i 的旋转角度； d_i 为沿着 Z_{i-1} 轴，从 X_{i-1} 到 X_i 的距离。两连杆之间的坐标变换关系为：

$${}^{n-1}_n T = \text{trans}_{Z_{n-1}}(d_n) \bullet \text{rot}_{Z_{n-1}}(\theta_n) \bullet \text{trans}_{X_n}(a_n) \bullet \text{rot}_{X_n}(\alpha_n) \quad (3-10)$$

此外，为简化坐标系变化复杂性以及减小误差传播，在标准 D-H 法的基础上，将机器人的 0 坐标系与连杆 1 坐标系进行重合，如图 3-10 所示。




图 3-10 改进 D-H 建模

Fig.3-10 Improved D-H modeling

其中， α_{i-1} 为绕着 X_{i-1} 轴，从 Z_{i-1} 到 Z_i 的旋转角度； a_{i-1} 为沿着 X_{i-1} 轴，从 Z_{i-1} 到 Z_i 的距离；

θ_i 为绕着 Z_i 轴, 从 X_{i-1} 到 X_i 的旋转角度; d_i 为沿着 Z_i 轴, 从 X_{i-1} 到 X_i 的距离。两连杆之间的坐标变换关系则为:

$${}^{n-1}_nT = \text{rot}_{X_{n-1}}(\alpha_{n-1}) \bullet \text{trans}_{X_{n-1}}(a_{n-1}) \bullet \text{rot}_{Z_n}(\theta_n) \bullet \text{trans}_{Z_n}(d_n) \quad (3-11)$$

Sawyer 机器人各关节位于零位时如图 3-11 所示, 其中 $J_0 - J_6$ 为机器人的七个关节, 以及根据改进的 D-H 方法, 构建 Sawyer 机器人关节坐标系。




图 3-11 Sawyer 机器人零位 (左) 和关节坐标系构成 (右)

Fig.3-11 The Sawyer robot is composed of zero (left) and joint coordinate systems (right)

根据 Sawyer 技术手册提供的机器人基本参数信息, 构建改进的 D-H 参数表如下:

表 3-2 Sawyer 机器人 D-H 参数

Tab.3-2 Sawyer Robot D-H parameters

J_i	$a_{i-1}(m)$	$d_i(m)$	$\alpha_{n-1}(^\circ)$	旋转角度 $\theta_i (^\circ)$	旋转角范围 $(^\circ)$
0	0	0	0	θ_1	-175~175
1	0.081	0.1925	-90	θ_2	-175~175
2	0	0.4	-90	θ_3	-175~175
3	0	0.1685	-90	θ_4	-175~175
4	0	0.4	90	θ_5	-175~175
5	0	0.1363	90	θ_6	-175~175
6	0	0.1375	-90	θ_7	-270~270

将上述参数代入到式 (3-11), 计算机器人相邻坐标系间的齐次变换矩阵 ${}^{i+1}_iT$ 为

$${}^{i+1}_iT = \begin{pmatrix} c\theta_i & -s\theta_i & 0 & a_{i-1} \\ c\alpha_{i-1}s\theta_i & c\theta_i c\alpha_{i-1} & -s\alpha_{i-1} & -d_i s\alpha_{i-1} \\ s\alpha_{i-1}s\theta_i & s\alpha_{i-1}c\theta_i & c\alpha_{i-1} & d_i c\alpha_{i-1} \\ 0 & 0 & 0 & 1 \end{pmatrix} \quad (3-12)$$

由表 3-1 可得 Sawyer 机器人各个关节之间的齐次变换矩阵可表示为

$$\begin{aligned}
{}^0_1\mathbf{T} &= \begin{pmatrix} c\theta_1 & -s\theta_1 & 0 & 0 \\ s\theta_1 & c\theta_1 & 0 & 0 \\ 0 & 0 & 1 & d_1 \\ 0 & 0 & 0 & 1 \end{pmatrix} \quad {}^1_2\mathbf{T} = \begin{pmatrix} c\theta_2 & -s\theta_2 & 0 & 0.081 \\ 0 & 0 & 1 & d_2 \\ -s\theta_2 & -c\theta_2 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} \quad {}^2_3\mathbf{T} = \begin{pmatrix} c\theta_3 & -s\theta_3 & 0 & 0 \\ 0 & 0 & 1 & d_3 \\ -s\theta_3 & -c\theta_3 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} \\
{}^3_4\mathbf{T} &= \begin{pmatrix} c\theta_4 & -s\theta_4 & 0 & 0 \\ 0 & 0 & 1 & d_4 \\ -s\theta_4 & -c\theta_4 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} \quad {}^4_5\mathbf{T} = \begin{pmatrix} c\theta_5 & -s\theta_5 & 0 & 0 \\ 0 & 0 & -1 & -d_5 \\ s\theta_5 & c\theta_5 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} \quad {}^5_6\mathbf{T} = \begin{pmatrix} c\theta_6 & -s\theta_6 & 0 & 0 \\ 0 & 0 & -1 & -d_6 \\ s\theta_6 & c\theta_6 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} \\
{}^6_7\mathbf{T} &= \begin{pmatrix} c\theta_7 & -s\theta_7 & 0 & 0 \\ 0 & 0 & 1 & d_7 \\ -s\theta_7 & -c\theta_7 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}
\end{aligned}$$

由此可获得机器人末端位姿关于基坐标系的齐次变换矩阵:

$${}^0_7\mathbf{T} = {}^0_1\mathbf{T} {}^1_2\mathbf{T} {}^2_3\mathbf{T} {}^3_4\mathbf{T} {}^4_5\mathbf{T} {}^5_6\mathbf{T} {}^6_7\mathbf{T} \quad (3-13)$$

(2) 逆运动学求解

与正运动学求解相反,逆运动学求解是指根据机器人末端执行器的位置和姿态,计算机器人各个关节的位置(关节角度)。由于Sawyer机器人具有7自由度,存在冗余自由度,即机器人可以以多种方式达到相同的末端位姿,同样意味着机器人关节之间存在一定程度的耦合。本文采用牛顿-拉夫逊(Newton-Raphson)法进行关节角度求解^[71]。牛顿-拉夫逊是一种数值迭代法,常用于非线性问题求解,通过迭代方法求解关节角度,使得机器人末端执行器达到目标位置和姿态。

由上面正运动学求解可以获得各个关节角和机器人末端位姿之间的关系为,

$$\mathbf{X} = f(\boldsymbol{\theta}) \quad (3-14)$$

其中, $\mathbf{X}$ 为Sawyer机器人末端位姿, $\boldsymbol{\theta}$ 为其7个关节角: $\boldsymbol{\theta} = [\theta_1, \theta_2, \theta_3, \theta_4, \theta_5, \theta_6, \theta_7]$ 。

对上式进行时间的一阶求导,获得末端速度和各个关节角速度的关系为

$$\dot{\mathbf{X}} = \mathbf{J}(\boldsymbol{\theta})\dot{\boldsymbol{\theta}} \quad (3-15)$$

其中, $\mathbf{J}(\boldsymbol{\theta})$ 为机器人的雅可比矩阵,为6×7的矩阵。由于 $\mathbf{J}(\boldsymbol{\theta})$ 不为方阵,无法直接进行矩阵的逆解计算。因此,采用最小二乘法的伪逆求解法进行求解,核心思想为,在确保末端跟随误差最小的前提下,利用最小二乘法求解雅可比矩阵的伪逆,从而实现关节速度的最小范数。

$$\begin{cases} \min \|\dot{\boldsymbol{\theta}}\| \\ \text{s.t.} \min \|\dot{\mathbf{X}} - \mathbf{J}\dot{\boldsymbol{\theta}}\| \end{cases} \quad (3-16)$$

求解得到机器人雅可比矩阵伪逆解 $\mathbf{J}^+$, 根据定义可得到与雅可比矩阵 $\mathbf{J}$ 关系

$$J^+ = J^T (JJ^T)^{-1} \quad (3-17)$$

此外,当机器人处于奇异构型时,雅可比矩阵的行列式接近于零,这意味着机器人的某些关节自由度已经丧失,无法控制末端执行器的运动。奇异构型通常出现在机器人的关节角度处于某些特定位置或机器人的关节角度过于接近某些临界值的情况下。因此需要避免奇异构型发生,对雅可比矩阵 J 进行奇异值分解

$$J^+ = \mathbf{V} \mathbf{A}^+ \mathbf{U}^T \quad (3-18)$$

其中 $\mathbf{A}^+$ 为 $R^{n \times m}$ 矩阵, $\mathbf{V}$ 为 $n \times n$ 方阵。

$$\mathbf{A}^+ = \begin{bmatrix} \frac{1}{\sigma_1} & 0 & \cdots & 0 \\ 0 & \frac{1}{\sigma_2} & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & \frac{1}{\sigma_m} \\ 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \cdots & 0 \end{bmatrix} \quad (3-19)$$

其中, σ_i 为奇异值。利用伪逆解 J^+ 计算关节角速度的最小范数,代入式(3-18)中得:

$$\|\dot{\theta}\| = \sqrt{\sum_{i=1}^m \frac{\gamma_i^2}{\sigma_i^2}} \quad (3-20)$$

其中, $[\gamma_1, \gamma_2, \dots, \gamma_m] = \mathbf{U}^T \dot{\mathbf{X}}$ 。此外,在普通的最小二乘法中,当矩阵的条件数较大时(即矩阵的奇异值之比很大),求解过程可能会因为数值上的不稳定性而产生较大误差。因此,使用阻尼最小二乘法通过引入阻尼因子,控制矩阵的条件数,平衡拟合精度与参数平滑度。具体实现为:

$$\|\dot{\theta}\| = \sqrt{\sum_{i=1}^m \frac{\gamma_i^2}{\lambda_i^2 + \sigma^2}} \quad (3-21)$$

$$\|\dot{\mathbf{X}} - J\dot{\theta}\|^2 = \sum_{i=1}^m \gamma_i^2 \left[\frac{\lambda_i^2}{(\lambda_i^2 + \sigma^2)} \right]^2 + \sum_{i=r+1}^m \gamma_i^2 \quad (3-22)$$

其中, λ 为阻尼系数。根据机器人距离奇异点的远近,动态调整阻尼系数的大小,设定奇异值阈值 σ_0 ,当机器人远离时,最小奇异值大于阈值,反之则小于阈值,公式为。

$$\lambda = \begin{cases} \lambda_0^2 \left(1 - \frac{\sigma}{\sigma_0} \right)^2, & \sigma < \sigma_0 \\ 0, & \sigma \geq \sigma_0 \end{cases} \quad (3-23)$$

其中, λ_0 为阻尼系数最大值, σ_0 为最小奇异值阈值。若 $\sigma < \sigma_0$, 则使用阻尼最小二乘求其逆解; 若 $\sigma \geq \sigma_0$ 则直接求伪逆矩阵进而求机器人逆解。

3.2.3 状态空间

强化学习环境中的状态空间是指所有可能的状态的集合, 描述了智能体在环境中所能观察到的状态的所有可能情况。状态空间的目标是为强化学习问题提供一个全面、准确、可观察和适应性强的状态集合, 以描述环境。机器人装配中常见的状态空间包含待装配零部件的位置姿态信息机器人各关节转角和力传感器信息。根据 Sawyer 机器人的正运动学求解功能, 可以通过关节转角计算末端执行器的位姿, 进而解得待装配零部件位姿。为简化模型并减少强化学习网络参数, 本文使用待装配零件位姿信息代替关节转角信息。此外, 考虑实际轴孔装配环境中的孔位姿的多样性, 本节针对不同孔位姿装配问题, 将轴的坐标系转化到孔坐标系下进行简化, 增强强化学习模型的泛化性, 具体关系如图 3-12 所示。




图 3-12 轴孔位姿关系

Fig.3-12 Peg-hole pose relationship

根据图 3-12, 可以获得轴坐标系转换到孔坐标系的齐次坐标矩阵为

$${}_{Hole}^{Peg}T = {}_{Sawyer}^{Peg}T {}_{Hole}^{Sawyer}T = {}_{Sawyer}^{Peg}T {}_{Sawyer}^{Hole}T^{-1} \quad (3-24)$$

故本文的状态空间 S 包含轴孔的相对位置姿态和机器人 7 个关节的力/力矩, 用 13 维向量表示, 如式(3-25)所示。

$$\begin{cases} T = [{}_{Hole}^{Peg}x, {}_{Hole}^{Peg}y, {}_{Hole}^{Peg}z, {}_{Hole}^{Peg}\sigma, {}_{Hole}^{Peg}\beta, {}_{Hole}^{Peg}\gamma] \\ \tau = [\tau_1, \tau_2, \dots, \tau_7] \\ S = [T, \tau] \end{cases} \quad (3-25)$$

其中, ${}_{Hole}^{Peg}x, {}_{Hole}^{Peg}y, {}_{Hole}^{Peg}z$ 分别为轴建模坐标原点相对于孔建模中心的位置, ${}_{Hole}^{Peg}\sigma, {}_{Hole}^{Peg}\beta, {}_{Hole}^{Peg}\gamma$ 分别为轴坐标系相对于孔坐标系的旋转变换, τ 为机器人 7 个关节的关节力矩。

3.2.4 动作空间

强化学习环境中的动作空间是指智能体可以执行的所有可能动作的集合。设计动作空间的目的是为了使智能体能够有效地控制机器人执行任务，并在与环境的交互中学习到最优的策略。从机器人运动控制方式出发，机器人能够通过算法规划获得笛卡尔坐标坐标系下的目标位姿，如式(3-26)所示，进行轨迹插补算法后，再通过逆运动学求解每步关节角增量；此外，也可通过直接执行关节角增量插补算法实现运动。考虑机器人为 7 自由度冗余机器人，频繁逆运动学求解操作会存在运动误差增大以及求解失败问题，影响模型训练的稳定性及复杂性。因此，需要尽量避免逆运动学求解。故将动作空间设计为机器人的 7 个关节角增量，有助于直接控制机器人的动作，降低计算复杂度，避免逆运动学求解问题，符合机器人的执行方式，并提高训练的稳定性及效率。因此，本节动作空间 a 可用 7 维向量表示，如式(3-27)所示。

$$a = [\Delta x, \Delta y, \Delta z, \Delta \alpha, \Delta \beta, \Delta \gamma] \quad (3-26)$$

$$a = [\Delta j_1, \Delta j_2, \dots, \Delta j_n] \quad (3-27)$$

由于装配过程需要精细的动作控制，为了保持机器人每次动作的幅度适中，本文在使用 SAC 算法时，已经通过激活函数将网络输出的动作限制在 $(-1, 1)$ 之间。然而，在仿真场景中控制是以弧度值进行的，因此，需要将网络输出的动作乘以一个系数进行调整。本文选择该系数为 0.005，以便使动作的幅度在控制机器人时保持合适的范围。

3.2.5 奖励函数

奖励函数的设计是强化学习环境设置中至关重要的一环，它直接影响着智能体学习到的策略和行为。一个合适的奖励函数应该能够引导智能体朝着实现任务目标的方向学习，并且具有稳定性和可解释性。本文将机器人轴孔装配过程分为垂直于孔轴线的平面搜索和插孔搜索两个阶段：首先从初始位姿出发，在垂直于孔轴线的平面探索，直至轴到达孔中心上方的邻域范围内，即到达孔附近。随后进入插孔探索，直至轴孔成功装配，如图 3-13 所示。




图 3-13 轴孔装配过程

Fig.3-13 Peg-hole Assembly Process

根据轴孔装配的两个过程构建对应的平面搜索奖励以及插孔搜索奖励。平面搜索奖励基本思路为，在垂直于孔轴心线的平面上，当轴末端中心的位置越接近孔中心位置时，奖励值越大；当轴末端坐标系姿态越接近于孔坐标系姿态时，奖励值越大，如式(3-28)所示。

$$r_reach = r_{pos} + r_{ori} = (\lambda_1 (\delta_0 - \tanh(s_1)) \sigma_{pos} + \lambda_2 (\delta_1 - \tanh(s_2)) \sigma_{ori}) \quad (3-28)$$

式中， $s_1 = \sqrt{(x_p - 0)^2 + (y_p - 0)^2}$ 为轴孔间平面方向上的欧氏距离；

$s_2 = \sqrt{(\alpha_p - 0)^2 + (\beta_p - 0)^2 + (\gamma_p - 0)^2}$ 为轴孔坐标系姿态的欧氏距离；

x_p, y_p 是轴心的 x, y 坐标； $\alpha_p, \beta_p, \gamma_p$ 是轴的旋转姿态；

λ_1, λ_2 为轴和孔的相对位置与相对姿态的欧氏距离系数；

δ_0, δ_1 是为了实现奖励正负均匀化而引入的调整参数；

$\sigma_{pos}, \sigma_{ori}$ 是奖励的探索系数。

插孔搜索奖励的基本思路是，机器人完成水平面搜索到达孔心上方后进行探索，当轴插入孔时，给予额外的奖励，直至完成插孔操作。即为 $s_1 < s_p$ ， $s_2 < s_o$ 时，轴插入深度越深奖励越大，可以得到式 (3-29)

$$r_insert = \frac{(H_p - z_p)}{H_p} \sigma_{insert} + r_reach \quad (3-29)$$

式中：

σ_{insert} 是插入奖励的系数；

z_p 是轴心在孔坐标系下 z 轴方向坐标；

H_p 为孔深度。

3.2.6 终止函数

设计强化学习的终止函数是指确定智能体何时停止与环境的交互，并结束训练。终止函数的设计应考虑任务的性质、智能体的学习进度以及性能的评估。为提升学习效率并避免无意义探索，本文设计了以下终止条件：

(1) 当轴的位置距孔心的距离大于设定的距离阈值，判定当前探索远离目标位置，则回合结束，并给予惩罚奖励；

(2) 为防止模型进行无限探索，设置每一回合最大探索次数，若探索次数超出限制，结束当前回合；

(3) 当完成装配操作时，结束回合，并给予最大正向奖励；

(4) 若获得机器人 7 个关节的关节力矩超过允许的阈值时，认定机器人无法继续运动，结束当前回合，并给予惩罚奖励。

3.2.7 环境初始化

强化学习环境初始化是指在开始强化学习任务之前，设置环境的初始状态和条件；此外，在每个回合结束时，需要将仿真环境恢复到初始状态。本文为提高模型泛化性，在孔

位置保持不变的情况下,对轴的初始位置添加随机扰动,增强初始环境的随机性。具体实现为在轴的位置添加随机增量,并将初始位置分布在孔中心为圆心,半径为 0.015m 圆内,高度 0.02m,如式 (3-30)

$$\begin{cases} |\Delta x| = \text{rand}(0.015) \\ |\Delta y| = \text{rand}(0.015) \\ z_p = H_p + \text{rand}(0.02) \\ \sqrt{x^2 + y^2} = 0.015 \end{cases} \quad (3-30)$$

本节设置轴的初始位置,如图 3-14 所示。通过机器人逆运动学的离线求解,可以获取 7 个关节的目标关节角度。然后,计算目标关节角度与机器人零位关节角差值,并将其除以执行步数,以此得到机器人各个关节平均变化增量,实现机器人从零位到初始位置操作。为避免机器人频繁逆运动学求解,随机选取 12 个位置,并将机器人运动轨迹记录存储。在仿真过程中,从 12 个预先存储的初始位姿中随机抽取一个位姿作为初始位姿。




图 3-14 环境初始化位置

Fig.3-14 Environment initialization location

3.2.8 算法训练整体流程

整个模型训练过程可以概括为以下步骤:首先,初始化仿真场景,根据预设规则,获取机器人的 12 个随机初始位姿。随机选取一个初始位姿,机器人从零位运动到初始位姿,然后开始进行装配任务的强化学习训练。机器人执行由强化学习算法输出的七个关节角增量,使得环境状态转移到下一个状态。如果在执行动作后满足预设的终止条件,则结束本回合的训练并重新进行环境初始化。随着机器人不断与环境交互,积累从环境中获取的动作-状态-奖励经验序列,不断填充经验池。同时,从经验池中随机抽取一批经验用于更新强化学习网络参数,循环往复直到算法收敛。训练流程图如图 3-15,整个过程能够让机器人在仿真场景中学习到最优的装配策略,以满足任务的要求。




图 3-15 强化学习训练整体流程

Fig.3-15 Reinforcement learning training process

3.3 轴孔装配仿真训练及测试

为验证设计模型环境的泛化性，采用相同的强化学习环境分别训练垂直和斜孔装配模型，然后，加载训练后的模型进行不同孔径、间隙以及方形孔的装配仿真测试。

3.3.1 强化学习模型参数

首先，基于 SolidWorks 建模分别建立轴和垂直孔的三维模型，如图 3-16 所示。其中轴的直径为 49.95mm，长度为 140mm；垂直孔的直径为 50.00mm，孔深 120mm，轴和孔的倒角均为 1mm。




图 3-16 垂直轴孔三维模型

Fig.3-16 3D model of a vertical shaft hole

斜孔三维模型设计如图 3-17 所示，轴直径为 49.92mm，斜孔直径为 50mm，孔深 100mm，孔倒角为 1mm，斜孔中心线与垂直平面夹角为 30° 。




图 3-17 斜孔三维模型

Fig.3-17 3D model of the oblique hole

输入为 13 维状态量和中间 3 层 512 维的全连接层以及 7 维的输出关节角增量，Q critic 和 V critic 与之类似输入都为 13 维状态量，输出都为 1 维的 critic 值。

深度强化学习 SAC 模型的超参数设置对于模型学习收敛速度至关重要。通过在训练过程中不断测试调整，本文超参数设置如表 3-3 所示。

表 3-3 SAC 算法超参数

Tab.3-3 SAC algorithm hyperparameters

参数名称	大小
Sample batch	256
经验池容量	1000000
单回合最大步长	300
折扣因子	0.992
Q 网络学习率	0.0005
策略网络学习率	0.0005
α 学习率	0.0005

3.3.2 仿真装配训练

根据上面给出的模型参数以及整体的装配流程，分别进行垂直和斜插孔的仿真训练。本次轴孔装配仿真训练所配置的硬件环境为：操作系统为 Ubuntu20.04 系统，GPU 为 AMD 6600，CPU 为 AMD 5600x，运行内存 16GB，程序语言为 Python3.8。

(1) 垂直插孔

预设轴建模原点相对机器人基座标位置为 $[-0.31, 0.6, -0.145]$ ，单位 m，轴坐标系姿态相较于机器人基坐标的欧拉角为 $[0, 0, 0]$ ，单位弧度 rad，孔建模原点位置为 $[0, 0.6, -0.145]$ ，单位 m，孔坐标系姿态的欧拉角为 $[0, 0, 0]$ ，单位弧度 rad，训练 4000 回合，最终训练时间为 4.2h，垂直插孔的每回合累计奖励(Cumulative Rewards)以及平均每步奖励(Average Reward)的仿真曲线如图 3-18 所示，由强化学习目标函数可知，算法训练追求累计奖励最大化，同时平均奖励值达到最大化。




图 3-18 垂直装配累计奖励（左）和平均奖励（右）

Fig.3-18 Vertical Assembly Cumulative Reward (left) and Average Reward (right)

分析曲线可以看出，在训练的前 500 回合中，累计奖励波动比较大，机器人与环境交互并进行随机探索，导致 SAC 算法会输出的累计奖励值波动比较大的动作序列。随着机器人持续探索，积累经验并存储到经验池中。通过在经验池中随机抽取样本来更新模型自身网络参数，可以看出在 500-1000 回合中奖励显著增长，并出现成功装配案例。在训练的 1000 至 1700 回合中，机器人基本能够完成装配任务，但仍存在探索失败情况，累计奖励值偶尔有所波动。在后续的回合并中，累计奖励值基本保持稳定，模型趋于收敛，机器人能够在规定探索步数完成仿真装配。

(2) 斜插孔

在斜孔装配过程中，由于状态空间需要将轴位姿转换为相对于孔的相对位姿，在坐标变换过程中存在计算误差，可能会导致机器人无法完成高精度装配任务。因此，通过训练不同直径的轴孔装配模型，本文选用直径为 49.92mm 的轴孔。同样，首先预设轴位置为 $[-0.31, 0.6, -0.145]$ ，轴坐标系姿态的欧拉角为 $[0, 0, 0]$ ，斜孔位置为 $[0, 0.8, -0.145]$ ，孔坐标系姿态的欧拉角为 $[0.53, 0, 0]$ ，进行 4000 次回合训练，训练时间为 5.3h。斜插孔的仿真曲线如图 3-19 所示。




图 3-19 倾斜轴孔装配累计奖励（左）和平均奖励（右）

Fig.3-19 Angled hole assembly cumulative reward (left) and average reward (right)

相较于垂直插孔，斜插孔在训练前期的随机探索回合次数要大于垂直插孔。且由图 3-19 平均奖励曲线图可看出，初始阶段的平均奖励要小于垂直插孔。在前 1500 次的训练回

合中，累计奖励快速增长，但仍存在累计奖励波动问题。一方面是因为算法自身需要不断探索动作获取经验，另一方面由于孔的多样性，导致机器人在转换后空间中探索的复杂性要高于垂直插孔的复杂性。因此，训练需要更多回合进行探索。在 1500-200 回合之间，模型基本达到收敛状态，机器人能够实现斜孔装配。在后续训练中模型趋于收敛，偶尔出现装配失败情况。

3.3.3 仿真装配测试

为测试训练后的模型鲁棒性和泛化性，建立不同尺寸和配合间隙的轴孔模型，将前文训练好的垂直和斜孔装模型参数加载到测试的 SAC 网络中，分别进行垂直不同孔径间隙、斜孔不同孔径间隙以及方孔装配的仿真测试。整个轴孔装配过程包括 4 个步骤：机器人抓取轴、到达装配初始位姿、插入过程以及完成装配。强化学习模型应用于机器人到达初始位姿后的轴孔装配过程，机器人的抓取动作则是通过执行简单插补算法来完成的。设置单回合最大步长为 500，并统计 100 次测试中装配成功率。在测试方孔仿真装配时，SAC 网络加载垂直装配模型参数，如表 3-4。

表 3-4 垂直装配不同孔径间隙测试

Tab.3-4 Vertical assembly with different aperture clearance tests

公称直径 (mm)	轴孔间隙 (mm)	成功率	平均耗时 (s)
20	0.05	98%	4.42
	0.08	97%	4.02
	0.1	99%	3.89
30	0.05	98%	4.23
	0.08	98%	3.90
	0.1	100%	3.80
40	0.05	97%	4.20
	0.08	99%	4.01
	0.1	99%	3.84

由表 3-4 可知，在垂直孔装配中，尽管状态空间涉及轴孔位姿坐标变化存在计算误差，模型仍能实现间隙为 0.05mm 的轴孔装配仿真，即孔轴单边间隙为 0.025mm 及以上的装配任务。并且装配的成功率能够达到 97%以上，能够满足常规的轴孔装配任务需求。此外，对比训练所用轴孔，可以看出训练后 SAC 模型对于不同轴径装配问题具有很强的鲁棒性同时，完成整体装配的平均耗时基本保证在 4s 左右，可以高效完成任务。

为测试训练后的 SAC 模型对不同形状的轴孔装配的鲁棒性，构建 20*20、30*30 以及 40*40 的方孔、方轴三维模型，其中轴高度 140mm，孔深 120mm，加载垂直装配模型参数到 SAC 算法中进行仿真测试，仿真测试结果如表 3-5。

表 3-5 方形孔轴不同孔径间隙装配测试
Tab.3-5 Square bore shaft with different aperture clearance assembly test

长*宽*孔深（mm）	轴孔间隙（mm）	成功率	平均耗时（s）
20*20*140	0.05	80%	5.28
	0.08	92%	4.43
	0.1	95%	4.15
30*30*140	0.05	78%	5.32
	0.08	90%	4.35
	0.1	94%	4.08
40*40*140	0.05	76%	5.23
	0.08	89%	4.28
	0.1	96%	4.05

由表 3-5 可以看出，在轴孔间隙为 0.05mm 的时，使用所训练的垂直装配强化学习模型参数进行方形轴孔装配的成功率最大降低至 78%左右。这主要是由于方形轴孔装配过程中容易出现边角干涉问题，尤其在间隙较小的情况，干涉问题更加突出。因此，垂直模型输出的一些动作可能会导致轴孔边角碰撞，从而无法完成装配。当测试轴孔间隙大于训练轴孔间隙 0.05mm 后，装配成功率明显提高，能够达到 90%左右的成功率。测试结果可以说明，垂直轴孔装配训练模型对于方形轴孔装配具有一定的鲁棒性，但装配精度会受影响而减小，装配成功率有所下降，且装配时间略有增加。

此外，加载倾斜轴孔装配训练模型参数，进行不同孔径间隙仿真测试，结果如表 3-6。

表 3-6 倾斜轴孔装配不同孔径间隙测试
Tab.3-6 Oblique hole assembly with different aperture clearance test

公称直径（mm）	轴孔间隙（mm）	成功率	平均耗时（s）
20	0.05	49%	4.80
	0.08	98%	4.12
	0.1	98%	3.99
30	0.05	50%	4.89
	0.08	100%	3.98
	0.1	98%	3.90
40	0.05	49%	4.95
	0.08	100%	4.05
	0.1	100%	3.86

与训练时的轴孔间隙 0.08mm 比较，对于训练间隙包括大于训练间隙的轴孔装配，装配成功率能够达到 98%左右。根据上面的统计数据可以看出在斜孔装配中模型仍对不同

孔径和间隙具有一定的鲁棒性。

图 3-20 与 3-21 分别为垂直装配和斜孔装配的整个装配过程。




图 3-20 垂直轴孔装配过程

Fig.3-20 Vertical shaft hole assembly process




图 3-21 斜孔装配过程

Fig.3-21 Oblique hole assembly process

在垂直轴孔和倾斜轴孔装配过程中，在水平面的欧氏距离以及轴建模中心距孔心的

垂直距离的变化曲线分别如图 3-22 和图 3-23。可以看出，垂直装配时机器人装配平稳进行，并未出现位姿剧烈变化，而倾斜装配过程中存在位姿调整，整体装配进程较为平稳。




图 3-22 垂直轴孔装配曲线

Fig.3-22 Vertical shaft hole assembly curves




图 3-23 斜孔装配曲线

Fig.3-23 Angled hole assembly curves

通过上述三组的仿真测试，可以验证本文设计的轴孔装配算法环境在不同孔径、不同孔型以及不同孔位姿下都具有良好的鲁棒性和泛化性。

3.4 在线搭建仿真场景

在线创建仿真场景是指当在人机协作过程中，为考虑实际装配场景中零部件分布情况对于机器人仿真装配效果的影响，在线对场景中零部件进行识别和定位，并将零部件导入到仿真平台中，以搭建用于机器人强化学习装配的仿真场景。其主要应用场景包括：在第二章动态任务分配过程中，评价为存疑的任务需要在线搭建仿真场景进行机器人执行任务的可行性测试；此外，机器人进入插空学习状态时，需要搭建仿真环境进行模型训练。

仿真场景在线创建可分为离线建库、离线场景搭建以及在线场景搭建 3 部分，如图 3-24 所示。




图 3-24 在线搭建仿真场景流程

Fig.3-24 Build the simulation scene process online

3.4.1 离线建库

离线建库是指为实现在线创建装配仿真场景，需要事先离线建立产品装配过程所用零部件三维 CAD 模型库。以便在线仿真时，与场景信息匹配后，将待装配零件的三维 CAD 模型导入 Gazebo 仿真场景中。

首先，使用 SolidWorks 软件对装配任务中使用的零部件、工具进行三维 CAD 模型建模；然后，使用 sw_urdf_exporter 插件，将模型三维模型输出为所需的 URDF 类型，如图 3-25 所示。其中，文件夹包含用于 Gazebo 仿真场景调用的 launch 文件、包含模型几何外形的 STL 文件、描述模型的几何形状、关节、传感器以及其它相关参数的 XML 文件等。

名称	修改日期
config	2023/10/1
launch	2023/10/1
meshes	2023/10/1
textures	2023/10/9
urdf	2023/10/1
CMakeLists.txt	2023/10/9
export.log	2023/10/9
package.xml	2023/10/9

图 3-25 URDF 数据库文件类型

Fig.3-25 URDF database file type

为了使模型导出后的模型坐标系与建模坐标系相同，需要构建参考坐标系与建模坐标系重合。在模型导出时，选择参考坐标系为导出坐标系。由于机器人轴孔装配精度要求高，而插件直接输出的模型 STL 文件显示的零件表面粗糙，因此，需要对数据库文件进

行改进，具体方法为将模型CAD模型另存为STL文件，并将插件输出文件的STL文件替换原始文件，如图3-26所示。




图 3-26 未优化前（左）与优化后（右）三维模型

Fig.3-26 3D models before optimization (left) and after optimization (right).

3.4.2 离线仿真场景搭建

鉴于实际装配场景的复杂性和多样性，直接从现实场景到仿真场景的映射较为困难。为降低在线创建仿真场景的复杂度，在线搭建场景前对装配场景中固定不变的物体进行三维建模，例如工具箱、机器人以及装配工作台等，可将其预先导入仿真场景中。具体步骤：首先是创建空的Gazebo仿真场景，利用官方提供的Sawyer SDK实现Sawyer机器人模型的导入；然后，根据离线建库步骤，构建物体相应的URDF文件库，通过其中提供的launch文件接口，将零部件模型导入，并进行模型的位姿调整；最后，将离线仿真场景保存为.world文件。离线生成的仿真场景如图3-27所示。




图 3-27 离线场景搭建

Fig.3-27 Offline scene building

3.4.3 在线仿真场景创建

实际动态装配过程中，需要在线仿真验证的任务可以通过前文中构建的复杂动态任务分配流程确定。由于在实际装配过程中的装配对象、工具等及其位姿不能事先离线确定，

需要通过现场机器视觉识别、定位获取。当某一装配任务需要在线验证时，首先是通过识别定位模块获取装配场景中零件位姿信息，并将现场获取的待装配零件信息以名称-位置-姿态的格式保存到本地文件 Pose.txt 中；接着，通过在离线构建的 URDF 模型库中，检索实际场景中识别出的零件名称，进而获取到匹配的 URDF 模型文件。然后，根据 ROS 提供的 ServiceProxy 函数中的 SpawnModel 服务类型，生成一个服务通讯节点。并通过该节点，结合获取到的实际场景中零件位置和姿态信息，将实际场景中零件的三维模型导入前文预先搭建的离线仿真场景当中。

通过以上步骤，完成机器人实际场景的仿真装配场景的在线创建，如图 3-28 所示，由于本章不直接涉及实际装配场景，因此上文强化学习训练中的零部件位姿信息为预设的数值。在第四章中，本文将通过应用点云识别定位技术实现场景零部件信息的获取，从而对在线仿真场景搭建可行性进行验证。对于机器人插空学习的仿真环境搭建问题，主要搭建之前仿真失败场景进行训练，零部件位姿信息已知。因此，无需通过识别定位模块进行场景信息获取。



图 3-28 在线仿真场景创建

Fig.3-28 Online simulation scene construction

3.4.4 在线插空学习测试

为充分利用机器人资源，在 2.2.2 节中设计当机器人在无法完成装配任务时，机器人在线搭建之前仿真失败的场景，机器人进入插空学习状态并训练 SAC 算法模型，以此实现机器人自身能力的增长。期间，当操作者意图发生变化时，机器人结束学习状态。在整个产品的装配过程中机器人可能包含多个插空学习状态，为验证机器人通过插空学习提升能力的可行性，将一次完整的垂直装配模型训练过程平均分为 3 次进行学习。在初次训练时，随机初始化神经网络参数，而之后每次训练开始时加载上一次训练完成后的神经网络参数，连续训练和分段训练累计奖励曲线如图 3-29 所示，连续训练设计为 3600 个回合，分段训练每隔 1200 回合为一次训练。




图 3-29 连续与分段训练平均奖励曲线

Fig.3-29 Average reward curves for continuous and segmented training

由图 3-29 可以看出, 分段训练的模型在下次训练开始时, 一定程度上会从上一次训练结果的基础上继续训练。然而, 由于每次训练开始时经验池为空, 导致每次训练初期都会存在机器人探索阶段, 影响模型收敛速度。通过对比最终模型的平均奖励值, 可以发现经历相同训练回合后, 分段学习的第三次模型平均奖励基本上可以达到连续训练模型结果。此外, 在三次分段训练中, 模型开始时的平均奖励数值由 50 提升到 250 左右。因此, 机器人在线插空学习仿真能够在一定程度上有助于提高机器人自身能力。这种分段的学习方法, 尽管在每个训练周期开始时都需要经历一个探索阶段, 但最终仍然能够达到与连续训练基本相同的表现。通过这种方式, 机器人可以逐渐地学习并提升其在实际装配任务中的性能。

3.5 本章小结

本章通过轴孔位姿变换, 将轴相对于孔的位姿以及机器人 7 关节力矩作为强化学习环境的状态空间, 提高了对于不同孔位姿装配的泛化性; 根据轴孔装配过程, 构建了强化学习算法奖励函数, 确保算法模型的准确性和高效性, 算法环境可以很好的应用于复杂装配场景中斜孔装配问题; 设计在线搭建仿真场景流程, 通过离线搭建模型库和装配环境, 在获取零部件位姿后, 实现在线搭建仿真场景, 提升了装配算法模型输出在实际装配场景的可靠性, 同时验证机器人通过插空学习的实现机器人能力增长的可行性。通过对不同孔径间隙、孔型以及孔位姿的仿真, 可以得出所设计的强化学习环境具有良好的鲁棒性和泛化性, 能够满足大多数的装配需求。

<此页空白>

Sawyer 机器人本体自重为 19 kg，有效臂展范围为 1260 mm，拥有 7 个自由度，最大有效载荷 4 kg，各个关节配备嵌入式力觉传感器，重复定位精度为 ± 0.1 mm。下表 4-1 为相机的相关参数：

表 4-1 KinectV2 相机参数
Tab.4-1 KinectV2 Camera parameters

性能指标	性能参数
色彩图像分辨率	1920x1080
深度图像分辨率	512x424
红外图形分辨率	512x424
视角范围	水平 70°，垂直 60°
深度检测范围	0.5m-8m
深度误差	<0.5% of range
每秒帧数	30/15fps

轴孔装配参数如表 4-2 所示

表 4-2 轴孔尺寸表
Tab.4-2 Shaft hole size table

尺寸(单位：mm)	轴	孔
内径	—	50
倒角	1	1
外径	49.90	—
长度	140	120
倾角(°)	—	30

4.2 相机标定

4.2.1 Kinectv2 相机标定

相机标定的基本思想是通过已知的三维场景信息和对应的二维图像信息，推导出相机的参数，即建立从三维空间点到二维图像点的映射关系。这个映射关系涵盖了相机的内部几何特性、光学特性和图像传感器特性。相机参数可分为内部参数、外部参数和镜头引起的畸变参数。内部参数包含焦距、主点坐标和畸变系数，外部参数包括旋转和平移矩阵。图 4-3 为相机成像下坐标关系图以及小孔成像原理图^[72]。




图 4-3 相机成像坐标系（左）以及小孔成像（右）

Fig.4-3 Camera imaging coordinate system (left) and small hole imaging (right)

图 4-3 中, x_w 、 y_w 、 z_w 为世界坐标系, x_c 、 y_c 、 z_c 为以相机光学中心为原点的相机坐标系, x 、 y 为图像坐标系, 以相机光轴与成像平面交点为原点, u 、 v 为像素坐标系, P 为世界坐标系下点位姿, p 为 P 向量与成像平面的交点。

标定板是用于摄像机标定和图像处理中的一种检测工具, 用于提供一个具有已知几何特征的参考系。它是一种具有特定图案的板, 通常为黑白对比色, 这些图案可以是棋盘格、圆圈、或者其他设计, 用以帮助精确地测量和校正摄像机的畸变、焦距、姿态以及三维空间中的位置。本实验所用标定板为棋盘格类型, 大小为 6×9 , 方格尺寸为 $27\text{mm} \times 27\text{mm}$, 如图 4-4 所示。




图 4-4 相机标定板

Fig.4-4 Camera calibration plate

将标定板放置在机器人末端执行上, 通过改变机器人位姿, 获取不同位姿下的标定板图像, 如图 4-5 所示。根据张氏标定法^[73]在 Matlab 软件中进行标定。




图 4-5 采集标定板图像

Fig.4-5 Acquire an image of the calibration plate

标定得到的相机内参如表 4-3 所示。

表 4-3 相机参数

Tab.4-3 Camera parameters

相机内参	标定结果
f_x	371.2607
f_y	376.8720
c_x	274.0744
c_y	206.7581
k_1	0.1346
k_2	-0.0014
p_1	-0.0062
p_2	0.0010

4.2.2 手眼标定

手眼标定(Eye To Hand)^[74]是一个确定机器人手臂末端执行器(手)和摄像头(眼)之间相对位置和取向的技术。它在机器视觉和机器人技术领域中非常重要,特别是当涉及到精确操作或协同工作时。手眼标定通常是为了使机器人能够基于摄像头的视觉信息来正确地进行操作。

手眼标定的原理主要包括两个方面:机器人运动学标定和摄像机标定。在这两个方面中,都要确立物理世界中的坐标系(如机器人基座的坐标系、摄像头的坐标系以及标定物体的坐标系)与图像坐标系之间的关系,原理图和标定场景图如图 4-6 所示。




图 4-6 手眼标定原理图(左)以及标定实验场景图(右)

Fig.4-6 Hand-eye calibration schematic diagram (left) and calibration experiment diagram (right)

手眼标定一般需要让机器人的手臂末端执行器作出一系列不同姿态的移动,在每个不同姿态下,用摄像头拍摄固定场景中的标定板,通过计算机器人手臂末端执行器的位置变换和摄像头视图变换之间的关系来求解手眼之间的转移矩阵。记录相机标定时机器人末端位姿信息,如表 4-4 所示,其中, X 、 Y 、 Z 表示末端相对于机器人基坐标系的位移量; α 、 β 、 γ 表示机器人末端相对于基坐标系的旋转角度。

表 4-4 机器人末端位姿
Tab.4-4 Robot end positions

编号	X (mm)	Y (mm)	Z (mm)	A (deg)	B (deg)	C (deg)
1	-95	457.6	120.6	-168.05	-1.89	-74.13
2	16.8	576.2	138.9	-134.97	11.87	-77.15
3	-75.7	572.8	147.2	-144.46	12.6	-47.7
4	115	494.7	96.3	-115.49	2.59	-84.65
5	160.8	523	62.1	-102.1	-41.95	-96.22
6	-22.3	506.4	86.3	-137.33	14.89	-56.42
7	26.4	460.9	185.5	-173.43	13.47	-78.35
8	77	526.5	124.4	-152.17	27.4	-72.09
9	10	534.7	104.2	-131.87	49.82	-60.07
10	72.4	445.0	48.4	-135.77	33.75	-65.66

通过手眼标定原理解算相机坐标系相对于机器人基坐标系的刚体变换矩阵:

$$\mathbf{T}_{cam}^{base} = \begin{pmatrix} 0.7038 & -0.0041 & -0.7104 & -0.4523 \\ -0.7103 & 0.0044 & -0.7038 & -1.0569 \\ 0.0060 & 1 & 0.0002 & 0.7719 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

4.3 点云识别与定位

4.3.1 点云预处理

由图 4-7 可以看出,通过相机直接采集到的原始点云数据中包含大量的噪声和异常点,这些数据会影响后续点云处理和分析的准确性。因此本文对获取的原始点云首先保存为.ply 文件,然后进行点云滤波和点云分割的点云预处理操作^[75],去除或减轻异常数据,从而提高最终结果的精度。



图 4-7 实际装配场景视觉点云

Fig.4-7 Visual point cloud of the actual assembly scene

(1).点云滤波

点云滤波其目标是去除噪声和异常点以获得更平滑、更一致的数据集,本文采用半径滤波、统计滤波和体素滤波进行点云滤波操作。

如图 4-8 为滤波后的点云图,可以看出相较于原始点云异常点减少,点云质量增强。



图 4-8 装配场景滤波后点云

Fig.4-8 Assemble the scene after filtering the point cloud

(2).点云分割

点云分割的基本思想是将一个点云数据集划分成若干个具有特定特征和属性的子集。点云分割通常是为了识别并提取出具有独特几何或反射特性的区域,从而为对象识别、分类以及三维重构等后续任务提供便利。对于获取到的滤波后的点云数据,本文首先进行背景点云去除,再进行点云分割。

背景点云去除^[54]是通过离线对工作台和背景物体进行点云采集和预处理,得到背景点云数据,利用最近邻搜索算法,对场景视觉点云中的每一个点寻找在背景点云中的最近邻点。如果两者距离小于阈值时,认为是重叠区域,记录下构成重叠部分的点对的索引值。使用这些索引值来从场景视觉点云中排除那些与背景点云匹配的点,从而除去不需要的背景部分。

如图 4-9 为背景点云和去除背景点云后点云数据,



图 4-9 背景点云(左)和去除背景后点云(右)

Fig.4-9 Background point cloud (left) and point cloud with background removed (right)

根据图 4-9 可以看出,通过背景点云去除后的点云数据虽然仍存在少量噪点,但同时可以得到较为清晰的零部件点云。对处理后的点云进行分割,本文采用区域增长算法。算法基本思路为首先从点云中选择一个或多个种子点,然后根据预定的相似性准则(例如点之间的距离、法线的方向、曲率等)将邻近的点添加到种子点所在的区域,逐渐“生长”出

分割的区域或聚类。如图 4-10 为分割后图像:




图 4-10 点云分割结果

Fig.4-10 Point cloud segmentation results

4.3.2 离线构建 CAD 模型点云库

获取到场景点云后, 还需要构建关于模型的点云库, 用于与场景点云的匹配和配准, 最终实现点云识别和定位^[54]。具体方法首先使用 SolidWorks 软件建立零部件的三维 CAD 模型, 通过 PCL 算法中设置虚拟相机获取 CAD 模型不同视角下的模型点云。PCL 提供 renderViewTesselatedSphere 函数核心思想是环绕 CAD 模型的几何中心放置一个正二十面体, 使其紧密包围模型。该多面体在球面上的分布能够允许从多个精准和均匀分散的视角获取点云, 模拟一个全面的三维视觉采集过程, 如图 4-11 所示。




图 4-11 模型单视角点云采集

Fig.4-11 Model single-view point cloud acquisition

在 renderViewTesselatedSphere 函数中 tessellation_level 参数控制正二十面体的每个面细化程度, 进而控制虚拟相机拍摄模型的单视角点云数量。当 tessellation_level 设为 0 时, 仅利用原始正二十面体的 12 个顶点和 20 个面中心作为初始化的虚拟相机的位置, 提供 32 个视角来观察并采集 CAD 模型点云。此外, tessellation_level 设为 1 时, 每个面会被划分为更小的三角形, 总共 42 个顶点和 80 个面中心, 合计 122 个不同的视角来捕捉单视角点云。本文将虚拟相机放置在 0.5 米远的位置, 设置分辨率为 512×424 像素, 模型点云单视角点云库如图 4-12。




图 4-12 零件 CAD 模型及单视角点云

Fig.4-12 CAD models of parts and point clouds from a single view

4.3.3 点云识别

本文基于点云全局特征实现零部件的识别方法基本思路为在模型单视角点云模型库构建完成后，计算所有的模型点云 VFH 特征作为标准特征库，然后计算点云预处理后的场景点云 VFH 全局特征，将场景点云特征与标准特征库进行近邻搜索 kd-tree^[76]，并输出识别结果，识别流程图如图 4-13。




图 4-13 点云识别流程

Fig.4-13 Point cloud identification process

在 PCL 库中，VFH 为 308 维的数据格式，前 135 维为形状描述分量，[181,308]维为视点方向分量，使用各个点到质心距离与最远点到质心的距离平方比值填充[136,180]维数据，用于扩展形状描述分量，反映点云表面所有点的分布情况。

kd-tree 数据库建立基本思想是将 VFH 特征描述子进行规则排布，并以树形结构进行

保存。具体步骤为:

Step1: 确定分割轴, 选择点云每维数据中方差最大的维度作为根节点分割轴。

Step2: 确定节点, 依据获得的分割轴进行排序检索, 寻找中位数数据并放置到当前节点。

Step3: 确定左右分支, 将小于中位值的数据放置在左支, 大于的则放置在右支中

Step4: 重复 1-3 步骤直至所有数据进行排布。

将特征数据构建为以树形结构保存后, 通过k近邻搜索算法快速获取到与目标点云相似的k个样本。近邻搜索基本原理是通过遍历二叉树每一个节点, 通过比较每个节点与目标节点的欧式距离, 取相似度最高的k个节点进行输出, 本文设置k=3, 如式(4-1)。

$$d = V_0 - V_1 = \sum_{i=1}^n \sqrt{(v_{0i} - v_{1i})^2} \quad (4-1)$$

其中, V_0, V_1 为两个点云的全局特征数组, v_{0i}, v_{1i} 分别为其每一维度的值, n 为全局特征的维数。

对构建的单视角模型点云库和预处理完的场景点云进行 VFH 特征描述子的计算, 然后构建 kd-tree 特征数据库。其中, 将特征文件保存为.h5 文件, 将 kd-tree 数据结构保存为.idx 文件。此外, 将模型点云数据保存为.list 文件, 最后进行近邻搜索识别并获得输出结果, 如表 4-5 所示。

表 4-5 点云识别结果
Tab.4-5 Point cloud recognition results

零件名称	斜孔	光轴	V 型块	螺栓	中间试件	阶梯轴
识别结果	√	√	√	√	√	√

4.3.4 点云定位

对场景点云中的所有零部件进行点云识别操作后, 搭建强化学习仿真环境仍需要获得零部件的位姿信息。本文仍采用点云配准的方法进行零部件定位操作^[54], 主要分为点云初定位和精定位两部分。

点云初定位主要目的是为计算场景点云与模型点云的刚体变换矩阵, 本文通过采用奇异值分解和特征匹配方法来估计点云之间的位姿关系, 从而实现初定位。其中刚体变换矩阵通常可以由 4×4 矩阵组成, 如下式 $\begin{bmatrix} R & t \\ 0 & 1 \end{bmatrix}$, 其中 R 为 3×3 旋转矩阵, t 为 3 维平移向量。求解 t 与 R 设置目标函数为

$$J(\mathbf{R}, \mathbf{T}) = \min \frac{1}{k} \sum_{i=1}^k m_i - (\mathbf{R} \cdot \mathbf{s}_i + \mathbf{T})^2 \quad (4-2)$$

其中, m_i, s_i 分别为模型点云和场景点云的点。对其进行求解可以得到,

$$\begin{cases} T = m_c - R s_c \\ R = A U^T \\ M = U A V^T \\ M = \sum_{i=1}^k m_i' s_i'^T = \sum_{i=1}^k (m_i - m_c)(s_i - s_c)^T \end{cases} \quad (4-3)$$

其中, m_c , s_c 分别为模型点云和场景点云的质心。

由于初定位获取的点云位姿信息存在精度低误差大问题, 需要进行二次点云精定位操作。本文采用 ICP(Iterative Closest Point) 算法进行精定位, 算法的基本思想是在初定位的基础上通过迭代的方式不断优化配准变换, 使得源点云与目标点云尽可能地对齐。通过寻找最优的刚体变换, 实现高精度的点云配准。流程图如图 4-14 所示。




图 4-14 点云定位流程

Fig.4-14 Point cloud positioning process

点云定位具体步骤为:

Step1: 对场景点云与模型点云的欧氏距离, 并选择距离相近的点作为对应点并组成点集。由于构成点集中存在错误点对, 计算点对法向量夹角, 大于阈值的进行剔除。

Step2: 进行点云初定位操作, 通过奇异值分解求解出模型点云与场景点云的刚体变换矩阵。

Step3: 将求解到的刚体变换矩阵用于场景点云更新中, 获得变换后的场景点云。

Step4: 根据式(4-4)计算更新后的场景点云与模型点云对之间的均方误差。

$$\varepsilon = \frac{1}{k} \sum_{i=1}^k \|m_i - s_i\|^2 \quad (4-4)$$

Step5: 判断误差是否小于误差阈值, 大于阈值则重新执行 1-4 步骤, 直至误差小于阈值实现精配准。

根据上述定位方法, 进行模型与场景点云配准, 如图 4-15 为斜孔配准结果。




图 4-15 点云配准结果

Fig.4-15 Point cloud registration results

由表 4-3 可知, 存在相机标定误差、机器人重复定位误差以及相机测距误差, 导致通过点云定位获取的位姿信息无法满足高精度轴孔装配要求。本文通过将机器人拖拽至孔轴中心上方, 通过读取机器人关节信息, 进行机器人运行学正解, 以获得孔轴相对机器人位姿变换矩阵。场景中的其他零部件则通过点云配准方法, 获得零部件相对于相机的位姿变换矩阵, 并与上面手眼标定求得的变换矩阵 T_{cam}^{base} 相乘^[54], 最终获取零部件位于机器人坐标的刚体变换矩阵:

$$\begin{aligned}
 T_{中} &= \begin{bmatrix} 0.976 & -0.228 & 0.021 & -0.21 \\ -0.226 & -0.974 & 0.082 & 0.510 \\ 0 & -0.082 & -0.993 & -0.121 \\ 0 & 0 & 0 & 1 \end{bmatrix} & T_V &= \begin{bmatrix} 1 & 0 & 0.002 & -0.202 \\ -0.002 & 0.012 & 1 & 0.760 \\ 0 & -1 & 0 & -0.145 \\ 0 & 0 & 0 & 1 \end{bmatrix} \\
 T_{螺} &= \begin{bmatrix} 0.997 & -0.004 & 0.075 & 0.199 \\ 0.075 & 0.051 & -0.996 & 0.522 \\ 0 & 0.999 & 0.051 & -0.130 \\ 0 & 0 & 0 & 1 \end{bmatrix} & T_{阶} &= \begin{bmatrix} 0.931 & -0.023 & -0.363 & 0.002 \\ 0.364 & 0.059 & 0.929 & 0.439 \\ 0 & -0.998 & 0.064 & -0.131 \\ 0 & 0 & 0 & 1 \end{bmatrix} \\
 T_{斜} &= \begin{bmatrix} 1.0 & 0 & 0 & 0 \\ 0 & 0.675 & -0.738 & 0.800 \\ 0 & 0.738 & 0.675 & -0.145 \\ 0 & 0 & 0 & 1.0 \end{bmatrix} & T_{光轴} &= \begin{bmatrix} 0.633 & -0.646 & -0.425 & -0.085 \\ -0.297 & 0.303 & -0.905 & 0.681 \\ 0.714 & 0.699 & 0.001 & -0.145 \\ 0 & 0 & 0 & 1 \end{bmatrix}
 \end{aligned}$$

4.4 轴孔装配仿真实验

根据在 3.3.1 节建库流程, 首先进行离线建库, 对装配中所使用到的零件, 通过插件搭建 URDF 文件库, 并进行数据库 STL 文件改进, 将建立完成的库保存到 Ubuntu 系统操作空间下进行编译。然后, 将桌子以及工具箱导入 Gazebo 场景中, 构建离线场景, 如图 4-16 所示, 其中工具箱相对机器人基座标位置为 $[-0.2, 0.95, -0.145]$, 单位为 m, 姿态为 $[0, 0, 0]$, 单位为 rad。




图 4-16 离线仿真场景

Fig.4-16 Offline simulation scenarios

根据上面获取的零部件位姿变换矩阵，将模型导入离线仿真环境中。由于本文训练模型为轴孔装配模型，通过运动学反解计算出机器人抓取轴和到达待装配位置的关节角，然后均分关节角差值并作为关节增量交由机器人执行。当机器人到达待装配位置后，机器人加载第 3 章训练的斜孔装配模型，成功进行仿真装配，装配过程如下图 4-17 所示。




图 4-17 轴孔仿真装配实验过程

Fig.4-17 The shaft hole simulates the assembly experimental process

4.5 机器人轴孔装配实验

将 SAC 算法在仿真环境中输出的关节轨迹输入给机器人，由于装配系统中存在机器

人电机运动误差、点云识别定位误差以及抓取误差，如图 4-18 所示为机器人两次轴抓取的情况，可以看出轴相对于夹爪存在微小的位姿偏移。



图 4-18 机器人抓取误差

Fig.4-18 Robot gripping error

由于误差的存在直接导致机器人在轴孔到达倒角接触状态后，根据孔的导向性，轴孔发生轻微碰撞后，实现机器人轴孔装配，装配过程如图 4-19 所示。




图 4-19 轴孔装配实验过程

Fig.4-19 Experimental process of shaft hole assembly

通过 Sawyer SDK 中提供的机器人末端执行器接口 `endpoint_effort()`，采集机器人末端的受力和力矩数据，并绘制变化曲线，如图 4-20 所示。并采集机器人仿真装配过程中末端受力和力矩情况，如图 4-21 所示。




图 4-20 机器人实际轴孔装配力(左)与力矩(右)曲线图

Fig.4-20 Diagram of the actual shaft hole assembly force (left) and moment (right) curves of the robot




图 4-21 机器人仿真轴孔装配力(左)与力矩(右)曲线图

Fig.4-21 The robot simulates the assembly force (left) and moment (right) curves of the shaft hole

由图 4-20 看出, 在 100 左右步数时, 末端在 y 和 z 方向上的受力发生突变, 因考虑到轴自身重力对末端受力影响, 可以推断机器人成功抓取轴。机器人在 100 到 230 左右步数时, 平稳进行运动, 机器人到达倒角接触阶段。在 230 左右步数时 y 和 z 方向受力发生快速变化后趋于稳定, 推断是由于抓取误差, 轴借助孔导向性调整位姿, 轴快速完成位姿调整, 直至装配结束受力总体趋于平稳。分析力矩曲线可知, 力矩整体趋于平稳, 其中从抓取轴到完成装配期间, x 方向存在一定的力矩, 这是由于在机器人完成斜孔装配过程中, 需要保持一定的倾斜角度完成装配, 导致末端会产生 x 方向的力矩。与图 4-12 曲线对比, 可以看出, 在仿真环境下机器人在完成抓取到装配完成期间, 力和力矩趋于稳定, 验证本文设计的轴孔装配算法在仿真环境中装配力学性能良好。总的可以看出, 在实际机器人装配期间除去轴受短暂的位姿调整外, 整体装配过程力学性能较为良好。后续可深入研究机器人运动误差补偿, 以实现更高效和稳定的装配性能。

4.6 本章小结

本文验证在线搭建仿真环境搭建可行性, 搭建实际轴孔装配场景, 基于 Kinect V2 深度相机采集场景点云并进行预处理, 通过采用场景点云与模型点云匹配配准算法, 实现对场景零部件信息获取; 离线构建零部件模型库, 依据在线搭建仿真环境框架, 完成实际装配场景搭建; 加载斜孔装配算法模型进行仿真装配, 将仿真关节轨迹输入给机器人, 在存在运动、抓取以及识别误差的情况下, 机器人能够借助孔导向性最终完成实际场景的轴孔装配。通过分析仿真与实际装配过程中机器人末端的受力与力矩情况, 验证了在线搭建仿真场景框架的可行性和实用性, 后续可通过采用不同识别定位方法以实现更高效的装配。

5 结论与展望

5.1 结论

本文以实现工业装配过程中高效的人机协作为研究目的, 基于传统的复杂度分配模型, 考虑机器人在线学习和实际装配场景的影响, 研究了在高度协作过程中的动态任务分配问题, 并基于 SAC 强化学习算法设计机器人不同位姿孔轴装配算法环境, 增强了轴孔装配算法的鲁棒性和泛化性。本文的结论如下:

(1) 面向复杂动态装配过程的人机协作任务分配方法研究。通过实例分析, 展示了在人机协作装配过程中, 如何有效地运用所提出的复杂任务动态分配流程来指导机器人实现任务动态分配, 确保了装配流程的高效性和准确性。在动态分配流程中, 通过引入操作者装配意图因素, 并采用预训练模型 GPT 来分解装配任务, 实现了对装配任务的精细化管理和优化。此外, 改进复杂度评价流程, 细化任务评价结果, 对存疑任务需要进行在线仿真装配测试, 有效地提高了任务复杂度评价结果的准确性, 进而为任务的合理分配提供了更为可靠的依据。同时, 通过机器人执行任务的成功率来反映其能力的变化, 并更新任务评价集合。使得模型评价结果可以适应机器人自身能力变化, 提高系统资源利用率。综上所述, 本文为解决复杂的人机协作装配任务动态分配问题提供了一种新的思路和方法。通过对传统任务复杂度评价流程的改良, 引入新的评价因素, 并利用最新的技术手段进行任务分解和顺序确定, 有助于提高任务分配的精确度和效率。

(2) 基于深度强化学习的复杂轴孔装配仿真。建立强化学习环境, 设计轴孔相对位姿以及关节力矩为算法状态空间, 提高了算法针对不同轴孔装配场景的适用性; 分析轴孔装配过程, 设计强化学习算法的奖励函数, 提高了决策模型收敛速度和决策性能。此外, 设计在线仿真环境搭建框架, 能够有效地将真实情景映射到虚拟场景中, 为模型在线训练和测试提供了支持。通过训练垂直装配和斜孔装配模型进行不同孔径、不同孔型以及不同孔位姿的仿真测试, 仿真结果: 针对不同公称直径 20、30 以及 40mm, 不同间隙 0.05、0.08 以及 0.1mm 的仿真测试, 垂直装配和斜孔装配模型装配成功率分别为 97%和 98%, 其中斜孔装配由于训练间隙为 0.08mm, 所以间隙 0.05mm 的测试仿真成功率显著下降; 针对圆孔与方孔测试, 加载垂直装配模型, 能够实现间隙为 0.08mm 及以上的仿真装配。以上测试结果验证了本文设计的算法环境具备良好的鲁棒性和通用性, 也为后续的智能机器人完成高精度的复杂装配任务奠定基础。

(3) 机器人轴孔自主装配实验。搭建 Sawyer 机器人斜孔装配实验场景, 对 Kinect V2 深度相机进行相机标定和手眼标定, 获取相机内参和坐标变换矩阵。离线构建模型点云库, 相机采集场景点云并进行预处理, 通过点云匹配配准算法实现了零部件识别定位。根据在线仿真搭建框架实现了仿真环境构建, 机器人加载斜孔模型并进行仿真装配测试, 将测试输出轨迹输出给机器人执行。由于存在机器人运动误差, 需要借助孔的导向性来实现实验

场景轴孔装配。通过真实场景中轴孔装配实验，实现间隙为 0.1mm，倾角为 30 度的轴孔装配，验证了本文提出的在线仿真场景搭建流程在实际应用中具有一定的可行性，后续仍需要提升机器人在复杂装配任务中能力，如抓取、避障以及识别定位能力，实现机器人高效和高精度装配。

5.2 展望

本文实现对动态任务分配模型框架和轴孔装配算法环境的搭建，但本文在以下方面仍存在完善空间。

（1）任务分配问题并非单一的人机协作研究问题，除却操作者意图输入外，可尝试将人机协作其他研究内容进行融合，包括动态避障、人机交互以及安全设计等。此外，意图输入为假设条件，可深入研究意图预测识别方法，实现任务分配模型更好的应用。

（2）由于考虑机器人求反解的不确定性，本文动作空间选用机器人关节角度增量。在训练过程中模型会实现状态到关节增量的映射，但导致针对不同装配环境需要重新进行训练映射。可将不同场景中孔位姿变化作为输入，进行位姿变化处理，尝试实现单一模型实现不同装配任务，提升模型泛化性。

（3）在实际到虚拟场景映射以及机器人动作执行过程中，存在运动误差和识别误差等，会造成误差累积，后续可对误差补偿进行深入研究实现精确执行。

参考文献

- [1] 《中国制造 2025》重点领域技术创新绿皮书发布会召开[J].智能制造,2018,(Z1):3-4.
- [2] 周济.智能制造是“中国制造 2025”主攻方向[J].企业观察家,2019,(11):54-55.
- [3] 逯东,池毅.《中国制造 2025》与企业转型升级研究[J].产业经济研究,2019,(05):77-88.
- [4] 曲道奎.中国机器人产业发展现状与展望[J].中国科学院院刊,2015,30(03):342-346+429.
- [5] 黄海丰,刘培森,李擎,等.协作机器人智能控制与人机交互研究综述[J].工程科学学报,2022,44(4):780-791.
- [6] 董元发,蒋磊,彭巍,等.融合脑电-肌电信号的人机协作装配意图识别方法[J].中国机械工程,2022,33(17):2071-2078.
- [7] 肖明珠,朱文敏,范秀敏.人机时空共享协作装配技术研究综述[J].航空制造技术,2019,62(18):24-32.
- [8] 凌和靖.人机协作场景下机械臂路径规划方法研究[D].济南:山东大学,2022.
- [9] 南函池.考虑工作胜任度的人机协同任务分配模型与人机协作策略研究[D].杭州:杭州电子科技大学,2020.
- [10] 张凯.基于复杂度算法的人机协作装配任务分配方法研究[D].西安:西安理工大学,2022.
- [11] 朱新宇,李宜桐.基于人工势场算法和 RRT 算法的多无人机路径规划[J].自动化应用,2024,65(05):1-4.
- [12] 蔡方儿,周航,李昀宸,等.多中心无人机集群维修保障任务分配优化研究[J].航空计算技术,2024,54(01):66-70.
- [13] 赵太飞,刘阳,杜浩辰.改进粒子群算法的紫外光协作多无人机任务分配方法[J/OL].激光杂志,1-8[2024-05-07].
- [14] Samy S N, ElMaraghy H. A model for measuring products assembly complexity[J]. International Journal of Computer Integrated Manufacturing, 2010, 23(11): 1015-1027.
- [15] Liu P, Li Z. Task complexity: A review and conceptualization framework[J]. International Journal of Industrial Ergonomics, 2012, 42(6): 553-568.
- [16] 赵洪乐. 基于装配复杂度的数控机床装配可靠性研究[D]. 重庆:重庆大学, 2014.
- [17] Ahmad M, Alkan B, Ahmad B, et al. The use of a complexity model to facilitate in the selection of a fuel cell assembly sequence[J]. Procedia Cirp, 2016, 44: 169-174.
- [18] 周伟明.机械装配系统复杂性及其应用研究[D].长春:吉林大学,2017.
- [19] Lamon E, De Franco A, Peternel L, et al. A capability-aware role allocation approach to industrial assembly tasks[J]. IEEE Robotics and Automation Letters, 2019, 4(4): 3378-3385.
- [20] Marsden P, Kirby M. Allocation of functions[J]. Handbook of human factors and ergonomics methods, 2005: 34-1.

- [21] Ranz F, Hummel V, Sihn W. Capability-based task allocation in human-robot collaboration[J]. *Procedia Manufacturing*, 2017, 9: 182-189.
- [22] 陈志贤.面向复杂环境的服务机器人自主规划方法研究[D].深圳:中国科学院大学(中国科学院深圳先进技术研究院),2019.
- [23] Shao T, Zhang H, Cheng K, et al. The hierarchical task network planning method based on Monte Carlo Tree Search[J]. *Knowledge-Based Systems*, 2021, 225: 107067.
- [24] Hari S K K, Nayak A, Rathinam S. An approximation algorithm for a task allocation, sequencing and scheduling problem involving a human-robot team[J]. *IEEE Robotics and Automation Letters*, 2020, 5(2): 2146-2153.
- [25] 李吉轩.基于动作识别的人机协作任务规划方法研究[D].武汉:武汉理工大学,2022.
- [26] 夏青云.面向协作装配的人-外肢体任务分配与路径规划研究[D].成都:电子科技大学,2023.
- [27] Cramer M, Kellens K, Demeester E. Probabilistic decision model for adaptive task planning in human-robot collaborative assembly based on designer and operator intents[J]. *IEEE Robotics and Automation Letters*, 2021, 6(4): 7325-7332.
- [28] 王艺宸.基于数字孪生的人机协作装配任务分配与运行研究[D].武汉:华中科技大学,2022.
- [29] 熊志华,陈昊,王长生,等.基于深度强化学习的人机协作组装任务分配[J].*计算机集成制造系统*,2023,29(03):789-800.
- [30] Adu-Bredu A, Devraj N, Lin P H, et al. Probabilistic inference in planning for partially observable long horizon problems[C], 2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2021: 3154-3161.
- [31] Garrett C R, Paxton C, Lozano-Pérez T, et al. Online replanning in belief space for partially observable task and motion problems[C], 2020 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2020: 5678-5684.
- [32] Lee M L, Liu W, Behdad S, et al. Robot-assisted disassembly sequence planning with real-time human motion prediction[J]. *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, 2022, 53(1): 438-450.
- [33] Hasan S M, Baqai AA, Butt S U, et al. Product family formation based on complexity for assembly systems[J]. *The International Journal of Advanced Manufacturing Technology*, 2018, 95: 569-585.
- [34] Bruno G, Antonelli D. Dynamic task classification and assignment for the management of human-robot collaborative teams in workcells[J]. *The International Journal of Advanced Manufacturing Technology*, 2018, 98: 2415-2427.
- [35] Mateus J C, Claeys D, Limère V, et al. Base part centered assembly task precedence

- generation[J]. The International Journal of Advanced Manufacturing Technology, 2020, 107: 607-616.
- [36] Parsa S, Saadat M. Human-robot collaboration disassembly planning for end-of-life product disassembly process[J]. Robotics and Computer-Integrated Manufacturing, 2021, 71: 102170.
- [37] Merlo E, Lamon E, Fusaro F, et al. Dynamic human-robot role allocation based on human ergonomics risk prediction and robot actions adaptation[C], 2022 International Conference on Robotics and Automation (ICRA). IEEE, 2022: 2825-2831.
- [38] 梁人升. 人机协作混合装配单元中考虑任务匹配和人因的任务分配策略研究[D]. 杭州: 杭州电子科技大学, 2023.
- [39] 陈婵娟, 赵飞飞, 李承, 等. 多传感器协助机器人精确装配[J]. 机械设计与制造, 2020, (03): 281-284.
- [40] 魏明明, 傅卫平, 蒋家婷, 等. 操作机器人轴孔装配的行为动力学控制策略[J]. 机械工程学报, 2015, 51(05): 14-21.
- [41] Song J, Chen Q, Li Z. A peg-in-hole robot assembly system based on Gauss mixture model[J]. Robotics and Computer-Integrated Manufacturing, 2021, 67: 101996.
- [42] Xu Y, Song A G, Li H J. Research on automatic assembly technology based on machine vision and force feedback[J]. Measurement Control Technology, 2019, 38(4): 11-16.
- [43] Xu J, Hou Z, Wang W, et al. Feedback deep deterministic policy gradient with fuzzy reward for robotic multiple peg-in-hole assembly tasks[J]. IEEE Transactions on Industrial Informatics, 2018, 15(3): 1658-1667.
- [44] Zou P, Zhu Q, Wu J, et al. Learning-based optimization algorithms combining force control strategies for peg-in-hole assembly[C], 2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2020: 7403-7410.
- [45] Khader S A, Yin H, Falco P, et al. Stability-guaranteed reinforcement learning for contact-rich manipulation[J]. IEEE Robotics and Automation Letters, 2020, 6(1): 1-8.
- [46] Hou Z, Fei J, Deng Y, et al. Data-efficient hierarchical reinforcement learning for robotic assembly control applications[J]. IEEE Transactions on Industrial Electronics, 2020, 68(11): 11565-11575.
- [47] 鄢智超, 周勇, 胡楷雄, 等. 考虑可变旋转参数的机器人多轴孔装配强化学习策略[J/OL]. 计算机集成制造系统, 1-18[2024-05-14].
- [48] Zhang X, Sun L, Kuang Z, et al. Learning variable impedance control via inverse reinforcement learning for force-related tasks[J]. IEEE Robotics and Automation Letters, 2021, 6(2): 2225-2232.
- [49] Yu T, Chang Q. User-guided motion planning with reinforcement learning for human-robot

- collaboration in smart manufacturing[J]. Expert Systems with Applications, 2022, 209: 118291.
- [50] Hou Z, Li Z, Hsu C, et al. Fuzzy logic-driven variable time-scale prediction-based reinforcement learning for robotic multiple peg-in-hole assembly[J]. IEEE Transactions on Automation Science and Engineering, 2020, 19(1): 218-229.
- [51] Liu Q, Ji Z, Xu W, et al. Knowledge-guided robot learning on compliance control for robotic assembly task with predictive model[J]. Expert Systems with Applications, 2023, 234: 121037.
- [52]** L, Men Y, Song R, et al. Robot skill generalization: Feature-selected adaptation transfer for peg-in-hole assembly[J]. IEEE Transactions on Industrial Electronics, 2023, 71(3): 2748-2757.
- [53] 苟小虎. 基于 Sawyer 机器人的自主装配方法研究[D]. 西安: 西安理工大学, 2022.
- [54] 闫少凡. 机器人目标识别/定位与自主轴孔装配方法研究[D]. 西安: 西安理工大学, 2023.
- [55] 高天宇. 基于复杂性的人机协作装配任务分配问题研究[D]. 长春: 吉林大学, 2020.
- [56] Zhao W X, Zhou K, Li J, et al. A survey of large language models[J]. arxiv preprint arxiv:2303.18223, 2023.
- [57] Ouyang L, Wu J, Jiang X, et al. Training language models to follow instructions with human feedback[J]. Advances in neural information processing systems, 2022, 35: 27730-27744.
- [58] 徐兵. 基于操作难度指标的可装配性评价方法[D]. 苏州: 苏州大学, 2009.
- [59] Inoue T, De Magistris G, Munawar A, et al. Deep reinforcement learning for high precision assembly tasks[C], 2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2017: 819-825.
- [60] Bellman R E. A markov decision process. journal of Mathematical Mechanics[J]. 1957. 679-71684
- [61] Cole A J, Aris R. Discrete dynamic programming[J]. The Mathematical Gazette, 1965, 49(369): 349.
- [62] Watkins C J C H, Dayan P. Technical note: Q-learning[J]. Machine Learning, 1992, 8(3-4): 279-292.
- [63] Baxter J, Bartlett P L. Infinite-horizon policy-gradient estimation[J]. Journal of Artificial Intelligence Research, 2001, 15: 319-350.
- [64] Mnih V, Kavukcuoglu K, Silver D, et al. Playing Atari with deep reinforcement learning[J]. Computer Science, 2013.
- [65] Peters J, Schaal S. Natural actor-critic[J]. Neurocomputing, 2008, 71(7-9): 1180-1190.
- [66] Lillicrap T P, Hunt J J, Pritzel A, et al. Continuous control with deep reinforcement learning[J]. arXiv preprint arXiv:1509.02971, 2015.

- [67]Fujimoto S, Hoof H, Meger D. Addressing function approximation error in actor-critic methods[C], International conference on machine learning. PMLR, 2018: 1587-1596.
- [68]Haarnoja T, Zhou A, Abbeel P, et al. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor[C], International conference on machine learning. PMLR, 2018: 1861-1870.
- [69]Shannon C E. A mathematical theory of communication[J]. The Bell system technical journal, 1948, 27(3): 379-423.
- [70]Corke P I, Armstrong-Helouvry B. A search for consensus among model parameters reported for the PUMA 560 robot[C], Proceedings of the 1994 IEEE International Conference on Robotics and Automation. IEEE, 1994: 1608-1613.
- [71]马金琦, 郭冰菁, 韩建海等. 冗余自由度协作机器人运动规划研究[J]. 计算机仿真, 2021, 38(3): 309-315.
- [72]Brown D C. Decentering distortion of lenses[J]. Photometric Engineering, 1996, 32(3): 444-462.
- [73]Zhang Z Y. A flexible new technique for camera calibration[R]. [S.l.]: Microsoft Research, 1998.Peters J, Schaal S. Natural actor-critic[J]. Neurocomputing, 2008, 71(7-9): 1180-1190.
- [74]郅娜. 基于 ETH 与 EIH 视觉系统的装配机器人目标定位研究[D]. 西安: 西安理工大学, 2015.
- [75]李朋超, 王金涛, 宋吉来. 基于 PCL 的 3D 点云视觉数据预处理[J]. 计算机应用, 2019, 39(z2): 227-230.
- [76]Muja M, Lowe D G. Fast approximate nearest neighbors with automatic algorithm configuration[C], International Conference on Computer Vision Theory and Applications. 2009: 331-340