

博士学位论文

复杂装备拆卸工艺知识图谱自动构建及实 体链接方法研究

RESEARCH ON METHOD FOR AUTOMATIC CONSTRUCTION AND ENTITY LINKING FOR KNOWLEDGE GRAPH OF COMPLEX EQUIPMENT DISASSEMBLY PROCESS

刘杰

哈尔滨工业大学
2023 年 6 月

国内图书分类号: TP399

国际图书分类号: 004

学校代码: 10213

密级: 公开

工学博士学位论文

复杂装备拆卸工艺知识图谱自动构建及实 体链接方法研究

博士研究生: 刘 杰

导 师: 林 琳教授

申 请 学 位: 工学博士

学 科: 机械工程

所 在 单 位: 机电工程学院

答 辩 日 期: 2023 年 6 月

授予学位单位: 哈尔滨工业大学

Classified Index: TP399

U.D.C: 004

Dissertation for the Doctoral Degree in Engineering

**RESEARCH ON METHOD FOR AUTOMATIC
CONSTRUCTION AND ENTITY LINKING FOR
KNOWLEDGE GRAPH OF COMPLEX
EQUIPMENT DISASSEMBLY PROCESS**

Candidate:	Liu Jie
Supervisor:	Prof. Lin Lin
Academic Degree Applied for:	Doctor of Engineering
Speciality:	Mechanical Engineering
Affiliation:	School of Mechatronics Engineering
Date of Defence:	June, 2023
Degree-Conferring-Institution:	Harbin Institute of Technology

摘 要

目前,我国复杂装备制造业正在加速实现服务型转型,装备质量和复杂度不断提高,装备维修次数、复杂度和成本显著增加,这些因素导致全生命周期内的运维服务质量成为企业竞争力的关键因素。在维修中,拆卸作业是装备维修的第一道工序,具有极其重要的地位。一般地,拆卸工艺是按照装配的逆序进行。但是与装配过程不同,拆卸中零部件劣化状态千差万别,事先难以预料,每一步拆卸可能面临新的问题。更为重要的是,拆卸工艺实施不当不仅影响装备拆卸效率,而且可能加剧零件损伤甚至造成安全事故。但是,当前拆卸工艺构建严重依赖于专家技术和专家经验、易受到个人主观影响,难以实现工艺知识统一规范化组织和表达,并且当前工艺知识多以文本形式存储,难以支持模糊语义检索,工艺知识利用率低下。因此,亟需装备拆卸工艺知识库构建和知识检索技术支撑工艺人员快速地构建拆卸工艺方案并指导装备拆卸过程。当前,知识图谱以结构化的知识表示方式、强大的可视化和语义表达能力,被广泛应用于各个领域的知识工程中。考虑到工艺路径与知识图谱表达形式相似,即工艺路径中的节点可视为知识图谱的实体,节点之间关系可视为实体的关系,论文将利用知识图谱强大的处理能力探索拆卸中突发状况的解决方案。具体地,论文的主要工作组织如下:

为能够有效提取工艺实体和工艺关系语义特征,论文建立了工艺实体和关系双投影超平面模型,将实体和关系的语义表示分别投影在关系超平面和关系投影超平面,使得模型能够同时提取实体和关系的相似信息和差异信息,利用模型学习得到的语义向量有效表示工艺实体的语义信息。利用 JH70 发动机拆卸工艺碎片化知识图谱和公共数据验证了语义向量学习的准确性和有效性。

为实现拆卸工艺知识图谱的实体信息补全,论文研究自动化的补全方法。文中以实体类别补充为例,研究了信息的自动化补全方法。装备零部件通常按照由外到内和先后顺序拆卸,零件的类别体系呈现层次结构特征和序列特征。为了准确获得实体的类别,论文建立了样本自适应长短时记忆网络(LSTM)神经树模型,该模型将决策树和 LSTM 融合在一起,能同时提取实体的层次结构特征和序列特征,提高了实体的类别预测精度和鲁棒性。论文利用 JH70 发动机拆卸工艺知识图谱验证了工艺实体的类别预测精度。

为实现碎片化知识图谱相似度量与融合,论文建立了强化极大连通同归结构相似度模型来有效度量碎片化知识图谱的整体相似度,提出了基于实体和图结构的拆卸工艺知识图谱融合方法,保证信息不丢失的情况下有效融合相似知

识图谱。通过理论证明了所建立的相似度模型在碎片化知识图谱融合中不会出现漏融问题，确保融合后的模型满足工程实际需求；最后，通过 JH70 发动机拆卸工艺碎片化知识图谱融合建模实验验证了方法的有效性。

为支持面向拆卸工艺知识图谱的模糊检索和语义检索，论文提出了一种基于强相关序列的细粒度集体实体链接方法，将一段检索文本中所有的关键词视为一个整体，建立了整体相关度模型和整体语义相似度模型，充分体现工艺知识的强逻辑关联，从而在语义层面完成工艺知识准确检索。利用 JH70 发动机拆卸工艺知识图谱和若干公共数据进行实体链接实验，证明了所提方法可以提高语义检索精度。

关键词：复杂装备；拆卸工艺知识图谱；语义向量化；实体类别预测；集体实体链接

Abstract

The manufacturing industry for complex equipment in China is presently experiencing a rapid shift towards service-oriented transformation. With continuous enhancements in equipment quality and complexity, maintenance frequency, complexity, and costs have significantly increased. As a result, ensuring the quality of operation and maintenance services throughout the entire lifecycle has become a crucial factor for enterprise competitiveness. During equipment maintenance, the disassembly process holds a critical position as the primary operation. The disassembly process typically follows the reverse order of the assembly process. However, unlike the assembly process, the deterioration state of components during disassembly varies greatly and is difficult to anticipate beforehand. Each step of the disassembly process may present new challenges. More importantly, improper disassembly process not only reduces the efficiency of equipment disassembly but also increases the possibility of component damage or safety accidents. However, the current construction of disassembly processes relies heavily on expert technology and experience, and is easily influenced by personal subjectivity, which hinders the ability to organize and express process knowledge in a unified and standardized manner. Currently, process knowledge is predominantly stored in textual form, which poses a significant challenge in supporting fuzzy and semantic retrieval, ultimately resulting in low utilization of process knowledge. Therefore, there is an urgent need for the construction of a knowledge repository for equipment disassembly processes and knowledge retrieval technology to support process personnel in quickly constructing disassembly process plans and guiding the equipment disassembly process. Currently, knowledge graph (KG) is widely used in knowledge engineering in various fields due to their structured knowledge representation, powerful visualization, and semantic expression capabilities. Considering that the process path is similar to the KG representation form, where the nodes in the process path can be regarded as entities in the KG, and the relations between the nodes can be regarded as relations between entities. Therefore, this paper aims to explore solutions to unexpected situations in the disassembly process by utilizing the powerful processing capabilities of KG. The main contributions of this paper are organized as follows.

To effectively extract semantic features of process entities and relations, the paper proposes a process entity and relation translating on hyperplanes model (ERTransH). ERTransH projects the semantic representation of entities and relations onto the relation hyperplane and the relation projection hyperplane, respectively. Then ERTransH can extract both similarity and dissimilarity information of entities

and relations, and learn the semantic vectors that can effectively represent the semantic information of entities. The accuracy and effectiveness of semantic vector learning are validated by using the FKG of JH70 engine disassembly process and public data.

To complete entity information in the KG of disassembly process, there is an urgent need to research automated completion methods. In this study, the automatic completion method for information is researched, using entity categorization supplementation as an example. Equipment components are usually disassembled in order from the outside to the inside and in a specific sequence, making the component have hierarchy and series features. To accurately predict entity category, this paper proposes a sample adaptive long short-term memory neural tree model (SALNT). The SALNT combines decision tree and LSTM to extract both hierarchy and series features of entities, thereby improving the accuracy and robustness of entity category prediction. The accuracy of the SALNT is verified by using the FKGs of JH70 engine disassembly process.

To achieve similarity measurement and fusion of, this paper proposes a reinforcement local maximum connection same destination structure similarity model (RLMCSDS) to effectively measure the overall similarity of FKGs. Furthermore, a fusion method based on entity and graph structure is proposed to fuse similar FKGs without losing information. The proposed RLMCSDS is theoretically proven to avoid missing fusion in the fusion of FKGs, ensuring that the fused model meets practical engineering requirements. Finally, the effectiveness of the proposed RLMCSDS and fusion method are verified using the fusion modeling of FKGs of JH70 engine disassembly process.

To support fuzzy and semantic retrieval for disassembly process KG, a strong-relatedness-sequence-based fine-grained collective entity linking method (SRSCLE) is proposed in this paper. The SRSCLE treats all keywords in a retrieval text as a whole, establishes a overall relatedness measurement model, and a overall semantic similarity model, thereby fully reflecting the strong logical connection of process knowledge and accomplishing accurate retrieval at the semantic level. The entity linking experiment is conducted using the KG of JH70 engine disassembly process and several public data sources, demonstrating that the proposed SRSCLE can improve the accuracy of semantic retrieval.

Keywords: Complex Equipment, Disassembly Process Knowledge Graph, Semantic Vectorization, Entity Category Prediction, Collective Entity Linking

目 录

第 1 章 绪论.....	1
1.1 课题背景及研究的目的和意义	1
1.2 国内外研究发展现状.....	5
1.2.1 复杂装备制造和运维领域知识图谱应用现状	6
1.2.2 知识语义向量化表达方法研究现状.....	8
1.2.3 知识图谱的实体类别预测技术研究现状	10
1.2.4 实体和图结构相似度量研究现状.....	12
1.2.5 知识图谱实体链接技术研究现状.....	14
1.3 相关文献解析.....	17
1.4 本文的主要研究内容.....	18
第 2 章 复杂装备拆卸工艺知识语义向量化表达方法	22
2.1 引言.....	22
2.2 基于翻译模型的语义向量化表达方法对比分析	23
2.2.1 Trans E 模型	24
2.2.2 Trans H 模型	27
2.2.3 Trans R 模型	28
2.2.4 Trans D 模型	30
2.2.5 现有翻译模型不适应性分析.....	31
2.3 基于 ERTrans H 的语义向量化表达方法.....	32
2.3.1 ERTrans H 模型构建	33
2.3.2 ERTrans H 模型训练方法	36
2.4 面向复杂装备拆卸工艺知识图谱的 ERTrans H 模型案例分析	39
2.4.1 实验数据	40
2.4.2 模型评估	40
2.4.3 实验设置	43
2.4.4 对比实验	44
2.5 本章小结.....	49
第 3 章 复杂装备拆卸工艺知识图谱的实体类别预测方法	50
3.1 引言.....	50
3.2 复杂装备拆卸工艺实体特征及学习模型分析	51
3.2.1 复杂装备拆卸工艺实体特征分析.....	51
3.2.2 决策树类别预测模型分析.....	52
3.2.3 长短时记忆网络类别预测模型分析.....	53
3.3 样本自适应 LSTM 神经树实体类别预测建模.....	55

3.4 复杂装备拆卸工艺实体类别预测案例分析	60
3.4.1 实验数据分析	60
3.4.2 实验设置	63
3.4.3 发动机拆卸工艺实体类别预测对比实验	65
3.5 本章小结	72
第 4 章 装备拆卸工艺碎片化知识图谱相似度量与融合建模方法	73
4.1 引言	73
4.2 复杂装备拆卸工艺碎片化知识图谱类别分析	74
4.3 基于极大连通同归结构的相似度量建模与知识图谱融合方法	75
4.3.1 基于 LMCSDS 的相似度建模	75
4.3.2 拆卸工艺碎片化知识图谱融合方法	82
4.3.3 基于 LMCSDS 相似度模型的适用性分析	85
4.4 面向知识图谱迭代融合的强化 LMCSDS 相似度建模	88
4.4.1 RLMCSDS 相似度建模	88
4.4.2 RLMCSDS 相似度模型有效性理论证明	89
4.5 复杂装备拆卸工艺知识图谱自动构建案例分析	97
4.5.1 实验数据	98
4.5.2 发动机拆卸工艺知识图谱融合建模案例	99
4.5.3 两种相似度模型在结构相似度量的优势分析	102
4.5.4 基于 RLMCSDS 模型的知识图谱融合建模实例	106
4.6 本章小结	108
第 5 章 面向复杂装备拆卸工艺知识图谱的细粒度集体实体链接方法	110
5.1 引言	110
5.2 现有实体链接方法及其工程不适应性分析	111
5.2.1 基本概念定义	111
5.2.2 实体流行度模型	113
5.2.3 基于概率的实体链接方法	114
5.2.4 集体实体链接方法对领域内实体链接的工程不适应性分析	116
5.3 复杂装备拆卸工艺候选实体生成及两步法剪枝策略	117
5.4 基于强相关序列的细粒度集体实体链接方法	118
5.4.1 面向拆卸工艺知识图谱的集体实体链接目标函数构建	118
5.4.2 基于强相关序列的候选实体组整体相关性度量模型	119
5.4.3 基于三种 2-hop 路径的实体相关性度量模型	121
5.4.4 基于实体提及组和候选实体组的整体语义相似度模型	123
5.4.5 细粒度集体实体链接方法	126
5.5 复杂装备拆卸工艺知识图谱实体链接案例分析	126

5.5.1 实验数据分析.....	127
5.5.2 模型评估.....	129
5.5.3 实验设置.....	130
5.5.4 对比实验.....	134
5.6 本章小结.....	142
结论.....	143
参考文献.....	146
附录.....	157

第1章 绪论

1.1 课题背景及研究的目的和意义

本课题来源于国家自然科学基金面上项目——“基于超可加测度的融合设计建模机器不确定推理方法研究”(51775132)和国家重点研发计划——“复杂产品全生命周期模型协同方法及数据管理技术”(2018YFB1700902)。

“十二五”期间,我国装备制造产业蓬勃发展,取得了一系列重大成果,装备制造业逐步向服务型制造业转化,装备全寿命周期内的运维服务质量越来越成为提高企业竞争力的决定因素。由于复杂装备长期处于复杂多变甚至恶劣的运行环境,加剧了零件的劣化,导致复杂装备在其全生命周期中维修次数、维修复杂度和维修成本显著增加。以航空业为例,根据《航空周刊》的数据,在役商用飞机数量预计从2019年的33312架增长到2028年的42679架,并产生累计8620亿美元的维修需求,仅CFM56型发动机平均每年将有超过2000台进行返厂大修。CFM国际公司的赛峰公司预计,Leap发动机的年返厂维修数量将从2025年的近500次开始迅速增长到2030年的近2000次,整个CFM发动机机队的年返厂维修量将达到4000次。因此,复杂装备的科学维护成为当下和未来的重大需求。

复杂装备是指其系统结构、功能需求、技术难度、制造工艺、维修难度、管理复杂度等方面均达到一定程度的装备产品,在制造、运营、维护和管理等各个阶段都具有较高的技术含量、知识密度、系统性和集成度。由于其跨学科、跨领域的特性,通常需要进行综合研究和综合技术应用。复杂装备的研制周期长、研制成本高、技术难度大、运营维护成本高,但同时也具有高的经济效益和社会效益。与普通装备相比,复杂装备的维修和拆卸更加复杂、更依赖于专业知识和技能,需要更为严格要求的拆卸工艺及更高的拆卸安全系数等。具体而言,(1)复杂装备的系统集成度高,通常由多个系统和子系统组成,这些系统和子系统之间相互依存、相互作用,紧密集成。因此,在维修和拆卸时,更需要了解系统之间的相互关系,以避免出现意外的拆卸损坏;(2)复杂装备应用了各种先进技术,如先进材料、复杂结构、高性能传感器和控制系统等。这些技术要求维修人员具有更高的技能水平和专业知识,以确保正确地维修和拆卸;(3)由于复杂装备的复杂性,维修和拆卸难度较大,需要选择更多的专业工具和设备,需要更多决策知识和更高决策效率。(4)复杂装备所用零部件更为精密,拆卸不当产生的拆卸成本和后果更为严重,甚至威胁到生命安全。综

上所述,相比于普通装备,复杂装备维修和拆卸需更加准确的拆卸工艺指导拆卸过程,因此面向复杂装备拆卸工艺决策的智能化支持工具是迫切需要的。

一般地,复杂装备拆卸过程按照装配工艺的逆序进行。例如,在拆卸航空发动机燃油泵时,必须使用专门的排放管或者将燃油泵的进口和出口连接管路松开,确保燃油系统中的燃油排空;随后,严格按照装配工艺的逆序由机务人员完成燃油泵拆卸工作。然而,与装配不同的是,复杂装备拆卸过程并非是一个成熟的过程,实际面临的拆卸状态更为复杂,拆卸工艺也不是一个固定的拆卸工艺方案。拆卸中,拆卸工人仅能观测到外表的零部件状态,无法事先预料内部的拆卸环境和零部件状态。例如,内部零部件磨损程度、各零部件之间由于劣化或失效导致的更为复杂的约束关系等。因此,拆卸过程中充满不可控因素和未知因素。例如,发动机上面的螺母托盘断裂时,机务人员难以按照装配工艺的逆序将螺母托盘拆卸下来。此时,机务人员将工作交给“金工”,由“金工”重新设计螺母托盘的拆卸工艺。此外,在涡轮叶片斜面上安装的螺钉受到腐蚀难以有效拆除时,需要设计特殊拆卸工艺,防止损坏涡轮叶片。为了应对可能出现的突发情况,技术人员应随时准备调整拆卸工艺方案。

此外,复杂装备拆卸严重依赖于专家的技术和拆卸经验。如若拆卸不当,不仅会延长拆卸周期、增加拆卸成本,还可能造成零部件的二次损伤甚至引发安全事故。例如,2020年10月23日黑龙江伊春市南岔热电厂4名检修人员在拆解阀门门盖时由于拆卸不当,致1人死亡,3人重伤。值得注意的是,拆卸是一项复杂且繁琐的工作,涉及诸多细节问题,需统筹拆卸环境、拆卸工具等因素。例如:(1)在燃油泵拆卸过程中,需使用电梯、夹具等特殊工具,如若由于拆卸工人操作不当或者失误,拆卸中产生的金属屑可能污染燃油泵和发动机,造成燃油泵和发动机故障;(2)燃油泵拆卸方向尤为重要,拆卸不当可能会损伤燃油泵的螺纹,导致燃油泵报废;(3)拆卸不当也会引发接近困难问题,降低拆卸效率和拆卸的可操作性。比如:航空发动机通常被安装在狭小的机舱中,拆卸工艺选择不合理可能造成燃油泵周围空间狭小,产生接近困难问题,不利于燃油泵的拆除。

综上所述,由于拆卸工艺具有的较高不确定性和经验依赖性,亟需具有充足知识和经验作为支撑的决策工具,保证拆卸过程正确、安全地进行。一个用于指导工艺人员科学专业的拆卸装备和支撑工艺人员快速地构建拆卸工艺方案的工艺知识库是复杂装备拆卸的实际需求。

由于拆卸中遇到问题的不可预见性,工艺知识库实际应用中,所输入的工艺知识查询条件可能是多样的。实际工艺知识检索中,同一个装备系统下,可能存在相关工艺也可能不存在相关工艺。为了找到可借鉴的拆卸工艺,工艺知

识检索应是面向泛化的知识检索并且支持多模式输入。具体地, (1) 由于拆卸工艺知识没有统一规范化表达, 并且每个工艺人员先验知识和对问题理解程度不同, 可能输入的是与检索目标表达不一样但语义含义相同的检索文本; (2) 支持模糊检索, 由于对零部件的名称、损伤情况、装配关系、属性等信息理解不充分和疏忽, 实际的输入可能出现错别字、名称字符不全、损伤情况不明确、装配关系模糊等情况。因此, 迫切需要一个能够基于历史知识支持模糊检索和语义检索而非文本形式检索的知识库和检索方法。

传统的关系型数据库难以支撑语义化表达, 而知识图谱以强大的知识表示能力、知识推理能力和支持语义检索而著称。复杂装备拆卸工艺知识图谱能够把工艺中诸多要素和它们之间的复杂关系清晰呈现出来, 从而帮助技术工程师统筹诸多拆卸工艺要素和更好地理解拆卸步骤以确保复杂装备的拆卸正确、安全和高效, 避免因疏忽或缺乏经验而产生诸如零件丢失、零件失效、拆卸工具选择错误、污染物泄露等问题。同时, 复杂装备拆卸工艺知识图谱能够支持工艺人员处理拆卸中的突发情况, 为难以按照装配工艺逆序拆卸的零件或装备快速地构建新的装备拆卸工艺, 促进装备拆装技术的发展, 推动装备运维的可操作性和可靠性, 有效地提高装备运行安全性和可靠性。

本文重点研究利用现有工艺路径来实现复杂装备拆卸工艺知识图谱自动构建和基于语义检索技术。当前复杂装备拆卸工艺知识存储形式可分为两种: 一种是结构化的工艺路径; 另一种是非结构化的文本。值得注意的是, 工艺路径有着有向图的结构形式, 在组织形式上与知识图谱相似。工艺路径中每个节点可以被视为知识图谱中的一个实体, 节点与节点之间的关系被视为知识图谱中实体之间的关系。考虑到一个工艺路径对应某个零部件的拆卸工艺, 因此, 一个工艺路径可以视为装备拆卸的一个碎片知识图谱, 如图 1-1 所示。拆卸工艺碎片知识图谱是由专家构建而来, 可靠性和可用性得到一定的保障。因此, 整合这些拆卸工艺碎片化知识图谱是实现复杂装备拆卸工艺知识图谱构建的重要手段。

综上所述, 建立复杂装备拆卸工艺知识图谱和研究基于语义的检索方法是有效提高装备拆卸效率、缩短拆卸周期、保证装备拆卸正确性和安全性的关键技术手段。然而, 在复杂装备拆卸工艺知识图谱的构建及应用方面存在以下挑战:

(1) 碎片化知识图谱间工艺实体的表达不统一, 难以有效组织和再利用。如前所述, 各个维修企业中已存在大量与知识图谱结构相似的拆卸工艺知识。然而, 不同维修企业以及同一个维修企业内构建的拆卸工艺知识缺乏统一的表达标准, 导致这些拆卸工艺知识难以形成大规模系统化的知识模型。当前复杂

装备拆卸工艺知识内容繁多，复杂异构且知识层次多，各个复杂装备拆卸工艺要素之间耦合性强，导致碎片化知识图谱中的工艺实体具有复杂多样化特征，工艺关系具有多样化特征。如何充分提取工艺实体和工艺关系之间的语义信息是实现工艺知识语义检索的难点问题。




图1-1 复杂装备拆卸工艺碎片化知识图谱示例

Fig. 1-1 An example of fragmentation knowledge graph of complex equipment disassembly process

(2) 现有拆卸工艺知识图谱信息不完备，导致当前碎片化知识难以支持实际应用。碎片化工艺知识建模中缺乏统一建模框架，各建模人员构建的拆卸工艺碎片化知识图谱严重依赖于个人经验和建模习惯，导致拆卸工艺碎片化知识图谱的侧重点各不相同。例如：有些维修企业在构建拆卸工艺知识图谱时，明确规定添加零部件的类别信息；而有些维修企业并未强制添加零部件的类别信息。此外，由于工艺人员的疏忽，同样可能遗漏一些信息。多种原因导致当前的碎片化知识图谱信息完整度有待提升，尤其是实体类别信息的缺失致使当

前的碎片化知识图谱难以支持实际工艺知识图谱构建和工艺知识检索。

(3) 缺少基于碎片知识图谱的融合方法, 难以实现复杂装备拆卸工艺知识图谱的自动构建。复杂装备拆卸工艺知识图谱涉及的工艺实体和工艺关系数量庞大。人工构建拆卸工艺知识图谱需要大量的拆卸工艺领域专家, 并且需耗费大量的时间成本。此外, 人工构建知识图谱受到个人主观意见的影响, 创建拆卸工艺知识图谱存在可能出错的风险。随着知识图谱规模的增加, 知识图谱的错误检查和知识图谱迭代更新变得异常困难。因此, 复杂装备拆卸工艺知识图谱构建应是自动构建。考虑到拆卸工艺碎片化知识图谱是专家构建而来, 在可靠性和可用性能得到保障。因此, 整合拆卸工艺碎片化知识图谱是自动构建高可用性、高可靠性的复杂装备拆卸工艺知识图谱的重要途径。然而, 当前缺乏可以准确度量拆卸工艺碎片化知识图谱相似度量方法和相似知识图谱的融合方法, 以致无法利用拆卸工艺碎片化知识图谱来自动构建复杂装备拆卸工艺知识图谱。

(4) 当前缺乏面向特定领域的模糊和语义检索方法, 检索精度受限。工艺知识检索没有统一的表达形式, 严重依赖于工艺人员的先验知识和检索习惯。实际检索时, 每个工艺人员根据自己对问题的理解以及脑海中的知识进行工艺知识检索。当对同一个装备或者零部件的工艺检索时, 由于每个工艺人员对问题的理解程度随时随地发生变化、个人的先验知识水平不同等, 所输入的检索文本具有不同的表达形式。此外, 工艺人员若对同一个装备或者零部件的工艺检索, 不同工艺人员所输入的检索文本只能在语义上保持相似。因此, 工艺知识检索是面向语义相似度的模糊检索。当前的知识检索方法通常采用搜索引擎等第三方库中的知识作为所输入知识的补充信息, 考虑到工艺知识难以在第三方库中查询到相关知识, 这些方法表现极大不适应。如何构建面向复杂装备拆卸工艺知识图谱的语义检索方法是当前难点问题。

为了研发出适合复杂装备拆卸工艺领域的知识图谱自动构建和应用相关方法和理论, 本文对上述问题的相关领域研究成果进行了广泛的检索、研究和分析, 获得了目前阶段的技术方法现状, 为复杂装备拆卸工艺知识图谱自动构建及应用技术研究提供了较好的参考价值。

1.2 国内外研究发展现状

随着知识图谱及自然语言处理技术的深入研究, 知识图谱和领域知识图谱自动构建方法及知识图谱应用技术已经取得了一系列研究成果。本研究深入分析了复杂装备制造和运维领域知识图谱、知识语义向量化表达方法、实体类别预测技术、实体和图结构相似度量方法以及实体链接技术的国内外研究现状。

同时，也对相关问题和适用性进行了分析。通过这些分析，获得了复杂装备拆卸工艺知识图谱自动构建和应用的相关知识，为本论文的开展提供了技术支持。

1.2.1 复杂装备制造和运维领域知识图谱应用现状

知识图谱以简单的三元组表达方式，高效的逻辑推理能力，强大的可解释性，有效的高资源发现，透明共享及可视化等优势，受到各个领域的追捧。目前，知识图谱已经在各个领域得到了广泛应用，例如：金融、电商、司法辅助、教育、医疗等。知识图谱也被众多国内外知名企业所使用，例如：谷歌、微软、IBM、百度等。

局限于知识来源的难易度、丰富度以及规模程度，当前关于知识图谱的构建及应用大都集中在自然科学层面。在极具针对性的专业领域，通用知识图谱的不足之处就显现了出来。例如：通用知识图谱可能不具备针对某一特定领域的特定功能，比如支持某一特定的应用程序框架、支持特定的算法实现或者支持特定的业务逻辑等，因此，它们无法满足某一特定领域专业的需求。当前，将知识图谱与领域知识相结合建立领域知识图谱成为新的发展趋势，从而有效实现相关领域大规模知识梳理、知识存储、知识推理、数字化检索等。当前复杂装备制造和运维领域中的数据以及知识的存储形式大多以传统关系型数据库为基础，冗余性较高、分布分散、关联性较弱且储量相对较小^[1]。因此，为了从冗余的数据与知识文本中抽取有用信息，有效表达数据之间的内在关联与知识之间的内在关联来实现高效的信息检索与信息推理，提高复杂装备领域知识的重用性，知识图谱已经逐渐被应用于复杂装备制造和运维的各个阶段。

总体来看，复杂装备制造和运维领域知识图谱的构建与使用尚处于初步发展的阶段，尤其是在复杂装备拆卸工艺领域中。具体地，复杂装备制造和运维领域知识图谱构建技术发展速度慢、扩展性差，虽有研究成果但推广性差、欠缺影响力。主要原因在于领域知识学习欠缺，领域知识图谱自动构建方法不足；数据虽然丰富，但由于缺乏统一管理导致数据采集、汇总困难，无法形成对知识图谱的迭代更新与丰富；受限于专业人员的本身素质，导致知识图谱的工程化程度低。目前的研究成果主要集中在设备维护数据的相互关联^[2,3]，复杂材料查询^[4,5]，装备故障知识问答^[6,7]，装备故障诊断^[8,9]等方面。

在复杂装备制造和运维方面，德国的研究目前处于先进水平。德国西门子建立了设备维护知识图谱，将企业的生产设备、生产资料、人员、生产流程等不同方面的数据关联起来，为用户提供更直接有效的数字化解决方案^[10]；德国博世公司为了支持工程师开发和引进新材料用于生产，构建了底盘系统控制相关数据的大型知识图谱，以满足工程师对于复杂材料属性的查询要求^[11]。

随着知识图谱的推广,我国研究学者在复杂装备制造和运维领域知识图谱取得了一系列成果。在复杂装备制造领域中,Zhao 等利用开放平台构建了工业知识图谱,提出了一个分层匹配策略以支持装备制造服务的语义匹配,这些匹配主要包括特征相似度匹配、数值匹配以及功能匹配^[12]。针对目前装备制造领域知识图谱构建方式存在的问题,袁芳怡建立面向装备制造领域的知识图谱构建与表示模型,研究了命名实体抽取、知识图谱补全等技术,并对制造业知识图谱的构建方式进行改进,为制造业图谱构建提供了借鉴^[13]。He 等基于本体技术构建了制造知识图谱,以获取、集成多层制造知识;并建立了面向图的元知识模型以表示知识实体之间语义信息,运用基于语义的知识计算方法计算两个知识实体之间的固有术语相似度和关系术语相似度^[14]。在复杂装备运维领域中,张栋豪等通过大量的工程机械故障数据构建了机械故障知识图谱,并开发了数控车床分析系统,高效准确地帮助专家针对数控车床故障分析,有效获取数控车床的故障模式、故障原因^[1]。Feng 等建立了面向故障运维知识图谱的电力信息采集系统故障诊断知识问答系统,实现节点和路径的高效遍历搜索,有效提高知识推理效率,实现了维修故障诊断的高效化、智能化^[6]。Lu 等建立了故障知识图谱的定义,研究了基于多个数据源的工程机械和设备故障领域知识获取和知识融合技术,提出了一种数据驱动的知识图谱迭代自动构建方法,并探讨了基于模板的故障知识问答和基于知识图谱推理的故障排除等数字化应用^[15]。

随着知识图谱不断融合到装备各个阶段的关键问题攻关中,国内外部分研究学者也将知识图谱引进制造和维修工艺领域中。李秀玲等人提出了异构 CAM 模型的结构化建模方法,构建了工艺知识图谱,该图谱包括模式层和数据层,解决复杂、多样的工艺知识难以统一表示所导致的工艺知识重用和共享问题,利用规则推理技术可以获取图谱数据层中的隐藏信息^[16,17]。凡天娣等研究基于知识图谱的焊接工艺知识建模技术,针对目前知识管理中存在的知识检索效率低的问题,提出了语义检索、规则推理检索和案例匹配检索的检索方式,以实现焊接工艺知识的建模及重用,提高船舶焊接工艺设计和知识重用效率^[18]。段阳等人建立了金属切削加工知识图谱,实现切削加工数据全面融合,提升数据的价值密度并开发了知识图谱的可视化系统,在国内某航空发动机维修公司获得初步应用^[19]。顾星海等人基于知识图谱提出一种面向装配语义信息的建模方法,结合传统的数据映射与人工数字化中的自然语言处理技术,实现了 CAD 模型的几何信息与装配工艺文档中工艺过程信息的数字化集成^[20]。

分析文献得知,由于知识图谱有效的知识组织形式和强大的语义推理能力,知识图谱已经逐渐被应用于复杂装备制造和运维的各个阶段。然而,鲜少有人

将知识图谱应用于复杂装备拆卸工艺领域中。同时,上述领域知识图谱的构建是以文本形式而非结构化的数据作为支撑,还未见有人研究利用结构化的碎片化知识图谱来自动构建领域完备知识图谱的研究。在复杂装备拆卸工艺领域中,已经存在一些复杂装备拆卸工艺碎片化知识图谱。目前,这些碎片化的知识图谱并没有得到有效利用,不但造成了资源浪费还占据大量存储空间。因此,有必要研究基于拆卸工艺碎片化知识图谱来实现复杂装备拆卸工艺知识图谱自动构建的方法。

1.2.2 知识语义向量化表达方法研究现状

知识表示学习旨在通过模型来学习知识图谱中实体和关系的结构信息,将实体和关系的自然语言表达转化为低维稠密的语义向量,完成文本知识的数字化表达,因而,也可以称之为知识语义向量化表达方法。知识的语义向量化表达对于度量语义信息相同而表达形式不同的拆卸工艺实体的相似度具有重要意义,能有效支持相似工艺知识的融合并提升拆卸工艺领域中知识的统一表达。在知识图谱应用过程中,通过将文本形式的数据转化为语义向量化表达就可以使用基于向量的距离度量方法来有效地量化实体与实体之间、实体与关系之间、关系与关系之间的语义相似程度。当前,知识表示学习已经被广泛应用于知识图谱补全^[21-23],语义检索^[24,25],社区发现^[26,27],智能推送系统^[28,29]等。

在知识表示学习发展初期阶段,经典的知识表示学习模型主要包括距离模型^[30],单层神经网络模型和张量神经网络模型^[31],语义能量匹配^[32,33],双线性模型^[34-36],矩阵分解模型^[37,38]。距离模型是初期较为经典的知识表示模型之一,距离模型通过为每个关系建立两个关系矩阵,并将头实体和尾实体分别在两个矩阵下进行投影,其目标是最小化头实体投影和尾实体投影之间的距离^[30]。单层神经网络模型通过在距离模型中引入单层神经网络来增加距离模型的非线性性,从而进一步提取实体和关系的语义联系^[31]。张量神经网络结合单层神经网络和双线性模型,从而能够更好地捕获实体和关系之间的语义信息^[31]。语义能量匹配模型通过引入更多的投影矩阵来获得具有丰富语义信息的实体和关系的低维稠密向量^[32,33]。双线性模型为每个关系定义了一个关系双线性变换矩阵,通过将双线性变换矩阵作用于头实体和尾实体来获得实体和关系的语义表达^[34-36]。RESCAL模型是矩阵分解模型的代表方法,该模型与双线性模型类似,不同之处在于 RESCAL 模型同时优化双线性变换矩阵中 0 和非 0 的位置^[37]。

随着知识图谱的广泛引用和发展,科研人员发现了一种全新的方法来解读知识图谱中三元组结构特征,他们将三元组看作是一个从头实体经过关系平移

来获得尾实体的过程,因此,该方法被命名为翻译模型。基于新的解读方式构建了一系列翻译模型来学习知识图谱中实体和关系的语义信息,获得具有丰富语义特征的实体和关系的嵌入向量。进一步,翻译模型逐渐成为知识表示学习的主流,被应用于各个领域。

翻译模型以优化参数少,模型简单高效,能够有效提取实体和关系的语义特征而著称。Mikolov 等提出了 word2vec 词表示学习模型和工具包,并发现了词向量空间存在平移不变现象^[39,40]。Fu 等基于平移不变现象提出了一种新的、有效的基于词嵌入的语义层次结构构建方法,可以用来度量词之间的语义关系^[41]。受到 word2vec 的启发,Bordes 等首次提出了翻译的概念,并建立了 TransE 模型,该模型将知识图谱的三元组视为一个翻译过程,并以三元组中关系的嵌入向量作为嵌入空间中头实体到尾实体的翻译向量,从而获得实体和关系嵌入表示^[42]。然而,知识图谱存在复杂关系问题,如一对一,一对多,多对一,多对多,自反性等。理论分析及实验结果表明,TransE 模型难以解决知识图谱的复杂关系问题,在提取实体和关系的语义特征方面有待进一步提高。

为了解决知识图谱的复杂关系问题,研究人员先后对 TransE 模型进行改进。Wang 等提出了 TransH 模型,该模型为每个关系构建一个关系超平面,并将头实体和尾实体投影在关系超平面中,最后,在超平面中完成头实体到尾实体的翻译过程。实验结果表明,相比于 TransE,TransH 模型在解决知识图谱复杂关系方面具有较大优势,然而,TransH 难以有效解决简单关系^[43]。Lin 等认为 TransH 模型中仍然假设实体和关系同处于一个语义空间中限制了实体和关系的表达,因此,他们建立了 TransR 模型。该模型分别为实体和关系建立实体空间和关系空间,并为每个关系建立了一个映射矩阵来获得头实体和尾实体投影,最后,以关系作为头实体投影到尾实体投影的翻译向量^[44]。考虑到 TransR 中头实体和尾实体共用一个映射矩阵限制了实体和关系的语义表达, Ji 等建立了 TransD 模型。该模型为每个实体和关系分配一个向量,以向量的乘积构造头实体的映射矩阵和尾实体的映射矩阵,降低了 TransR 的参数复杂度。结果表明,TransD 模型能有效解决知识图谱的复杂关系问题^[45]。Xiao 等认为当前的翻译模型的损失函数过于简单,灵活性不足。为了解决上述问题,他们将损失函数中的距离度量方式改为马氏距离并为实体和关系的每一个维度学习一个权重,建立了 TransA 模型^[46]。TransG^[47]和 KG2E^[48]采用 Gauss 分布来描述实体和关系。PTransE^[49]和 PaSKoGE^[50]是翻译模型发展的另外一个方向,它们是基于知识图谱中路径的重要程度进行建模。

早期的知识表示学习方法与基于翻译的知识表示学习方法是知识表示学习的两个研究方向。当前基于翻译的知识表示学习方法均是通过解决知识图谱

的复杂关系问题,获得能够表示实体和关系的嵌入向量。然而,在本文的复杂装备拆卸工艺知识图谱中,各工艺实体之间的耦合关系强,工艺关系类型多,上述方法由于均没有考虑关系自身的多样性,导致难以提取到工艺关系的语义特征。进一步,导致了工艺实体的语义特征提取不充分。例如,在工艺实体“气缸头”与工艺实体“螺栓【气缸左盖】”之间存在“螺纹连接”和“前序零件”等多种工艺关系,通过上述方法获得的多种工艺关系的向量区分度小甚至是完全相同。因此,需要重新定义复杂装备拆卸工艺知识图谱的复杂关系类型,并研发能有效提取工艺知识图谱复杂关系特征的翻译模型来获得具有丰富语义信息的工艺实体和关系嵌入向量的关键技术。

1.2.3 知识图谱的实体类别预测技术研究现状

实体类别预测技术是预测已经构建完成的知识图谱中缺失类别信息的实体类别,或者针对处于构建中的知识图谱将其实体映射到知识图谱本体层预先定义的实体类型集合中。实体类别信息在关系抽取^[51-53],共指消解^[54,55],实体链接^[56,57],智能问答^[58,59],知识推荐^[60,61]等任务中具有重要的作用,包括但不限于提升知识问答、知识推荐的准确性。例如:为关系抽取和共指消解等任务提供实体的类型信息,从而更有效地获取实体和关系的语义信息;通过具有丰富语义信息的实体和关系表示,实现关系分类;通过类别信息对候选实体提及集合剪枝,提升实体链接准确性和效率等。

实体类别预测的实质就是利用文本或者知识图谱中实体的上下文信息预测当前实体所属类别。例如:在本文中,预测工艺实体“离合器”所属的类别,首先获取其在复杂装备拆卸工艺知识图谱的上下文信息:“离合器”在知识图谱中存在路径“齿轮外套【离合器】^{前序零件} → 离合器^{前序零件} → 蝶形垫圈【离合器】”,则以“离合器”的尾实体“齿轮外套【离合器】”作为“离合器”的上文信息,以“离合器”的头实体“蝶形垫圈【离合器】”作为“离合器”的下文信息。随后,将“离合器”和其上下文信息的向量作为实体类别预测方法的输入,并采用实体分类方法预测工艺实体“离合器”所属的类别。比如,实体类别预测方法输出的类别标签为“5”;最后,通过对比得知“5”表示“组合零件”,因此,“离合器”的类别为“组合零件”。

知识图谱建模人员会根据当前研究的领域知识,为知识图谱构建本体层和数据层。为了打通本体层和数据层的壁垒,建模人员通常为每个实体打上类别标签,实现本体层和数据层的互联互通。完全基于人工标注的实体类型标注模式是不切合实际的。一方面,人工标注需要消耗成本的巨大,另一方面,人工标注严重依赖于专家经验,在海量的知识实体类型标注工作中,难免出现类别

缺失,标注失误等问题,为知识图谱带来更多的噪声,难以支持下游任务的应用。因此,科研人员致力于研究实体类别自动标注方法。

当前的实体类别自动标注方法分为两大类,一类是在自动构建知识图谱时,通过实体提及的上下文特征对实体提及进行类别标注^[62,63]。另一类是基于构建完的知识图谱,通过实体的上下文特征对知识图谱中的实体进行类别预测^[64,65]。

在传统的实体提及类别标注方法和实体类别预测方法中,研究人员会根据每个数据集的特点,通过手工设计特征或者手工设计推理规则得到实体在上下文的表征^[66,67],再使用机器学习模型^[68]、统计方法^[69]、语言模型^[70-72]来实现实体提及或者实体类别预测。例如,Kliegr 等将词典句法模式分析与监督分类相结合,提了一种新的类别推理技术,该技术结合了基于共现的统计类型推断算法和 SVM 模型的互补特性,有效实现了实体类别标注^[69]。Lee 等定义了 147 种细粒度实体类别,并提出了一种使用条件随机场(CRF)进行问答的细粒度命名实体识别,最后使用最大熵对命名实体进行分类^[73]。为了解决带噪声知识库的实体类别预测,Paulheim 等提出了基于启发式链接的类别推理机制 SDType,该模型使用类别的统计分布来预测实体类别^[74]。

近年来,随着知识图谱嵌入表示的高速发展,研究人员将研究重点放在实体类别标注上面。知识表示学习能够根据当前知识图谱的三元组中提取到实体和关系的语义特征,获得实体和关系的语义向量表示。因此,知识表示学习模型可以适应大多数数据集自身特性来构建实体的特征,而不需要单独为每个数据集手工设计特征。基于知识表示学习模型的实体类别预测可以分为两类:一类是基于知识表示学习模型学习实体的嵌入表示,随后采用一些分类模型对实体类别预测;另一类是基于知识表示学习模型学习实体和实体类别的嵌入表示,通过相似度等手段,预测实体类别。

基于实体的嵌入表示对实体类别预测是指以知识表示学习模型学习到的实体的嵌入向量为输入,以类别标签作为输出,训练分类模型。例如,逻辑回归模型^[75,76]、随机森林^[77,78]、SVM^[79]、循环神经网络^[80]、卷积神经网络^[81]、长短时记忆网络^[82](Long short-term memory, LSTM)等。Jon Arne Bø Hovda 等提出了两种简单的神经网络框架并构建了多种输入实体表示策略,有效解决自动为知识库中给定的实体分配类别的问题^[83]。Russa Biswas 等基于卷积神经网络提出了一种多标签分类方法,该模型使用多种现有的词嵌入模型来捕获图结构的知识图谱嵌入和可用的隐式文本信息,有效完成了细粒度实体类别分类^[84]。Zahera 等将知识图谱表示方法与逻辑回归、随机森林和深度神经网络相结合来进行实体类别预测^[85]。

基于实体和实体类别的嵌入表示对实体类别预测通常构造实体三元组和

类别三元组，以实体三元组训练知识表示学习模型来构建实体嵌入空间，然后采用类似的训练策略通过类别三元组来构建实体类型嵌入空间，最后直接或者间接度量实体向量和实体类别向量的相似度，实现实体类别预测。例如，Neelakantan 等构建了一个大型数据集来支持实体类别预测并提出了一种全局训练目标来进行实体类别预测，结果验证了全局训练目标的有效性^[86]。Zhao 等建立了两种新的基于嵌入的模型来分别编码实体三元组和类别三元组，将两个模型联合起来推断缺失的实体类别，完成知识图谱的实体类别的补全^[87]。Li 等建立了一种新颖的实体类别结构化嵌入模型，该模型考虑局部元组和全局三元组信息来构建两个元组的可信度并使用结构投影矩阵将实体和实体类别单独在实体空间和实体类别空间中编码来进行实体类别嵌入，有效解决了传统模型在带噪声的知识图谱上实体类别难以准确预测的问题^[88]。

分析文献得知，基于实体的嵌入表示对实体类别预测是目前的主流研究方向之一。影响实体类别预测的两大关键因素分别是知识表示学习模型和实体类别预测模型：一个优秀的知识表示学习模型能够学习到具有丰富语义特征的实体嵌入向量，在实体类别预测中起积极作用，甚至在实体类别预测中起决定性作用；一个能够有效提取实体语义特征的实体类别预测模型，能够提高实体类别预测的精度，有效完成实体类别预测。然而，现有的实体类别预测方法难以准确地预测出复杂装备拆卸工艺实体的类别。复杂装备的拆卸过程通常是由表及里，并且各零件按照先后顺序进行拆卸，致使复杂装备拆卸工艺实体同时具有层次结构特征和序列特征。当前的实体类别预测方法难以同时提取工艺实体的层次结构特征和序列特征，导致实体类别预测的精度有待提升。因此，需要研制能够同时提取拆卸工艺实体层次结构特征和序列特征的类别预测方法。

1.2.4 实体和图结构相似度度量研究现状

（1）实体相似度度量研究现状

实体相似度度量旨在判断相同或不同数据集中的两个实体是否指向真实世界同一对象。实体的相似度度量主要应用于实体对齐^[89]、记录匹配^[90]、指代消解^[91]和对象合并^[92]等。本质上，实体的相似度度量是知识融合中的关键任务，在数据清洗、数据集成和数据挖掘与多元数据融合方面具有重要作用^[93]。例如，通过计算不同拆卸工艺碎片化知识图谱中工艺实体之间的相似度，判断工艺实体是否为同一个工艺实体，从而为相似工艺实体的整合和工艺知识的统一表示提供支撑。实体的相似度度量可分为两大类：一类是采用传统的文本相似度计算方法计算实体的相似度；另一类是基于知识表示学习模型计算实体的语义相似度。

传统的文本相似度计算方法主要包括字符串匹配^[94]、词袋模型^[95]和主题模型^[96]。字符串匹配方法通过计算文本中相同部分的长度来估计文本之间的相似程度。通常使用的算法有最长公共子序列算法^[97]、最长公共子串算法等^[98]。字符串匹配方法由于不考虑文本的语义信息,难以度量具有相同语义信息而表达不一致的文本的相似度。词袋模型^[99]是将文本表示为词语的集合,并将每个文本表示为一个向量,向量中的每个维度代表一个词语,向量中的值代表该词语在文本中出现的次数。随后,基于所获得向量,通过向量之间的余弦相似度^[100]、欧氏距离^[101]等来计算文本相似度。然而,基于词袋模型的实体相似度计算方法仍然不能很好地反映实体的语义相似度。主题模型是一种基于概率的文本分析方法,它将文本表示为多个主题的分布,主题表示一组相关的词语。主题模型中常用的方法包括潜在语义分析^[102]和潜在狄利克雷分配^[103]等。

近年来,随着知识表示学习方法的发展,基于知识表示学习模型的实体相似度度量已经成为当前主要的实体相似度度量方法。知识表示学习模型能够有效地捕捉知识图谱中实体的语义信息,为每个实体学习一个语义向量。随后,基于语义向量,采用余弦相似度、欧氏距离等来有效量化实体的相似度,有效度量具有相同语义信息而表达不一致的实体的相似度。基于知识表示学习模型的难点是获得具有丰富语义信息的实体向量。

(2) 图结构相似度度量研究现状

图结构相似度度量是图论中的一个重要问题。一般地,图结构相似度度量是指采用某些方法或手段,确定两个图在结构上的相似程度。图结构相似度度量在碎片化知识的相似度度量与融合中起重要作用。例如:通过图结构相似度度量可以判断两个拆卸工艺碎片化知识图谱是否是相似的拆卸工艺,从而为相似拆卸工艺知识图谱的融合及知识图谱的构建提供技术支撑。

当前的图结构相似度度量方法可分为三大类:1)基于图同构的相似度度量方法;2)基于网络距离的相似度度量方法;3)基于最大公共子图的相似度度量方法。图同构是指两个图之间存在一一对应的节点映射,使得两个图之间的边也存在一一对应的映射^[104]。图同构能够准确计算图结构的相似度,但图同构算法的计算复杂度较高。例如:图同构网络算法^[105]。网络距离是指在图中两个节点之间的最短路径长度。基于网络距离的相似度度量方法只考虑了节点之间的距离,而忽略了节点之间的图谱结构。因此,基于网络距离的相似度度量方法计算速度快,但是精度有待提高。常用的算法包括 Random Walk^[106]、Shortest Path Kernel^[107]等算法。最大公共子图^[108]是指两个图中存在一一对应的子图,使得这两个子图之间存在同构映射,如图 1-2 所示。不同于图同构,最大公共子图算法无需两个图结构之间具有严格的一一映射关系,而是通过两个图结构之中

存在的相同部分来度量图结构的相似度。因此，最大公共子图应用范围广，计算准确度高。当前主要的求解算法包括子图枚举算法^[109]、McGregor's 算法^[110]、最大团算法^[111]等。总体来说，不同的图结构相似度方法有各自的优缺点，需要根据具体的应用场景来选择合适的方法。




图1-2 最大公共子图示例
Fig. 1-2 Example of the maximum common subgraph

分析文献得知，当前基于知识表示学习的实体相似度方法能够有效度量实体的相似度，其难点在于如何充分提取实体的语义信息。考虑到拆卸工艺碎片化知识图谱构建可能是面向某个零部件或者是面向组合零部件，拆卸工艺碎片化知识图谱的相似是在某个部分相似，而不是完全相似。基于此，基于最大公共子图的图结构相似度方法能够有效度量碎片化知识图谱间的结构相似度。综合分析，基于知识表示学习的实体相似度方法和基于最大公共子图的图结构相似度方法能够为拆卸工艺碎片化知识图谱的相似度提供支撑。然而，最大公共子图不能度量拆卸工艺碎片化知识图谱中的路径相似度。例如：拆卸工艺碎片化知识图谱中，存在路径“气缸头 $\xrightarrow{\text{前序零件}}$ 右侧盖【气缸头】”和“气缸头 $\xrightarrow{\text{前序零件}}$ 密封【气缸头右盖】 $\xrightarrow{\text{前序零件}}$ 右侧盖【气缸头】”。由于二者都实现了零部件“右侧盖【气缸头】”到“气缸头”的拆卸目标，并且后者是前者更为详细的拆卸工艺。因此，这两条路径是相似路径。然而，通过最大公共子图计算二者之间的相似度为 0。因此，应将路径相似融入最大公共子图，研究面向复杂装备拆卸工艺碎片化知识图谱的相似度方法。

1.2.5 知识图谱实体链接技术研究现状

实体链接技术是将所构建的知识图谱应用于实际的关键技术。实体链接的任务是将文本中表示实体的词语(通常称为实体提及)关联到对应的知识库(例

如：知识图谱）中，即在知识库中找到实体提及所对应的唯一实体，完成实体提及到知识库的映射过程^[112]。实体链接通常可以分解为两部分研究内容：候选实体生成^[113-115]和候选实体排序^[116,117]。通过候选实体生成方法生成实体提及可能对应的实体，通过候选实体排序找到实体提及最可能链接的实体。如图 1-3 所示，对于文本中的实体提及“Benjamin Netanyahu”，通过候选实体生成方法，得知在 YAGO^[118]数据库中存在 101 个“Benjamin Netanyahu”的候选实体，从 101 个候选实体中确定唯一与实体提及“Benjamin Netanyahu”指向相同现实事物的候选实体是实体链接的目标；又如图 1-4 所示，对于 JH70 发动机实际拆卸工艺检索文本中的实体提及“轴套-离合器”，通过候选实体生成，基于 JH70 发动机拆卸工艺知识图谱共为其生成 65 个候选实体，实体链接的目的是从 65 个候选实体中找到与实体提及“轴套-离合器”指向相同现实事物的候选实体。通过实体链接技术的定义，不难发现实体链接技术在知识检索，知识推荐中起着重要作用。




图1-3 一段文本中实体提及链接到 YAGO 数据集的示例

Fig. 1-3 An example of entity linking in YAGO




图1-4 发动机拆卸工艺知识图谱实体链接示例

Fig. 1-4 An example of entity linking in knowledge graph of engine disassembly process

实体链接包含了独立实体链接和集体实体链接^[119]。独立实体链接技术^[120,122]通常不考虑一个窗口或者一句话中实体提及之间的关联性，其实体链接的进行仅依赖于当前实体提及的独立信息。这种方法的缺点很明显，由于不考

考虑实体提及之间的关联性,如果实体提及的上下文稀疏或存在相当大的噪声时,实体链接的精度大大降低。然而,这些实体链接方法通常不需要训练,它们的时间复杂度通常比较低。例如,Seufert等基于关键短语重叠提出了一种KORE方法来估计实体之间的语义相似度^[123]。Daiber等开发了一个开源实体链接系统Spotlight,允许用户根据自己的具体需求配置系统^[124]。

集体实体链接方法^[125-127]通常考虑一个窗口或者一句话中出现的多个实体提及之间的关联性。在实体链接的过程中,不仅考虑当前实体提及的特征,还需要考虑其他实体提及所链接的实体对当前实体提及实体链接的影响。实体链接过程中,各个实体提及相互印证,获得一组候选实体。然而,由于要计算各个实体提及之间的语义关系,集体实体链接方法通常链接精度高,时间复杂度较高。例如,Chong等考虑到事件或地理兴趣点通常会导致相关实体在时空上被提及,使用空间和时间相近的推文进行集体实体链接^[128]。Xia等结合实体上下文和实体之间的语义关系,提出了一种基于主题模型和图的集合实体链接算法^[129]。

知识图谱是知识库的一种,因此,为了不局限于实体链接技术的应用,有些研究人员面向知识图谱开发实体链接方法。目前的实体链接方法多数是以维基百科^[130]和Dbpedia^[131]等第三方数据库作为实体的补充信息,从而完成实体链接。例如,使用的维基百科文章^[132,133],链接^[134,135]作为实体的补充信息。尽管维基百科是一个多种知识共存的大数据库,仍然有某些特定领域的信息不在或者极少能够在维基百科等大型公开数据库中查到。因此,在对某些特定领域的知识图谱进行实体链接时,这些用维基百科等大型公开数据库为实体提及或者候选实体补充信息的实体链接方法表现出极大的不适应,甚至难以使用。因此,对某些特定领域的实体链接时仅能使用当前知识图谱的知识。如何充分提取知识图谱中的知识,提高实体链接的精度是难点问题。针对这一难点问题,产生了各种各样的解决方法。

基于概率模型的知识图谱实体链接方法是目前研究的热点内容。针对知识图谱信息有限的问题,Shen等建立了通用的SHINE知识图谱实体链接框架,这是第一个将Web文本中的命名实体与知识图谱联系起来的概率模型^[136]。此外,Shen等建立了一种面向知识图谱的实体流行度模型,该模型以实体的上下位实体作为实体的上下文,通过一个矩阵捕获每个候选实体在知识图谱中的周围信息,进而获得实体的流行度,从而根据实体流行度对候选实体排序,实现实体链接^[137]。为了解决知识图谱中信息有限的问题,Shen等在SHINE中添加了知识填充算法,并建立了一个通用的无监督框架SHINE+^[137]。但是,上述方法均是假定文本中的实体是独立的,而忽略了上下文中实体之间的关系。为了解决

上述问题, Li等首次将人脑的“全局优先”认知机制^[138]与实体链接相结合, 提出了一种从粗到细的集体实体链接算法CFEL^[139]。

分析文献得知, 集体实体链接方法考虑到一段文本中的实体提及的关系, 即在实体链接过程中, 每个实体提及链接候选实体的选择是相互印证、相互影响的。因而, 集体实体链接方法的实体链接精度更高, 适合应用在复杂装备拆卸领域。当前面向仅使用当前领域知识图谱的集体实体链接尚处于初期研究阶段, 研究前景广阔。在复杂装备拆卸工艺领域中, 有些知识难以在搜索引擎等第三方库中查询到。基于此, 有必要研究面向仅使用复杂装备拆卸工艺知识图谱的集体实体链接方法。

1.3 相关文献解析

通过上述国内外相关文献, 目前在复杂装备拆卸工艺知识语义向量化表达方法、复杂装备拆卸工艺实体类别预测方法、装备拆卸工艺碎片化知识图谱相似度量与融合建模方法、复杂装备拆卸工艺知识图谱实体链接方法中还存在相关问题亟待解决:

(1) 当前知识语义向量化方法难以准确提取工艺关系的语义信息

在复杂装备拆卸工艺知识语义向量化表达方法中, 当前基于翻译模型的知识表示学习模型由于没有考虑复杂装备拆卸工艺知识图谱的工艺关系自身多样化特征, 致使当前的翻译模型难以有效提取到领域知识图谱中工艺实体和关系的语义特征, 导致获得的语义向量难以准确表征工艺实体和关系。因此, 有必要考虑复杂装备拆卸工艺领域中工艺实体和工艺关系的特征, 构建面向复杂装备拆卸工艺领域的翻译模型。

(2) 现有语义翻译模型难以实现拆卸工艺知识图谱中实体类别的预测

在复杂装备拆卸工艺实体类别预测方法中, 存在分类精度难以保证的问题。目前基于实体嵌入表示的实体类别预测中, 通常以获得的实体嵌入向量为输入, 以类别标签为输出, 采用训练决策树、随机森林以及深度学习模型来预测实体类别。决策树、深度学习等模型在类别预测中的精度虽然已经比较高了。但是, 拆卸工艺实体层次结构多, 且呈现序列特性, 目前缺乏能够同时提取复杂装备拆卸工艺实体层次结构特征和序列特征类别预测方法。

(3) 缺乏碎片化知识图谱相似度量与融合建模方法

在复杂装备拆卸工艺知识图谱自动构建方法中, 存在缺乏碎片化知识图谱相似度量方法和融合方法的问题。目前大部分领域知识图谱自动构建方法是基于文本数据实现知识图谱自动构建, 鲜少有人研究采用结构化的碎片化知识来自动构建知识图谱。特别是在对现有的碎片化知识图谱进行相似度量与融合,

从而实现知识图谱自动构建方法方面有待研究。碎片化知识图谱在结构上与有向图类似，基于最大公共子图的相似度量方法能有效图结构的相似度。然而，最大公共子图不能度量相似路径，导致碎片化知识图谱相似度量不准。因此，有必要探索面向拆卸工艺碎片化知识图谱的相似度量方法与融合方法。

（4）面向特定领域的实体链接方法难以支持模糊语义检索

在复杂装备拆卸工艺知识图谱实体链接方面，存在实体链接精度难以保证的问题。由于复杂装备拆卸领域的特殊性，当前基于第三方库的实体链接方法难以使用。面向仅使用领域知识图谱的实体链接方法研究处于初阶段，大多数方法属于独立实体链接，导致实体链接的精度往往难以保证并且难以支持语义检索。当前缺乏使用复杂装备拆卸工艺知识图谱的高精度集体实体链接方法。

1.4 本文的主要研究内容

针对上述问题和复杂装备拆卸工艺智能规划实际需求，本文重点研究复杂装备拆卸工艺知识图谱自动构建和实体链接方法。本文的主要研究内容如图 1-5，具体如下所示。




图1-5 全文研究内容
Fig. 1-5 Research contents

（1）复杂装备拆卸工艺知识语义向量化表达方法

针对当前翻译模型难以提取工艺实体和关系复杂关联的语义信息问题,建立一种新的基于 ERTransH 的翻译模型,实现工艺知识准确的语义向量化表达。当前的知识语义向量化表达方法均是面向通用领域,由于没有定义复杂装备拆卸工艺知识图谱的多种复杂关系,导致传统模型难以同时提取到工艺实体和多种关系的语义特征。针对该问题,本文分析复杂装备拆卸工艺知识图谱的复杂关系类型,建立能有效提取复杂关系语义特征的工艺实体和关系双投影超平面模型,获得能准确表示工艺实体和关系的语义向量。

（2）复杂装备拆卸工艺知识图谱的实体类别预测方法

当前,拆卸工艺碎片化知识图谱中存在海量的实体,但是由于实体类别信息不影响工艺方案的实施,因此存在实体类别漏标问题,人工为每个实体标注实体类别将耗费巨大的成本。为了能够实现类别信息的自动化补全,可利用已经获得的工艺知识语义向量,建立机器学习模型,预测未知实体类别。由于工艺实体类别同时具有层次和序列特征,本文将决策树和 LSTM 融合,建立样本自适应 LSTM 神经树实体类别预测模型。该模型通过决策树提取工艺实体的层次结构信息,通过 LSTM 提取工艺实体的序列特征,实现工艺实体类别的准确预测。

（3）装备拆卸工艺碎片化知识图谱相似度量与融合建模方法

目前,知识图谱基本上都是采用人工建模方法,不仅耗时、也存在建模人员主观性问题,这已经成为制约知识图谱工程应用的瓶颈问题。为了解决这一问题,在复杂装备拆卸知识图谱建模过程中,充分考虑已有拆卸工艺方案,研究通过融合碎片工艺方案实现知识图谱自动化建模的方法,重点解决相似知识图谱图度量和融合问题。本文拟结合图结构相似、路径相似和实体重要度建立强化极大连通同归结构相似度模型,从图结构和路径相似方面度量碎片化知识图谱的相似度。同时,提出基于实体融合、路径融合和插枝融合的相似知识图谱融合方法,支持完整复杂装备拆卸工艺知识图谱的自动化构建。

（4）面向复杂装备拆卸工艺知识图谱的细粒度集体实体链接方法

为实现复杂装备拆卸工艺知识的高效模糊语义检索,研究基于装备拆卸工艺知识图谱的实体链接方法。本文提出一种基于强相关序列的细粒度集体实体链接方法,考虑语言逻辑特征,将一段检索文本中的实体视为一个整体,定义三种 2-hop 实体路径,同时引入知识语义向量化表达,最后建立强相关序列相似度模型来度量候选实体组的整体相关性。该方法能够有效提升实体链接精度,实现工艺知识模糊语义检索。

上述研究内容分别对应于本文第 2 章、第 3 章、第 4 章、第 5 章,如图 1-

6 所示。第 2 章、第 3 章、第 4 章的关键技术用来支持复杂装备拆卸工艺知识图谱自动构建，第 5 章的关键技术用来支持工艺知识图谱上的知识检索。第 2 章的语义向量化表达为第 3 章的实体类别预测提供数字化的输入；第 2 章的知识语义向量化表达和第 3 章的实体类别信息用来准确度量第 4 章的实体相似度，支持碎片化知识图谱相似度与融合；最后，上述 3 章用来支持第 5 章的细粒度集体实体链接，实现工艺知识准确地模糊语义检索。





图1-6 各章关联图

Fig. 1-6 Association diagram of each chapter

本文实验中使用的数据来源于 JH70 发动机。JH70 发动机拆卸工艺知识图谱如图 1-7 所示。该知识图谱包含 JH70 发动机较为完整的拆卸过程。具体地，描述各工艺实体的名称及它们之间的关系，如零部件与零部件之间的拆卸关系、零部件的功能及零部件所需的拆卸工具等。为了更好地适应实际应用，对 JH70 发动机拆卸工艺知识图谱进行补充，包括标注部分工艺实体的类别信息以及补充一些工艺实体的属性等信息，如零部件的生产时间、生产单位、使用寿命、剩余寿命等。受限于本文篇幅影响，所补充的工艺实体的信息及现有工艺实体信息在附录中介绍。



- 21 -

第2章 复杂装备拆卸工艺知识语义向量化表达方法

2.1 引言

拆卸工艺知识缺乏统一表达框架导致工艺知识的相似度量 and 融合成为难点问题。例如：在对零部件“燃油泵”建模时，工艺人员可能将其建模为与“燃油泵”具有相同语义信息的“增压泵”。此外，工艺实体之间通过复杂多样的工艺关系相互耦合，工艺实体的相似度量不仅要考虑自身信息，还应考虑其上下序的信息。因此，仅从文本相似度，难以准确度量具有相同语义信息而表达形式不一致的工艺实体的相似度。因此，工艺知识的相似度量并非文本相似度量，而是基于语义的相似度量。为了准确度量工艺知识的语义相似度，实现工艺知识的相似相融，本章重点研究复杂装备拆卸工艺知识语义向量化表达方法。

经过多年的积累，当前复杂装备拆卸领域已经存在一些与知识图谱结构相同的复杂装备拆卸工艺路径。工艺路径中的节点可以视为知识图谱中的实体，节点之间的关系可以视为实体之间的关系，如图 2-1 所示。由于工艺路径可能针对某个局部零部件的拆卸工艺，因此，工艺路径被视为碎片化知识图谱。由于拆卸工艺中各零部件之间的关系丰富，并且各零部件的拆卸顺序相互影响。因而，在拆卸工艺知识图谱中，工艺实体具有复杂多样性特征，工艺关系具有多样化特征。例如：图 2-1 中，“气缸体”的前序零件不唯一，并且“气缸体”又作为“时规链条”的前序零件；“气缸体”与“导向滚轮【链条】”之间具有多种工艺关系。

在知识语义向量化表达方法中，翻译模型以简单的模型结构、高效的训练模式、有效的语义信息提取方式而著称。翻译模型将语义向量学习视为一个翻译过程，以关系的表示作为平移向量，将尾实体表示看作头实体经过关系表示平移后的结果。当前的翻译模型以解决知识图谱的复杂关系为出发点，来解决实体的复杂多样化问题，获得实体和关系的语义表示。因此，可以利用翻译模型的特点来提取复杂装备拆卸工艺知识图谱的语义信息，获得具有丰富语义信息的实体表示和关系表示。

为了有效提取复杂装备拆卸工艺实体和工艺关系的语义信息，翻译模型需同时提取工艺实体的复杂多样化特征和工艺关系的多样化特征。本章建立一种工艺实体和关系双投影超平面模型。区别于传统的语义向量化表达模型，该模型不仅仅以解决工艺实体复杂多样性为研究的出发点，还考虑如何解决工艺关系多样性的问题。因此，该模型能够同时提取复杂装备拆卸工艺知识图谱中工




Fig. 2-1 An example of complex equipment knowledge graph of disassembly process

2.2 基于翻译模型的语义向量化表达方法对比分析

在知识图谱中,知识以三元组的形式存储,即采用(h,r,t)来表示知识,其中,h表示三元组中的头实体,t表示三元组中的尾实体,r表示头实体h和尾实体t之间的关系。例如,图2-2中复杂装备拆卸工艺碎片化知识图谱中的三元组(气缸头,前序零件,密封【气缸头右盖】),“气缸头”为三元组的头实体,“密封【气缸头右盖】”为三元组的尾实体,“前序零件”是二者之间的关系。

知识图谱简单的知识表达结构有效提升了知识梳理、知识存储的效率，但是知识图谱中的知识仍然是以自然语言或者符号的形式表示，难以支持一些复杂操作。例如：语义检索、知识推理、工艺实体的语义相似度量等。比如度量工艺实体“燃油泵”和“增压泵”的相似度，从文本形式来看，这两个实体的相似度并不高。然而，这两个工艺实体表示的是同一个零部件，即这两个工艺实体所含的语义信息相同。结果表明了仅从文本上度量实体相似度，而不考虑它们的语义信息难以准确度量工艺实体的相似度。为了解决上述问题，研究人员提出了一种语义向量化表达方法——翻译模型来实现文本信息的语义向量化

表达^[42]。具体地，翻译模型通过学习知识图谱中实体和关系的语义信息，将实体和关系的自然语言表达转化为低维稠密的语义向量，进而通过基于向量的相似度量方法有效地量化实体与实体之间、实体与关系之间、关系与关系之间的语义相似程度，而不是文本相似距离，这使得文本表达不一致时难以准确度量文本相似度的问题得到有效解决。




图2-2 某拆卸工艺碎片化知识图谱

Fig. 2-2 A fragmentation knowledge graph of disassembly process

2.2.1 TransE 模型

当前翻译模型的不同之处在于得分函数不同。表2-1描述了几种典型翻译模型以及本章建立的工艺实体和关系双投影超平面模型 (process entity and relation translating on hyperplanes, ERTransH) 的得分函数和参数复杂度。每种翻译模型都单独设计了自己的得分函数 $f_r(h, t)$ ，在得分函数中可以清晰地得到头实体与尾实体的投影方式和头实体到尾实体的翻译模式。在表2-1中， n_e 表示实体的数量， m_r 表示关系的数量。 k 为实体嵌入空间的维度， n 为关系嵌入空间的维度， m_i 代表一个关系聚簇的平均数量。

翻译模型的基础是词向量的平移不变特性。Mikolov 等利用 word2vec 模型学习词向量时发现了词向量空间存在平移不变现象^[39-40]。例如，研究表明：

$$\text{Vec}(\text{气缸体}) - \text{Vec}(\text{时规链条}) \approx \text{Vec}(\text{链轮【正时从动】}) - \text{Vec}(\text{气缸头}) \quad (2-1)$$

式中 $\text{Vec}(\text{word})$ ——通过 word2vec 模型训练得到的 word 的词向量。

公式(2-1)表明，词向量能够发现“气缸体”和“时规链条”之间，“链轮【正时从动】”和“气缸头”之间隐藏的语义信息。

表2-1 几种典型和本章建立的翻译模型的得分函数与模型的复杂度分析
Table 2-1 Score functions and complexity analysis of several typical and the proposed translation models

模型	得分函数 $f_r(h, t)$	参数复杂度
TransE ^[42]	$\ h + r - t\ _{L_1/L_2}, h, t, r \in \mathbb{R}^k$	$O(n_e k + n_r k)$
TransH ^[43]	$\ (h - w_r^T h w_r) + d_r - (t - w_r^T t w_r)\ _{L_1/L_2}, h, t, d_r, w_r \in \mathbb{R}^k$	$O(n_e k + 2n_r k)$
TransR ^[44]	$\ (M_r h) + r - (M_r t)\ _{L_1/L_2}, h, t \in \mathbb{R}^k, r \in \mathbb{R}^n, M_r \in \mathbb{R}^{n \times k}$	$O(n_e k + n_r (k+1)n)$
CTransR ^[44]	$\ M_r h + r_c - M_r t\ _2^2 + \alpha \ r_c - r\ _{L_1/L_2},$ $h, t \in \mathbb{R}^k, r, r_c \in \mathbb{R}^n, M_r \in \mathbb{R}^{n \times k}$	$O(n_e k + n_r (k+d)n)$
TransD ^[45]	$\ M_{r,h} h + r - M_{r,t} t\ _{L_1/L_2}, h, t \in \mathbb{R}^k, r \in \mathbb{R}^n, M_{r,h}, M_{r,t} \in \mathbb{R}^{n \times k}$	$O(2n_e k + 2n_r n)$
ERTransH	$\ (h - w_r^T h w_r) + (r - s_r^T r s_r) - (t - w_r^T t w_r)\ , h, t, r, w_r, s_r \in \mathbb{R}^k$	$O(n_e k + 3n_r k)$

受到平移不变现象的启发, Bordes 等首次建立了翻译的概念, 建立了第一个翻译模型——TransE 模型^[42]。TransE 模型将三元组中的关系看做平移向量, 将尾实体看作是头实体在关系下的翻译过程, 并通过该过程提取实体和关系的语义特征。具体地, 该过程以关系的嵌入向量为平移向量, 通过将头实体的嵌入向量与平移向量结合得到尾实体的嵌入向量, 即在训练过程中尽可能满足 $h+r \approx t$ 。因此, TransE 模型的得分函数被建模为公式(2-2)。

$$f_r(h, t) = \|h + r - t\|_{L_1/L_2} \quad (2-2)$$

式中 $f_r(h, t)$ ——三元组 (h, r, t) 的得分函数;

k ——实体和关系的嵌入维度;

h 、 r 、 t ——分别为头实体 h 、关系 r 和尾实体 t 的嵌入向量, 并且

$$h, t, r \in \mathbb{R}^k;$$

$\|x\|_{L_1}$ 、 $\|x\|_{L_2}$ ——分别为 x 的 1-范数和 2-范数。

具体地, 对于图 2-2 中的三元组(气缸头, 前序零件, 密封【气缸头右盖】), TransE 模型简图如图 2-3 所示。

Bordes 等发现知识图谱的实体之间的关系可分为 4 种: 1-1、1-N、N-1 和 N-N。其中, 1-N、N-1、N-N 为知识图谱的复杂关系。然而, TransE 模型难以解决知识图谱的复杂关系问题。比如, 对于图 2-4 中复杂装备拆卸工艺知识图谱的 1-N 问题, 理想条件下, TransE 模型训练的目标是 $h+r=t_1$, $h+r=t_2, \dots, h+r=t_m$, 最终导致 $t_1=t_2=\dots=t_m$, 即“螺母【飞轮转子】”, “螺栓【箱底】”, “螺栓【变速鼓】”等的嵌入向量一样。事实上, “螺母【飞轮转子】”, “螺栓【箱底】”, “螺栓【变速鼓】”等之间具有一定的相似度, 同时也具有较大的差异性。TransE 模型导致了不同的尾实体具有相同的嵌入向量, 致使在实

体嵌入空间中的各尾实体难以被区分。因此，TransE 模型难以解决实体之间的 1-N 关系。




图2-3 TransE 模型
Fig. 2-3 TransE model

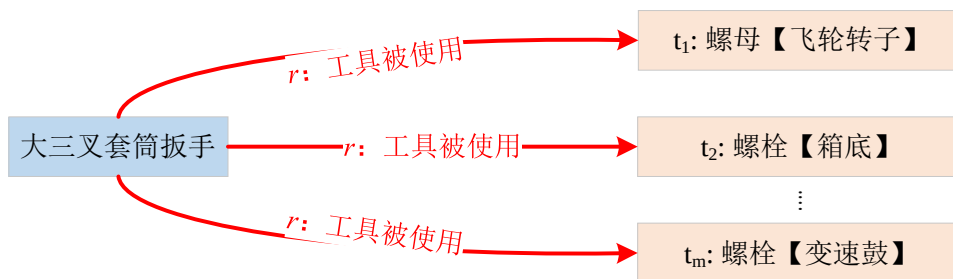


图2-4 拆卸工艺知识图谱中 1-N 关系示例

Fig. 2-4 Example of 1-N relationship in knowledge graph of disassembly process

对于图 2-5 中拆卸工艺知识图谱的 N-1 问题，理想条件下，TransE 模型训练的目标是 $h_1 + r = t$, $h_2 + r = t$, $\dots$, $h_n + r = t$, 最终导致 $h_1 = h_2 = \dots = h_n$, 即“密封【气缸头右盖】”，“气缸头”，“右侧盖【气缸头】”等的嵌入向量一样。事实上，“密封【气缸头右盖】”，“气缸头”，“右侧盖【气缸头】”等之间具有一定的相似度，同时也具有较大的差异性。TransE 模型表明不同的头实体具有相同的嵌入向量，导致各头实体在实体嵌入空间中难以被区分开。因此，TransE 模型难以解决实体之间的 N-1 关系。




图2-5 拆卸工艺知识图谱中 N-1 关系示例

Fig. 2-5 Example of N-1 relationship in knowledge graph of disassembly process

综上所述, TransE 模型虽然简单高效, 但是它难以解决实体之间的复杂关系问题, 因此无法有效提取实体之间的相异的语义信息, 从而通过 TransE 模型学习到的向量难以有效表征实体和关系, 这大大限制了 TransE 模型的应用。

2.2.2 TransH 模型

为了解决实体的复杂关系问题, 使得翻译模型能够充分提取实体和关系的语义特征, Wang 等在 TransE 模型的基础上, 建立了 TransH 模型^[43]。该模型为每个关系构建一个关系超平面, 并将头实体和尾实体投影在该超平面中, 最后以关系嵌入作为平移向量, 在超平面中完成头实体到尾实体的翻译过程。TransH 模型简图如图 2-6 所示。

如图 2-6 所示, 针对三元组 (气缸头, 前序零件, 密封【气缸头右盖】), TransH 模型首先为“前序零件”构建关系超平面 W_r , 随后, 将头实体“气缸体”投影在关系超平面 W_r 中, 获得头实体的投影向量 $h_{\perp}$ 。同理, 将尾实体“密封【气缸头右盖】”投影在关系超平面 W_r 中, 获得尾实体的投影向量 $t_{\perp}$, 最后在超平面 W_r 中实现 $h_{\perp} + r = t_{\perp}$ 。因此, TransH 的得分函数可表示为公式(2-3)。

$$f_r(h, t) = \|h_{\perp} + r - t_{\perp}\|_{L_1/L_2} = \|(h - w_r^T h w_r) + r - (t - w_r^T t w_r)\|_{L_1/L_2} \quad (2-3)$$

式中 k ——实体和关系的嵌入维度;

h 、 r 、 t ——分别为头实体 h 、关系 r 和尾实体 t 的嵌入向量, 并且

$$h, t, r \in \mathbb{R}^k;$$

$h_{\perp}$ 、 $t_{\perp}$ ——分别表示 h 和 t 在关系超平面 W_r 中的投影;

w_r ——关系超平面 W_r 的单位法向量, 并且 $w_r \in \mathbb{R}^k$ 。




图2-6 TransH 模型
Fig. 2-6 TransH model

由 TransH 模型的得分函数可知，TransH 模型能够一定程度上解决实体的复杂关系问题。例如，对于 1-N 问题，TransH 模型只需要保证尾实体的嵌入向量在关系超平面中的投影一样，而不需要尾实体的嵌入向量一致，因而，TransH 模型学习到的尾实体的嵌入向量既能包含尾实体之间的相似信息又能包含尾实体之间的相异信息；同理，对于 N-1 问题，TransH 模型只需要保证头实体的嵌入向量在关系超平面中的投影一样，而不需要头实体的嵌入向量一致，因而，TransH 模型学习到的头实体的嵌入向量既能包含头实体之间的相似信息又能包含头实体之间的相异信息。

2.2.3 TransR 模型

相比于 TransE 模型，TransH 模型有效提升了翻译模型解决实体之间复杂关系的能力。然而，TransH 模型假设实体和关系的嵌入向量仍然在同一个语义空间中，这限制了 TransH 模型的代表能力。Lin 等认为一个实体可能是由多个层面的信息组合而成的一个综合体，不同的关系可能关注实体不同层面的信息^[44]。例如，在复杂装备拆卸工艺碎片化知识图谱中，实体“螺母【飞轮转子】”可能具有多种类别的属性信息，包括了产地、生产时间、部署位置、服役时间、拆卸所使用的工具等信息。拆卸工艺设计人员可能更关注拆卸所使用的工具、部署位置等信息，而使用人员可能更关注产地、生产时间、服役时间等信息。为了使关系关注到实体不同层面的信息，Lin 等人构建了 TransR 模型，如图 2-7 所示。




图2-7 TransR 模型

Fig. 2-7 TransR model

图 2-7 表明 TransR 为每个关系创建一个关系矩阵, 并通过关系矩阵将实体从实体嵌入空间投影到关系嵌入空间, 最后在关系嵌入空间完成头实体到尾实体的翻译过程, 从而使得不同的关系能够关注实体不同层面的信息。因此, TransR 的得分函数如公式(2-4)所示。

$$f_r(h, t) = \|h_{\perp} + r - t_{\perp}\|_{L_1/L_2} = \|(M_r h) + r - (M_r t)\|_{L_1/L_2} \quad (2-4)$$

式中

k —— 实体嵌入空间的嵌入维度;

n —— 关系嵌入空间的嵌入维度, 并且 $k \neq n$;

h 、 r 、 t —— 分别为头实体 h 、关系 r 和尾实体 t 的嵌入向量, 并且

$$h, t \in \mathbb{R}^k, r \in \mathbb{R}^n;$$

$h_{\perp}$ 、 $t_{\perp}$ —— 分别表示 h 和 t 在关系嵌入空间中的投影;

M_r —— 实体嵌入空间投影到关系嵌入空间的投影矩阵, 并且

$$M_r \in \mathbb{R}^{n \times k}。$$

CtransR 模型在 TransR 模型的基础上, 对每种关系下的三元组聚类, 为每类三元组分配一个虚拟的子关系。然后, 为每个类别构建一个关系语义向量同时保证该语义向量与关系的语义向量相近, 从而挖掘关系深层次的细粒度语义特征。因此, CtransR 模型得分函数如公式(2-5)所示, 并且公式(2-5)中其他参数的含义与 TransR 模型中的参数含义相同。

$$f_r(h, t) = \|h_{r,c} + r_c - t_{r,c}\|_{L_1/L_2} + \alpha \|r_c - r\| = \|(M_r h) + r_c - (M_r t)\|_{L_1/L_2} + \alpha \|r_c - r\| \quad (2-5)$$

式中

r_c —— 系 r 的子关系的语义表示向量;

α —— 衡量关系与子关系的语义相似度和三元组正确翻译的重要度。

2.2.4 TransD 模型

相比于 TransE 和 TransH, TransR 模型和 CTransR 模型能更有效地解决知识图谱的复杂关系问题。然而, TransR 模型和 CTransR 模型仍然存在较大缺陷。

(1) 由于 TransR 模型和 CTransR 模型引入了关系的投影矩阵, 在模型中包含了大量的矩阵运算, 导致 TransR 模型和 CTransR 模型的计算复杂度高。(2) TransR 模型和 CTransR 模型中头实体和尾实体共用一个投影矩阵, 难以同时有效地提取头实体和尾实体的语义特征。例如, 在三元组(螺母【飞轮转子】, 使用工具, 大三叉套筒扳手), 其头实体和尾实体所属的类别存在较大差异, 头实体的属性与尾实体的属性等信息差异明显。为了解决上述问题, Ji 等建立了 TransD 模型^[45], 如图 2-8 所示。




图2-8 TransD 模型

Fig. 2-8 TransD model

图 2-8 所示, TransD 模型通过两个投影向量相乘来构造投影矩阵; 为了同时有效地提取头实体和尾实体的语义特征, TransD 模型为头实体和尾实体分别构建了一个投影矩阵, 如公式(2-6)所示。

$$\begin{aligned} M_{rh} &= r_p h_p^T + I^{n \times k} \\ M_{rt} &= r_p t_p^T + I^{n \times k} \end{aligned} \quad (2-6)$$

式中 M_{rh} 、 M_{rt} ——分别为头实体向量 h 和尾实体向量 t 的投影矩阵;

r_p 、 h_p 、 t_p ——分别为关系向量 r 、头实体 h 向量和尾实体向量 t 的投影向量, 并且 $r_p \in \mathbb{R}^n$, h_p 、 $t_p \in \mathbb{R}^k$;

I —— $n \times k$ 维空间的单位矩阵;

具体地, TransD 模型的得分函数如公式(2-7)所示。

$$f_r(h, t) = \|M_{r,h}h + r - M_{r,t}t\|_{L_1/L_2} \quad (2-7)$$

式中 h 、 t ——分别为头实体和尾实体在 k 维实体空间中的嵌入向量；
 r ——关系在 n 维向量空间中的嵌入向量；

2.2.5 现有翻译模型不适应性分析

当前的翻译模型均是为了有效解决知识图谱的实体复杂多样化问题，从而有效学习实体和关系的语义向量。由于未直接考虑关系的多样化特征，当前翻译模型难以有效提取实体和关系复杂的语义联系，导致所学习的实体向量中缺乏关系的语义特征。为了有效提取工艺实体和工艺关系的语义信息，本节首先分析复杂装备拆卸工艺知识图谱的复杂关系类型，从根源上建立能够有效提取复杂装备拆卸工艺知识图谱中实体和关系语义信息的翻译模型。根据三元组的表达形式，传统的知识图谱的复杂关系被表示为 1-1、1-N、N-1 和 N-N，分别表示一种关系下一个头实体平均对应一个尾实体、一种关系下一个头实体对应多个尾实体、一种关系下一个尾实体平均对应多个头实体和一种关系下多个头实体对应多个尾实体。

事实上，传统知识图谱的复杂关系是根据头实体对应的尾实体数量或者尾实体对应的头实体数量来定义的。因此，当前的复杂关系是实体之间的复杂关系，并未真正考虑两个实体之间关系的多样化问题。例如，在复杂装备拆卸工艺知识图谱中，同一对工艺实体之间可能存在多种关系：对于工艺实体“定子总成”和工艺实体“螺栓【左箱】-1”来说，它们之间的工艺关系不仅有关系“前序零件”，还有工艺关系“螺纹连接”；对于某些零件和工具来说，它们之间的关系可以是“候选工具”，也可以是“工具被使用”。因此，复杂装备拆卸工艺知识图谱的复杂关系被重新定义为图 2-9。

考虑到工艺实体的复杂多样性和工艺关系自身的多样性问题，复杂装备拆卸工艺知识图谱的复杂关系被延伸为：一对一对多、多对一对一、一对多对一、多对一对多、多对多对一、一对多对多和多对多对多，记为 N-1-1、1-1-N、N-1-N、1-M-1、1-M-N、N-M-1 和 N-M-N。具体地，如图 2-9 所示，拆卸工艺知识图谱的复杂关系分别表示一种工艺关系下多个工艺尾实体对应一个工艺头实体、一种工艺关系下一个工艺头实体对应多个工艺尾实体、一种关系下多个工艺头实体对应多个工艺尾实体、一对工艺实体之间具有多种关系、一个工艺头实体对应于多种工艺关系和多个工艺尾实体、多个工艺头实体对应于多种工艺关系和一个工艺尾实体、多个工艺头实体对应于多种工艺关系和多个工艺尾实体。




图2-9 拆卸工艺知识图谱复杂关系示例

Fig. 2-9 Example of complex relationships in knowledge graph of disassembly process

2.3 基于 ERTransH 的语义向量化表达方法

工艺关系在拆卸工艺知识图谱中具有极其重要的作用。工艺关系描述不同工艺实体之间的相互作用关系，能有效实现对工艺过程的控制和管理。例如，“时规链条”与“气缸体”之间的关系为“前序零件”，说明了要拆卸“气缸体”，必须要提前拆卸“时规链条”。“前序零件”指导着拆卸的正确进行。又如，“导向销【气缸体】”与“小三叉套筒扳手”之间的关系为“使用工具”，说明了拆卸“导向销【气缸体】”最合适的工具为“小三叉套筒扳手”。选择正确的拆卸工具对减小零部件的磨损以及提高拆卸效率有至关重要的作用。因此，在复杂装备拆卸工艺知识语义向量化表达方法中，不仅要充分提取工艺实体的语义特征，也需要充分提取工艺关系的语义特征。

为了能够有效学习工艺实体和工艺关系的语义特征，本章从拆卸工艺知识图谱的复杂关系出发，建立了一种 ERTransH 模型，使得学习到的语义向量能够表征复杂装备拆卸工艺知识图谱中的工艺实体和工艺关系。

2.3.1 ERTransH 模型构建

首先，定义本章通用的概念和符号。正体 (h, r, t) 表示复杂装备拆卸工艺知识图谱中的工艺三元组，其中， h 、 r 和 t 分别为三元组的工艺头实体、工艺关系和工艺尾实体。对应地，斜体 (h, r, t) 表示工艺三元组 (h, r, t) 的嵌入向量，其中， h 为工艺头实体嵌入向量、 r 为工艺关系嵌入向量、 t 为工艺尾实体嵌入向量。 E 和 R 分别表示知识图谱的工艺实体集合和工艺关系集合。 Δ 和 Δ' 表示正确工艺三元组集合与错误工艺三元组集合，即 $(h, r, t) \in \Delta$ 是拆卸工艺知识图谱中的工艺三元组，而 $(h', r, t') \in \Delta'_{(h, r, t)}$ 表示为 (h, r, t) 生成的不存在于知识图谱中的工艺三元组，即错误工艺三元组。

为了能同时有效获取工艺实体和工艺关系的语义信息，区别于其他翻译模型，本章从根源上研究翻译模型，即研究 TransE 模型并分析了复杂装备拆卸工艺知识图谱中工艺实体的复杂多样性和工艺关系的多样性。

针对一个正确的三元组 (h, r, t) ，TransE 模型的训练目标是使误差函数 $\|h + r - t\|_{L_1/L_2}$ 最小化。实验结果表明，相比于传统的非翻译模型，TransE 模型能有效提取知识图谱中实体和关系的语义特征性，其链接预测的性能有了显著提高。然而，由于 TransE 模型太过简单，对包含传统复杂关系：N-1、1-N 和 N-N 的知识图谱，TransE 模型存在一定的不适应性。具体表现为 TransE 往往难以有效地提取知识图谱的复杂关系特征，使得通过学习得到的实体嵌入向量往往难以将多个实体区分开，即多个头实体或者多个尾实体可以被表示为同一个向量。

为了探究如何有效提取拆卸工艺知识图谱中实体和关系的语义特征，本章将最为经典的 TransE 模型应用在复杂装备拆卸工艺知识图谱复杂关系中，探索 TransE 模型在实际工程应用中产生的具体问题，并有针对性的建立改进的模型。在理想条件下，对正确的工艺三元组 (h, r, t) ，TransE 模型满足 $h + r = t$ 。基于复杂关系中的 1-M-1，可以得到以下结论：

● $\forall i \in \{1, 2, 3, \dots, m\}, (h, r_i, t) \in \Delta$ ，根据 TransE 模型的训练目标，可以得到： $h + r_i = t$ ，则通过 TransE 模型得到的工艺关系的嵌入向量满足： $r_1 = r_2 = r_3 = \dots = r_m$ 。

结果表明，经过 TransE 模型，一对工艺实体之间所有工艺关系的嵌入向量是相同的。例如，对于工艺三元组（气缸头，前序零件，螺栓【气缸左盖】）和

工艺三元组（气缸头，螺纹连接，螺栓【气缸左盖】），通过TransE模型获得的“前序零件”和“螺纹连接”的嵌入向量一样。这与常理不符合，“前序零件”和“螺纹连接”的语义是不相同的。因此，TransE模型难以解决拆卸工艺知识图谱中1-M-1关系，导致工艺实体之间的多种工艺关系无法区分开。根据工艺人员的认知，“前序零件”是指当前零件拆除之前必须拆除的零件，而“螺纹连接”表示的是两种零件的连接方式。具有“前序零件”关系的零件之间可能是“螺纹连接”，也可能是“铰链连接”、“联轴器连接”等其他连接方式；具有“螺纹连接”的零件之间可能后者是前者的“前序零件”，也可能前者是后者的“前序零件”。因此，“前序零件”和“螺纹连接”这两种关系中有相似的语义成分，也有相异的语义成分。从而，“前序零件”和“螺纹连接”的嵌入向量并不是整体完全相同的，而是在某一局部相同。

为解决上述问题，本章建立了一种RTransE模型。RTransE模型为每个工艺关系创建一个超平面，将工艺关系映射到该超平面上，允许工艺实体之间的多种工艺关系在超平面中的投影向量相同。因此，RTransE学习到的多种工艺关系的嵌入向量同时包含了相似语义信息和相异语义信息，使得RTransE能够增大工艺实体之间多种工艺关系的区分程度。

对于一个复杂装备拆卸工艺知识图谱中的工艺三元组 (h, r, t) ，RTransE模型首先为工艺关系 r 创建一个关系超平面 S_r 。随后，将工艺关系的嵌入向量 r 投影到超平面 S_r 中，获得 r 的投影向量 $r_{\perp}$ 。因此，对于工艺三元组 (h, r, t) ，RTransE模型满足 $h+r_{\perp} \approx t$ 。

然而，理论分析表明，RTransE模型并不能解决工艺实体的多对一和一对多关系问题，即拆卸工艺知识图谱复杂关系中的N-1-1和1-1-N。具体地，将RTransE模型用在N-1-1和1-1-N上，可以得到以下结论：

- 针对N-1-1关系，即 $\forall i \in \{1, 2, 3, \dots, m\}, (h_i, r, t) \in \Delta$ ，通过RTransE模型可以得到工艺头实体的嵌入向量满足： $h_1=h_2=h_3=\dots=h_m$ 。
- 针对1-1-N关系，即 $\forall i \in \{1, 2, 3, \dots, m\}, (h, r, t_i) \in \Delta$ ，通过RTransE模型可以得到工艺尾实体的嵌入向量满足： $t_1=t_2=t_3=\dots=t_m$ 。

结果表明，经过RTransE模型，针对N-1-1问题，所有的工艺头实体的嵌入向量一样；针对1-1-N问题，所有的工艺尾实体的嵌入向量一样。例如，对于工艺三元组（密封【气缸头右盖】，前序零件，螺栓【气缸左盖】）和工艺三元组（气缸头，前序零件，螺栓【气缸左盖】），通过RTransE模型学习得到的“密封【气缸头右盖】”和“气缸头”的嵌入向量一样；对于工艺三元组（大三叉套筒扳手，工具被使用，螺母【飞轮转子】）和工艺三元组（大三叉套筒扳手，工具被

使用, 螺栓【变速鼓】), 通过RTransE模型学习得到的“螺母【飞轮转子】”和“螺栓【变速鼓】”的嵌入向量一样。这与事实不相符, 说明RTransE模型难以有效解决复杂装备拆卸工艺知识图谱中工艺实体的复杂多样性问题。

因此, 本章在RTransE模型的基础上建立ERTransH。ERTransH为每个工艺关系建立一个关系超平面, 将工艺关系的嵌入向量投影在关系超平面中, 获得工艺关系投影, 以增大多种工艺关系之间的可区分程度; 随后, 该模型为每个关系投影建立一个关系投影超平面, 将工艺实体的嵌入向量投影在关系投影超平面中, 以关系投影作为平移向量完成翻译过程。所以, ERTransH在保证增大工艺关系区分程度的同时解决工艺实体的复杂多样化问题, ERTransH的结构如图2-10所示。




图2-10 ERTransH的模型结构

Fig. 2-10 The model structure of ERTransH

如图2-10所示, 对拆卸工艺知识图谱中的一个工艺三元组 (h, r, t) , ERTransH 首先为工艺关系 r 建立一个关系超平面 S_r , 并将工艺关系的嵌入向量 r 投影到 S_r 中, 得到工艺关系在关系超平面中的投影向量 $r_{\perp}$ 。随后, 为关系投影 $r_{\perp}$ 建立一个关系投影超平面 W_r , 将工艺头实体的嵌入向量 h 和工艺尾实体的嵌入向量 t 投影到关系投影 $r_{\perp}$ 所在的超平面 W_r 中, 获得工艺头实体和工艺尾实体的嵌入向量在超平面 W_r 中的投影向量 $h_{\perp}$ 和 $t_{\perp}$ 。最后, 以关系投影 $r_{\perp}$ 作为平移向量, 在关

系投影超平面中完成工艺头实体到工艺尾实体的翻译过程, 即 $h_{\perp} + r_{\perp} \approx t_{\perp}$ 。因此, ERTransH 的得分函数可以被表示为公式(2-8)。

$$\begin{aligned} f_r(h, t) &= \|h_{\perp} + r_{\perp} - t_{\perp}\|_{L_1/L_2} \\ &= \|(h - w_r^T h w_r) + (r - s_r^T r s_r) - (t - w_r^T t w_r)\|_{L_1/L_2} \end{aligned} \quad (2-8)$$

式中 $f_r(h, t)$ ——工艺三元组 (h, r, t) 的得分函数;

h 、 r 、 t ——分别为工艺头实体 h 、工艺关系 r 和工艺尾实体 t 的嵌入向量, 并且 h 、 r 、 t 均为 k 维空间中的向量;

$\|x\|_{L_1}$ 、 $\|x\|_{L_2}$ ——分别为 x 的 1-范数和 2-范数;

$r_{\perp}$ ——工艺关系 r 在关系超平面 S_r 中的投影, 并且 $r_{\perp} = r - s_r^T r s_r$;

$h_{\perp}$ 、 $t_{\perp}$ ——分别表示 h 和 t 在关系投影超平面 W_r 中的投影, 并且

$$h_{\perp} = h - w_r^T h w_r, \quad t_{\perp} = t - w_r^T t w_r;$$

s_r ——关系超平面 S_r 对应的单位法向量;

w_r ——关系投影超平面 W_r 对应的单位法向量。

如公式(2-8)所示, 得分函数是一个距离函数。对于正确的工艺三元组, 希望得分函数会尽可能小, 以保证正确工艺三元组翻译过程的正确进行; 对于错误的工艺三元组, 希望得分函数大一点, 以增大错误工艺三元组翻译过程的不合理性。基于此, 使得所建立的 ERTransH 能够充分学习到工艺实体和工艺关系的语义信息。

2.3.2 ERTransH 模型训练方法

为了准确地学习复杂装备拆卸工艺实体的语义向量表示和工艺关系的语义向量表示, 在模型训练过程中, 在公式(2-8)中引入最大间隔法, 建立了一个基于边界的目标函数, 如公式(2-9)所示。

$$L = \sum_{(h, r, t) \in \Delta} \sum_{(h', r', t') \in \Delta'_{(h, r, t)}} \max(f_r(h, t) + \gamma - f_r(h', t'), 0) \quad (2-9)$$

式中 $\max(x, 0)$ —— x 和 0 之间取最大值;

$f_r(h, t)$ ——正确工艺三元组通过 ERTransH 得分函数计算的得分值;

$f_r(h', t')$ ——错误工艺三元组通过 ERTransH 得分函数计算的得分值;

γ ——一个大于 0 的边界超参数;

Δ ——复杂装备拆卸工艺知识图谱的三元组集合;

$\Delta'_{(h,r,t)}$ ——生成的错误三元组集合。

$\Delta'_{(h,r,t)}$ 是根据拆卸工艺知识图谱中的工艺三元组 (h,r,t) 生成的错误工艺三元组集合， $\Delta'_{(h,r,t)}$ 可由公式(2-10)构造。

$$\Delta'_{(h,r,t)} = \{(h',r,t) | h' \in E\} \cup \{(h,r,t') | t' \in E\} \quad (2-10)$$

公式(2-10)表明，针对一个正确工艺三元组 (h,r,t) ，其错误工艺三元组采用两种方式生成：（1）随机抽取工艺实体集合中一个工艺实体替换该正确工艺三元组的工艺头实体；（2）随机抽取工艺实体集合中一个工艺实体替换该正确工艺三元组的工艺尾实体。例如，为工艺三元组（气缸头，前序零件，螺栓【气缸左盖】）生成的错误工艺三元组如图2-11所示。事实上，生成的错误工艺三元组也可能是拆卸工艺知识图谱中的三元组，即该错误工艺三元组可能是正确的三元组。因此，称该错误工艺三元组为伪错误三元组，将不存在于工艺知识图谱的三元组称为真错误三元组，如表2-2所示。




图2-11 错误三元组生成示例

Fig. 2-11 Example of incorrect triple generation

若是在训练ERTransH时，将伪错误三元组（气缸头，前序零件，链轮【正时从动】）视为错误工艺三元组，则难以充分学习到“气缸头”与“链轮【正时从动】”的语义关系。因此，为了降低生成的错误工艺三元组中出现正确工艺三元组的概率，在生成错误工艺三元组的过程中，不能以相同的概率替换工艺头实体和工艺尾实体。一方面，在复杂装备拆卸工艺知识图谱中一种工艺关系可能对应多个工艺头实体和多个工艺尾实体；另一方面，在知识图谱中一种工艺关系对应的工艺头实体和工艺尾实体数量不一定相等。伯努利分布^[43]指出：如果一种关系下，一个头实体对应多个尾实体，增大替换头实体的机会就会降低错误三元组是伪错误三元组的概率；如果一种关系下，一个尾实体对应多个头

实体，增大替换尾实体的机会就会降低错误三元组是伪错误三元组的概率。

表2-2 生成的错误工艺三元组类别

Table 2-2 The type of the generated incorrect process triple

错误三元组生成方式	错误三元组类型	错误三元组示例
替换头实体生成的错误三元组	伪错误三元组	(右侧盖【气缸头】，前序零件，螺栓【气缸左盖】) (左侧盖【气缸头】，前序零件，螺栓【气缸左盖】)
	真错误三元组	(飞轮转子，前序零件，螺栓【气缸左盖】) (时规链条，前序零件，螺栓【气缸左盖】)
替换尾实体生成的错误三元组	伪错误三元组	(气缸头，前序零件，密封【气缸头右盖】) (气缸头，前序零件，链轮【正时从动】)
	真错误三元组	(气缸头，前序零件，右侧盖【气缸头】) (气缸头，前序零件，时规链条)

基于上述分析，本章采用伯努利分布生成包含工艺关系 r 的错误工艺三元组。给定一个复杂装备拆卸工艺知识图谱中的工艺三元组 (h, r, t) ，分三步构造其错误工艺三元组：(1) 统计在包含工艺关系 r 的所有工艺三元组中一个工艺头实体平均对应的工艺尾实体数量，记为 tph ；(2) 统计在包含工艺关系 r 的所有工艺三元组中一个工艺尾实体平均对应的工艺头实体数量，记为 hpt ；(3) 以 $\frac{tph}{tph + hpt}$ 的概率替换工艺三元组 (h, r, t) 中的工艺头实体，以 $\frac{hpt}{tph + hpt}$ 的概率替换工艺三元组 (h, r, t) 中的工艺尾实体。这大大提升了错误工艺三元组的质量，为提高翻译模型的知识表示能力提供了支持。

综上所述，ERTransH 的详细训练过程可以表示为图 2-12。通过 ERTransH，工艺实体和关系的语义向量可以表示为表 2-3 和表 2-4。

表2-3 拆卸工艺知识图谱部分工艺实体向量展示

Table 2-3 Partial process entity vectors in knowledge graph of disassembly process

实体	实体语义向量	向量维度
飞轮转子	[-0.0278, 0.1088, 0.1975,..., -0.1068, 0.1111, 0.0159]	60
定子总成	[0.1828, 0.1137, 0.1083,..., 0.0412, 0.0687, 0.0807]	60
...	...	60
右侧盖【气缸头】	[-0.1219, 0.1145, 0.0502,..., 0.0617, 0.1463, -0.1553]	60

表2-4 复杂装备拆卸工艺知识图谱部分工艺关系向量展示

Table 2-4 Partial process relation vectors in knowledge graph of disassembly process

关系	关系语义向量	向量维度
功能	[0.2651, -0.0777, -0.1416,..., -0.2008, -0.3393, 0.0952]	60
前序零件	[0.1775, 0.3957, 0.0346,..., -0.0481, -0.0711, -0.0166]	60
...	...	60
使用工具	[0.1858, 0.1482, -0.0866,..., 0.2064, -0.2315, -0.2089]	60




图2-12 ERTransH 训练流程

Fig. 2-12 Training process of the ERTransH

2.4 面向复杂装备拆卸工艺知识图谱的 ERTransH 模型案例分析

本节中，以 JH70 发动机作为复杂装备的代表，将所建立的 ERTransH 应用在 JH70 发动机拆卸工艺实体和工艺关系的补全中。通过补全 JH70 发动机拆卸工艺知识图谱中缺失工艺头尾实体和工艺关系的拆卸工艺，验证 ERTransH 模型提取拆卸工艺知识图谱中工艺实体和工艺关系语义特征的能力；并将 ERTransH 模型应用在几个公共数据集的链接预测中，验证 ERTransH 模型的泛化性能。

2.4.1 实验数据

在复杂装备拆卸工艺补全实验中，采用 JH70 发动机拆卸工艺碎片化知识图谱库中所有工艺三元组对模型进行训练和测试，并将数据集简称为发动机拆卸工艺知识图谱（engine disassembly process knowledge graph, EDPKG）。所采用的发动机拆卸工艺知识图谱中的工艺三元组形式如表 2-5 所示。实验中，采用 1/5 的数据对 ERTransH 模型进行训练，4/5 的数据对 ERTransH 模型进行测试。

表2-5 部分发动机拆卸工艺知识图谱三元组

Table 2-5 Partial triple in EDPKG

头实体	关系	尾实体
气缸头	前序零件	密封【气缸头盖罩】
箱体组合【中右侧】	前序零件	定子总成
张紧杆组件【张紧链轮】	前序零件	弹簧【张紧】
螺栓【箱底】	功能	用于配合张紧杆组，位于曲轴箱体底部
左侧盖【气缸头】	功能	用于封闭气缸头
时规链条	前序零件	气缸体
...	...	...
气缸体	前序零件	导向滚轮【链条】
气缸头	前序零件	链轮【正时从动】
导向销【气缸体】	使用工具	小三叉套筒扳手
链轮【正时从动】	使用工具	一字螺丝刀

此外，为了验证 ERTransH 模型的泛化能力，进一步，将 ERTransH 模型应用自然语言处理的四个公共数据集，包括 Wordnet 的两个子数据集：WN18 数据集和 WN18RR 数据集；Freebase 的两个子数据集：具有稠密关系的 FB15K 数据集和 FB15K-237 数据集。表 2-6 显示四个数据集的具体信息，包括关系数量，实体数量，训练集数据量，验证集数据量和测试集数据量。

表2-6 链接预测的公共数据集详细信息

Table 2-6 Public dataset details for link prediction

数据集	关系/个	实体/个	三元组		
			训练集/个	验证集/个	测试集/个
WN18	18	40,943	141,442	5,000	5000
FB15K	1,345	14,951	483,142	50,000	59,071
WN18RR	11	40,943	86,835	3,034	3,134
FB15K-237	237	14,541	271,115	17,535	20,466

2.4.2 模型评估

为了能准确地评估模型提取发动机拆卸工艺实体和工艺关系语义特征的能

力,通过两个部分来综合评估模型的性能:一是对工艺三元组中缺失的工艺实体进行预测,用来评估模型提取工艺实体语义信息的能力,即对给定的缺失尾实体的工艺三元组 $(h,r,?)$ 和缺失工艺头实体的工艺三元组 $(?,r,t)$,分别预测工艺尾实体和预测工艺头实体;二是对工艺三元组中缺失的工艺关系进行预测,用来评估模型提取工艺关系语义信息的能力,即对给定的缺失工艺关系的工艺三元组 $(h,?,t)$,预测工艺实体 h 和 t 之间的工艺关系。

在工艺实体预测中,采用 Mean Rank 和 Hits@10 来评估模型的工艺实体预测效果。类似地,在工艺关系预测中,采用 Mean Rank 和 Hits@N 来评估模型的工艺关系预测效果。注意到, Hits@10 为 Hits@N 中 $N=10$ 的特殊情况。通过工艺实体预测和工艺关系预测效果来表征模型提取知识图谱中实体和关系的语义信息能力。Mean Rank 和 Hits@N 的计算方式如下所示。

Mean Rank: 对每个测试工艺三元组 (h,r,t) ,首先用知识图谱中的每个工艺实体替换工艺三元组 (h,r,t) 中的工艺尾实体 t ,得到重组的工艺三元组;其次,通过得分函数 $f_r(h,t)$ 计算重组工艺三元组和测试工艺三元组 (h,r,t) 的得分;随后,将这些工艺三元组的工艺尾实体按照得分升序排列;最后,找到测试工艺三元组 (h,r,t) 中的工艺尾实体 t 在该序列中的位置排名。同理,计算得到工艺头实体的位置排名。最后,将所有测试工艺三元组的工艺头实体和工艺尾实体的排名取平均值得到实体 Mean Rank,如公式(2-11)所示。

$$\text{Mean Rank} = \frac{\sum_{(h,r,t) \in Tt} \text{Rank}((t, f_r(h,t)), S_t) + \sum_{(h,r,t) \in Tt} \text{Rank}((h, f_r(h,t)), S_h)}{2 * |Tt|} \quad (2-11)$$

式中 $\text{Rank}(x, X)$ ——元素 x 在集合 X 中的位置;

Tt ——测试工艺三元组集合;

$|Tt|$ ——测试工艺三元组的数量;

S_t ——测试工艺三元组 (h,r,t) 的尾实体预测得分序列;

S_h ——测试工艺三元组 (h,r,t) 的头实体预测得分序列;

S_r ——测试工艺三元组 (h,r,t) 的关系预测得分序列。

具体地, S_t 、 S_h 和 S_r 如公式(2-12)所示。

$$\begin{aligned} S_t &= \text{sort} \left\{ (t', f_r(h, t')) \mid t' \in E \right\}, \quad S_h = \text{sort} \left\{ (h', f_r(h', t)) \mid h' \in E \right\}, \\ S_r &= \text{sort} \left\{ (r', f_r(h, t)) \mid r' \in R \right\} \end{aligned} \quad (2-12)$$

式中 $\text{sort}\{(x, y)_n\}$ ——按照 y 对序列升序排列；

E 、 R ——分别为测试集的工艺实体集合和工艺关系集合。

采用相同的方法，用知识图谱中的每种工艺关系替换三元组 (h, r, t) 中的工艺关系 r ，通过得分函数 $f_r(h, t)$ 计算每个替换工艺关系以后的工艺三元组得分；随后，将这些工艺三元组的工艺关系按照得分升序排列；最后，找到测试工艺三元组 (h, r, t) 中的工艺关系 r 在该序列中的位置排名，即工艺关系的位置排名。均值化所有测试工艺三元组的工艺关系的位置排名得到关系 Mean Rank，如公式所示(2-13)。

$$\text{Mean Rank} = \frac{\sum_{(h, r, t) \in Tt} \text{Rank}((r, f_r(h, t)), S_r)}{|Tt|} \quad (2-13)$$

Hits@N: 对于上述的升序序列 S_t 和 S_h ，如果测试工艺三元组的正确答案排在前 N ，则计数加 1，最后，对计数求平均值，得到实体的 Hits@N；同理，对上述的升序序列 S_r 执行相同操作，得到关系的 Hits@N。实体的 Hits@N 和关系的 Hits@N 分别如公式(2-14)和公式(2-15)所示。

$$\text{Hits@N} = \frac{\sum_{(h, r, t) \in Tt} s_N(\text{Rank}((t, f_r(h, t)), S_t))}{2 * |Tt|} + \frac{\sum_{(h, r, t) \in Tt} s_N(\text{Rank}((h, f_r(h, t)), S_h))}{2 * |Tt|} \quad (2-14)$$

$$\text{Hits@N} = \frac{\sum_{(h, r, t) \in Tt} s_N(\text{Rank}((r, f_r(h, t)), S_r))}{|Tt|} \quad (2-15)$$

式中 s_N ——计数函数，如公式(2-16)所示；

$s_N(\text{Rank}(x, X))$ 用来判断元素 x 是否是集合 X 中的前 N 个元素，若是则为 1，否则为 0，如公式(2-16)所示。

$$s_N(\text{Rank}(x, X)) = \begin{cases} 1 & \text{Rank}(x, X) \leq N \\ 0 & \text{Rank}(x, X) > N \end{cases} \quad (2-16)$$

上述的 Mean Rank 和 Hits@N 被称为“Raw”。事实上，在为知识图谱中测试工艺三元组生成的错误的工艺三元组也有可能是正确的，那么将其排在测试工艺三元组之前并没有错。为了消除这个因素，在对每个测试工艺三元组和它的重组工艺三元组排序之前，首先对每个测试工艺三元组的重组工艺三元组进行筛选，去除伪错误工艺三元组，该操作称之为称为“Filt”。得分函数 $f_r(h, t)$ 本质是一种距离函数， $f_r(h, t)$ 越小表明模型的翻译效果越好，反之效果越差。

因此, Mean Rank 越小, Hits@N 越大表示预测越准。

2.4.3 实验设置

本节中, ERTransH 分别应用在 EDPKG 的工艺补全和公共数据集的链接预测中, 并且实验中采用 Pytorch 框架和 Adam 优化方法对所建立的 ERTransH 模型进行参数优化实验。

参数优化实验分为两部分。第一部分是 ERTransH 模型在 EDPKG、WN18 和 FB15K 上的实体补全/预测参数优化实验。第二部分是 ERTransH 模型在 EDPKG、WN18RR、FB15K 和 FB15K-237 上的关系补全/预测参数优化实验。

(1) 实体补全/预测参数优化实验

在实体补全/预测实验中, 学习率 (lr)、边界超参数 (γ)、实体和关系嵌入维数 (k)、批量大小 (B) 和模型训练次数 (e) 均是需要优化的超参数。ERTransH 在 EDPKG、WN18 和 FB15K 上的超参数优化空间如表 2-7 所示。

表2-7 ERTransH 模型在 EDPKG、WN18 和 FB15K 上的超参数优化空间
Table 2-7 The hyperparameter optimization spaces of ERTransH on EDPKG, WN18 and FB15K

超参数	lr	γ	k	B	e
EDPKG	{0.01,0.001}	{1,2,4,8,12}	{40,60,100}	{10,20,40}	100
WN18	{0.01,0.001}	{1,2,4,6}	{50,100}	{1200,2400,4800}	500
FB15K	{0.01,0.001}	{1,1.5,2,2.5}	{50,100}	{1200,2400,4800}	500

通过多次实验, ERTransH 模型取表 2-8 中的超参数时, ERTransH 在 EDPKG、WN18 和 FB15K 上分别取得最优值。

表2-8 ERTransH 模型在 EDPKG、WN18 和 FB15K 上的最优参数设置
Table 2-8 The optimal hyperparameters of ERTransH on Edpkg, WN18 and FB15K

超参数	lr	γ	k	B	e
EDPKG	0.001	8	60	10	100
WN18	0.001	2	50	1200	500
FB15K	0.001	2.5	100	2400	500

(2) 关系补全/预测参数优化实验

在关系补全/预测实验中, 将 ERTransH 模型应用在 EDPKG、WN18RR、FB15K 和 FB15K-237 上来验证 ERTransH 提取知识图谱中关系的语义信息的能力。ERTransH 在四个数据集的超参数优化空间如表 2-9 所示。

通过多次实验, ERTransH 模型在 EDPKG、WN18RR、FB15K 和 FB15K-237 上的最优参数如表 2-10 所示。

表2-9 ERTransH 在四个数据集上的超参数优化空间

Table 2-9 The hyperparameter optimization spaces of ERTransH on four datasets

超参数	lr	γ	k	B	e
EDPKG	{0.01,0.001}	{1,2,4,8,12}	{40,60,100}	{10,20,40}	100
WN18RR	{0.01,0.001}	{0.5,1,2,4}	{50,100}	{1200,2400,4800}	500
FB15K	{0.01,0.001}	{1,1.5,2,2.5}	{50,100}	{1200,2400,4800}	500
FB15K-237	{0.01,0.001}	{0.5,1,2,4}	{50,100}	{1200,2400,4800}	500

表2-10 关系补全/预测中 ERTransH 模型不同数据集下的最优参数

Table 2-10 The optimal hyperparameters of ERTransH on various datasets in relation completion/prediction

数据集	EDPKG	WN18RR	FB15K	FB15K-237
lr	0.001	0.001	0.001	0.01
γ	8	4	2.5	4
k	60	100	100	100
B	10	4800	1200	4800
e	100	500	500	500

2.4.4 对比实验

在本节中，以补全工艺三元组中缺失部分的精度来验证所建立的 ERTransH 在提取复杂装备拆卸工艺知识图谱工艺实体和工艺关系语义特征的有效性；此外，为了验证所建立的 ERTransH 模型的泛化性，将所建立的 ERTransH 模型应用在几个公共数据集上进行实体预测和关系预测实验。

(1) JH70 发动机拆卸工艺三元组补全效果对比实验

在发动机拆卸工艺三元组补全对比实验中共包含两组实验，一组为发动机拆卸工艺实体的补全；一组为发动机拆卸工艺关系的补全。以补全尾实体为例，工艺实体的补全是根据已知的工艺头实体和工艺关系，推断最可能存在的工艺尾实体。例如：图 2-13 中“导向滚轮【链条】”缺失了功能“用于链条导向”，工艺实体补齐就是找到“用于链条导向”。同理，工艺关系补齐是寻找工艺实体之间最可能存在的工艺关系。例如：图 2-13 中工艺实体“导向滚轮【链条】”与“导向销轴【气缸体】”之间缺失关系“前序零件”，工艺关系补齐就是找到“前序零件”。

在发动机拆卸工艺实体的补全实验中，以 EDPKG 为数据集；采用 RESCAL 模型、SE 模型、SME (Linear) 模型、SME (Bilinear) 模型等传统知识语义向量化表达模型和 TransE 模型、TransH 模型、TransD 模型等翻译模型作为对比模型；并采用 Raw Mean rank、Filt Mean rank、Raw Hits@10 和 Filt Hits@10 来评估发动机拆卸工艺实体补全的准确性。对比模型和 ERTransH 在 EDPKG 上的工艺实体补全结果如表 2-11 所示。




图2-13 工艺实体和工艺关系预测示例

Fig. 2-13 Example of predicting the process entity and process relation

表2-11 发动机拆卸工艺实体补全结果

Table 2-11 Results of engine disassembly process entity completion

评价	Mean Rank		Hits@10	
	Raw	Filt	Raw	Filt
RESCAL	43	39	33.1%	40.4%
SME (Linear)	29	24	42.7%	49.3%
SME (Bilinear)	36	31	22.8%	45.6%
TransE	28	23	42.7%	50.7%
TransH	30	26	41.9%	51.5%
TransD	31	26	45.6%	52.9%
ERTransH	27	22	48.5%	55.9%

表 2-11 中的实验结果表明，相比于传统知识表示学习模型和翻译模型，所建立的 ERTransH 在 EDPKG 上实现了最佳的工艺实体补全精度，说明了 ERTransH 模型能够有效提取复杂装备拆卸工艺知识图谱中工艺实体的语义特征。

相比于传统的知识表示学习模型，ERTransH 在 Raw Mean Rank 上提升 2-16、在 Filt Mean Rank 上提升 2-17、在 Raw Hits@10 上提升 5.8%-25.7%、在 Filt Hits@10 上提升 6.6%-15.5%。实验结果表明相比于传统的知识表示学习模型，ERTransH 更能够提取发动机拆卸工艺知识图谱中实体的语义特征，因而，ERTransH 能够完成发动机拆卸工艺实体补全。相比于对比的翻译模型，ERTransH 在 Raw Mean Rank 上提升 2-4、在 Filt Mean Rank 上提升 1-4、在 Raw Hits@10 上提升 2.9%-6.6%、在 Filt Hits@10 上提升 3.0%-5.2%。实验结果表明通过所建立的 ERTransH 有效地提升了翻译模型的发动机拆卸工艺实体补全精度，验证了 ERTransH 的有效性和考虑拆卸工艺知识图谱复杂关系的必要性。上

述结果表明所建立的 ERTransH 能有效支持发动机拆卸工艺知识图谱中工艺三元组的实体补全任务。

此外,为了验证 ERTransH 提取发动机拆卸工艺知识图谱中工艺关系语义信息的能力,将 ERTransH、TransH 和 TransD 分别应用在 EDPKG 中的工艺关系预测任务中,预测缺失的发动机拆卸工艺关系,并采用 Filt Mean Rank、Filt Hits@1、Filt Hits@3 和 Filt Hits@10 作为工艺关系预测精度。实验结果如表 2-12 所示。

表2-12 发动机拆卸工艺关系补全结果

Table 2-12 Results of engine disassembly process relation completion

评估	Filt Mean Rank	Filt Hits@1	Filt Hits@3	Filt Hits@10
TransH	1.3	82.4%	1.0%	1.0%
TransD	1.3	76.5%	1.0%	1.0%
ERTransH	1.2	88.2%	1.0%	1.0%

表 2-12 表明,相比于 TransH 和 TransD,本章所建立的 ERTransH 能够更有效地提取发动机拆卸工艺知识图谱中工艺关系的语义信息。因而,在工艺关系预测中,所建立的 ERTransH 在 Filt Mean Rank、Filt Hits@1、Filt Hits@3 和 Filt Hits@10 上取得了最好的结果。在 Filt Mean Rank 和 Filt Hits@1 上,ERTransH 显著优于 TransH 和 TransD。实验结果验证了,通过考虑工艺关系多样性的 ERTransH 能有效提升工艺关系预测精度;在 Filt Hits@3 和 Filt Hits@10 上,ERTransH、TransH 和 TransD 三者取得的结果一样,均为最高值。实验表明,翻译模型能够有效地提取拆卸工艺知识图谱中工艺关系的语义信息,尤其是本章建立的 ERTransH。

发动机拆卸工艺实体补全实验和发动机拆卸工艺关系补全实验表明,本章建立的 ERTransH 能够有效提取工艺实体和工艺关系的语义信息。因而,通过 ERTransH 学习到的向量能够表征发动机拆卸工艺知识图谱中的工艺实体和工艺关系,能够为工艺知识的语义相似度计算提供支撑。

(2) 基于公共数据集的实体预测和关系预测对比实验

为了进一步验证 ERTransH 的泛化性,将 ERTransH 应用在公开数据集 WN18 和 FB15K 进行实体预测实验,并将 ERTransH 应用在公开数据集 WN18RR、FB15K、FB15K-237 上进行关系预测实验。

在实体预测实验中,采用 Unstructured、RESCAL、SE、SME (Linear)、SME (Bilinear)、LFM、TransE、TransH、TransR、CTransR 和 TransD 模型作为对比模型,并采用 Raw Mean rank、Filt Mean rank、Raw Hits@10 和 Filt Hits@10 来评估模型的实体预测精度。ERTransH 和对比模型在 WN18 和 FB15K 上的实体预测结果如表 2-13 所示。

表2-13 ERTransH 和对比模型在 WN18 和 FB15K 上的实体预测结果
Table 2-13 Entity prediction results of ERTransH and baselines on WN18 and FB15K

数据集 评价	WN18				FB15K			
	Mean Rank		Hits@10		Mean Rank		Hits@10	
	Raw	Filt	Raw	Filt	Raw	Filt	Raw	Filt
Unstructured	315	304	35.3%	38.2%	1074	979	4.5%	6.3%
RESCAL	1180	1163	37.2%	52.8%	828	683	28.4%	44.1%
SE	1011	985	68.5%	80.5%	273	162	28.8%	39.8%
SME (Line)	545	533	65.1%	74.1%	274	154	30.7%	40.8%
SME (Bilinear)	526	509	54.7%	61.3%	284	158	31.3%	41.3%
LFM	469	456	71.4%	81.6%	283	164	26.0%	33.1%
TransE	263	251	75.4%	89.2%	243	125	34.9%	47.1%
TransH	400.8	388	73%	82.3%	212	87	45.7%	64.4%
TransR	238	225	79.8%	92.0%	198	77	48.2%	68.7%
CTransR	231	218	79.4%	92.3%	199	75	48.4%	70.2%
TransD	224	212	79.6%	92.2%	194	91	53.4%	77.3%
ERTransH	258	246	79.9%	93.2%	189	54	49.1%	71.1%

表 2-13 表明, 除 TransD 模型外, ERTransH 在 WN18 和 FB15K 上实现了最佳实体预测精度。ERTransH 的实体预测精度与 TransD 相当, 但是根据表 2-1, TransD 的参数复杂度显著高于 ERTransH。因此, ERTransH 的实体预测性能优于 TransD。综合来看, ERTransH 模型能够有效提取 WN18 和 FB15K 中实体和关系的语义特征, 验证了 ERTransH 的泛化能力。

在 WN18 上, ERTransH 的实体预测精度明显优于 TransH 和其他非翻译模型。与 TransR、CTransR 和 TransD 相比, ERTransH 在 Hits@10 上取得最佳的效果, 这表明大多数测试三元组的头/尾实体在头/尾实体得分序列中排名前 10。ERTransH 在 Mean Rank 上表现不佳, 这是因为少数测试三元组的头/尾实体在头/尾实体得分中排名靠后。ERTransH 在模型结构和参数复杂度上与 TransH 模型最为相近。与 TransH 相比, ERTransH 可以显著提高 TransH 处理简单关系的能力。例如, 与 TransH 相比, ERTransH 的 Raw Mean Rank 和 Filt Mean Rank 分别提升了 142.8 和 122; ERTransH 的 Raw Hits@10 和 Filt Hits@10 分别提升 6.6% 和 9%。结果表明, 通过考虑关系的多样性, ERTransH 可以有效地处理简单关系, 从而有效地完成实体预测。

在 FB15K 上, ERTransH 的实体预测精度显著优于除 TransD 以外的其他对比模型, 并且 ERTransH 的实体预测精度与 TransD 不分上下。在 Mean Rank 上, ERTransH 的实体预测精度高; 在 Hits@10 上, TransD 的实体预测精度高。但是, ERTransH 的参数复杂度显著小于 TransD。因此, ERTransH 在整体上优于 TransD。与 TransH、TransR 和 CTransR 相比, ERTransH 在所有评价指标上提升显著。尤其是与 TransH 相比, ERTransH 的 Raw Mean Rank 和 Filt Mean Rank

分别提升了 23 和 33; ERTransH 的 Raw Hits@10 和 Filt Hits@10 分别提升 3.4% 和 6.7%。所建立的 ERTransH 可以有效地在具有复杂关系的数据集上实现实体预测, 即 ERTransH 可以有效地解决知识图谱的复杂关系问题。

实体预测的结果表明, 通过考虑关系自身的多样性, ERTransH 能够有效提取知识图谱的实体和关系的语义信息, 获得能够有效表征实体的语义向量。综合上述分析, ERTransH 可以有效地解决知识图谱的简单关系和复杂关系。

为了验证 ERTransH 的关系嵌入向量包含关系的多样性信息, 将 ERTransH、TransH 和 TransD 应用于 WN18RR、FB15K 和 FB15K-237 上进行关系预测的对比实验。此外, 选择 Filt Mean Rank、Filt Hits@1、Filt Hits@3 和 Filt Hits@10 作为关系预测准确性的评价指标。关系预测的实验结果如表 2-14 所示。

表2-14 ERTransH、TransH 和 TransD 模型的关系预测实验结果
Table 2-14 Relation prediction results of ERTransH, TransH and TransD

数据集		WN18RR	FB15K	FB15K-237
TransH	Mean Rank	5	111	28
	Hits@1	43.2%	40.7%	43.4%
	Hits@3	54.0%	55.6%	50.5%
	Hits@10	63.8%	66.4%	57.0%
TransD	Mean Rank	3	5.4	2.3
	Hits@1	38.2%	72.8%	84.9%
	Hits@3	69.8%	86.4%	93.5%
	Hits@10	99.9%	93.6%	96.6%
ERTransH	Mean Rank	2	4.6	2.1
	Hits@1	43.7%	74.9%	86.9%
	Hits@3	78.3%	87.8%	94.2%
	Hits@10	99.9%	94.3%	96.7%

表 2-14 表明, 与 TransH 和 TransD 相比, ERTransH 模型在三个公共数据集上的所有评价指标均取得了最好的结果。在三个数据集中, WN18RR 包含 11 个关系, FB15K 包含 1345 个关系, FB15K-237 包含 237 个关系。就 Mean Rank 而言, 与 TransH 相比, 数据集包含的关系越多, ERTransH 提高的关系预测精度就越高。例如, 在 WN18 上 Mean Rank 增加 3, 在 FB15K-237 上 Mean Rank 增加 26, 而在 FB15K 上 Mean Rank 增加 106。与 TransD 相比, ERTransH 的 Mean Rank 在 WN18、FB15K-237 和 FB15K 上分别在增加 1、0.2 和 0.8。

从 Hits@N 来看, ERTransH 在三个数据集上的关系预测精度显著高于 TransH 和 TransD。这是由于 TransH 和 TransD 在建模过程中没有考虑关系的多样性问题。因而, TransH 和 TransD 难以有效提取关系的语义特征。与 TransH 相比, ERTransH 的 Hits@1、Hits@3 和 Hits@10 在 WN18RR 上分别提高 0.7%、24.3%和 36.1%; 在 FB15K 上分别提高 34.2%、32.2%和 27.9%; 在 FB15K-237 上分别提高 43.5%、43.7%、39.7。与 TransD 相比, ERTransH 的 Hits@1、Hits@3

和 Hits@10 在 WN18RR 上分别提高 5.5%、8.5%和 0%；在 FB15K 上分别提高 2.1%、1.4%和 0.7%；在 FB15K-237 上分别提高 2%、0.7%和 0.1%。

综上所述，在公共数据集上，ERTransH 能直接处理关系的多样性和实体的复杂多样性特征，从而能有效地提取实体和关系的语义特征并实现实体和关系的准确预测。

通过上述分析可得，ERTransH 通过考虑关系的多样性并为每个关系构建关系超平面，考虑实体的复杂关系并为每个关系投影构建关系投影超平面的方式显著提高了发动机拆卸工艺关系补全精度和发动机拆卸工艺实体补全精度。ERTransH 可以有效地实现发动机拆卸工艺知识的补全。因此，ERTransH 解决了发动机拆卸工艺知识图谱的复杂关系问题，有效地提取了实体和关系的语义信息，支持工艺知识的语义相似度量。特别是在关系较多的数据集上，ERTransH 的关系补全精度显著高于 TransH。在复杂装备拆卸工艺知识图谱的不断扩建中，工艺实体之间的关系更加复杂多样。因此，通过 ERTransH 模型得到的复杂装备拆卸工艺实体和工艺关系的语义向量可以表征对应的工艺实体和工艺关系。此外，ERTransH 的泛化性强，能够为其他领域的知识语义向量化表达提供借鉴。

2.5 本章小结

针对难以有效量化具有相同语义信息而表达不一致的工艺实体间相似度问题，建立了一种面向复杂装备拆卸工艺知识图谱的工艺实体和关系双投影超平面模型。通过分析复杂装备拆卸工艺知识图谱中工艺关系的多样性和工艺实体的复杂多样性，重新定义了拆卸工艺知识图谱的复杂关系。所建立的模型能有效提取拆卸工艺知识图谱的复杂关系特征，从而，为每个复杂装备拆卸工艺实体和工艺关系学习一个能够表征实体和关系语义信息的语义向量。为了验证该模型的有效性和语义信息提取能力，将该模型与传统的模型在 JH70 发动机拆卸工艺知识图谱上进行工艺实体和工艺关系补全对比实验。实体补全结果显示相比于其他模型，本章建立的模型在 Mean Rank 提升 4 以上、Hits@10 提升 3% 以上；关系补全结果显示相比于其他模型，所建立模型 Filt Hits@1 提升 5% 以上。实验结果表明了该模型能有效提取 JH70 发动机拆卸工艺实体和工艺关系的语义信息。为了验证模型的泛化能力，采用了四个公共数据集进行实体预测和关系预测实验，实验结果表明，该模型的实体预测和关系预测精度取得了最好的结果。这表明该模型能有效提取实体和关系的语义信息，通过该模型学习到的语义向量能够表征实体和关系。本章的研究内容可为实体类别预测、复杂装备拆卸工艺碎片化知识图谱的相似度量和实体链接中实体的语义相似度量提供基础技术支持。

第3章 复杂装备拆卸工艺知识图谱的实体类别预测方法

3.1 引言

如前所述,由于拆卸工艺模型构建设没有一个严格的标准、每个工艺建模人员的专业水平和对问题的理解不同、现有的工艺知识相关信息缺乏等问题,使得工艺知识检索和应用难以实现智能化和自动化。例如,在某碎片化知识图谱中,工艺实体“螺栓【右箱】”所属的类别为“连接零件”,而工艺实体“套筒【离合器】”的类别信息缺失。如果按照技术需求,手动将所有信息进行补全,则需耗费大量的人力,且其信息的准确性也难以保证。针对这一个问题,本章以实体的类别信息自动补全为例,研究基于已有知识图谱的学习,预测实体缺失的类别信息的相关方法,为后续碎片化知识图谱的相似度量与工艺知识的检索提供信息支持。

工艺实体的类别信息对于提升拆卸工艺碎片化知识图谱的完整度和可用性有至关重要的作用。例如,在碎片化知识图谱的实体相似度量中,可以通过实体的类别对不相似的实体进行筛选;在工艺知识检索中,可以通过实体的类别完成对候选实体的剪枝,帮助用户准确快速地匹配到与查询目标相关联的知识,快速完成工艺知识检索。拆卸工艺碎片化知识图谱是由同种类型和不同类型的拆卸零部件相互耦合,并且按照由外到内和一定的拆卸顺序构建而成。若根据零件所处的位置,零件可能位于装备外层,也可能处于装备内部;若根据零件所属的类型,同一条工艺路径中的零件可能属于不同的零件类型。因此,零部件具有层次结构特征。若按照零件的先后顺序来看,零部件具有明显的序列特征。因此,拆卸工艺碎片化知识图谱中的实体明显具有层次结构特征和序列特征。经文献分析,当前的机器学习方法难以同时有效提取工艺实体的层次结构特征和序列特征。例如,在序列特征提取方面见长的 LSTM 仅能够有效提取工艺实体的序列特征,无法有效提取层次结构特征;层次特征提取方面见长的决策树仅能有效提取工艺实体的层级结构特征,无法有效提取工艺实体的序列特征。因此,使用当前的机器学习方法难以保证工艺实体类别预测的精度,易导致类别预测不准。

为了能够使得模型充分提取复杂装备拆卸工艺实体的层次结构特征和序列特征,以保证工艺实体类别预测的精度,本章通过将 LSTM 与决策树融合在一起,建立一种样本自适应 LSTM 神经树模型,通过学习完备信息的实体的特征,

来准确预测实体的类别。样本自适应 LSTM 神经树模型仍然是以树结构为框架,并基于 LSTM 设计特征提取模块、路由选择模块和类别标签预测模块作为树模型的增长节点。通过树结构和三种模块,样本自适应 LSTM 神经树模型具备了决策树模型的层次结构特征提取能力和 LSTM 的序列特征处理能力。因此,样本自适应 LSTM 神经树模型能够同时提取拆卸工艺实体的层次结构特征和序列特征,从而有效实现复杂装备拆卸工艺实体的类别预测。

3.2 复杂装备拆卸工艺实体特征及学习模型分析

在人脑的认知过程中,获取的某一事物的信息越多,对事物的了解越全面。因此,在工艺实体类别预测中,对工艺实体的认知越全面,越容易准确地预测出工艺实体所属的类别。为了准确预测实体的类别,本节对工艺实体的特征进行分析,并分析能够充分提取实体特征的学习模型。

3.2.1 复杂装备拆卸工艺实体特征分析

为了满足拆卸复杂装备的目标要求,复杂装备拆卸建模人员在构建拆卸工艺碎片化知识图谱时,通常采取由外到内和从粗略到详细的逻辑顺序,构建出具有严密数学逻辑和容易理解的知识图谱。此外,在复杂装备中,零件具有先后的拆卸顺序。因此,复杂装备拆卸工艺知识图谱中的工艺实体具有层级结构特征和序列特征。

一方面,同属于不同零件类别的工艺实体具有明显的层级结构特征。以图 3-1 中 JH70 发动机拆卸工艺知识图谱为例,“从动减速齿轮”所处的层级结构可以描述为“传动零件→从动减速齿轮”,而“弹性挡圈【启动轴】”所属的层级结构为“其他零件→弹性挡圈【启动轴】”。“从动减速齿轮”的部分上下文属于传动零件系列,“弹性挡圈【启动轴】”的部分上下文属于其他零件系列,因而“从动减速齿轮”与“弹性挡圈【启动轴】”所属的层级结构明显不同。在复杂装备拆卸工艺知识图谱中,存在多种零件类别,例如:连接零件、轴系零件、箱体零件、组合零件等等。因此,在复杂装备拆卸工艺知识图谱中,工艺实体具有明显的层次结构特征。

另一方面,同属于相同零件类别和不同零件类别的工艺实体具有明显的序列特征。以图 3-1 中的 JH70 发动机拆卸工艺知识图谱为例,“从动减速齿轮→主动齿轮【离合器】→齿轮外套【离合器】”中“主动齿轮【离合器】”的上下文完全属于传动零件,并且各零件的拆除顺序依次从右到左;而“回位弹簧【启动轴】→回位弹簧座【启动轴】→弹性挡圈【启动轴】”中“回位弹簧座【启动轴】”的上下文完全属于其他零件,并且各零件的拆除顺序依次从右到左。因此,

同属于相同零件类别的发动机拆卸工艺实体具有明显的序列特征。此外，不同零件类别之间的发动机拆卸工艺实体之间存在明显的序列特征。图 3-1 中，“齿轮外套【离合器】→离合器→蝶形垫圈【离合器】”中三个零件的类别各不相同，并且各零件的拆除顺序依次从右到左。因此，同属于不同零件类别的发动机拆卸工艺实体具有明显的序列特征。上述结果表明，在复杂装备拆卸工艺知识图谱中，工艺实体具有明显的序列特征。




图3-1 JH70 发动机拆卸工艺知识图谱部分示例

Fig. 3-1 Part of knowledge graph of JH70 engine disassembly process

如何能同时有效地提取复杂装备拆卸工艺实体的层次结构特征和序列特征是准确预测工艺实体类别的关键难题。决策树模型以有效提取数据的层次结构特征而著称，LSTM 以有效处理具有明显序列特征的数据而被广泛应用。本章预计将决策树与长短时记忆网络结合起来，构建一种能够同时有效提取复杂装备拆卸工艺实体层次结构特征和序列特征的模型。下面详细分析决策树模型与 LSTM。

3.2.2 决策树类别预测模型分析

决策树^[140]是由 Hunt 等人提出的一种高效的分类和回归方法。一般地，决策树可以分为多叉决策树算法和二叉决策树算法，例如，ID3 算法和 C4.5 算法既可以建模为多叉决策树又可以建模为二叉决策树，而分类回归树只能建模为

二叉树。分类回归树是一种经典的二叉树算法，它通过模拟人类做决策的过程，能够有效实现数据分类和回归。分类回归树算法采用二分递归分割的技术将当前样本集分为两个子样本集，使得生成的每个非叶子节点都有两个分支。非叶子节点的特征取值为 True 和 False，左分支取值为 True，右分支取值为 False，因此分类与回归树算法生成的决策树是结构简洁的二叉树。分类与回归树可以处理连续型变量和离散型变量，利用训练数据递归的划分特征空间进行建树。

相比于神经网络模型和其他机器学习方法，决策树模型在解决分类问题方面效果突出，具体地，决策树模型同时具备以下四个优点：

（1）模型简单，能有效提取层次结构：决策树模型以数据的层次结构信息建模，可以自动捕捉数据中的层次结构特征，无需构建复杂的模型，不需要太多的计算时间；

（2）强大的非线性处理能力：决策树模型可以自动捕捉变量之间的复杂关系，并且可以很好地表示多个变量之间复杂的非线性关系；

（3）分类精度高，适应范围广：决策树可以很好地处理大规模数据集，并且具有较高的分类精度；同时决策树可以处理多种数据类型，包括连续型数据和离散型数据；

（5）可解释性强，易于理解：决策树模型模拟人的决策过程，具有较强的可解释性，易于人们理解和解释，可以作为决策的一种重要参考。

工艺实体呈现明显的层次结构信息，因而，本章拟改进决策树模型使得改进的模型具备决策树的层次结构特征提取能力，以实现工艺实体类别的准确预测。

3.2.3 长短时记忆网络类别预测模型分析

LSTM 深度学习网络^[82]是由 Hochreiter 和 Schmidhuber 提出的。与传统 RNN 不同，LSTM 深度学习网络中以 LSTM 单元体取代传统 RNN 单元。LSTM 单元为网络模型从长跨度序列中提取有效序列信息提供了结构基础。随着 LSTM 深度学习网络的发展，LSTM 单元不断改进。目前最有效的 LSTM 单元是 Vanilla LSTM 单元。不同于传统 LSTM 单元，Vanilla LSTM 单元中加入了遗忘门。相关研究表明，遗忘门不仅节省计算成本，还能够有效提升网络模型的预测精度。相比于其他循环神经网络单元，如：传统 LSTM 单元、门限循环单元（Gated Recurrent Unit, GRU）等，Vanilla LSTM 单元更具优势。此外，vanilla LSTM 单元有效地解决了分类和预测的问题，适用于复杂装备拆卸工艺实体类别预测。因此，拟采用了 Vanilla LSTM 单元来有效提取复杂装备拆卸工艺实体的序列特征。Vanilla LSTM 单元的结构示意图如图 3-2 所示。




图3-2 Vanilla LSTM 单元结构示意图

Fig. 3-2 Schematic diagram of vanilla LSTM unit

在 Vanilla LSTM 单元中，遗忘信号、输入信号、输出信号和单元状态由一系列的非线性函数计算，将用来处理遗忘信号、输入信号、输出信号的结构单元分别称为遗忘门、输入门、输出门。其中，遗忘门决定剔除哪部分信息；输入门决定哪些输入信息用于更新单元状态；输出门决定输出哪部分状态信息。遗忘门、输入门、输出门如下所示：

$$\begin{cases} f_t = \sigma(W_{fx} \cdot x_t + W_{fh} \cdot h_{t-1} + b_f) \\ i_t = \sigma(W_{ix} \cdot x_t + W_{ih} \cdot h_{t-1} + b_i) \\ o_t = \sigma(W_{ox} \cdot x_t + W_{oh} \cdot h_{t-1} + b_o) \end{cases} \quad (3-1)$$

式中 W_{fx} 、 W_{ix} 、 W_{ox} ——分别为遗忘门、输入门、输出门的输入权重系数矩阵；

b_f 、 b_i 、 b_o ——分别为遗忘门、输入门、输出门的偏置矩阵；

f_t 、 i_t 、 o_t ——分别为遗忘门、输入门、输出门的输出量；

σ ——门限激活函数。

Vanilla LSTM 单元的状态 c_t 基于遗忘门和输出门进行计算，如式(3-2)所示。

$$c_t = c_{t-1} \cdot f_t + \varphi(W_{cx} \cdot x_t + W_{ch} \cdot h_{t-1} + b_c) \cdot i_t \quad (3-2)$$

式中 W_{cx} 、 W_{ch} ——为单元状态的输入权重系数矩阵和循环权重系数矩阵；

c_{t-1} —— $t-1$ 时刻的单元状态；

b_c ——单元状态偏置矩阵；

φ ——单元状态激活函数。

基于上述结构， t 时刻的 LSTM 单元输出 h_t 表示为：

$$h_t = \mu(c_t) \cdot o_t \quad (3-3)$$

式中 μ ——输出激活函数。

LSTM 的门控机制可以控制信息的流动,控制单元可以学习序列之间的依赖关系,从而有效处理序列数据。此外,LSTM 通过门控机制有效减少梯度消失或者梯度爆炸的问题,提升了模型的鲁棒性。3.2.1 节表明工艺实体具有明显的序列特征。为了充分提取工艺实体的序列特征,本章拟在所构建的工艺实体类别预测模型中融合 LSTM。在实际工艺实体类别预测模型中,采用先进优化算法(Adam)得到 LSTM 单元的权矩阵和偏差矩阵的最优值。为了更准确的实现工艺实体的类别预测,通过对比实验确定所构建的工艺实体类别预测模型中 LSTM 网络的具体结构。

3.3 样本自适应 LSTM 神经树实体类别预测建模

为了准确地实现复杂装备拆卸工艺实体的类别预测,在工艺实体类别预测模型构建中,需要考虑两个关键因素:一是工艺实体呈现序列特征,二是工艺实体具有层次结构特征。在机器学习和深度学习模型中,LSTM 能够直接有效地提取序列数据的特征,从而在序列数据的分类中表现出优异的性能;决策树直接以数据的层次结构建模,从而能有效实现对具有层次结构信息的数据分类。值得注意的是,在决策树模型中不同样本根据自身特性及样本之间的差异性,选择不同路径,进入不同的叶子节点,实现样本的准确划分。基于此,本章拟将 LSTM 与决策树融合,建立一种样本自适应 LSTM 神经树模型,有效地提取复杂装备拆卸工艺实体的序列特征和层次结构特征。

在样本自适应 LSTM 神经树模型中,共定义了三个模块来有效提取工艺实体的序列特征和层次结构特征,分别为序列特征提取模块(Transform, T)、路由选择模块(Router, R)和类别标签预测模块(Prediction, P)。这三个模块由同一种结构的 LSTM 神经网络模型构成。样本自适应 LSTM 神经树模型是以序列特征提取模块、路由选择模块和类别标签预测模块分别作为树模型的根节点、内部节点和叶子节点来构建的,其核心仍然是树模型的结构增长。图 3-3 是样本自适应 LSTM 神经树模型的结构及其增长模式。图 3-3 显示若当前叶子节点满足结构增长的条件,则将原来叶子节点更新为内部节点,即类别标签预测模块替换为路由选择模块,并为新的内部节点添加两个叶子节点,即为每个新增路由选择模块构建两个类别标签预测模块;若当前叶子节点不满足架构增长的条件,则当前叶子节点保持原有状态。通过上述方法,样本自适应 LSTM 神经树模型的结构逐步完善,最终得到一个完整的树模型。

在样本自适应 LSTM 神经树模型中,序列特征提取模块、路由选择模块和类别标签预测模块的连接方式如图 3-4 所示。图 3-3 和图 3-4 表明,在所建立的模型中,工艺实体首先经过序列特征提取模块,提取工艺实体序列特征的低维

特征表示；随后，工艺实体的低维特征传递到路由选择模块，通过多个路由选择模块，计算工艺实体流入不同叶子节点的概率；其次，工艺实体的低维特征表示依概率传入叶子节点，通过叶子节点的类别标签预测模块来预测工艺实体所属的类别；最后，将工艺实体传入各叶子节点的概率与对应叶子节点预测的类别结合起来，获取工艺实体所属每个类别的期望。




图3-3 样本自适应 LSTM 神经树模型结构

Fig. 3-3 Sample adaptive LSTM neural tree prognostic model structure




图3-4 样本自适应 LSTM 神经树模块（FC 表示全连接层，S 表示 Sigmoid 函数）

Fig. 3-4 SALNT modules (FC represents the full connection layer, S is the Sigmoid function)

样本自适应 LSTM 神经树模型以序列特征提取模块、路由选择模块和类别标签预测模块作为树模型的节点来建模。这三个模块的具体实现原理如下所示：

(1) 在样本自适应 LSTM 神经树中, 带有上下文特征的工艺实体首先进入序列特征提取模块, 通过该模块来提取工艺实体的序列特征, 并得到工艺实体在低维特征空间的表示。具体地, 序列特征提取模块可以表示为公式(3-4)。通过序列特征提取模块获得的低维特征空间可以表示为 $\tilde{X} = \{\tilde{x} | \tilde{x} = T(x), x \in X\}$ 。

$$\forall x \in X \subset \mathbb{R}^{m \times n}, \tilde{x} = T(x) \in \mathbb{R}^{m \times l} \quad (3-4)$$

式中 $T(x)$ ——LSTM 神经网络模型;

x ——工艺实体的上下文特征;

m ——工艺实体所需要考虑的上下文长度;

n ——工艺实体嵌入向量的维度;

l ——提取的特征维度;

$\tilde{x}$ ——工艺实体经过特征提取后的低维特征表示

(2) 路由选择模块是样本自适应 LSTM 神经树的内部节点。由于提取的工艺实体上下文特征也是序列特征, 路由选择模块同样由 LSTM 神经网络模型构成。路由选择模块功能是计算工艺实体选择左右路径的概率, 从而工艺实体能够根据自身特性, 自适应地以不同的概率传递到叶子节点中。路由选择模块可由公式(3-5)表示。

$$\forall \tilde{x} \in \tilde{X}, R_i(\tilde{x}) \in [0, 1] \in \mathbb{R} \quad (3-5)$$

式中 $\tilde{x}$ ——工艺实体的低维序列特征, 由公式(3-4)计算得到;

$\tilde{X}$ ——工艺实体的低维特征空间, 通过公式(3-4)获得;

R_i ——路由选择模块 i 。

(3) 在样本自适应 LSTM 神经树中, 路由选择模块并不改变工艺实体的低维序列特征。因此, 类别标签预测模块的输入仍然是序列特征, 其同样由 LSTM 神经网络模型构成。工艺实体的低维序列特征最终传递到叶子节点, 由叶子节点内部的类别标签预测模块预测工艺实体所属类别, 如公式(3-6)所示。

$$\forall \tilde{x} \in \tilde{X}, y_{j,pre} = P_j(\tilde{x}) \in \mathbb{R}^k \quad (3-6)$$

式中 $\tilde{x}$ ——工艺实体的低维序列特征, 由公式(3-4)计算得到;

$\tilde{X}$ ——工艺实体的低维特征空间, 通过公式(3-4)获得;

P_j ——第 j 个叶子节点对应的类别标签预测模块;

$y_{j,pre}$ ——第 j 个叶子节点的输出值;

k ——工艺实体的类别数量。

在样本自适应 LSTM 神经树中, 从根节点到叶子节点只存在唯一的路径。工艺实体通过多个路由选择模块依据概率沿着该路径传递到最终的叶子节点。如图 3-4 所示, 红色路径表示工艺实体最终选择该路径传递到某个叶子节点的

概率。由于工艺实体是通过多个路由选择模块到达某个叶子节点的，且路径上每个路由选择模块的左路径和右路径的选择是相互独立的。因此，工艺实体到达叶子节点的概率可以表示为：

$$\begin{aligned} p(x, z_l = 1) &= \prod_{li \in R_l} \{ [\checkmark li] R_{li}(\tilde{x}) + (1 - [\checkmark li]) [1 - R_{li}(\tilde{x})] \} \\ &= \prod_{li \in R_l} \{ [\checkmark li] R_{li}(T(x)) + (1 - [\checkmark li]) [1 - R_{li}(T(x))] \} \end{aligned} \quad (3-7)$$

式中 x —— 样本自适应 LSTM 神经网络模型的输入样本；
 $\tilde{x}$ —— 样本 x 的低维序列特征；
 $T(*)$ —— 样本自适应 LSTM 神经网络模型的特征提取模块；
 $p(x, z_l = 1)$ —— 样本 x 沿着路径到达叶子节点 l 的概率；
 R_l —— 样本从根节点到达叶子节点所经过的路由选择模块集合；
 li —— 第 li 个路由选择模块，
 $R_{li}(\tilde{x})$ —— 样本 x 在第 li 个路由选择模块选择左测路径的概率；
 $[\checkmark li]$ —— 样本选择左侧路径才能到达叶子节点 l ，若样本选择左侧路径，则 $[\checkmark li] = 1$ ，否则 $[\checkmark li] = 0$ 。

进而，得到样本 x 在叶子节点 l 的输出值可以表示为 $p_l(\tilde{x})$ 。根据样本到达每个叶子节点的概率和在每个叶子节点的类别预测值，则样本所属每个类别的期望值可以表示为公式(3-8)。最后，以期望值最大的类别作为样本的类别。

$$E(x) = \sum_{l=1}^N p(z_l = 1) P_l(\tilde{x}) = \sum_{l=1}^N p(z_l = 1) P_l(T(x)) \quad (3-8)$$

式中 x —— 样本自适应 LSTM 神经树模型的输入样本；
 $\tilde{x}$ —— 样本 x 的低维序列特征；
 $T(*)$ —— 样本自适应 LSTM 神经树模型的特征提取模块；
 $p(x, z_l = 1)$ —— 样本 x 沿着路径到达叶子节点 l 的概率；
 N —— 样本自适应 LSTM 神经树模型的叶子节点个数；
 $P_l(\tilde{x})$ —— 样本 x 在叶子节点 l 的类别预测值；
 $E(x)$ —— 样本 x 在所有叶子节点的类别预测值的均值。

在多类别预测任务中，交叉熵损失函数在模型训练中具有明显的优点。(1) 当模型输出为概率时，交叉熵损失函数可以完美解决平方损失函数权重更新过慢的问题，具有“误差大的时候，权重更新快；误差小的时候，权重更新慢”的良好性质。(2) 交叉熵损失函数采用了类间竞争机制，比较擅长于学习类间的信息，有利于提高工艺实体类别预测的精度。鉴于本章的样本自适应 LSTM

神经树模型是应用于多类别预测任务中，并且以概率作为输出。因此，选择交叉熵损失函数作为样本自适应 LSTM 神经树模型优化的误差函数。具体地，交叉熵损失函数的表达式如公式(3-9)所示。

$$L = \frac{1}{N} \sum_i L_i = -\frac{1}{N} \sum_i \sum_{c=1}^M y_{ic} \log(p_{ic}) \quad (3-9)$$

式中 N ——工艺实体数量；
 i ——第 i 个工艺实体；
 M ——工艺实体所属的类别数量；
 y_{ic} ——符号函数，如果样本 i 的真实类别等于 c ， $y_{ic}=1$ ，否则， $y_{ic}=0$ ；
 p_{ic} ——观测工艺实体 i 属于类别 c 的预测概率。

下面以样本类别预测误差作为判断模型结构增长的条件来构建样本自适应 LSTM 神经树模型，如图 3-5 所示。具体地，样本自适应 LSTM 神经树建模可分为七个主要步骤。

步骤一：确定 LSTM 的结构。将训练样本输入到 LSTM 神经网络，以类别预测误差作为评价指标，对 LSTM 神经网络进行参数调优，寻找一组使得样本类别预测误差最小的参数，从而确定 LSTM 神经网络模型的结构。以确定的 LSTM 结构作为特征提取模块、路由选择模块和类别标签预测模块；

步骤二：初始化样本自适应 LSTM 神经树模型。如图 3-3 和图 3-4 所示，初始化的样本自适应 LSTM 神经树模型仅包含一个根节点和一个叶子节点，均由已经确定的 LSTM 神经网络模型构成；

步骤三：模型结构增长。如图 3-3 所示，通过将树模型中的叶子节点转换为内部节点并将该内部节点分裂为两个叶子节点来实现模型的结构增长；

步骤四：模型局部训练。固定样本自适应 LSTM 神经树模型的其他参数，以最小化样本类别预测误差为目标，以训练样本为输入对模型新增的内部节点和叶子节点进行局部参数寻优，如图 3-3 所示中的红色线圈所示；

步骤五：确定模型结构是否增长。若经过局部训练，新的样本自适应 LSTM 神经树模型的测试样本类别预测误差比步骤三之前的预测误差更低，则保留新的样本自适应 LSTM 神经树模型，否则保留步骤三之前的样本自适应 LSTM 神经树模型；

步骤六：确定样本自适应 LSTM 神经树模型结构。对模型的每个叶子节点执行步骤三、步骤四、步骤五，直到样本自适应 LSTM 神经树模型的结构不再增长或者类别预测误差满足要求；

步骤七：样本自适应 LSTM 神经树模型全局训练。以最小化样本类别预测误差为目标，以训练样本为输入，微调结构确定的样本自适应 LSTM 神经树模

型的参数。以测试样本的类别预测误差最低为指示，选择最优的参数，完成样本自适应 LSTM 神经树模型的构建。




图3-5 样本自适应 LSTM 神经树实现流程图

Fig. 3-5 Implementation flowchart of sample adaptive LSTM neural tree

3.4 复杂装备拆卸工艺实体类别预测案例分析

以 JH70 发动机拆卸工艺碎片化知识图谱库作为案例，验证样本自适应 LSTM 神经树模型在类别预测的性能。

3.4.1 实验数据分析

(1) 实验数据描述

本章以复杂装备拆卸工艺知识语义向量化表达方法中使用的 JH70 发动机拆卸工艺碎片化知识图谱库作为实验数据。拆卸工艺数据首先经过语义向量化表达方法完成拆卸零件、工具等工艺实体的向量化过程。具体地,经过本章建立的 ERTransH,每条拆卸工艺中涉及的零件、所使用的工具等实体信息均可被转换为 60 维的语义向量,如表 3-1 所示。

表3-1 拆卸工艺实体示例
Table 3-1 Example of disassembly process entity

拆卸工艺实体	语义向量
链轮固定装置	[0.0521,-0.09671,0.18720,...,0.08975,0.18820,0.11814]
离合器	[0.00228,0.01716,-0.06596,...,-0.04950,-0.06008,-0.11997]
气缸头	[-0.09683,0.05409,0.03012,...,-0.001148,0.16347,-0.10740]
⋮	⋮
气缸头盖罩	[-0.21088,0.08465,-0.15934,...,-0.16174,0.17633,-0.08471]
小三叉套筒扳手	[0.15659,0.08117,0.04458,...,0.09711,0.06706,-0.01139]
T 型套筒扳手	[0.09965,-0.11469,0.08795,...,0.13238,-0.03264,-0.06250]

随后,人工为实验中采用的拆卸工艺实体标注实体类别。具体地,拆卸工艺实体可分为 7 类,包括:连接零件、轴系零件、传动零件、箱体零件、其他零件、组合零件、功能知识,如表 3-1 所示。通过所定义的拆卸工艺实体类别,可为实验中采用的拆卸工艺实体标注实体类别信息。例如,“时规链条”属于“传动零件”,“螺栓【箱底】”属于“连接零件”等。

表3-2 拆卸工艺实体类别定义
Table 3-2 Category definition of disassembly process entity

拆卸工艺实体类别编号	拆卸工艺实体类别	示例
1	连接零件	包括螺栓、螺钉、螺母等
2	轴系零件	包括普通轴、凸轴、轴套等
3	传动零件	包括各类齿轮、链条等。
4	箱体零件	包括各箱体、机架类等。
5	其他零件	包括垫圈、弹簧等。
6	组合零件	零件组合,一种系统内识别的中间表示。
7	功能知识	重要零件的描述信息,例如,圆头螺帽的功能:用于连接气缸头盖罩、垫片与气缸头等

(2) 样本生成

复杂装备拆卸工艺实体具有明显的序列特征,各零部件之间存在着明显的先后拆卸顺序,若零件的前序零件未拆除,则该零件不能被拆卸。以 JH70 发动机的实际拆卸过程为例,若要对零件“定子总成”进行拆卸,首先要拆卸定子总成上面的两个十字螺钉,“十字螺钉【定子总成】-1”和“十字螺钉【定子总成】-2”;若要拆卸两个十字螺钉,就要首先拆卸其前序零件——“飞轮转子”,如图 3-6 所示。




图3-6 发动机拆卸工艺实体序列特征示意图

Fig. 3-6 Schematic diagram of engine disassembly process entity series features

经过上述分析，JH70 发动机拆卸工艺实体具有明显的序列特征。进一步，工艺实体可以被视为序列特征数据。具体地，将当前拆卸工艺实体的工艺尾实体视为第一维度特征、当前拆卸工艺实体视为第二维度特征、当前拆卸工艺实体的工艺头实体作为第三维度特征。从而，将每个拆卸工艺实体构建为三维序列数据，并将当前拆卸工艺实体的类别作为输出，完成一个样本的构造过程。

注意到，每个拆卸工艺实体可能包含多个工艺头实体和多个工艺尾实体。如果在样本构造过程中仅使用一个工艺头实体或者一个工艺尾实体来构造三维序列特征，则单独一个拆卸工艺实体的三维特征难以有效表征其所有信息。因此，在构造每个拆卸工艺实体的样本时，应尽可能地将拆卸工艺实体所有的工艺头实体和工艺尾实体信息包含在三维序列特征内。为了解决上述问题，对拆卸工艺实体的所有工艺尾实体的语义向量表达采用均值池化操作，以最终均值化的语义向量作为拆卸工艺实体的第一维度特征。同样地，对拆卸工艺实体的所有工艺头实体的语义向量采用均值池化操作，以最终均值化的语义向量作为拆卸工艺实体的第三维度特征。最终，每个拆卸工艺实体的三维序列特征可以表示为“均值化工艺尾实体语义向量-拆卸工艺实体语义向量-均值化工艺头实体语义向量”，如图 3-7 所示。

以构造拆卸工艺实体“定子总成”的三维序列特征作为示例，图 3-7 演示样本了构建过程。若将“定子总成”的所有前序零件的语义向量的均值池化视为“定子总成”第一维度特征，则“定子总成”的语义向量可以视为“定子总成”第二维度特征，对所有以“定子总成”为前序零件的拆卸工艺实体的语义向量采用均值化操作，得到“定子总成”第三维度的特征。最终，“定子总成”可以被一个三维序列特征表征。




图3-7 样本构造过程

Fig. 3-7 Sample construction process

3.4.2 实验设置

(1) 样本自适应 LSTM 神经树模型超参数设置

样本自适应 LSTM 神经树模型通过样本误差来自动实现树结构的生长，实现复杂模型的构建。在实验设置中，序列特征提取模块、路由选择模块和类别标签预测模块中的 LSTM 网络均设置为 1 个隐藏层。根据实验样本描述，样本自适应 LSTM 神经树模型的输入序列长度为 3，特征数量为 60。样本自适应 LSTM 神经树模型各模块的超参数设置如表 3-3 所示。

表3-3 样本自适应 LSTM 神经树模型超参数设置

Table 3-3 Hyperparameter setting of SALNT

超参数	样本自适应 LSTM 神经树模型		
	序列特征提取模块	路由选择模块	类别标签预测模块
输入层节点数	60	10	10
输出层节点数	10	1	7
激活函数	ReLU/tanh	ReLU/tanh	无
批量大小		10	
迭代次数		30	

(2) 模型评估指标

为了全面评估模型的多类别预测结果，采用 Accuracy、Macro-average 方法

和 Weighted-average 方法来分别评估样本自适应 LSTM 神经树模型的分类效果。在计算 Accuracy、Macro-average 和 Weighted-average 时,可能会用到三个概念,分别为 TP_i 、 FP_i 和 FN_i 。具体地, TP_i 表示第 i 个类别的样本中类别预测正确的样本数、 FP_i 表示将其他类别的样本预测为类别 i 的样本数、 FN_i 表示将第 i 个类别的样本预测错误的样本数。下面分别介绍 Accuracy、Macro-average 和 Weighted-average 的计算方法。

Accuracy 通过计算类别预测正确的样本数与总样本数的比值来从全局评估样本类别预测情况。Accuracy 的计算方式如公式(3-10)所示。

$$Accuracy = \frac{\sum_{i=1}^M TP_i}{N} \quad (3-10)$$

式中 N ——样本数量;
 i ——第 i 个类别;
 M ——样本的类别数量;

Macro-average 方法能够平等的看待每个类别的分类效果对整体分类效果的贡献,它直接将不同类别的评估指标 (Precision/Recall/F1-score) 加起来求平均,在计算过程中为所有类别赋予相同的权重。因此,Macro-average 方法包含 Macro 查准率 ($macro-P$)、Macro 查全率 ($macro-R$) 和 Macro F1 分数 ($macro-F1$) 等三个指标,具体计算方式如公式(3-11)所示。

$$\begin{aligned} macro-P &= \frac{1}{M} \sum_{i=1}^M P_i = \frac{1}{M} \sum_{i=1}^M \left(\frac{TP_i}{TP_i + FP_i} \right) \\ macro-R &= \frac{1}{M} \sum_{i=1}^M R_i = \frac{1}{M} \sum_{i=1}^M \left(\frac{TP_i}{TP_i + FN_i} \right) \\ macro-F1 &= \frac{1}{M} \sum_{i=1}^M F1_i = \frac{1}{M} \sum_{i=1}^M \left(\frac{2 \times P_i \times R_i}{P_i + R_i} \right) \end{aligned} \quad (3-11)$$

式中 M ——样本的类别数量;
 P_i ——第 i 个类别的样本查准率;
 R_i ——第 i 个类别的样本查全率;
 $F1_i$ ——第 i 个类别的样本 F1 分数。

不同于 Macro-average, Weighted-average 方法考虑了类别不平衡的情况,它基于每个类别的真实分布比例为每个实体类别赋予不同的权重,将不同类别的评估指标 (Precision/Recall/F1-score) 加权平均作为评估模型多分类效果的指标。因此,Weighted-average 方法包含 Weighted 查准率 ($weighted-P$)、Weighted

查全率（ $weighted-R$ ）和 $Weighted F1$ 分数（ $weighted-F1$ ）等三个指标，具体计算方式如公式(3-12)所示。

$$\begin{aligned} weighted-P &= \sum_{i=1}^M \frac{N_i}{N} P_i = \sum_{i=1}^M \frac{N_i}{N} \left(\frac{TP_i}{TP_i + FP_i} \right) \\ weighted-R &= \sum_{i=1}^M \frac{N_i}{N} R_i = \sum_{i=1}^M \frac{N_i}{N} \left(\frac{TP_i}{TP_i + FN_i} \right) \\ weighted-F1 &= \sum_{i=1}^M \frac{N_i}{N} F1_i = \sum_{i=1}^M \frac{N_i}{N} \left(\frac{2 \times P_i \times R_i}{P_i + R_i} \right) \end{aligned} \quad (3-12)$$

式中 N ——样本数量；

N_i ——第 i 个类别的样本数量。

3.4.3 发动机拆卸工艺实体类别预测对比实验

工艺实体类别预测是通过已知实体类型的数据来训练所构建的模型；随后，将缺失类别信息的实体的上下文特征输入模型；最后输出实体的类别，完成工艺实体类别信息的补全。如图 3-8 所示，采用已知实体类别的“变速机构”、“链轮【正时从动】”等数据训练模型，进而预测未知的实体类别。模型类别预测结果依赖于模型是否能够有效提取工艺实体的特征。例如：“定子总成”的实际类别为“组合零件”。在预测“定子总成”的实体类别时，模型可能输出实体类别为“组合零件”，也可能输出“箱体零件”等。为了有效验证所建立的样本自适应 LSTM 神经树模型（sample adaptive LSTM neural tree, SALNT）的工艺实体类别预测的有效性，本节采用两部分实验：（1）基于 SALNT 的发动机拆卸工艺类别预测实验；（2）发动机拆卸工艺实体类别预测对比实验。




图3-8 实体类别预测示例

Fig. 3-8 Entity category prediction example

(1) 基于 SALNT 的发动机拆卸工艺类别预测实验

为了验证所建立的 SALNT，本章以 JH70 发动机拆卸工艺碎片化知识图谱库（见第 2 章中的知识图谱库）为数据，采用实验数据分析中的样本生成方法为工艺实体生成三维序列特征（当前工艺实体的尾实体作为第一维度特征，当前工艺实体自身作为第二维度序列特征，当前工艺实体的头实体作为第三维度序列特征），并以三维序列特征作为 SALNT 的输入，以 JH70 发动机拆卸工艺实体的类别作为输出。实验过程中，随机采用 3/4 的发动机拆卸工艺实体来训练 SALNT，采用剩下的发动机拆卸工艺实体作为测试样本验证 SALNT。

SALNT 属于树模型和神经网络模型的融合模型。该模型存在一些与基于神经网络的类别预测模型的相同问题，例如：模型的类别预测效果受到初值选择的影响。为弱化建立的 SALNT 的工艺实体类别预测波动，实验中的 SALNT 采用 10 次重复建模，取 10 次重复建模的平均值作为评估模型类别预测效果的最终结果。SALNT 采用 10 次重复建模的分类精度结果如图 3-9 所示。

图 3-9 表明，10 次重复建模中，SALNT 的工艺实体类别预测精度最高为 94.44%、最低为 88.89%，并且中位数为 91.67%。经过计算，SALNT 的平均类别预测精度为 91.95%。实验结果表明了 SALNT 具有较好的工艺实体类别预测精度。分类精度能够从全局来评估模型的样本类别预测情况。整体上，SALNT 能够有效对发动机拆卸工艺实体的类别进行预测。




图3-9 SALNT 的 10 次重复建模分类精度

Fig. 3-9 The classification accuracy of 10-trial of SALNT

此外，Macro-average 和 Weighted-average 能够根据样本类别的分布情况对模型进行有效评估。因此，同样采用 Macro-average 和 Weighted-average 来评估

样本自适应 LSTM 神经树模型的类别预测效果。SALNT10 次重复建模的 Macro-average 和 Weighted-average 结果如表 3-4 所示。

表3-4 SALNT 的 Macro-average 和 Weighted-average 结果
Table 3-4 Macro-average and Weighted-average results of SALNT

实验序号	Macro-average			Weighted-average		
	<i>macro-P</i>	<i>macro-R</i>	<i>macro-F1</i>	<i>weighted-P</i>	<i>weighted-R</i>	<i>weighted-F1</i>
1	72.95%	72.36%	72.60%	88.76%	88.89%	88.73%
2	54.29%	60.00%	56.67%	90.48%	94.44%	92.13%
3	64.95%	74.18%	67.84%	90.42%	91.67%	90.71%
4	65.61%	70.18%	65.18%	88.11%	88.89%	87.49%
5	53.33%	58.18%	55.57%	87.04%	91.67%	89.20%
6	74.85%	78.18%	76.36%	92.13%	94.44%	93.18%
7	64.95%	74.18%	67.84%	90.42%	91.67%	90.71%
8	73.61%	76.36%	74.78%	89.22%	91.67%	90.24%
9	67.13%	74.18%	68.75%	90.42%	91.67%	90.62%
10	65.28%	63.33%	64.09%	94.68%	94.44%	94.35%
均值	65.70%	70.11%	66.97%	90.17%	91.95%	90.74%

Macro-average 同等看待每个类别的样本对所有样本的精度、召回率和 F1 分数的贡献，而 Weighted-average 将每类样本占有所有样本的比重作为每类样本的权重，并使用权重均值化实验中所有样本类别的精度、召回率和 F1 分数。表 3-4 表明建立的 SALNT 在 Macro-average 中的 *macro-P*、*macro-R* 和 *macro-F1* 结果显著小于在 Weighted-average 中的 *weighted-P*、*weighted-R* 和 *weighted-F1* 结果。实验结果表明，同等的看待每个类别的样本对所有样本的贡献导致了模型类别预测精度、召回率和 F1 分数的降低。其原因是模型难以准确预测某些类别的实体类别或者某类样本数量较小，导致模型预测的效果降低。例如：极限情况下，某类样本的测试数量为 0，则其精度、召回率和 F1 分数均为 0。若直接将该类别样本的预测精度、召回率和 F1 分数与其他类别样本的预测精度、召回率和 F1 分数取均值，显然会导致所有样本的精度、召回率和 F1 分数降低。在 Weighted-average 上的评估指标表明本章建立的 SALNT 能有效实现多类别的实体类别预测任务。

综上所述，在 JH70 发动机拆卸工艺知识图谱的工艺实体类别预测任务中，所建立的 SALNT 在整体上取得了较高的工艺实体类别预测精度。若考虑类别因素影响，*weighted-P*、*weighted-R* 和 *weighted-F1* 也取得了较高值。因此，SALNT 能有效完成发动机拆卸工艺实体的类别预测任务。

（2）发动机拆卸工艺实体类别预测对比实验

为了对比验证 SALNT 在 JH70 发动机拆卸工艺实体类别预测的有效性，本节采用了七个拆卸工艺实体类别预测对比实验模型，包括：LSTM 模型、经典

BP 模型、决策树模型 (decision tree, DT)、梯度提升树模型 (gradient boosting decision tree, GBDT)、随机森林模型 (random forest, RF)、支持向量基模型 (support vector machines, SVM) 和 K 近邻模型 (K-nearest neighbor, KNN)。在对比实验中, 采用 3/4 的发动机拆卸工艺实体来训练所有模型, 剩下拆卸工艺实体来测试所有模型的类别预测效果。

由于 SALNT 的基础是 LSTM 和 DT, 并且发动机拆卸工艺实体呈现明显的序列特征, LSTM 模型能够有效处理序列数据。因此, 将 LSTM 和 DT 作为对比实验模型; 由于深度学习方法是目前热度较高的神经网络方法, 且其能够有效的提取样本中的特征信息, 故将 LSTM 和经典 BP 模型作为对比实验模型。GBDT 模型、SVM 模型和 KNN 模型均是机器学习中经典的分类模型, 其分类效果好, 应用范围广, 常常被应用于实际的分类任务中。因此, 将 GBDT、SVM 和 KNN 作为对比实验模型。由于 RF 是极具代表性的集成学习模型, 其适用性强, 不容易过拟合, 具有很好的抗噪声能力, 并且分类精度高, 故将 RF 作为集成学习的代表作为对比实验模型。除了 LSTM 模型外, 其他模型均不能够直接以三维序列作为输入。考虑到采用发动机拆卸工艺实体数据构建的样本序列长度为 3, 特征维度为 60, 将 3×60 的三维序列特征转变为 1×180 的一维特征。进而, 对比模型的输入设置为 180。三维序列特征转变为一维特征过程如图 3-10 所示。




图3-10 三维序列特征转变为一维特征

Fig. 3-10 Transforming three-dimensional series features into one-dimensional features

采用所构造的发动机拆卸工艺数据对所有模型训练, 并基于测试集以 Accuracy、Macro-average 方法和 Weighted-average 方法作为评估指标评估各模型的类别预测效果。神经网络模型和机器学习模型的类别预测效果与初值的选择有关。为弱化神经网络模型和机器学习模型的预测波动, 对比实验中的所有模型均采用 10 次重复建模, 并以 10 次重复建模的平均结果作为最终实验结果。

在发动机拆卸工艺实体类别预测对比实验中, 部分发动机拆卸工艺实体类别预测结果如表 3-5 所示。在表 3-5 中将预测错误的类别设置粗体显示。

表 3-5 表明, SALNT 能准确地预测大部分工艺实体的类别。例如: 在预测“弹性挡圈【从动减速齿轮】”的类别时, SALNT、DT 和 GBDT 的类别预测值与真实值相同; 在预测“右侧盖【气缸头】”的类别时, SALNT、LSTM 和 SVM 的类别预测值与真实值相同。实验结果表明 SALNT 在总体上的类别预测

精度最高。

表3-5 部分工艺实体类别预测结果

Table 3-5 Forecast results of some process entity category labels

工艺实体	真实类别	所预测的类别							
		LSTM	BP	DT	GBDT	RF	SVM	KNN	SALNT
密封【气缸头盖罩】	5	5	5	5	2	5	5	1	5
发动机的重要组成部分, ...	7	7	7	7	2	7	7	7	7
弹性挡圈【从动减速齿轮】	5	6	1	5	5	1	3	7	5
圆螺母【离合器】	1	1	1	4	1	1	5	5	1
普通垫片-4	5	5	1	5	5	5	5	5	5
十字螺钉【定子总成】-2	1	1	1	5	1	1	1	5	1
右侧盖【气缸头】	5	5	1	4	1	1	5	1	5
六角螺栓【传动链轮】	1	7	1	7	1	1	1	1	1
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
螺栓【右箱】-6	1	7	7	7	1	1	7	1	1
离合器用套筒	7	7	7	7	7	7	7	7	7
回位弹簧座【启动轴】	5	5	1	3	3	1	3	5	5

为了进一步验证 SALNT 的工艺实体类别预测效果,采用精度从整个数据集的全局角度来表征各模型在发动机拆卸工艺实体类别预测效果。各模型的发动机拆卸工艺实体类别预测精度结果如表 3-6 所示。

表3-6 发动机拆卸工艺实体类别预测精度

Table 3-6 Category prediction accuracy of engine disassembly process entity

模型	LSTM	BP	DT	GBDT	RF	SVM	KNN	SALNT
Accuracy	86.94%	81.39%	76.11%	79.45%	80.28%	83.33%	75.00%	91.95%

表 3-6 表明,所建立的 SALNT 取得了最好的分类结果。除 SALNT 外,在神经网络模型中, LSTM 取得了最好的类别预测结果;在树模型中,随机森林取得了最好的类别预测结果;在非深度学习的机器学习模型中, SVM 取得了最好的分类效果。相比于其他对比模型, LSTM 在精度上最少提升 3.61%、最高提升 11.94%。由于 LSTM 能够有效提取序列数据的特征,此实验结果表明了发动机拆卸工艺实体具有明显的序列特征,并验证了前文对发动机拆卸工艺数据理论分析的可靠性。相比于 LSTM,本章建立的 SALNT 在类别预测精度上提升 5.01%,实验结果表明了 SALNT 显著优于 LSTM。相比于 LSTM, SALNT 中除了采用 LSTM 来提取发动机拆卸工艺实体的序列特征,还采用树模型来提取发动机拆卸工艺实体的层次结构信息。实验结果验证了发动机拆卸工艺实体具有

层次结构特征，并且 SALNT 能够有效提取发动机拆卸工艺实体的层次结构信息。相比于 DT，本章建立的 SALNT 在类别预测精度上提升 15.84%，实验结果表明了 SALNT 的实体类别预测效果显著优于 DT。相比于 DT，SALNT 模型中除了采用树模型来提取发动机拆卸工艺实体的层次结构特征，还采用 LSTM 来提取发动机拆卸工艺实体的序列特征。实验结果再次验证了发动机拆卸工艺实体具有序列特征，并且 SALNT 能够有效提取发动机拆卸工艺实体的序列特征。因而，在所有的类别预测模型中，SALNT 的类别预测精度显著优于其他模型。

此外，为了验证各模型类别预测稳定性，以历次类别预测精度为评估指标，构建类别预测精度箱形图。各神经网络模型和机器学习模型的 10 次重复建模类别预测精度箱形图如图 3-11 所示。

图 3-11 表明各神经网络模型中，SALNT 获得了最佳类别预测稳定性。此外，在 10 次重复建模实验中，SALNT 的历次类别预测精度均获得了最高值，验证了 SALNT 模型在发动机拆卸工艺实体类别预测的有效性。各类别预测模型中，KNN 取得了最佳的类别预测稳定性。这主要是由于 KNN 模型不需要设置初值，KNN 模型的精度不会随着重复建模而改变。除却 KNN 外，在所有的类别预测模型中，GBDT 获得了最佳类别预测稳定性、SALNT 获得了次好类别预测稳定性。然而，GBDT 的类别预测精度远远差于 SALNT。整体上，SALNT 模型具有优秀的类别预测稳定性和高精度的类别预测性能。此外，采用 Macro-average 方法和 Weighted-average 方法来进一步对比 SALNT 的类别预测效果，实验结果如表 3-7 所示。




图3-11 各模型的类别预测精度箱型图

Fig. 3-11 The accuracy boxplots of comparison models and SALNT

从 Macro-average 方法和 Weighted-average 方法来看, 相比于对比模型, SALNT 在所有评估指标上取得了最优值。在所有的对比模型中, LSTM 在五个指标中取得最优值, 并在 *macro-P* 上取得了第二好的结果, 与第一好的 SVM 相差不足 2%。因而, LSTM 总体上取得了第二好的类别预测效果。实验结果证明了所使用的发动机拆卸工艺实体具有序列特征, 并且 LSTM 能有效提取序列特征。相比于所有对比模型, SALNT 在 *macro-P* 和 *weighted-P* 上分别提升 11.22%-28.18% 和 2.82%-19.69%; 在 *macro-R* 和 *weighted-R* 上分别提升 14.79%-36.47% 和 5.01%-16.95%; 在 *macro-F1* 和 *weighted-F1* 上分别提升 13.87%-31.93% 和 4.27%-18.25%。实验结果表明, 与其他分类模型对比, SALNT 模型显著提升了工艺实体类别预测的精度、召回率和 F1 分数。SALNT 融合了 LSTM 的优点, 同样能有效提取发动机拆卸工艺实体的序列特征。因此, SALNT 具有优秀的类别预测性能。

表3-7 发动机拆卸工艺实体类别预测的 Macro-average 和 Weighted-average
Table 3-7 Macro coverage and Weighted coverage for the prediction of engine disassembly process entity category label

评估	Macro-average			Weighted-average		
	<i>macro-P</i>	<i>macro-R</i>	<i>macro-F1</i>	<i>weighted-P</i>	<i>weighted-R</i>	<i>weighted-F1</i>
LSTM	52.82%	55.32%	53.10%	87.35%	86.94%	86.47%
BP	42.61%	43.16%	41.63%	75.48%	81.39%	77.26%
DT	46.18%	39.39%	41.11%	85.81%	76.11%	78.66%
GBDT	37.56%	33.64%	35.04%	85.28%	79.45%	81.65%
RF	43.00%	43.76%	42.33%	75.07%	80.28%	76.69%
SVM	54.58%	53.79%	52.95%	85.10%	83.33%	83.44%
KNN	40.20%	41.43%	40.60%	70.48%	75.00%	72.49%
SALNT	65.70%	70.11%	66.97%	90.17%	91.95%	90.74%

实际上, SALNT 模型是 LSTM 和 DT 的融合模型。为了验证 SALNT 模型的有效性, 将 SALNT 模型与 LSTM 和 DT 在 Weighted-average 方法上单独对比, 实验结果如图 3-12 所示。

图 3-12 表明, 在 LSTM、DT 和 SALNT 的对比中, SALNT 在 Weighted-average 上的结果全面超越了 LSTM 和 DT, 并且 LSTM 在 Weighted-average 上的结果全面超越 DT。与 DT 不同的是, LSTM 采用自身神经网络结构来提取序列特征, 实验结果表明了 LSTM 能有效提取发动机拆卸工艺的序列特征。因而, LSTM 的工艺实体类别预测结果全面优于 DT。与 LSTM 不同的是, SALNT 除了采用 LSTM 来提取发动机拆卸工艺的序列特征, 还采用决策树来提取发动机拆卸工艺实体的结构层次特征。实验结果表明 SALNT 在 Weighted-average 上显著优于 LSTM, 验证了 SALNT 能有效提取发动机拆卸工艺实体的层次结构特征。通过对比 LSTM 和 DT, 验证了 SALNT 能同时有效提取发动机拆卸工艺实

体的序列特征和层次结构特征。因此，所建立的 SALNT 能有效完成发动机拆卸工艺实体的类别预测任务。




图3-12 SALNT 与 LSTM 和 DT 的对比结果

Fig. 3-12 Comparison results of SALNT with LSTM and DT

上述实验结果验证了所采用的发动机拆卸工艺实体存在层次结构特征和序列特征。实验结果表明所建立的 SALNT 融合了决策树与 LSTM 的优点，能够有效提取工艺实体的层次结构特征和序列特征。因而，SALNT 能准确地预测工艺实体的类别。

3.5 本章小结

针对发动机拆卸工艺实体呈现序列特征和层次结构特征的特点，建立了样本自适应 LSTM 神经树模型来完成发动机拆卸工艺实体的类别预测任务。鉴于 LSTM 能有效提取序列特征，决策树能有效提取层次结构信息的特性，样本自适应 LSTM 神经树模型将 LSTM 与决策树融合起来，以决策树作为样本自适应 LSTM 神经树模型的框架，并基于 LSTM 设计了特征提取模块、路由选择模块和类别标签预测模块作为树模型的三类节点来完成树模型的增长。因而，样本自适应 LSTM 神经树模型能有效处理序列特征和层次结构特征，提高了发动机拆卸工艺实体的类别预测精度。最后在 JH70 发动机实际拆卸工艺实体的类别预测上进行验证。实验结果表明，与传统的方法相比，工艺实体类别预测精度达到 91.95%，提升 8% 以上。因此，所提出的方法能有效完成发动机拆卸工艺实体的类别预测任务，为复杂装备拆卸工艺碎片化知识图谱的相似度量 and 实体链接技术提供支持。

第4章 装备拆卸工艺碎片化知识图谱相似度量与融合建模方法

4.1 引言

为了自动构建一个可用性高、可靠性高的复杂装备拆卸工艺知识图谱，整合现有的拆卸工艺碎片化知识图谱同时消除碎片化知识图谱的冗余信息是一种重要的技术手段。人工构建知识图谱需要耗费大量的时间、精力、财力和物力，同时知识图谱的维护和更新也是一个棘手的问题，人工构建知识图谱带来的巨大工作量已经成为知识图谱工程应用的主要瓶颈问题。此外，面向特定领域的知识图谱自动构建多依赖于文本数据而非结构化数据，导致了缺乏碎片化知识图谱相似度量手段和融合方法。

如前所述，前面已经给出一些实际的复杂装备拆卸工艺碎片化知识图谱例子。碎片化知识图谱由专家构建而来，在可用性和可靠性上得到保障。因此，通过整合碎片化知识图谱来构建复杂装备拆卸工艺知识图谱更贴合实际工程。整合这些碎片化知识图谱的重点是它们之间的相似度量。第2, 3章节获得的工艺知识语义向量化表达与实体的类别信息可以支持碎片化知识图谱的相似度量。度量时，两个碎片化知识图谱的相似度量不应该局限于局部的相似，更应该注重整体上的相似度。因此，本章拟采用基于图同构的相似度量方法完成这一目标。图同构是一种基于图中节点和边的结构信息，建立两个图中节点和边之间的一一对应关系，进而判断两个图在整体结构上是否相似的一种方法。这种方法可以从拓扑结构的角度来度量相似性。但是，拆卸工艺知识图谱相似性不仅要考虑结构一致的知识图谱可能相似，还要考虑路径相似，即要考虑通过不同的拆卸工艺实现相同的拆卸目标的工艺也是相似的。因此，必须对图同构相似度量法进行改进以解决实际度量中的特殊问题。

本章提出一种面向碎片化知识图谱迭代融合的复杂装备拆卸工艺知识图谱自动构建方法。该方法基于图同构理论并结合路径相似度，建立极大连通同归结构的概念。基于连通同归结构和拆卸工艺实体重要度，建立一种强化极大连通同归结构相似度模型来准确度量任意两个碎片化知识图谱的相似度，然后，提出一种基于实体和图结构的复杂装备拆卸工艺碎片化知识图谱融合方法。最后，在理论和实验中验证所建立的相似度模型和提出的融合方法的有效性。

4.2 复杂装备拆卸工艺碎片化知识图谱类别分析

本节首先分析针对同一拆卸目标建模时可能构建的碎片化知识图谱类型，从而为构建碎片化知识图谱相似度量模型和研究融合方法做准备。

目前复杂装备拆卸工艺建模过程的自动化与智能化支持较少，建模过程一般需要工艺设计人员将工艺知识建模为可执行拓扑结构模型。一般地，复杂装备拆卸工艺建模过程通常是按从面到点、从前到后的逻辑顺序，形成具有严密数学逻辑和容易理解的图形模型。例如，图 4-1 中对发动机气缸头的部分拆卸工艺进行建模。




图4-1 JH70 发动机气缸头的部分拆卸工艺

Fig. 4-1 Partial disassembly process of the cylinder head in JH70 engine

在复杂装备拆卸工艺知识图谱建模过程中，由于建模人员的知识水平和建模工具掌握水平不一致，众多建模人员建立的拆卸工艺碎片化知识图谱的拓扑结构、拆卸工艺要素、约束关系等难以统一化表达。因而，当多建模人员会在不同场景中针对同一复杂装备进行拆卸工艺建模时，所建立的拆卸工艺知识图谱也会不同；即使是同一个建模人员，不同时间建立的拆卸工艺知识图谱也可能是不同的。这些包含相似内容的拆卸工艺知识图谱不断增加，不但占据了存储空间，而且在利用这些拆卸工艺知识图谱时也可能造成混乱。因此，有必要研究这些拆卸工艺碎片化知识图谱的类型，并探索碎片化知识图谱相似度量模

型和融合方法，从而消除知识图谱的冗余信息，构建一个统一表达和完整的复杂装备拆卸工艺知识图谱。

实际上，建模人员会建立五类碎片化知识图谱，下面以 JH70 发动机“气缸头”的拆卸工艺知识图谱建模为例进行说明。表 4-1 中的第一类碎片化知识图谱是某建模人员在当下时刻建立的一个发动机拆卸工艺知识图谱。对比该拆卸工艺知识图谱，其他建模人员或者该建模人员在其他时刻可能还会构建四种类别的拆卸工艺碎片化知识图谱，如表 4-1 所示。（1）建模人员对各拆卸要素之间的关系认识更明确后，则其可能对第一类模型进行关系扩充，构建出第二类发动机拆卸工艺知识图谱。（2）建模人员对各拆卸要素表达有不同的理解，比如“螺栓【气缸左盖】”被其定义为“螺丝【气缸左侧盖】”，则其可能对第一类模型进行修改，构建出第三类发动机拆卸工艺知识图谱。（3）建模人员对各拆卸要素有着深入了解，则其可能对第一类模型进行外延，构建出第四类发动机拆卸工艺知识图谱。（4）建模人员对各拆卸要素深入了解后，则其可能对第一类模型进行内部扩展，构建出第五类发动机拆卸工艺知识图谱。

4.3 基于极大连通同归结构的相似度量建模与知识图谱融合方法

为了能有效量化碎片化知识图谱的相似度，并实现相似知识融合及消除知识图谱的冗余信息，本章建立了基于极大连通同归结构（local maximum connection same destination structure, LMCSDS）的相似度模型并提出了碎片化知识图谱融合方法。

4.3.1 基于 LMCSDS 的相似度建模

拆卸工艺碎片化知识图谱与有向图的拓扑结构一致。通过对比，拆卸工艺碎片化知识图谱中的工艺实体可以被视为有向图中的节点，工艺关系可以被视为有向图中的关系。因此，可以采用图同构理论来有效度量两个碎片化知识图谱的拓扑结构相似度。

由于拆卸工艺知识图谱建模过程没有统一标准，在拆卸工艺碎片化知识图谱中对于同一类拆卸工艺要素的表达很难统一。因此，无法直接应用图同构度量拆卸工艺碎片化知识图谱的相似性。为了解决上述问题，首先将拆卸工艺碎片化知识图谱数字化为拓扑图结构，即将工艺实体抽象为数字节点，将工艺关系抽象为边。由于建模人员的知识水平和对问题的理解不同，同一个工艺实体可能存在不同的文本形式。

表4-1 发动机拆卸工艺碎片化知识图谱类别

Table 4-1 Types of fragmentation knowledge garphs of engine disassembly process

发动机拆卸工 艺碎片化知识 图谱	问题理解程度	逻辑结构
第 1 类	当下时刻对拆卸工艺各要素的理解	
第 2 类	对发动机拆卸工艺实体之间的关系认识充分时建模	
第 3 类	发动机拆卸工艺实体理解存在偏差时建模	
第 4 类	对发动机拆卸工艺外延	
第 5 类	对发动机拆卸工艺内扩	

通过上述分析，在工艺实体抽象为数字节点时，需要重点将表示相同语义的工艺实体抽象为相同的数字节点。例如：工艺实体“燃油泵”和“增压泵”

表示的是一个零部件，其语义含义相同。然而，从表面形式来看，这两个工艺实体并不相似。若采用基于文本的相似度度量手段，容易将“燃油泵”和“增压泵”判别为不相似。因此，必须从语义层面度量工艺实体的相似度，以便准确判断具有不同文本表达形式但语义相同的实体是否相似。

为了度量实体之间的语义相似度，本章首先利用第3章中的已经补全的实体类别信息进行判断，类别不同的工艺实体判定为不相似的工艺实体；类别相同的工艺实体通过第2章获得的工艺实体语义向量来有效度量其语义相似度，对于满足相似度阈值的工艺实体将其抽象为相同的数字节点。例如，图4-2是通过计算两个拆卸工艺碎片化知识图谱中工艺实体相似度，实现了碎片化知识图谱数字化为拓扑图结构的过程。具体地，A中的“密封【气缸头盖罩】”与B中的“密封【气缸头盖罩】”满足语义相似度阈值，则A中的“密封【气缸头盖罩】”与B中的“密封【气缸头盖罩】”都被数字化“3”；A中的“右侧盖【气缸头】”与B中的“右盖【气缸头】”满足语义相似度阈值，则A中的“右侧盖【气缸头】”与B中的“右盖【气缸头】”都被数字化“2”；A中没有与B中的“密封【气缸头右盖】”满足语义相似度阈值的实体，因此，B中的“密封【气缸头右盖】”被数字化为单独的数字“6”；若两个工艺实体之前存在工艺关系，则在拓扑结构中，两个实体的数字节点之间也存在边。

通过上述操作，拆卸工艺碎片化知识图谱就可以被抽象为拓扑图。进而可以采用图同构来度量两个拆卸工艺碎片化知识图谱的相似度。然而，图同构有着严格的结构要求：要求两图节点与节点之间，边与边之间存在一个一一映射函数。因此，图同构不能度量起始和终点相同但是中间节点不完全相同的两条路径的相似度。例如，表4-1中的第一类碎片化知识图谱中的路径“气缸头 $\xrightarrow{\text{前序零件}}$ 右侧盖【气缸头】”与第五类碎片化知识图谱中的路径“气缸头 $\xrightarrow{\text{前序零件}}$ 密封【气缸头右盖】 $\xrightarrow{\text{前序零件}}$ 右侧盖【气缸头】”是两条相似的路径，后者是前者更完整的详细描述。然而，在图同构理论下，这两条路径是不相似的。因此，结合复杂装备拆卸工艺实际工程应用问题，本章重点将路径相似引入图同构，定义了同归路径和同归结构的概念，并建立了基于LMCSDS的相似度模型来度量两个碎片化知识图谱的相似度。下面定义本章的基本概念。

定义1. 有向图：一个复杂装备拆卸工艺碎片化知识图谱可以被抽象为一个有向图 $D=\langle V, E, W^D \rangle$ ，其中， $\langle V, E, W^D \rangle$ 满足如下三个条件。

(1) V 是一个非空的有限集合，称为 D 的节点集。通常用 $V(D)$ 表示有向图 D 的节点集，用 $|V(D)|$ 表示有向图 D 的节点数。此外， $v \in V(D)$ 表示节点 v 是

有向图 D 中的一个节点， v 由该知识图谱中对应的实体数字化获得；

(2) E 是卡氏积 $V \times V$ 的多重子图，称为 D 的边集。通常用 $E(D)$ 表示 D 的边集，用 $|E(D)|$ 表示有向图 D 的边数。此外， $(v_i, v_j) \in E(D)$ 表示节点 v_i 到 v_j 存在有向边，并且若实体之间存在关系，则实体的数字表示之间存在一条边；

(3) W^D 是卡氏积 $V \times R^+$ 的多重子图，称为 D 的节点权重集。 W_v^D 表示节点的权重， W_v^D 有两层含义： v 在有向图 D 中， v 在有向图 D 中的权重为 W_v^D 。




图4-2 碎片化知识图谱抽象为图结构过程示意图

Fig. 4-2 The process of fragmentation knowledge garphs into graph structures

根据有向图的定义，图 4-2 中的碎片化知识图谱 A 可以被抽象为表 4-2 中的有向图形式。

表4-2 某拆卸工艺碎片化知识图谱的有向图表示

Table 4-2 Directed graph of a fragmentation knowledge graph of disassembly process

V	E	W^D
$\{1,2,3,4,5\}$	$\{(1,2),(1,3),(1,4),(1,5)\}$	$\{[1,1],[2,1],[3,1],[4,1],[5,1]\}$

定义 2. 路径、连通：设有向图 D 中节点和有向边的交替序列 $\Gamma = v_0 e_1 v_1 e_2 \cdots e_l v_l$ ，若 v_{i-1} 是有向边 e_i 的始点， v_i 是有向边 e_i 的终点， $i = 1, 2, \dots, l$ ，则称 Γ 为节点 v_0 到 v_l 的通路。 v_0 和 v_l 分别称为此通路的起点和终点。若 Γ 中所有节点互不相同，所有的边也互不相同，则称此通路为初级通路或路径。在一个

有向图 D 中, 若从节点 u 到 v 存在通路, 则称 u 可达 v , 记为 $u \rightarrow v$ 。如果略去 D 中各有向边的方向后, 对 $\forall u, v \in V(D)$, $u \rightarrow v$, 则称 D 是弱连通图, 简称连通图。

根据连通图的定义, 图 4-3 中的有向图是一个非连通图。具体来看, 该有向图由上下两个子图构成, 并且上子图的任一节点与下子图的任一节点不存在通路。因此, 图 4-3 中的有向图是一个非连通图。然而, 单独看上子图或者下子图, 均为一个连通图。例如: 在上子图中, 任意两个上子图中的节点存在通路。此外, 根据路径的定义, 路径中的各顶点互不相同, 则图 4-3 中的 $1 \rightarrow 2$, $2 \rightarrow 3$ 或者 $1 \rightarrow 2 \rightarrow 4$ 均为路径, 而 $1 \rightarrow 2 \rightarrow 1$ 不是一条路径。




图4-3 一个复杂装备拆卸工艺碎片化知识图谱

Fig. 4-3 A fragmentation knowledge graph of complex equipment disassembly process

为了能有效度量拆卸工艺碎片化知识图谱的相似度, 本章将图同构与路径相似结合, 定义了同归路径和连通同归结构的概念。

定义 3. 极大连通同归结构: 设两个碎片化知识图谱抽象的有向图分别为 $D_1 = \langle V_1, E_1, W^{D_1} \rangle$, $D_2 = \langle V_2, E_2, W^{D_2} \rangle$ 。若 Γ_1 是 D_1 中的路径、 Γ_2 是 D_2 中的路径, 并且 Γ_1 与 Γ_2 的起点和始点相同, 并且中间节点互不相同或者不存在中间实体, 则称 Γ_1 和 Γ_2 互为同归路径。设 $P_1 = \{\Gamma_{1i}\}_{i=1,2,\dots,n}$ 和 $P_2 = \{\Gamma_{2i}\}_{i=1,2,\dots,n}$ 是 D_1 和 D_2 所有同归路径的集合, 其中, Γ_{1i} 和 Γ_{2i} 分别是 D_1 、 D_2 中的路径, 并且 P_1 和 P_2 中的路径一一对应, 即 Γ_{1i} 和 Γ_{2i} 互为同归路径。若 G_1 由 P_1 中的部分元素组成, 且 G_2 由 P_2 中与其对应的元素组成, 则称 G_1 与 G_2 互为同归结构。进一步, 若 G_1 、 G_2 满足以下两个条件, 则称 $\{G_1; G_2\}$ 为 D_1 与 D_2 的一个 LMCSDS。

(1) G_1 、 G_2 均连通;

(2) 对任意不包含在 G_1 , G_2 中的同归路径 Γ_{1j} 和 Γ_{2j} , 分别加入到 G_1 , G_2 中, G_1 或 G_2 不连通。

由同归路径的定义可知, 同归路径共包含三类: 第一类是一对中间过程不同的同归路径, 如图 4-4 中的 $\{2 \rightarrow 3 \rightarrow 6, 2 \rightarrow 16 \rightarrow 6\}$; 第二类是一对对问题理解深度不同的同归路径, 后者是前者的详细描述或者前者是后者的详细描述, 如图 4-4 中的 $\{2 \rightarrow 5, 2 \rightarrow 13 \rightarrow 5\}$; 第三类是一对描述完全相同的同归路径, 如图 4-4 中的 $\{17 \rightarrow 19, 17 \rightarrow 19\}$ 。从结果来看, 不管是由于拆卸工艺建模人员对目标理解完全一致还是存在偏差或者理解程度不同, 一对同归路径表示它们都实现了相同的拆卸工艺建模目标, 即第一类同归路径实现了 $2 \rightarrow 6$ 、第二类同归路径实现了 $2 \rightarrow 5$ 、第三类同归路径实现了 $17 \rightarrow 19$ 。基于拆卸工艺碎片化知识图谱的建模过程中的严密数学逻辑特性, 同归路径可以被视为相似路径。




图4-4 两个拆卸工艺碎片化知识图谱抽象的有向图形式

Fig. 4-4 Two directed graphs of two fragmentation knowledge garphs of disassembly process

根据 LMCSDS 的定义可知, 两个拆卸工艺碎片化知识图谱的 LMCSDS 能不止一组。例如, 图 4-4 中的两个拆卸工艺碎片化知识图谱的 LMCSDS 共有 2 组, 具体地, 如图 4-5 所示。

图同构能够很好地度量拓扑结构之间的相似度, 即能够有效度量拆卸工艺碎片化知识图谱之间的相似度。然而, 图同构是基于边集建模, 难以有效度量路径相似。同归路径可以很好的度量路径相似度, 则将图同构与同归路径结合起来的同归结构就可以从路径相似和结构相似两方面准确度量两个碎片化知识图谱的相似性, 具体分析如下。




图4-5 两个拆卸工艺碎片化知识图谱的 LMCSDSs

Fig. 4-5 LMCSDSs of two fragmentation knowledge garphs of disassembly process

如前所述，建模人员由于疏忽或者受限于个人经验，构建的拆卸工艺知识图谱不完善。例如，在对“箱体组合【左侧】”拆卸时，存在两条正确的拆卸工艺：“箱体组合【左侧】 $\xrightarrow{\text{前序零件}}$ 变速机构 $\xrightarrow{\text{前序零件}}$ 箱体组合【中右侧】和“箱体组合【左侧】 $\xrightarrow{\text{前序零件}}$ 曲轴连杆活塞组合 $\xrightarrow{\text{前序零件}}$ 箱体组合【中右侧】”。但在两个拆卸工艺碎片化知识图谱中均只建立了其中一条拆卸路径，结果导致由于“箱体组合【左侧】”的前序零件未被完全拆卸，“箱体组合【左侧】”不能被拆卸。观察两条拆卸工艺，其目的均是为了完成从“箱体组合【中右侧】”到“箱体组合【左侧】”的拆卸过程。因此，这两条拆卸工艺可以被视为相似的拆卸工艺，在融合的工艺碎片化知识图谱中同时保留这两条拆卸工艺，则“箱体组合【左侧】”能被正确拆卸，即所建立的工艺知识图谱能够有效指导拆卸的顺利进行。

为了构建一个可用性高的复杂装备拆卸工艺知识图谱来指导拆卸过程的正确进行，碎片化知识图谱相似度模型需准确地度量出知识图谱的相似度。因此，本章考虑路径相似，将三类同归路径引入图同构并考虑图的连通性，定义了 LMCSDS 的概念，以支持准确地度量拆卸工艺碎片化知识图谱的相似。最后，本章建立了一种基于 LMCSDS 的相似度模型(similarity model based on LMCSDS, SM-LMCSDS)来度量拆卸工艺碎片化知识图谱的相似度，如公式(4-1)所示。

$$SKG(D_1, D_2) = \max_i \max \left\{ \frac{|V(G_{1i})|}{|V(D_1)|}, \frac{|V(G_{2i})|}{|V(D_2)|} \right\} \quad (4-1)$$

式中 $SKG(*)$ ——有向图的相似度函数；

D_1 、 D_2 ——两个拆卸工艺碎片化知识图谱抽象的有向图；

$\{G_{1i}; G_{2i}\}$ —— D_1 与 D_2 的第 i 组 LMCS DS。

公式(4-1)达到最大时的 LMCS DS 被称为最大连通同归结构, 记为 $\{D_1 \bar{\cap} D_2; D_2 \bar{\cap} D_1\}$, 则 SM-LMCS DS 可以表示为:

$$SKG(D_1, D_2) = \max \left\{ \frac{|V(D_1 \bar{\cap} D_2)|}{|V(D_1)|}, \frac{|V(D_2 \bar{\cap} D_1)|}{|V(D_2)|} \right\} \quad (4-2)$$

4.3.2 拆卸工艺碎片化知识图谱融合方法

消除拆卸工艺碎片化知识图谱的冗余信息对于构建一个可用性高并且完整的复杂装备拆卸工艺知识图谱至关重要。为了保证相似的拆卸工艺碎片化知识图谱的有效融合, 本节提出了一种基于实体和图结构的拆卸工艺知识图谱融合方法, 实现知识图谱的相似相融。从碎片化知识图谱的相似度量方法来看, 知识图谱的融合方法可分为两个模块: 第一个模块是将具有完全相同语义信息而文本表达不同的工艺实体融合, 第二个模块是将知识图谱的图结构进行融合。

(1) 工艺实体融合方法

复杂装备拆卸工艺知识图谱中的工艺实体是由工艺知识构成的。由于拆卸工艺碎片化知识图谱的建立严重依赖于工艺建模人员的经验、对建模工具的熟练掌握、以及工艺建模人员的知识存储量和知识标准。因此, 在碎片化知识图谱中表示相同语义的工艺实体的表达难以统一。例如, 图 4-6 为两个工艺建模人员所建立的发动机拆卸工艺碎片化知识图谱, 由于他们的专业概念没有统一, 导致了表示相同语义的工艺实体具有不同的表示形式。通过 SM-LMCS DS 模型判断, 这两个拆卸工艺碎片化知识图谱是相似的。为了消除冗余信息, 在两个碎片化知识图谱的融合图谱中, 仅需要保留一个标准的工艺实体表达形式, 即保留工艺实体“螺栓【气缸左盖】”或者保留工艺实体“螺丝【气缸左侧盖】”。因此, 实体融合的目的是将表达相同语义含义的工艺实体消除歧义, 保留标准的工艺实体。

为实现复杂装备拆卸工艺实体的统一化和标准化表示, 本章建立标准实体表达库, 通过在库中匹配标准实体来完成实体消除歧义。具体地, 通过表面相似来判断实体是否在标准实体表达库中。若在标准库中, 则采用标准实体进行替换。例如, 在标准库中, 存在“螺栓【气缸左盖】”, 因而在融合的拆卸工艺知识图谱中, 仅保留“螺栓【气缸左盖】”。若两个工艺实体均没有在标准库中出现, 则需要进一步在拆卸工艺知识图谱库中统计每个工艺实体出现的频率, 选择出现频率大的工艺实体作为融合知识图谱的工艺实体。




图4-6 两个复杂装备拆卸工艺碎片化知识图谱示例

Fig. 4-6 Two fragmentation knowledge graphs of complex equipment disassembly process

(2) 图结构融合

1) “插枝融合”

当拆卸工艺碎片化知识图谱中不包含第一类和第二类同归路径时，采用求同存异的原则，将两个碎片化知识图谱完全相同的拓扑结构以覆盖的形式合二为一，相异的拓扑结构（即具有不同的关系或者具有不同的实体）通过插枝的方式插入到融合的拆卸工艺知识图谱中，则融合的知识图谱将继续继承两个拆卸工艺碎片化知识图谱中的所有信息，从而不会造成信息遗漏同时消除了冗余信息。例如，对图 4-7 中的两个相似的拆卸工艺碎片化知识图谱融合时，将红色线框中完全相同的部分进行覆盖，将相异的关系和实体以插枝的形式插入到融合知识图谱中。进而，融合的知识图谱能够包含两个拆卸工艺碎片化知识图谱的全部信息，同时消除了冗余信息。




图4-7 复杂装备拆卸工艺碎片化知识图谱插枝融合示例

Fig. 4-7 Cuttings fusion of two fragmentation knowledge graphs of disassembly process

2) “异构同归路径融合”

复杂装备拆卸工艺建模人员所构建拆卸工艺知识图谱具有严密的数学逻辑和容易理解的特征。当两个拆卸工艺碎片化知识图谱中包含第二类同归路径时，两条同归路径可以被视为两条能够实现相同拆卸目标的不同工艺。因此，为了防止信息的遗漏，这两条同归路径都应该被保存在融合的工艺知识图谱中。当拆卸工艺碎片化知识图谱中包含第一类同归路径时，由于后者是前者的详细描述或者是相对完整工艺，前者是由于工艺建模人员对拆卸工艺知识认知不透彻所建立的工艺模型。因此，仅需将更完善的工艺保存在融合知识图谱中就可以使得工艺知识图谱包含两个拆卸工艺碎片化知识图谱的全部信息，同时有效地消除了冗余信息。例如，对于图 4-8 中用红色线圈标记出来的一组第二类同归路径，“气缸体→链轮【正时从动】→螺栓【正时从动链轮】-1”是“气缸体→螺栓【正时从动链轮】-1”的详细工艺路径。显然，在详细工艺路径中，“螺栓【正时从动链轮】-1”是“链轮【正时从动】”的“前序零件”，“链轮【正时从动】”是“气缸体”的“前序零件”。因此，“螺栓【正时从动链轮】-1”可以被视为“气缸体”的“前序零件”。在融合的工艺知识图谱中仅需要保留“气缸体→链轮【正时从动】→螺栓【正时从动链轮】-1”就可以保存两个拆卸工艺碎片化知识图谱的所有信息。




图4-8 异构同归路径融合示例

Fig. 4-8 Heterogeneous same destination paths fusion

4.3.3 基于 LMCS DS 相似度模型的适用性分析

(1) 设 A 和 B 为两个相似的复杂装备拆卸工艺碎片化知识图谱抽象的图结构, α 是相似度阈值。若 $SKG(A, B) > \alpha$, 则 A 相似于 B , 记为 $A \sim B$; 否则, A 与 B 不相似, 记为 $A \not\sim B$ 。

设相似度阈值 $\alpha=0.6$, A 和 B 如图 4-9 和图 4-10 所示。则两个拆卸工艺碎片化知识图谱的最大连通同归结构为 $A \cap B$ 和 $B \cap A$, 如式(4-3)所示。




图4-9 拆卸工艺碎片化知识图谱 A

Fig. 4-9 Fragmentation knowledge graph A of disassembly process




图4-10 拆卸工艺碎片化知识图谱 B

Fig. 4-10 Fragmentation knowledge graph B of disassembly process

$$\begin{aligned}
 A &= \{(1, 2), (1, 3), (3, 6), (6, 7), (3, 5), (1, 4), (4, 16)\} \\
 B &= \{(1, 8), (8, 2), (1, 6), (6, 7), (6, 9), (1, 10)\} \\
 A \cap B &= \{(1, 2), (1, 3), (3, 6), (6, 7)\} \\
 B \cap A &= \{(1, 8), (8, 2), (1, 6), (6, 7)\}
 \end{aligned} \tag{4-3}$$

根据 SM-LMCS DS(4-1), 得:

$$\frac{|V(A \cap B)|}{|V(A)|} = \frac{5}{8} > \alpha, \quad \frac{|V(B \cap A)|}{|V(B)|} = \frac{5}{7} > \alpha \tag{4-4}$$

公式(4-4)表明 $SKG(A, B) > \alpha$, 即两个拆卸工艺碎片化知识图谱是相似的, 说明 SM-LMCS DS 能有效度量两个碎片化知识图谱的相似度。

(2) 在复杂装备维修企业中, 拆卸工艺建模人员会在各种情境下构建针对同一个装备相同部分或者不同部分进行拆卸工艺建模。知识图谱结构形式的拆卸工艺模型数量持续增长, 所有的知识图谱结构形式的拆卸工艺模型构成了一个工艺知识图谱库。经过长期的积累, 工艺知识图谱库的规模持续扩大。因而, 碎片化知识图谱相似度量与融合必须考虑信息存储量和计算复杂度问题。为节约拆卸工艺知识图谱存储成本, 对于满足相似度阈值要求的碎片化知识图谱应仅将其融合后的知识图谱保存, 将原拆卸工艺碎片化知识图谱从知识图谱库中删除, 释放空间。因此, 拆卸工艺碎片化知识图谱之间的相似计算和融合是面

向当前知识图谱库中现有的碎片化知识图谱进行的，不考虑已经删除的碎片化知识图谱的相似度计算；否则，随着碎片化知识图谱的扩增，相似度计算成本和知识图谱库的存储成本迅速增长。

为保证融合正确性，SM-LMCSDS 应该满足传递性，尽可能避免出现由于相似度模型度量不准确而引起的漏融现象。比如，若 A 、 B 、 C 为 3 个拆卸工艺碎片化知识图谱的抽象的有向图，且满足： $SKG(A, B) > \alpha$ 、 $SKG(B, C) > \alpha$ 或者 $SKG(A, B) > \alpha$ 、 $SKG(A, C) > \alpha$ ，则通过 SM-LMCSDS 应该得到 $SKG(A \bar{\cup} B, C) > \alpha$ （ $\bar{\cup}$ 表示采用本章提出的融合方法对碎片化知识图谱进行融合）。

设当前知识图谱库中仅存在两个相似的拆卸工艺碎片化知识图谱 A （如图 4-9 所示）和 B （如图 4-10 所示），并且 $A \bar{\cup} B$ （如图 4-11 所示）为 A 和 B 融合后的拆卸工艺知识图谱。现一个新的拆卸工艺碎片化知识图谱 C （如图 4-12 所示）被设计并放入知识图谱库中。目前知识图谱库中只有 $A \bar{\cup} B$ ，碎片化知识图谱 A 和 B 被删除。SM-LMCSDS 应保证：如果 $C \dashv\dashv A$ 或 $C \dashv\dashv B$ ，则 $C \dashv\dashv A \bar{\cup} B$ 。




图4-11 融合的碎片化知识图谱 $A \bar{\cup} B$
Fig. 4-11 The fusion fragmentation knowledge graph $A \bar{\cup} B$




图4-12 拆卸工艺碎片化知识图谱 C
Fig. 4-12 Fragmentation knowledge graph C of disassembly process

由最大连通同归结构的定义和 SM-LMCSDS，可以得到各个碎片化知识图谱、最大连通同归结构的边集和其相似度满足：

$$\begin{aligned}
 C &= \{(1, 2), (2, 15), (1, 7), (7, 11), (7, 12), (1, 13), (13, 14)\} \\
 B \bar{\cap} C &= \{(1, 8), (8, 2), (1, 6), (6, 7)\}, C \bar{\cap} B = \{(1, 2), (1, 7)\} \\
 A \bar{\cap} C &= \{(1, 2), (1, 3), (3, 6), (6, 7)\}, C \bar{\cap} A = \{(1, 2), (1, 7)\} \\
 A \bar{\cup} B &= \{(1, 8), (8, 2), (1, 3), (3, 6), (6, 7), (6, 9), (3, 5), (1, 4), (4, 16), (1, 10)\} \quad (4-5) \\
 (A \bar{\cup} B) \bar{\cap} C &= \{(1, 8), (8, 2), (1, 3), (3, 6), (6, 7)\}, C \bar{\cap} (A \bar{\cup} B) = \{(1, 2), (1, 7)\} \\
 SKG(A, C) &= \frac{5}{8} > \alpha, SKG(B, C) = \frac{5}{7} > \alpha, SKG(A \bar{\cup} B, C) = \frac{6}{11} < \alpha
 \end{aligned}$$

显然,公式(4-5)表明, $C \dashv\vdash A$ 并且 $C \dashv\vdash B$, 但是 $C \not\vdash A \cup B$ 。实验结果表明,随着融合的进行, SM-LMCSDS 出现了相似度度量不准确。结果说明了 SM-LMCSDS 可能导致在拆卸工艺碎片化知识图谱融合建模过程中出现漏融现象。

(3)复杂装备拆卸工艺知识图谱是以无序状态或者是按照时间顺序存入工艺知识图谱库中。因此,知识图谱库中的拆卸工艺碎片化知识图谱的相似度计算过程是按照存储顺序进行的。为保证融合的正确性,融合结果应该是具有顺序无关性的,即不同的融合顺序最终形成的是同一个融合结果。




图4-13 知识图谱库

Fig. 4-13 Knowledge graph library

图 4-13 表明知识图谱库中存在三个拆卸工艺碎片化知识图谱 A、B 和 C, 其中,黄色部分是三个碎片化知识图谱的相似部分、粉色为 A、B 的其他相似部分、蓝色是各自独有部分。

1) 设 A、B、C 的相似度计算顺序为 $A \rightarrow B \rightarrow C$, 通过相似度公式(4-1), 计算拆卸工艺碎片化知识图谱 A 与拆卸工艺碎片化知识图谱 B 的相似度, 得到 $SKG(A, B) = 0.857 > \alpha$ 。因此, $A \dashv\vdash B$, 融合得到 $A \cup B$ 。随后, 删除知识图谱库中的 A 和 B。继续计算 $A \cup B$ 与 C 的相似度, 得到 $SKG(A \cup B, C) = 0.455 < \alpha$, C 与 $A \cup B$ 不相似。因此, 知识图谱库中 C 与 $A \cup B$ 共存。

2) 设 A、B、C 的相似度计算顺序为 $B \rightarrow C \rightarrow A$, 通过相似度公式(4-1)计算拆卸工艺碎片化知识图谱 B 与拆卸工艺碎片化知识图谱 C 的相似度, 得到 $SKG(B, C) = 0.857 > \alpha$ 。因此, $B \dashv\vdash C$, 融合得到 $B \cup C$ 。随后, 删除知识图谱库中的 B 和 C。继续计算 $B \cup C$ 与 A 的相似度, 得到 $SKG(B \cup C, A) = 0.6 > \alpha$, 因此, A、B、C 可以融合在一起。知识图谱库中仅有 $B \cup C \cup A$ 。

两次融合的结果表明, SM-LMCSDS 模型会因为融合顺序的原因而导致不同的融合结果。上述结果说明了 SM-LMCSDS 模型与提出的碎片化知识图谱融合方法之间不适应, SM-LMCSDS 难以有效度量融合后的碎片化知识图谱的相似度。因此, SM-LMCSDS 有待进一步提升。

4.4 面向知识图谱迭代融合的强化 LMCSDS 相似度建模

为了解决 SM-LMCSDS 相似度模型在拆卸工艺碎片化知识图谱融合中带来的问题,本节对 SM-LMCSDS 进行改进,建立了一种强化极大连通同归结构(reinforcement LMCSDS, RLMCSDS)相似度模型来有效度量拆卸工艺碎片化知识图谱间的相似度,并使其能够与碎片化知识图谱融合方法相适应。

4.4.1 RLMCSDS 相似度建模

通常情况下,众多的拆卸工艺建模人员对极其重要的工艺知识印象更为深刻,在所建立的拆卸工艺知识图谱通常会包含这些极其重要的工艺知识。因而,在拆卸工艺碎片化知识图谱中,高频的工艺实体一般比低频工艺实体更重要。因此,在碎片化知识图谱的相似度量建模中同等重要程度看待工艺实体是不符合实际的。基于上述分析,为了解决 SM-LMCSDS 的不适应性,本节研究工艺实体出现的频率对碎片化知识图谱相似度的影响。通过强化多次出现的工艺实体,建立了一种 RLMCSDS 相似度模型来有效度量融合后的工艺碎片化知识图谱的相似度。在 RLMCSDS 相似度模型中,初始化未融合前的所有工艺知识图谱中的工艺实体权重为 1,即碎片化知识图谱抽象为有向图后,节点的权重均为 1。此外,将工艺建模人员构建的拆卸工艺碎片化知识图谱定义为基工艺知识图谱,并且由多个基工艺知识图谱构成的集合称为基工艺知识图谱库。

定义 4. 工艺实体强化方法:设两个拆卸工艺碎片化知识图谱抽象的有向图分别为 A 和 B , 并且 W^A 和 W^B 分别为 A 和 B 的节点权重集合。若 A 和 B 相似,则其融合的工艺知识图谱的有向图为 $A \bar{\cup} B$, $A \bar{\cup} B$ 中各节点权重强化方法定义为公式(4-6)。

$$\begin{aligned} v_1 \in V(A) - V(A) \cap V(B), W_{v_1}^{A \bar{\cup} B} &= W_{v_1}^A \cdot \frac{|V(A \bar{\cup} B)|}{|V(A)|} \\ v_2 \in V(B) - V(A) \cap V(B), W_{v_2}^{A \bar{\cup} B} &= W_{v_2}^B \cdot \frac{|V(A \bar{\cup} B)|}{|V(B)|} \\ v_3 \in V(A) \cap V(B), W_{v_3}^{A \bar{\cup} B} &= \max \left\{ W_{v_3}^A \cdot \frac{|V(A \bar{\cup} B)|}{|V(A)|}, W_{v_3}^B \cdot \frac{|V(A \bar{\cup} B)|}{|V(B)|} \right\} \end{aligned} \quad (4-6)$$

式中 v_1 ——在有向图 A 中而不在有向图 B 中的节点;
 v_2 ——在有向图 B 中而不在有向图 A 中的节点;
 v_3 ——有向图 A 和有向图 B 的公共节点;

W_v^G ——节点 v 在有向图 G 中的权重。

在拆卸工艺碎片化知识图谱的不断融合过程中,工艺实体每重复出现一次,该实体的权重被加强一次。直观地,如图 4-14 所示,覆盖区域的工艺实体被强化程度最大,覆盖区域重复次数越多,工艺实体被强化次数越多,从而将低频工艺实体和低频工艺实体区分开,凸显高频工艺实体的重要性。




图4-14 融合的碎片化知识图谱权重更新过程示意图

Fig. 4-14 Entity weight distribution of the fused fragmentation knowledge graph

继而,本章将工艺实体重要度与 LMCS DS 结合,建立了 RLMCS DS 相似度模型来有效度量融合过程中拆卸工艺碎片化知识图谱之间的相似,如公式(4-7)所示。

$$RSKG(A, B) = \max_i \max \left\{ \frac{\sum_{v \in V(G_{1i})} W_v^A}{|V(A)|}, \frac{\sum_{v \in V(G_{2i})} W_v^B}{|V(B)|} \right\} \quad (4-7)$$

式中 A 、 B ——两个拆卸工艺碎片化知识图谱的有向图形式;

$\{G_{1i}; G_{2i}\}$ —— A 和 B 所有的 LMCS DSs, $i = 1, \dots, n$;

$\sum_{v \in V(G_{1i})} W_v^A$ —— G_{1i} 中所有节点在有向图 A 中的权重和;

$\sum_{v \in V(G_{2i})} W_v^B$ —— G_{2i} 中所有的节点在有向图 B 中的权重和。

4.4.2 RLMCS DS 相似度模型有效性理论证明

RLMCS DS 是否能够解决 SM-LMCS DS 在碎片化知识图谱迭代融合中的漏融问题与融合后知识图谱相似度度量不准确问题有待进一步验证。为了在理论上证明所建立的 RLMCS DS 的有效性,本节提出以下定理并证明定理的正确性。

定理: 在拆卸工艺碎片化知识图谱的相似度计算与融合中,RLMCS DS 避免了 SM-LMCS DS 带来的漏融现象,并且通过 RLMCS DS 度量的相似度具有有界性。

本节分三步对定理进行证明：

第一步，证明在三个基工艺知识图谱的相似度量与融合中，RLMCSDS 相似度模型避免了 SM-LMCSDS 模型带来的漏融现象；

第二步，证明在一个基工艺知识图谱库内部的相似度量与融合中，RLMCSDS 避免了 SM-LMCSDS 带来的漏融现象；

第三步，证明在两个基工艺知识图谱库之间的相似度量与融合中，RLMCSDS 避免了 SM-LMCSDS 带来的漏融现象。

步骤一：假设基工艺知识图谱库中共有三个拆卸工艺碎片化知识图谱，其有向图形式记为 A 、 B 和 C ，并且根据 SM-LMCSDS，它们是相似的。根据权重初始化规则，这三个碎片化知识图谱中每个工艺实体的权重均为 1。不妨设 $A \rightarrow B \rightarrow C$ 为基工艺知识图谱的融合顺序，则 A 和 B 的融合知识图谱的有向图形式可以被表示为 $\bar{A}_1 = A \bar{\cup} B$ 。通过工艺实体强化方法， $\bar{A}_1$ 的权重集合可以表示为：

$$\left\{ \frac{|V(A \bar{\cup} B)|}{|V(A)|}, \frac{|V(A \bar{\cup} B)|}{|V(B)|} \right\}$$

不妨假设在 SM-LMCSDS 的计算下 A 与 C 的相似度最高。由于 A 、 B 和 C 在 SM-LMCSDS 下相似，则有：

$$\max\{SKG(A, C), SKG(B, C)\} = SKG(A, C) = \max\left\{ \frac{|V(A \bar{\cap} C)|}{|V(A)|}, \frac{|V(C \bar{\cap} A)|}{|V(C)|} \right\} > \alpha$$

容易得到， $\bar{A}_1$ 和 C 一定存在一个 LMCSDS $\{G_1; G_2\}$ 满足：
 $V(A \bar{\cap} C) \subseteq V(G_1) \subseteq V(\bar{A}_1)$ 和 $V(C \bar{\cap} A) \subseteq V(G_2) \subseteq V(C)$ 。进一步，可以推断出：

$$\frac{\sum_{v \in V(G_1)} w_v^{\bar{A}_1}}{|\bar{A}_1|} \geq \frac{\sum_{v \in V(A \bar{\cap} C)} w_v^{\bar{A}_1}}{|\bar{A}_1|} = \frac{\sum_{v \in V(A \bar{\cap} C)} w_v^{\bar{A}_1}}{|V(A \bar{\cup} B)|} \quad (4-8)$$

$$\frac{\sum_{v \in V(G_2)} w_v^C}{|V(C)|} = \frac{\sum_{v \in V(G_2)} 1}{|V(C)|} = \frac{|V(G_2)|}{|V(C)|} \geq \frac{|V(C \bar{\cap} A)|}{|V(C)|} \quad (4-9)$$

根据实体被强化程度的不同，将公式(4-8)中 $V(A \bar{\cap} C)$ 拆成两个互不相交的部分，得到：

$$\begin{aligned}
& \frac{\sum_{v \in V(A \cap C)} w_v^{\bar{A}}}{|V(A \cup B)|} \\
&= \frac{\sum_{v \in [V(A) - V(A) \cap V(B)] \cap V(A \cap C)} w_v^{\bar{A}} + \sum_{v \in [V(A) \cap V(B)] \cap V(A \cap C)} w_v^{\bar{A}}}{|V(A \cup B)|} \\
&= \frac{\sum_{v \in [V(A) - V(A) \cap V(B)] \cap V(A \cap C)} \frac{|V(A \cup B)|}{|V(A)|} + \sum_{v \in [V(A) \cap V(B)] \cap V(A \cap C)} \max \left\{ \frac{|V(A \cup B)|}{|V(A)|}, \frac{|V(A \cup B)|}{|V(B)|} \right\}}{|V(A \cup B)|} \quad (4-10) \\
&\geq \frac{\sum_{v \in [V(A) - V(A) \cap V(B)] \cap V(A \cap C)} \frac{|V(A \cup B)|}{|V(A)|} + \sum_{v \in [V(A) \cap V(B)] \cap V(A \cap C)} \frac{|V(A \cup B)|}{|V(A)|}}{|V(A \cup B)|} \\
&= \frac{\sum_{v \in V(A \cap C)} \frac{|V(A \cup B)|}{|V(A)|}}{|V(A \cup B)|} = \frac{|V(A \cup B)|}{|V(A \cup B)|} \cdot \frac{|V(A \cap C)|}{|V(A)|} = \frac{|V(A \cap C)|}{|V(A)|}
\end{aligned}$$

由公式(4-8)和公式(4-10)，可得：

$$\frac{\sum_{v \in V(G_1)} w_v^{\bar{A}}}{|V(\bar{A}_1)|} \geq \frac{|V(A \cap C)|}{|V(A)|} \quad (4-11)$$

$\{G_1; G_2\}$ 是 $\bar{A}_1$ 和 C 的一个 LMCS DS，由 RLMCS DS 的定义式(4-7)，可得：

$$RSKG(\bar{A}_1, C) \geq \max \left\{ \frac{\sum_{v \in V(G_1)} w_v^{\bar{A}}}{|V(\bar{A}_1)|}, \frac{\sum_{v \in V(G_2)} w_v^C}{|V(C)|} \right\} \quad (4-12)$$

由于 A 与 C 在 SM-LMCS DS 下相似，通过公式(4-12)可得： $RSKG(\bar{A}_1, C) \geq SKG(A, C) > \alpha$ 。结果表明融合后的知识图谱与基工艺知识图谱之间相似度不小于基工艺知识图谱之间的相似度，即在 RLMCS DS 下， $\bar{A}_1$ 与 C 相似， $\bar{A}_1$ 仍能够继续与 C 融合。结果证明了在三个基工艺知识图谱的相似度量与融合中，RLMCS DS 避免了 SM-LMCS DS 带来的漏融现象。

由本章提出的碎片化知识图谱融合方法，得到融合后的工艺知识图谱抽象的有向图可以表示为 $\bar{A}_2 = A \cup B \cup C$ 。根据实体权重强化方法， $\bar{A}_2$ 中各个节点的

权重可以由公式(4-13)计算得到。

$$\left\{ \begin{array}{l} v_1 \in V(A) - V_\alpha - V_\beta, W_{v_1}^{\bar{A}_2} = \frac{|V(\bar{A}_1)|}{|V(A)|} \cdot \frac{|V(\bar{A}_1 \bar{U} C)|}{|V(\bar{A}_1)|} = \frac{|V(A \bar{U} B \bar{U} C)|}{|V(A)|}, \\ v_2 \in V(B) - V_\beta - V_\gamma, W_{v_2}^{\bar{A}_2} = \frac{|V(\bar{A}_1)|}{|V(B)|} \cdot \frac{|V(\bar{A}_1 \bar{U} C)|}{|V(\bar{A}_1)|} = \frac{|V(A \bar{U} B \bar{U} C)|}{|V(B)|}, \\ v_3 \in V(C) - V_\alpha - V_\gamma, W_{v_3}^{\bar{A}_2} = 1 \cdot \frac{|V(\bar{A}_1 \bar{U} C)|}{|V(C)|} = \frac{|V(A \bar{U} B \bar{U} C)|}{|V(C)|}, \\ v_4 \in V_\beta - V_\delta, W_{v_4}^{\bar{A}_2} = \max \left\{ \frac{|V(A \bar{U} B \bar{U} C)|}{|V(A)|}, \frac{|V(A \bar{U} B \bar{U} C)|}{|V(B)|} \right\}, \\ v_5 \in V_\alpha - V_\delta, W_{v_5}^{\bar{A}_2} = \max \left\{ \frac{|V(A \bar{U} B \bar{U} C)|}{|V(A)|}, \frac{|V(A \bar{U} B \bar{U} C)|}{|V(C)|} \right\}, \\ v_6 \in V_\gamma - V_\delta, W_{v_6}^{\bar{A}_2} = \max \left\{ \frac{|V(A \bar{U} B \bar{U} C)|}{|V(B)|}, \frac{|V(A \bar{U} B \bar{U} C)|}{|V(C)|} \right\}, \\ v_7 \in V_\delta, W_{v_7}^{\bar{A}_2} = \max \left\{ \frac{|V(A \bar{U} B \bar{U} C)|}{|V(A)|}, \frac{|V(A \bar{U} B \bar{U} C)|}{|V(B)|}, \frac{|V(A \bar{U} B \bar{U} C)|}{|V(C)|} \right\} \end{array} \right. \quad (4-13)$$

式中 V_δ —— A 、 B 和 C 的公共节点, 即 $V_\delta = V(A) \cap V(B) \cap V(C)$;

V_α —— A 和 C 的公共节点, 即 $V_\alpha = V(A) \cap V(C)$;

V_β —— A 和 B 的公共节点, 即 $V_\beta = V(A) \cap V(B)$;

V_γ —— B 和 C 的公共节点, 即 $V_\gamma = V(B) \cap V(C)$ 。

根据两次强化的实体权重的不同, $\bar{A}_2$ 中可被表示为 7 个不交的区域, 并且每部分的节点权重与公式(4-13)一一对应, 如图 4-15 所示。

融合知识图谱 $\bar{A}_2$ 的权重集合可以表示为:

$$\left\{ \frac{|V(A \bar{U} B \bar{U} C)|}{|V(A)|}, \frac{|V(A \bar{U} B \bar{U} C)|}{|V(B)|}, \frac{|V(A \bar{U} B \bar{U} C)|}{|V(C)|} \right\} \quad (4-14)$$




图4-15 由三个基工艺知识图谱融合的工艺知识图谱权重图

Fig. 4-15 Weight distribution of fusion process knowledge graph of three basis

步骤二：采用数学归纳法来完成定理第二步的证明。假设基工艺知识图谱库中共有 n 个拆卸工艺碎片化知识图谱时定理仍然成立。设 $\{A_i\}_{i=1,2,\dots,n}$ 是基工艺知识图谱库的所有拆卸工艺碎片化知识图谱抽象的有向图， $\overline{A_{n-1}} = \bigcup_{i=1}^n A_i$ 是融合的

工艺知识图谱抽象的有向图，并且 $\overline{A_{n-1}}$ 的权重集合形如 $\left\{ \frac{|V(\overline{A_{n-1}})|}{|V(A_i)|} \right\}_{i=1,2,\dots,n}$ 。假设现

在又获取了一个基工艺知识图谱，其抽象的有向图为 A_{n+1} 。此外，在 SM-LMCSDS 的计算下， A_{n+1} 与 $\{A_i\}_{i=1,2,\dots,n}$ 中的某些相似。不妨设 A_{n+1} 与 A_1 相似度最高，则有：

$$\max_{i \in \{1,2,\dots,n\}} SKG(A_i, A_{n+1}) = SKG(A_1, A_{n+1}) = \max \left\{ \frac{|V(A_1 \cap A_{n+1})|}{|V(A_1)|}, \frac{|V(A_{n+1} \cap A_1)|}{|V(A_{n+1})|} \right\} > \alpha \quad (4-15)$$

容易得到， $\overline{A_{n-1}}$ 和 A_{n+1} 一定存在一个 LMCSDS $\{G_1; G_2\}$ 满足：
 $V(A_1 \cap A_{n+1}) \subseteq V(G_1) \subseteq V(\overline{A_{n-1}})$ 和 $V(A_{n+1} \cap A_1) \subseteq V(G_2) \subseteq V(A_{n+1})$ 。进一步，可以得到：

$$\frac{\sum_{v \in V(G_1)} w_v^{\overline{A_{n-1}}} }{|V(\overline{A_{n-1}})|} \geq \frac{\sum_{v \in V(A_1 \cap A_{n+1})} w_v^{\overline{A_{n-1}}} }{|V(\overline{A_{n-1}})|} \quad (4-16)$$

$$\frac{\sum_{v \in V(G_2)} w_v^{A_{n+1}} }{|V(A_{n+1})|} = \frac{\sum_{v \in V(G_2)} 1 }{|V(A_{n+1})|} = \frac{|V(G_2)|}{|V(A_{n+1})|} \geq \frac{|V(A_{n+1} \cap A_1)|}{|V(A_{n+1})|} \quad (4-17)$$

由实体强化方法， A_1 与其他有向图中的共有的节点被不断强化，故在融合

的拆卸工艺碎片化知识图谱的有向图 $\overline{A_{n-1}}$ 中, 原 A_1 中的所有节点权重满足公式 (4-18)。

$$v \in V(A_1), W_v^{\overline{A_{n-1}}} \geq \frac{|V(\overline{A_{n-1}})|}{|V(A_1)|} \quad (4-18)$$

由公式(4-16)及公式(4-18), 得到:

$$\begin{aligned} \frac{\sum_{v \in V(G_1)} W_v^{\overline{A_{n-1}}}}{|V(\overline{A_{n-1}})|} &\geq \frac{\sum_{v \in V(A_1 \cap A_{n+1})} W_v^{\overline{A_{n-1}}}}{|V(\overline{A_{n-1}})|} \geq \frac{\sum_{v \in V(A_1 \cap A_{n+1})} \frac{|V(\overline{A_{n-1}})|}{|V(A_1)|}}{|V(\overline{A_{n-1}})|} \\ &= \frac{|V(\overline{A_{n-1}})|}{|V(A_1)|} \cdot \frac{|V(A_1 \cap A_{n+1})|}{|V(\overline{A_{n-1}})|} = \frac{|V(A_1 \cap A_{n+1})|}{|V(A_1)|} \end{aligned} \quad (4-19)$$

因此, 根据 RLMCSDS 模型定义, 容易得到:

$$\begin{aligned} RSKG(\overline{A_{n-1}}, A_{n+1}) &\geq \max \left\{ \frac{\sum_{v \in V(G_1)} W_v^{\overline{A_{n-1}}}}{|V(\overline{A_{n-1}})|}, \frac{\sum_{v \in V(G_2)} W_v^{A_{n+1}}}{|V(A_{n+1})|} \right\} \\ &\geq \max_{i \in \{1, 2, \dots, n\}} SKG(A_i, A_{n+1}) = SKG(A_1, A_{n+1}) \end{aligned} \quad (4-20)$$

公式(4-20)表明 $RSKG(\overline{A_{n-1}}, A_{n+1}) > \alpha$ 。因此, $\overline{A_{n-1}}$ 与 A_{n+1} 的相似性仍然得以保证, 即融合的工艺知识图谱与新的基工艺知识图谱仍然是相似的。实验结果表明, RLMCSDS 不会出现由 SM-LMCSDS 带来的漏融现象。进一步, 得到 $\overline{A_{n-1}}$ 和 A_{n+1} 融合的有向图 $\overline{A_n} = \overline{A_{n-1}} \cup A_{n+1} = \bigcup_{i=1}^{n+1} A_i$ 。根据实体权重强化定义, 得到 $\overline{A_n}$ 中每个节点的权重, 如公式(4-21)所示。

$$\begin{cases} v_1 \in V(\overline{A_{n-1}}) - V_\alpha, W_{v_1}^{\overline{A_n}} = W_{v_1}^{\overline{A_{n-1}}} \cdot \frac{|V(\overline{A_{n-1}} \cup A_{n+1})|}{|V(\overline{A_{n-1}})|}, \\ v_2 \in V(A_{n+1}) - V_\alpha, W_{v_2}^{\overline{A_n}} = W_{v_2}^{A_{n+1}} \cdot \frac{|V(\overline{A_{n-1}} \cup A_{n+1})|}{|V(A_{n+1})|}, \\ v_3 \in V_\alpha, W_{v_3}^{\overline{A_n}} = \max \left\{ W_{v_3}^{\overline{A_{n-1}}} \cdot \frac{|V(\overline{A_{n-1}} \cup A_{n+1})|}{|V(\overline{A_{n-1}})|}, W_{v_3}^{A_{n+1}} \cdot \frac{|V(\overline{A_{n-1}} \cup A_{n+1})|}{|V(A_{n+1})|} \right\} \end{cases} \quad (4-21)$$

式中 V_α ——有向图 $\overline{A_{n-1}}$ 和 A_{n+1} 的公共节点, 即 $V_\alpha = V(\overline{A_{n-1}}) \cap V(A_{n+1})$ 。

从 $\overline{A_{n-1}}$ 的节点权重集合和公式(4-21)可以看出, $\overline{A_n}$ 的实体权重集合可以表达为 $\left\{ \frac{|V(\overline{A_n})|}{|V(A_i)|} \right\}_{i=1,2,\dots,n+1}$ 。由数学归纳法原理, 定理仍然成立。证明了在一个基工艺

知识图谱库内部的相似度量与融合中, RLMCSDS 避免了 SM-LMCSDS 带来的漏融现象。此外, 实体权重集合有通用表达式。

步骤三: 定理适用于单个基工艺知识图谱库的迭代融合, 定理是否适用于多个基工艺知识图谱库之间的迭代融合有待进一步验证。若能够证明两个基工艺知识图谱库之间的迭代融合仍然满足定理, 则通过步骤二, 可以进一步证明定理适用于多个基工艺知识图谱库之间的迭代融合。

不妨假设现有两个基工艺知识图谱库抽象的有向图集合分别为 $\{A_i\}_{i=1,2,\dots,n}$ 和 $\{B_i\}_{i=1,2,\dots,m}$, 其融合的结果分别为 $\overline{A_{n-1}} = \bigcup_{i=1}^n A_i$ 和 $\overline{B_{m-1}} = \bigcup_{j=1}^m B_j$, 其权重集合分别为 $\left\{ \frac{|V(\overline{A_{n-1}})|}{|V(A_i)|} \right\}_{i=1,2,\dots,n}$ 和 $\left\{ \frac{|V(\overline{B_{m-1}})|}{|V(B_j)|} \right\}_{j=1,2,\dots,m}$ 。在 SM-LMCSDS 的计算下, 不妨设在两个

基工艺知识图谱库之间 A_i 与 B_i 相似度最高, 并且 A_i 与 B_i 相似, 则有:

$$\max_{i \in \{1,2,\dots,n\}, j \in \{1,2,\dots,m\}} SKG(A_i, B_j) = SKG(A_i, B_i) = \max \left\{ \frac{|V(A_i \cap B_i)|}{|V(A_i)|}, \frac{|V(B_i \cap A_i)|}{|V(B_i)|} \right\} > \alpha \quad (4-22)$$

容易得到, $\overline{A_{n-1}}$ 和 $\overline{B_{m-1}}$ 一定存在一个 LMCSDS $\{G_1; G_2\}$ 满足: $V(A_i \cap B_i) \subseteq V(G_1) \subseteq V(\overline{A_{n-1}})$ 和 $V(B_i \cap A_i) \subseteq V(G_2) \subseteq V(\overline{B_{m-1}})$, 则:

$$\frac{\sum_{v \in V(G_1)} W_v^{\overline{A_{n-1}}} }{|V(\overline{A_{n-1}})|} \geq \frac{\sum_{v \in V(A_i \cap B_i)} W_v^{\overline{A_{n-1}}} }{|V(\overline{A_{n-1}})|} \quad (4-23)$$

$$\frac{\sum_{v \in V(G_2)} W_v^{\overline{B_{m-1}}} }{|V(\overline{B_{m-1}})|} \geq \frac{\sum_{v \in V(A_i \cap B_i)} W_v^{\overline{B_{m-1}}} }{|V(\overline{B_{m-1}})|} \quad (4-24)$$

由实体权重强化定义, 在融合过程中, A_i 与 $\{A_i\}_{i=1,2,\dots,n}$ 中的共有节点被不断强化, 故在 $\overline{A_{n-1}}$ 中, 原 A_i 中的所有节点权重满足:

$$v \in V(A_1), W_v^{\overline{A_{n-1}}} \geq \frac{|V(\overline{A_{n-1}})|}{|V(A_1)|} \quad (4-25)$$

因此，公式(4-23)可以简化为：

$$\frac{\sum_{v \in V(A_1 \cap B_1)} W_v^{\overline{A_{n-1}}}}{|V(\overline{A_{n-1}})|} \geq \frac{\sum_{v \in V(A_1 \cap B_1)} \frac{|V(\overline{A_{n-1}})|}{|V(A_1)|}}{|V(\overline{A_{n-1}})|} = \frac{|V(\overline{A_{n-1}})|}{|V(A_1)|} \cdot \frac{|V(A_1 \cap B_1)|}{|V(\overline{A_{n-1}})|} = \frac{|V(A_1 \cap B_1)|}{|V(A_1)|} \quad (4-26)$$

同理可得，公式(4-24)可以简化为证明：

$$\frac{\sum_{v \in V(G_2)} W_v^{\overline{B_{m-1}}}}{|V(\overline{B_{m-1}})|} \geq \frac{\sum_{v \in V(B_1 \cap A_1)} W_v^{\overline{B_{m-1}}}}{|V(\overline{B_{m-1}})|} \geq \frac{|V(B_1 \cap A_1)|}{|V(B_1)|} \quad (4-27)$$

因此，由 RLMCSDS、公式(4-26)和公式(4-27)，得到：

$$\begin{aligned} RSKG(\overline{A_{n-1}}, \overline{B_{m-1}}) &\geq \max \left\{ \frac{\sum_{v \in V(G_1)} W_v^{\overline{A_{n-1}}}}{|V(\overline{A_{n-1}})|}, \frac{\sum_{v \in V(G_2)} W_v^{\overline{B_{m-1}}}}{|V(\overline{B_{m-1}})|} \right\} \\ &\geq \max_{\substack{i \in \{1, 2, \dots, n\} \\ j \in \{1, 2, \dots, m\}}} SKG(A_i, B_j) = SKG(A_1, B_1) > \alpha \end{aligned} \quad (4-28)$$

结果表明， $\overline{A_{n-1}}$ 和 $\overline{B_{m-1}}$ 相似，即在两个基工艺知识图谱库之间的相似度量与融合中，RLMCSDS 避免了 SM-LMCSDS 带来的漏融现象。进一步，得到 $\overline{A_{n-1}}$ 和 $\overline{B_{m-1}}$ 融合的有向图 $\overline{A_{n+m-1}} = \overline{A_{n-1}} \cup \overline{B_{m-1}}$ 。根据工艺实体权重强化定义，得到 $\overline{A_{n+m-1}}$ 中每个节点的权重，如公式(4-29)所示。

$$\begin{cases} v_1 \in V(\overline{A_{n-1}}) - V_\alpha, W_{v_1}^{\overline{A_{n+m-1}}} = W_{v_1}^{\overline{A_{n-1}}} \cdot \frac{|V(\overline{A_{n-1}} \cup \overline{B_{m-1}})|}{|V(\overline{A_{n-1}})|}, \\ v_2 \in V(\overline{B_{m-1}}) - V_\alpha, W_{v_2}^{\overline{A_{n+m-1}}} = W_{v_2}^{\overline{B_{m-1}}} \cdot \frac{|V(\overline{A_{n-1}} \cup \overline{B_{m-1}})|}{|V(\overline{B_{m-1}})|}, \\ v_3 \in V_\alpha, W_{v_3}^{\overline{A_{n+m-1}}} = \max \left\{ W_{v_3}^{\overline{A_{n-1}}} \cdot \frac{|V(\overline{A_{n-1}} \cup \overline{B_{m-1}})|}{|V(\overline{A_{n-1}})|}, W_{v_3}^{\overline{B_{m-1}}} \cdot \frac{|V(\overline{A_{n-1}} \cup \overline{B_{m-1}})|}{|V(\overline{B_{m-1}})|} \right\} \end{cases} \quad (4-29)$$

式中 V_α —— $\overline{A_{n-1}}$ 和 $\overline{B_{m-1}}$ 的公共节点，即 $V_\alpha = V(\overline{A_{n-1}}) \cap V(\overline{B_{m-1}})$ 。

从 $\overline{A_{n-1}}$ 和 $\overline{B_{m-1}}$ 的节点权重集合和公式(4-29)可以看出， $\overline{A_{n+m-1}}$ 的节点权重集合

可以表达为 $\left\{ \frac{|V(\overline{A_{n+m-1}})|}{|V(A_i)|}, \frac{|V(\overline{A_{n+m-1}})|}{|V(B_j)|} \right\}_{i=1,2,\dots,n; j=1,2,\dots,m}$ ，则实体权重集合有通用表达式。

设 $\{G_{1k}; G_{2k}\}$ 为 $\overline{A_{n-1}}$ 和 $\overline{B_{m-1}}$ 的任意一个 LMCS DS，则容易得到：

$$\begin{aligned} \frac{\sum_{v \in V(G_{1k})} w_v^{\overline{A_{n-1}}} }{|V(\overline{A_{n-1}})|} &= \frac{\sum_{v \in V(G_{1k}) \cap V(\overline{A_{n-1}})} w_v^{\overline{A_{n-1}}} }{|V(\overline{A_{n-1}})|} = \frac{\sum_{v \in V(G_{1k}) \cap V(\bigcup_{i=1}^n A_i)} w_v^{\overline{A_{n-1}}} }{|\overline{A_{n-1}}|} \\ &\leq \frac{\sum_{i=1}^n \sum_{v \in V(G_{1k}) \cap V(A_i)} \frac{|\overline{A_{n-1}}|}{|A_i|}}{|V(\overline{A_{n-1}})|} = \sum_{i=1}^n \sum_{v \in V(G_{1k}) \cap V(A_i)} \frac{1}{|A_i|} < \sum_{i=1}^n 1 = n \end{aligned} \quad (4-30)$$

$$\begin{aligned} \frac{\sum_{v \in V(G_{2k})} w_v^{\overline{B_{m-1}}} }{|V(\overline{B_{m-1}})|} &= \frac{\sum_{v \in V(G_{2k}) \cap V(\overline{B_{m-1}})} w_v^{\overline{B_{m-1}}} }{|V(\overline{B_{m-1}})|} = \frac{\sum_{v \in V(G_{2k}) \cap V(\bigcup_{j=1}^m B_j)} w_v^{\overline{B_{m-1}}} }{|\overline{B_{m-1}}|} \\ &\leq \frac{\sum_{j=1}^m \sum_{v \in V(G_{2k}) \cap V(B_j)} \frac{|\overline{B_{m-1}}|}{|B_j|}}{|V(\overline{B_{m-1}})|} = \sum_{j=1}^m \sum_{v \in V(G_{2k}) \cap V(B_j)} \frac{1}{|B_j|} < \sum_{j=1}^m 1 = m \end{aligned} \quad (4-31)$$

进一步，根据 RLMCS DS，得到拆卸工艺碎片化知识图谱的相似度具有有界性，如公式(4-32)所示。

$$RSKG(\overline{A_{n-1}}, \overline{B_{m-1}}) = \max_k \max \left\{ \frac{\sum_{v \in V(G_{1k})} w_v^{\overline{A_{n-1}}} }{|V(\overline{A_{n-1}})|}, \frac{\sum_{v \in V(G_{2k})} w_v^{\overline{B_{m-1}}} }{|V(\overline{B_{m-1}})|} \right\} \leq \max\{n, m\} \quad (4-32)$$

上述定理说明了：（1）在拆卸工艺碎片化知识图谱的相似度与融合过程中，RLMCS DS 避免了 SM-LMCS DS 带来的漏融问题；（2）通过 RLMCS DS 计算的相似度具有有界性。（3）RLMCS DS 可以支持多个基工艺知识图谱库可以同时进行融合，并行运算是可实现的。

4.5 复杂装备拆卸工艺知识图谱自动构建案例分析

本节采用 JH70 发动机拆卸工艺碎片化知识图谱库来验证所建立的相似度模型和提出的融合方法的有效性。

4.5.1 实验数据

为了验证 RLMCSDS 和碎片化知识图谱融合方法在复杂装备拆卸工艺知识图谱自动构建的有效性，将 RLMCSDS 和融合方法应用在 JH70 发动机拆卸工艺知识图谱自动构建中，所采用的工艺知识图谱库共包含了 19 个发动机拆卸工艺碎片化知识图谱，如图 4-16 所示。




图4-16 发动机拆卸工艺碎片化知识图谱库

Fig. 4-16 Fragmentation knowledge graph library of engine disassembly process

为了验证本章建立的 RLMCSDS、SM-LMCSDS 相较于传统图结构相似度模型的优势，根据同归路径的类型，基于现有的 JH70 发动机拆卸工艺知识图谱，构建了两种实验数据集：一种是仅包含第三类同归路径的工艺知识图谱库，如图 4-17 所示；另一种是包含三类同归路径的工艺知识图谱库，如图 4-18 所示。第一类同归路径和第二类同归路径在关系上比第三类同归路径更为复杂。因此，称第一个工艺知识图谱库为简单关系发动机拆卸工艺知识图谱库，简称简单工艺知识图谱库；称第二个工艺知识图谱库为复杂关系发动机拆卸工艺知识图谱库，简称复杂工艺知识图谱库。在实验中，简单工艺知识图谱库和复杂

工艺知识图谱库分别包含 23 个发动机拆卸工艺碎片化知识图谱。




图4-17 简单工艺知识图谱库

Fig. 4-17 Simple process knowledge graph library




图4-18 复杂工艺知识图谱库

Fig. 4-18 Complex process knowledge graph

4.5.2 发动机拆卸工艺知识图谱融合建模案例

本节选取图4-16所示的工艺知识图谱库来验证面向碎片化知识图谱迭代融合建模方法的有效性。

首先，根据第2章和第3章中工艺知识语义向量化表达方法以及工艺实体类别预测方法，通过实体的相似度对比，将发动机拆卸工艺、气缸头、气缸体

等工艺实体分别用数字 1-28 表示。进一步，将图 4-16 中的所有工艺碎片化知识图谱抽象为有向图形式，如表 4-3 所示。

表4-3 发动机拆卸工艺碎片化知识图谱的有向图表达

Table 4-3 Directed graph of fragmentation knowledge graphs of engine disassembly process

碎片化知识图谱编号	有向图的边集	有向图的权重集合
1	$\{(3,6),(3,7),(6,14),(6,15),(6,16), (6,17),(7,18),(7,19),(7,20),(7,22)\}.$	$\{[3,1],[6,1],[7,1],[14,1],[15,1],[16,1], [17,1],[18,1],[19,1],[20,1],[22,1]\}.$
2	$\{(2,5),(5,11),(5,12),(11,27),(5,26)\}.$	$\{[2,1],[5,1],[11,1],[12,1],[26,1],[27,1]\}.$
3	$\{(3,6),(3,7),(6,13),(6,15),(6,16), (6,17),(7,19),(7,21)\}.$	$\{[3,1],[6,1],[7,1],[13,1],[15,1],[16,1], [17,1],[19,1],[21,1]\}.$
.....		
19	$\{(2,5),(5,10),(5,11),(5,12),(10,26), (11,27),(12,28)\}.$	$\{[2,1],[5,1],[10,1],[11,1],[12,1],[26,1], [27,1],[28,1]\}.$

设置相似度阈值 $\alpha = 0.6$ ，并采用 RLMCSDS 来度量两个工艺碎片化知识图谱间的相似度。若相似度大于 α ，则认为两个工艺碎片化知识图谱是相似的。随后，采用本章的融合方法对其融合，并在库中保留融合的工艺知识图谱及其权重，同时删除原来的工艺碎片化知识图谱。若相似度小于等于 α ，则认为两个工艺碎片化知识图谱是不相似的，进行其他工艺碎片化知识图谱的相似度量。

首先，计算工艺碎片化知识图谱 1 和工艺碎片化知识图谱 2 的相似度， $RSKG(1,2) = 0 < \alpha$ 。结果表明碎片化知识图谱 1 与碎片化知识图谱 2 不相似。随后，计算碎片化知识图谱 1 和碎片化知识图谱 3 的 LMCSDS：

$$1\bar{\cap}3 = \{(3,6),(3,7),(6,15),(6,16),(6,17),(7,19)\}$$

$$3\bar{\cap}1 = \{(3,6),(3,7),(6,15),(6,16),(6,17),(7,19)\}$$

进而，得到其相似度 $RSKG(1,3) = 0.7778 > \alpha$ 。由融合方法得到碎片化知识图谱 1 和碎片化知识图谱 3 融合的工艺知识图谱，如图 4-19 所示。




图4-19 碎片化知识图谱 1 和 3 的融合结果

Fig. 4-19 Fusion result of the 1st and 3rd fragmentation knowledge graphs

在发动机拆卸工艺碎片化知识图谱库中，删除碎片化知识图谱 1 和碎片化知识图谱 3，保留它们的融合知识图谱及其新的权重，为下次相似度量度和融合做准备。重复上述过程，经过反复迭代融合，得到最终融合的 JH70 发动机拆卸工艺知识图谱，如图 4-20 所示。此外，采用人工的方式对发动机拆卸工艺碎片化知识图谱库中的碎片化知识图谱进行相似度分析、融合和校验，得到的 JH70 发动机拆卸工艺知识图谱，如图 4-21 所示。




图4-20 所提出方法融合的发动机拆卸工艺知识图谱

Fig. 4-20 The fused knowledge graph of engine disassembly process with the proposed method

观察发现图 4-20 中的两个部分均为图 4-21 的子图。图 4-20 与图 4-21 基本相同，不同之处在于，图 4-20 中“气缸”和“气缸体”之间缺少一条关系。经过查询，发现在发动机拆卸工艺碎片化知识图谱库中不存在“气缸”和“气缸体”相关联的拆卸工艺碎片化知识图谱。事实上，图 4-21 是通过人工修正过获得的工艺知识图谱，即人为在“气缸”和“气缸体”添加工艺关系。因此，实验结果表明图 4-20 和图 4-21 的差异不是相似度量模型和融合方法带来的误差，而是初始的工艺碎片化知识图谱中缺乏“气缸”和“气缸体”的工艺关系。经人工修正，可以得到，由碎片化知识图谱迭代融合得到的发动机拆卸工艺知识图谱与人工融合得到的发动机拆卸工艺知识图谱完全一致，验证了建立的

RLMCSDS 相似度模型和提出的融合方法在复杂装备拆卸工艺知识图谱自动构建上的有效性。




图4-21 人工融合的发动机工艺知识图谱

Fig. 4-21 The fused knowledge graph of engine disassembly process with manual work

4.5.3 两种相似度模型在结构相似度量的优势分析

传统的最大公共子图模型（MCS）、最大公共连通子图模型（MCCS）仅能够度量边的相似度，无法度量路径相似度，而本章建立的基于同归结构的模型不仅能够有效度量边的相似度，还能够度量路径相似度。为了验证所建立的RLMCSDS和SM-LMCSDS的有效性，本节将MCS、MCCS与基于同归结构的模型在简单工艺知识图谱库和复杂工艺知识图谱库分别进行对比实验。

4.5.3.1 模型评估

在一个工艺知识图谱库中进行相似度量时，通常是计算两两工艺碎片化知识图谱的相似度，该方法难以有效评估相似度量模型在知识图谱库上整体的准确性。为了解决上述问题，本节建立碎片化知识图谱库相似度和匹配率来评估相似度量模型在知识图谱库上整体的准确性。

碎片化知识图谱库相似度：随机抽取知识图谱库中的一个碎片化知识图谱 x_i ，然后计算 x_i 与库中剩余的碎片化知识图谱的相似度。最后，对得到的相似度

取平均值,得到碎片化知识图谱库相似度,简称库相似度。具体地,如公式(4-33)所示。

$$Svg(model) = \frac{\sum_{j \neq i} model(x_j, x_i)}{a-1} \quad (4-33)$$

式中 $model$ ——所采用的相似度量模型;

a ——碎片化知识图谱库的规模;

x_i ——随机抽取的一个碎片化知识图谱;

$model(x_j, x_i)$ ——采用 $model$ 计算碎片化知识图谱 x_i 与碎片化知识图谱 x_j 的相似度。

匹配率: 若两个工艺碎片化知识图谱的相似度大于阈值,则称其是一个成功的匹配。碎片化知识图谱库相似度的计算过程可以被视为一次实验,在该次实验中计算成功的匹配次数占总匹配次数的比重,即为匹配率。为了避免结果的偶然性,多次重复实验,取匹配率的平均值作为实验最终的匹配率,如公式(4-34)所示。

$$MR = \frac{\frac{MN_1}{a-1} + \frac{MN_2}{a-1} + \dots + \frac{MN_k}{a-1} + \dots + \frac{MN_n}{a-1}}{n} = \frac{\sum_{k=1}^n MN_k}{n \times (a-1)} \quad (4-34)$$

式中 n ——重复实验的次数;

MN_k ——第 k 次实验中成功匹配的次數;

a ——碎片化知识图谱库的规模。

4.5.3.2 对比方法和实验方法设置

在知识图谱相似度量领域中,当前的研究成果主要集中在实体相似度量,缺乏度量知识图谱结构的相似度量方法。因此,本节选取图论中能有效度量图结构的方法作为本节的对比方法,即 MCS 和 MCCS。此外,将本章建立的基于同归结构的相似度量模型进行对比,共选取三种基于同归结构的相似度量模型作为实验方法,分别为 SM-LMCSDS、RLMCSDS 和同归结构相似度量模型(same destination structure, SDS)。实验过程中,只涉及基工艺知识图谱之间的相似度计算,因此,所有工艺实体的权重均为 1。因此,SM-LMCSDS 和 RLMCSDS 可以表示为公式(4-35),SDS 可以表示为公式(4-36)。此外,MCCS 和 MCS 分别如公式(4-37)和公式(4-38)所示。

$$SKG(A, B) = RSKG(A, B) = \max_i \max \left\{ \frac{\sum_{v \in V(G_{1i})} W_v^A}{|V(A)|}, \frac{\sum_{v \in V(G_{2i})} W_v^B}{|V(B)|} \right\} \quad (4-35)$$

$$Sim_{SDS}(A, B) = \max \left\{ \frac{\sum_{i=1}^n \sum_{v \in V(G_{1i})} W_v^A}{|V(A)|}, \frac{\sum_{i=1}^n \sum_{v \in V(G_{2i})} W_v^B}{|V(B)|} \right\} \quad (4-36)$$

$$Sim_{MCCS}(A, B) = \max_j \max \left\{ \frac{|V(G_j)|}{|V(A)|}, \frac{|V(G_j)|}{|V(B)|} \right\} \quad (4-37)$$

$$Sim_{MCS}(A, B) = \max \left\{ \frac{\sum_j |V(G_j)|}{|V(A)|}, \frac{\sum_j |V(G_j)|}{|V(B)|} \right\} \quad (4-38)$$

式中 A 、 B ——两个工艺碎片化知识图谱的有向图形式；

$\{G_{1i}; G_{2i}\}$ —— A 和 B 所有 LMCSDSs, $i=1, \dots, n$ ；

$\sum_{v \in V(G_{1i})} W_v^A$ —— G_{1i} 中所有节点在有向图 A 中的权重和；

$\sum_{v \in V(G_{2i})} W_v^B$ —— G_{2i} 中所有的节点在有向图 B 中的权重和；

G_j —— A 和 B 所有的最大公共连通子图, $j=1, \dots, m$ 。

4.5.3.3 对比实验及结果分析

将 RLMCSDS、SM-LMCSDS、SDS、MCCS 和 MCS 分别应用在简单工艺知识图谱库和复杂工艺知识图谱库中来验证模型在度量图结构相似和路径相似的准确性。相似度量模型在简单工艺知识图谱库上进行 10 次重复实验, 并采用库相似度和 10 次重复实验的库相似度均值来评估模型的准确性, 实验结果如表 4-4 所示。

从理论分析, 一方面, RLMCSDS、SM-LMCSDS 和 MCCS 相比于 SDS 和 MCS 多了连通性条件, RLMCSDS、SM-LMCSDS 和 MCCS 更能准确地度量工艺碎片化知识图谱的图结构的相似度; 另一方面, MCCS 和 MCS 是基于边相似来建模, 而 RLMCSDS、SM-LMCSDS 和 SDS 不仅考虑边相似来还考虑了路径相似。从而, RLMCSDS、SM-LMCSDS 和 SDS 更能有效度量工艺碎片化知识图谱的相似度。上述分析表明, 理论上各个模型的相似度量精度应该满足:

$MCCS \leq MCS \leq SDS \geq SM-LMCSDS = RLMCSDS \geq MCCS$ 。表 4-4 表明这五种模型的相似度量精度满足 $MCCS = MCS = SDS = SM-LMCSDS = RLMCSDS$ 。分析得知, 共有两方面因素导致了各模型的相似度量精度完全相同: (1) 实验采用的碎片化知识图谱结构简单; (2) 实验中采用的碎片化知识图谱均具有连通性。表 4-4 中的实验结果同样与理论结果相符合, 并说明了本章建立的 RLMCSDS、

SM-LMCSDS 和 SDS 与传统的 MCCS 和 MCS 模型在不包含第一类和第二类回归路径的数据集中具有相同的效果。

表4-4 相似度量模型在简单工艺知识图谱库上的 10 次实验结果

Table 4-4 10-trial results of the five methods on simple process knowledge graph library

评价指标	RLMCSDS	SM-LMCSDS	SDS	MCCS	MCS
库相似度	0.399441	0.399441	0.399441	0.399441	0.399441
	0.406385	0.406385	0.406385	0.406385	0.406385
	0.574910	0.574910	0.574910	0.574910	0.574910
	0.406385	0.406385	0.406385	0.406385	0.406385
	0.399441	0.399441	0.399441	0.399441	0.399441
	0.399441	0.399441	0.399441	0.399441	0.399441
	0.399441	0.399441	0.399441	0.399441	0.399441
	0.231331	0.231331	0.231331	0.231331	0.231331
	0.399441	0.399441	0.399441	0.399441	0.399441
	0.409091	0.409091	0.409091	0.409091	0.409091
均值库相似度	0.402531	0.402531	0.402531	0.402531	0.402531

为了验证本章建立的相似度模型能有效度量具有相似路径的工艺碎片化知识图谱的相似度,将五种相似度模型分别应用在复杂工艺知识图谱库中,并采用库相似度和匹配率来评估模型效果。各相似度模型在复杂工艺知识图谱库中的实验结果如表 4-5 所示。此外,通过调节相似度阈值,不同模型在复杂工艺知识图谱库中的匹配率如表 4-6 所示。

表4-5 相似度模型在复杂工艺知识图谱库上的 10 次实验结果

Table 4-5 10-trial results of the five methods on complex process knowledge graph library

评价指标	RLMCSDS	SM-LMCSDS	SDS	MCCS	MCS
库相似度	0.760931	0.760931	0.760931	0.219923	0.26642
	0.662202	0.662202	0.662202	0.243641	0.277732
	0.607450	0.607450	0.607450	0.159091	0.175620
	0.822192	0.822192	0.822192	0.160096	0.17719
	0.576389	0.576389	0.576389	0.1875	0.198864
	0.822192	0.822192	0.822192	0.160096	0.17719
	0.635945	0.635945	0.635945	0.238035	0.28349
	0.576389	0.576389	0.576389	0.1875	0.198864
	0.703439	0.703439	0.703439	0.199649	0.199649
	0.673617	0.673617	0.673617	0.280866	0.307885
均值库相似度	0.684075	0.684075	0.684075	0.203640	0.226290

表 4-5 和表 4-6 表明本章建立的基于回归路径的相似度模型不仅能有效度量边相似还能有效度量路径相似。因而,相比于传统的 MCS 和 MCCS,RLMCSDS、SM-LMCSDS 和 SDS 能准确度量发动机拆卸工艺碎片化知识图谱的相似度。表 4-5 结果表明,在相似度上,本章建立的 RLMCSDS、SM-LMCSDS

和 SDS 的精度平均提升了 48%。在匹配率上,不同的阈值下,RLMCSDS、SM-LMCSDS 和 SDS 模型的匹配率显著优于传统的 MCS 和 MCCS。事实上,由于 MCS 和 SDS 牺牲了工艺碎片化知识图谱的连通性,错误率会提高。RLMCSDS、SM-LMCSDS 和 SDS 在相似度和匹配率相同,这是由于拆卸工艺建模人员建立的工艺碎片化知识图谱通常具有连通性。因此,在复杂工艺知识图谱的相似度量过程中,RLMCSDS 和 SM-LMCSDS 更有效。

表4-6 相似度模型在不同相似度阈值下的匹配率

Table 4-6 Matching rate of the five methods under different similarity thresholds

模型	相似度阈值 α			
	0.5	0.6	0.7	0.8
RLMCSDS	0.845455	0.772727	0.586364	0.300000
SM-LMCSDS	0.845455	0.772727	0.586364	0.300000
SDS	0.845455	0.772727	0.586364	0.300000
MCCS	0.127273	0.095455	0.059091	0.050000
MCS	0.145455	0.109091	0.059091	0.050000

对比实验结果表明本章建立的 RLMCSDS 和 SM-LMCSDS 能有效度量工艺碎片化知识图谱的相似度,尤其是在具有第一类和第二类回归路径的知识图谱相似度量中效果突出。实际工程中,拆卸工艺建模人员建立的工艺碎片化知识图谱可能是各种各样的,可能包含三类回归路径的一种,两种或者三种。因而,RLMCSDS 和 SM-LMCSDS 模型更符合工程实际应用。

4.5.4 基于 RLMCSDS 模型的知识图谱融合建模实例

传统的 MCS 和 MCCS 模型,并不涉及碎片化知识图谱间的融合过程,而本章建立的 RLMCSDS 在知识图谱融合过程中不断强化出现的实体,与碎片化知识图谱融合方法相适应。因而,RLMCSDS 能够在工艺知识图谱库中实现工艺碎片化知识图谱的相似度量和融合的循环迭代,支持工艺知识图谱的自动化构建,下面分析 RLMCSDS 在融合过程中的优势。

图 4-22 是 4 个 JH70 发动机拆卸工艺碎片化知识图谱。显然,这四个工艺碎片化知识图谱都是发动机拆卸工艺知识图谱的一部分,它们之间存在着内在的联系。换句话说,经过人工判断,它们是相似的。

设置阈值 $\alpha=0.6$,大于阈值即认为两个工艺碎片化知识图谱是相似的,能进行融合。随后,将融合的知识图谱与其他工艺碎片化知识图谱进行相似度量与融合。根据公式(4-35),容易可得: $SKG(D,A)=RSKG(D,A)<\alpha$ 、 $SKG(D,B)=RSKG(D,B)<\alpha$ 和 $SKG(D,C)=RSKG(D,C)<\alpha$; 根据公式(4-36),可得: $Sim_{SDS}(D,A)<\alpha$ 、 $Sim_{SDS}(D,B)<\alpha$ 和 $Sim_{SDS}(D,C)<\alpha$; 根据公式(4-37),

可得： $Sim_{MCCS}(D,A) < \alpha$ 、 $Sim_{MCCS}(D,B) < \alpha$ 和 $Sim_{MCCS}(D,C) < \alpha$ ；根据公式(4-38)，可得： $Sim_{MCS}(D,A) < \alpha$ 、 $Sim_{MCS}(D,B) < \alpha$ 和 $Sim_{MCS}(D,C) < \alpha$ 。因此，未融合之前，单独计算 D 与 A 、 B 、 C 之间的相似度表明 D 与 A 、 B 、 C 不相似。采用本章建立的 RLMCSDS 模型与提出的融合方法，可以得到 $RSKG(D, A \bar{U} B \bar{U} C) > \alpha$ ，结果表明 D 与 A 、 B 、 C 相似。这说明了 RLMCSDS 模型在知识图谱的融合过程中能够充分挖掘工艺碎片化知识图谱之间的关系，实现知识图谱的准确相似度量与融合。




图4-22 4个发动机拆卸工艺碎片化知识图谱

Fig. 4-22 Four fragmentation knowledge graphs of engine disassembly processes

综合 4.5.2 节-4.5.4 节的实验结果，与其他模型相比，本章建立的 RLMCSDS 模型和 SM-LMCSDS 模型能够准确地度量具有三类同归路径的拆卸工艺碎片化知识图谱之间的相似性。此外，RLMCSDS 模型能够与融合方法相适应，能有效实现复杂装备拆卸工艺知识图谱自动构建。

根据第 2 章的知识语义向量化表达方法、第 3 章的实体类别预测方法以及本章的装备拆卸工艺碎片化知识图谱相似度量与融合方法，开发了发动机拆卸工艺知识图谱融合建模系统。JH70 发动机气缸头的拆卸工艺知识图谱融合建模如图 4-23 和图 4-24 所示。图 4-23 为两个碎片化知识图谱的相似度计算与融合结果，图 4-24 为多个碎片化知识图谱的融合建模过程。相似度计算与融合结果表明所建立的相似度模型与提出的融合方法能有效支撑装备拆卸工艺知识图谱自动构建。




图4-23 两个碎片化知识图谱相似度计算与融合结果

Fig. 4-23 Similarity calculation and fusion of two fragmentation knowledge graphs




图4-24 多个碎片化知识图谱融合建模

Fig. 4-24 Fusion modeling of multiple fragmentation knowledge graphs

4.6 本章小结

针对目前缺乏知识图谱自动构建方法、当前的碎片化知识图谱难以有效利用等问题, 本章建立了强化极大连通同归结构的相似度模型和碎片化知识图谱融合方法。首先基于图同构与路径相似建立了基于极大连通同归结构的相似度模型来进行相似度量。通过复杂装备拆卸工艺知识图谱上的案例分析, 该模型能够有效度量碎片化知识图谱的相似度。然而, 随着融合的进行, 基于极大连

通同归结构的相似度模型引起了漏融现象。为了解决上述问题，考虑工艺实体出现的频率对相似度的影响，建立了强化极大连通同归结构的相似度模型，并在理论上证明了所建立的模型消除了基于极大连通同归结构的相似度模型引起的漏融问题。将所建立的模型和提出的融合方法应用在实际 JH70 发动机拆卸工艺知识图谱自动构建中，实验结果表明了所建立的模型能准确度量碎片化知识图谱的相似度，并且所建立的模型和提出的融合方法迭代使用能有效完成复杂装备拆卸工艺知识图谱的自动构建。最后，与经典图结构相似度模型对比，所建立的模型在具有路径相似的碎片化知识图谱相似度量中平均精度提升 48%。

第 5 章 面向复杂装备拆卸工艺知识图谱的细粒度集体实体链接方法

5.1 引言

实际工艺知识的检索是一个模糊匹配和语义匹配的过程。工艺人员自身的专业水平和先验知识各不相同。因而，在使用复杂装备拆卸工艺知识图谱库进行工艺知识检索时，所输入的检索文本缺乏统一、规范化的表达形式。例如：实际检索中，技术人员想查询“定子总成”的相关拆卸工艺。真实输入可能为与“定子总成”语义相关的“定子装配体”、“定子总装”等。为了能准确地定位到相关知识，本章重点研究面向复杂装备拆卸工艺知识图谱的集体实体链接方法。

实体链接技术是将所构建的知识图谱应用于工程实际的关键技术，对于知识的检索和推荐起决定性作用。实体链接任务可以描述在知识库中找到与关键词指代相同的唯一实体，完成关键词到知识库的映射过程，实现知识的准确检索。例如：图 5-1 中检索 JH70 发动机拆卸工艺知识“轴套-离合器”，通过对比，在知识库中共查询到 65 个实体与关键词相关。实体链接的目的是从 65 个实体中找到与“轴套-离合器”指向相同现实事物的实体。然而，当前的多数实体链接方法均是面向通用领域，它们一般是将所检索的关键词输入到搜索引擎等第三方库中，获得关键词对应的关键词描述页面、重定向页面以及链接。随后，将这些相关知识作为关键词的补充信息来完成实体链接，以提高实体链接的精度。由于搜索引擎等第三方库存储的是通用知识，导致复杂装备拆卸工艺领域中的专业知识难以在第三方库中查询到。所以，这些基于搜索引擎等第三方库的实体链接方法在专业性强的领域中表现出极不适应，会出现实体链接精度低，实体链接方法不满足使用条件等问题。因此，在复杂装备拆卸工艺领域中进行实体链接时能够使用的信息有限。基于上述分析，如何充分提取当前拆卸工艺知识图谱的有效信息进而提升实体链接精度是目前的难点问题。

为了解决上述问题，本章提出了基于强相关序列的细粒度集体实体链接方法。该实体链接方法拟考虑人类语言逻辑特征：复杂装备拆卸工艺建模人员在检索时，输入的一段文本中的关键词是紧密关联的。因此，在实体链接过程中，该方法拟将一段文本中的所有关键词以及其所要链接的实体视为一个整体，并拟建立基于强相关序列的相似度模型来有效度量多个实体的整体相关性。为了提升当前知识图谱中信息的利用率，该实体链接方法拟采用三种 2-hop 路径

并拟考虑每种 2-hop 路径对两个实体之间相关性的贡献来度量两个实体之间的相关性。此外,该实体链接方法引入知识语义向量化表达方法来捕捉实体的语义信息,从而在语义层面完成实体链接,支持工艺知识的模糊匹配和语义检索。




图5-1 JH70发动机拆卸工艺知识图谱实体链接示例

Fig. 5-1 Example of entity linking to knowledge graph of JH70 engine disassembly process

5.2 现有实体链接方法及其工程不适应性分析

如何充分提取当前知识图谱中的有效信息,提高实体链接的精度是面向领域的实体链接方法面临的主要难点问题。针对这一难点问题,研究人员建立了多种模型来提升领域知识图谱中信息的利用率。

5.2.1 基本概念定义

为了便于理解本章的研究内容,首先定义本章可能用到的实体提及、候选实体、实体提及组等关键概念。

定义 5. 实体提及:实体提及是指某一文本对一个特定的实体(零件、功能、日期或者使用工具等)做出提及或引用的行为。例如:图 5-1 中 JH70 发动机实际拆卸工艺检索文本中的“双手”、“离合器连接的套筒”、“手”、“轴套-离合器”等加粗的词均为实体提及。

定义 6. 候选实体:知识图谱中可能与实体提及表示同一事物的实体。例如:图 5-1 中“轴套-离合器”可能与第 4 章所构建的 JH70 发动机拆卸工艺知识图谱中的工艺实体“通油管【离合器】”、“套筒【离合器】”等 65 个实体表示同一事物。因此,这 65 个实体均为“轴套-离合器”的候选实体。

定义 7. 实体链接:给定一段文本的实体提及集合 $M = \{m_1, m_2, \dots, m_q\}$ 和一个知识图谱 $G = (V, R, E)$ 。实体链接的目标是对于 M 中的任意一个实体提及 $m_i \in M$, 在知识图谱 G 中找到唯一与 m_i 指代相同的实体 $v \in V$ 。

图5-1是工艺人员在第4章所构建的JH70发动机拆卸工艺知识图谱上进行实体链接的真实案例。针对检索文本中的实体提及“套筒-离合器”，在工艺知识图谱库中找到了65个可能的候选实体。实体链接任务是通过某些方法，将这65个可能的候选实体排序，找到最可能的候选实体，从而为工艺知识推理、知识推荐提供支持。

定义 8. 实体提及组、候选实体组：给定一段文本的实体提及集合 $M = \{m_1, m_2, \dots, m_q\}$ ，以及通过候选实体生成方法为实体提及 m_i 生成的候选实体集合为 $E_i = \{e_{i_1}, e_{i_2}, \dots, e_{i_k}, \dots, e_{i_{n_i}}\}$ ，其中， e_{i_k} 表示实体提及 m_i 的第 k 个候选实体， n_i 表示实体提及 m_i 的候选实体数量。实体链接过程中，所有的实体提及 $(m_1, m_2, \dots, m_q)$ 被称为一个实体提及组，所有候选实体集合的笛卡尔积中的一个元素 $(e_{1_{k_1}}, e_{2_{k_2}}, \dots, e_{i_{k_i}}, \dots, e_{q_{k_q}}) \in E_1 \times E_2 \times \dots \times E_i \times \dots \times E_q$ 被称为候选实体组。

定义9. 集体实体链接：给定一段文本的实体提及集合 $M = \{m_1, m_2, \dots, m_q\}$ 和一个知识图谱 $G = (V, R, E)$ 。集体实体链接将这段文本中的所有实体提及视为一个整体，即实体提及组 $(m_1, m_2, \dots, m_q)$ ，其目标是在知识图谱 G 中找到一组与实体提及 $(m_1, m_2, \dots, m_q)$ 指代相同现实事物的候选实体组 $(e_1, e_2, \dots, e_q)$ ，其中， $e_1, e_2, \dots, e_q \in V$ 。

集体实体链接不仅仅要考虑候选实体与实体提及之间的相似度，还需要重点关注各实体提及之间的关联性和候选实体之间的关联性。这是因为一段文本中出现的实体提及具有较强的语言逻辑关联性，知识图谱的构建通常是基于文本抽取或者人脑中存储的先验知识，因而，其候选实体之间也具有较强的关联性。例如，在图5-2中所示的检索文本中，“一字型螺丝刀”、“链轮【正时从动】”、“扳手”和“螺栓【箱底】”是文本中所有的实体提及。根据集体实体链接的定义，构建这段检索文本的实体提及组，并为实体提及组生成两个候选实体组，如表5-1所示。从表面形式来看，候选实体组1与实体提及组最为相近。然而，实体提及组所要匹配的候选实体组并非候选实体组1，而是候选实体组2。虽然候选实体组2与实体提及组的表面形式并不是最相似的，但是候选实体组中各工艺实体之间的关联性更强。例如：拆卸“螺栓【箱底】”所采用的工具为“大三叉套筒扳手”，而不是“徒手”。因此，选择关联性更强的候选实体组作为实体提及组的链接对象通常更符合工艺逻辑特性。




图5-2 发动机拆卸工艺集体实体链接示例

Fig. 5-2 Engine disassembly process collective entity linking Example

表5-1 实体提及组及其候选实体组

Table 5-1 Entity mention group and its candidate entity groups

实体提及组	(一字型螺丝刀, 链轮【正时从动】, 扳手, 螺栓【箱底】)
候选实体组1	(一字螺丝刀, 链轮【正时从动】, 徒手, 螺栓【箱底】)
候选实体组2	(一字螺丝刀, 链轮【正时从动】, 大三叉套筒扳手, 螺栓【箱底】)

5.2.2 实体流行度模型

通常情况下, 在特定的领域中, 某个具有实际意义的事物出现的次数或者流行程度越高, 再次提到该事物的名称时, 该事物更可能被联想到。基于此, 研究人员建立了实体流行度模型^[137]。实体流行度模型通过某些方法计算每个实体的流程度, 并在实体链接中, 按照流行度对实体提及的候选实体排序, 将实体提及链接到流行度最大的候选实体。在仅使用当前知识图谱的情况下, 实体流行度模型以实体的头实体和尾实体作为实体的上下文特征, 通过邻接矩阵计算实体的PageRank分数, 随后, 以归一化的PageRank分数作为实体的流行度。最后, 根据实体流行度对候选实体排序, 实现实体链接。若用 G 表示一个知识图谱, V 表示知识图谱的实体集, $|V|$ 表示知识图谱中实体的数量, 则实体流行度模型的PageRank分数可以表示为公式(5-1)。

$$\overline{\mathbf{pr}} = \lambda \overline{\mathbf{ip}} + (1-\lambda) B \cdot \overline{\mathbf{pr}} \quad (5-1)$$

式中 $\overline{\mathbf{pr}}$ —— 实体集的 PageRank 分数, 并且 $\overline{\mathbf{pr}} = (pr_1, pr_2, \dots, pr_{|V|})$;

pr_i —— 实体 v_i 的 PageRank 分数;

$\vec{ip}$ ——初始的实体集的 PageRank 分数，并且 $\vec{ip} = (ip_1, ip_2, \dots, ip_{|V|})$ ，一

般 $ip_i = 1/|V|$ ；

ip_i ——实体 v_i 的初始 PageRank 分数；

B ——用来捕获实体周围信息的 $|V| \times |V|$ 列归一化矩阵，并且

$B = (b_{ij})_{|V| \times |V|}$ 。如果实体 v_j 到 v_i 存在边 (v_j, v_i) ，则 $b_{ij} = 1/N_{v_j}$ ，其中， N_{v_j}

表示实体 v_j 的出度数量；

λ ——调整初始实体的 PageRank 分数和基于聚合一次周围信息得到的实体 PageRank 分数的重要度参数，并且 $\lambda \in [0, 1]$ 。

最后，将归一化实体的 PageRank 分数作为实体的流行度，如公式(5-2)所示。

$$P(v_i) = \frac{pr_i}{\sum_{k=1}^{|V|} pr_k} \quad (5-2)$$

式中 v_i ——第 i 个实体；

pr_i ——实体 v_i 的 PageRank 分数；

$P(v_i)$ ——实体 v_i 的流行度。

5.2.3 基于概率的实体链接方法

基于概率模型的实体链接方法是当前面向领域实体链接方法的热点研究内容。

实体流行度模型虽然充分利用了实体的上下文信息，然而，忽略了实体之间的多种关系信息，例如：在 JH70 发动机拆卸工艺知识图谱中，工艺实体“定子总成”和工艺实体“螺栓【左箱】-1”的工艺关系为“前序零件”和“螺纹连接”。在实体流行度模型中，“前序零件”和“螺纹连接”被抽象为同一条无语义信息的边，这导致在复杂装备拆卸工艺知识图谱上的实体链接精度难以满足工艺知识检索实际需求。为了解决这一难点问题，Shen 等人建立了一个名为 SHINE 的知识图谱实体链接框架，这是第一个将 Web 文本中的命名实体与知识图谱联系起来的概率模型^[136]，如公式(5-3)所示

$$\arg \max_{e \in E} P(e | m, d) = \arg \max_{e \in E} \frac{P(m, d, e)}{P(m, d)} = \arg \max_{e \in E} P(m, d, e) \quad (5-3)$$

式中 E ——知识图谱的实体集；

e ——知识图谱中的一个实体；

d ——需要进行实体链接的文档或者语句；

m —— d 中的一个实体提及。

进一步, SHINE 方法假设对于给定的实体 e 、实体提及 m 和文档 d 的出现相互独立, 则实体提及 m 、文档 d 、实体 e 的共现概率可以表示为:

$$P(m, d, e) = P(e)P(m|e)P(d|e) \quad (5-4)$$

通常上, 候选实体与实体提及的表面形式相近。基于此, SHINE 模型假设在给定每个候选实体 e 的情况下, 观察到实体提及 m 的概率 $P(m|e)$ 是相同的, 因此, 将 $P(m|e)$ 设置为常数。此外, SHINE 模型将实体流行度模型引入到公式(5-4)中来计算候选实体 e 出现的概率。最后, SHINE 模型使用元路径来提取知识图谱中实体和关系的信息, 进一步计算 $P(d|e)$ 。

SHINE方法一定程度上提升了知识图谱中实体和关系的利用效率, 然而, 该模型仍有较大局限性。一方面, 在实体链接过程中, SHINE独立地为每个实体提及进行链接。事实上, 从语言逻辑上来看, 同一文本出现的实体提及必然有着内在的语言逻辑联系, 每个实体提及的链接过程是相互影响、相互印证的。因此, 有必要研究集体实体链接方法。另一方面, 元路径是基于实体类型和关系类型进行建模。虽然元路径一定程度上能够提取实体和关系的信息, 但是, 其建模过程仅使用了实体和关系的类型信息, 难以有效利用实体和关系本身的信息。

为了充分利用实体类型以及实体和关系本身的信息, Li等人提出了一种最新的集体实体链接方法。他们首次将人脑的“全局优先”认知机制与实体链接相结合, 提出了一种从粗到细的细粒度集体实体链接算法, 命名为CFEL^[139]。具体地, 如公式(5-5)所示:

$$\begin{aligned} & \arg \max_{e_{11}, \dots, e_{in}} P(m_1, \dots, m_i; e_{11}, \dots, e_{in}) \\ & = \arg \max_{e_{11}, \dots, e_{in}} P(e_{11}, \dots, e_{in}) \times P(m_1, \dots, m_i | e_{11}, \dots, e_{in}) \end{aligned} \quad (5-5)$$

式中

m_i ——一段文本中出现的第 i 个实体提及;

e_{in} ——实体提及 m_i 的一个候选实体;

$P(m_1, \dots, m_i; e_{11}, \dots, e_{in})$ ——实体提及 $m_1, \dots, m_i$ 链接到 $e_{11}, \dots, e_{in}$ 的概率;

$P(e_{11}, \dots, e_{in})$ ——候选实体 $e_{11}, \dots, e_{in}$ 的共现概率;

$P(m_1, \dots, m_i | e_{11}, \dots, e_{in})$ ——对于给定的候选实体 $e_{11}, \dots, e_{in}$, 实体提及 $m_1, \dots, m_i$ 出现的概率。

公式(5-5)表明, 在实体链接中, CFEL模型将一段文本中出现的所有实体提及视为一个整体, 同时对所有的实体提及进行实体链接。CFEL假设候选实体的

相关性越大，候选实体的共现概率越大；随后，采用累计两两候选实体的相关性来估计多个候选实体的共现概率。此外，CFEL假设每个实体提及的出现仅依赖于其候选实体，并且实体提及与候选实体的外形越像，对于给定的候选实体，实体提及出现的概率越大，如公式(5-6)所示。

$$P(e_{11}, \dots, e_{in}) = \sum_{i=1}^{|M|} \sum_{j=1 \& j \neq i}^{|M|} R(e_{in}, e_{jk}), P(m_1, \dots, m_i | e_{11}, \dots, e_{in}) = \prod_{i=1}^{|M|} P(m_i | e_{in}) \quad (5-6)$$

式中 $R(e_{in}, e_{jk})$ ——实体 e_{in} 与实体提及 e_{jk} 的相关度；

m_i ——一段文本中出现的第 i 个实体提及；

e_{in} ——实体提及 m_i 的一个候选实体；

M ——一段文本中出现的所有实体提及，即实体提及集；

$|M|$ ——一段文本中出现的所有实体提及数量。

5.2.4 集体实体链接方法对领域内实体链接的工程不适应性分析

下面以CFEL模型为例介绍目前的集体实体链接方法的工程不适应性。CFEL模型采用实体的相关性表征实体的共现概率，在集体实体链接中表现出了优异的实体链接性能。然而，CFEL模型在复杂装备拆卸工艺知识图谱的实体链接过程中仍然存在以下三个关键问题有待解决。

(1) CFEL模型采用累计任意两两候选实体（简称实体对）的相关性（简称为累计相关性）来度量候选实体组的整体相关性，并以整体相关性来估计 $P(e_{11}, \dots, e_{in})$ 。事实表明，在复杂装备拆卸工艺知识图谱的实体链接中，这种计算方式由于引入了不相关实体对或者是弱相关实体对的相关性，弱化了相关性强的实体对对候选实体组整体相关性的贡献，导致了集体实体链接失败。例如，在JH70发动机拆卸工艺知识图谱实体链接中的真实案例：对于一段文本中的实体提及组（启动轴回位弹簧座，手，启动轴的弹性挡圈，轴用卡簧钳），其对应的两个候选实体组为（回位弹簧座【启动轴】，徒手，弹性挡圈【启动轴】，卡簧钳）和（回位弹簧座【启动轴】，小三叉套筒扳手，弹性挡圈【启动轴】，卡簧钳）。第一个候选实体组为实体提及组真实对应的候选实体组。经过计算，第一个候选实体组的累计相关性为3.0，第二个候选实体组的累计相关性为4.0。实验结果表明实体链接失败。事实证明，采用累计相关性来估计候选实体组的共现概率可能会导致实体链接的失败。

(2) CFEL模型在计算实体对的相关性时，仅采用一种2-hop路径（有向2-hop），忽略了其他种类2-hop路径对实体对相关性的贡献，导致复杂装备拆卸工艺知识图谱中的信息难以被有效利用。事实表明，复杂装备拆卸工艺知识图谱

中的两个实体之间存在多种2-hop路径,除有向2-hop路径外,两个实体之间还存在两种2-hop路径:两个实体指向共同的实体组成的路径;两个实体被相同的实体指向组成的路径。这三种2-hop路径均对实体对的相关性有贡献。例如,在JH70发动机拆卸工艺知识图谱中,“螺栓【气缸左盖】”既是“右侧盖【气缸头】”的前序零件又是“气缸头”的前序零件。在计算“右侧盖【气缸头】”和“气缸头”之间的相关性时,“螺栓【气缸左盖】”对两者相关性的贡献是极其重要的。然而,在发动机拆卸工艺知识图谱的实体链接时,CFEL模型没有考虑其他类型的2-hop路径对候选实体对相关性的贡献,难以准确度量两个实体之间的相关性。

(3) CFEL模型在计算 $P(m_1, \dots, m_i | e_{11}, \dots, e_{in})$ 时,假设每个实体提及选择候选实体的概率是相互独立的。这完全脱离了集体实体链接的思想,导致CFEL模型在理论层面存在缺陷,进一步可能导致拆卸工艺知识图谱的集体实体链接失败。根据自然语言逻辑特性,在拆卸工艺知识的检索中,拆卸工艺人员输入的检索文本中实体提及之间具有较强的语义联系。因此,一段文本中所有的实体提及整体的语义相似度和其候选实体组整体的语义相似度越强, $P(m_1, \dots, m_i | e_{11}, \dots, e_{in})$ 越大。考虑复杂装备拆卸工艺知识图谱的实体链接实际情况, $P(m_1, \dots, m_i | e_{11}, \dots, e_{in})$ 有待进一步准确估计。

5.3 复杂装备拆卸工艺候选实体生成及两步法剪枝策略

候选实体生成在实体链接中具有重要的作用,它从给定知识图谱中找到每个实体提及可能对应的候选实体集合。若一个实体提及所链接的实体并不在它的候选实体集合中,则无法将实体提及链接到正确的实体上。因此,候选实体生成应尽可能的保证实体提及对应的实体在候选实体集合中,保证实体提及的查全率。

实际上,工艺人员在对拆卸工艺知识检索时脑海中已经有一些与检索目标相关的先验知识。从而,拆卸工艺人员输入的检索文本中通常会包含一些与检索目标相关或者外形相似的实体提及。例如,当检索目标为“定子总成”时,拆卸工艺人员可能会直接输入“定子装配体”、“定子总装”、“定子”等。因此,通过以下策略为每个实体提及 $m_i \in M$ 生成候选实体集合 E_i :

- 复杂装备拆卸工艺知识图谱中的实体完全包含在实体提及中或实体提及完全包含知识图谱中的实体。
- 对复杂装备拆卸工艺知识图谱中的实体和实体提及分词后,实体与实体提及有共同词。
- 复杂装备拆卸工艺知识图谱中的实体是实体提及的缩写或者实体提及是

实体的缩写。

然而，集体实体链接技术的时间复杂度通常较高。在为某些复杂装备拆卸工艺实体提及生成候选实体时，可能其数量很大，这大大增加了集体实体链接模型的计算复杂性。例如：“套筒用于离合器”的候选实体为65个。因此，为了减低实体链接的计算复杂性，需要对候选实体进行剪枝操作，降低候选实体的数量，同时保证实体提及对应的候选实体依然在候选实体集合中。复杂装备拆卸工艺知识图谱中实体的类别信息通过实体类别标注和第3章的类别预测很容易得到。实体提及的类别通过语言模型和分类模型也能够得到。因此，在本章中，假设已经知道实体提及和实体的类别信息。基于实体提及的类别信息和候选实体的类别信息，采用两种策略对候选实体集合剪枝，得到前top-k个候选实体。首先，基于实体提及类别，对候选实体进行剪枝，其次，基于候选实体与实体提及之间的表面相似程度，进行二次剪枝。通过剪枝操作就可以大大缩小实体链接的求解范围，例如：通过剪枝后，“套筒用于离合器”的候选实体变为2个。

- 删除候选实体集合中与实体提及类别不相同的实体。

- 若候选实体集合的规模仍然大于k，则计算实体提及与候选实体的表面相似度，并将候选实体的缩写与候选实体相似度设置为1。最后，取与实体提及最相似的前k个候选实体。

5.4 基于强相关序列的细粒度集体实体链接方法

5.4.1 面向拆卸工艺知识图谱的集体实体链接目标函数构建

面向复杂装备拆卸工艺知识图谱的集体实体链接目标函数构建过程如下所示。给定一段检索文本的实体提及集合 $M = \{m_1, m_2, \dots, m_q\}$ 、实体提及类型集合 $T = \{t_1, t_2, \dots, t_q\}$ 、以及带类别信息的候选实体集合 $E^T = \{E_1^T, E_2^T, \dots, E_q^T\}$ ，其中， $E_i^T = \{(e_{i_1}, t_{i1}), (e_{i_2}, t_{i2}), \dots, (e_{i_n}, t_{in})\}$ 表示实体提及 m_i 对应的候选实体集， (e_{i_1}, t_{i1}) 表示候选实体 e_{i_1} 的类型为 t_{i1} 。经过本章提出的剪枝策略，候选实体集合被剪枝为 $E = \{E_1, E_2, \dots, E_q\}$ ，其中， $E_i = \{e_{i1}, e_{i2}, \dots, e_{in_i}\}$ 为实体提及 m_i 剪枝后的候选实体集合， n_i 为剪枝后的候选实体数量。集体实体链接的目标是对实体提及组 $(m_1, m_2, \dots, m_q)$ ，在知识图谱中找到一组与实体提及指代相同事物的候选实体组 $(\tilde{e}_1, \tilde{e}_2, \dots, \tilde{e}_q)$ ，其中， $\tilde{e}_i \in E_i$ 。具体地，如公式(5-7)所示：

$$\begin{aligned}
& \arg \max_{e_{1k_1} \in E_1^T, \dots, e_{qk_q} \in E_q^T} P(M, T; E^T) \\
&= \arg \max_{(e_1, e_2, \dots, e_q) \in E_1 \times E_2 \times \dots \times E_q} P(m_1, m_2, \dots, m_q; e_1, e_2, \dots, e_q) \\
&= \arg \max_{(e_1, e_2, \dots, e_q) \in E_1 \times E_2 \times \dots \times E_q} P(e_1, e_2, \dots, e_q) \cdot P(m_1, m_2, \dots, m_q | e_1, e_2, \dots, e_q)
\end{aligned} \tag{5-7}$$

式中 $m_1, m_2, \dots, m_q$ ——给定一段工艺检索文本中的 q 个实体提及；
 $e_{i_{k_i}}$ ——实体提及 m_i 的候选实体集合 E_i^T 中的第 k_i 个候选实体；
 $E_1 \times E_2 \times \dots \times E_q$ ——所有实体提及的候选实体集的笛卡尔积；
 $(e_1, e_2, \dots, e_q)$ ——实体提及组 $(m_1, m_2, \dots, m_q)$ 的一个候选实体组；
 $P(m_1, \dots, m_q; e_1, \dots, e_q)$ ——实体提及组 $(m_1, m_2, \dots, m_q)$ 链接到候选实体组 $(e_1, e_2, \dots, e_q)$ 的概率；
 $P(e_1, e_2, \dots, e_q)$ 实体 $e_1, e_2, \dots, e_q$ 出现在同一段文本的概率；
 $P(m_1, \dots, m_q | e_1, \dots, e_q)$ ——在一段文本中，给定候选实体 $e_1, e_2, \dots, e_q$ 时，实体提及 $m_1, m_2, \dots, m_q$ 出现的概率。

基于上述目标函数，本章建立了三个模型来分别解决 CFEL 模型的三个关键问题以提升拆卸工艺知识图谱的实体链接精度，分别对应本章的 5.4.2 节、5.4.3 节和 5.4.4 节。

5.4.2 基于强相关序列的候选实体组整体相关性度量模型

为了解决采用累计实体对的相关性难以准确捕捉整体相关性的问题，强调相关性强的实体对对整个候选实体组整体相关性的贡献，本节建立了一种基于强相关序列的候选实体组整体相关性度量模型来捕捉整体的相关性。

知识图谱的构建来源于大量的文本或者人脑中的先验知识。因此，实体提及组对应的候选实体组也可以视为一个整体。在计算候选实体 $e_1, e_2, \dots, e_q$ 的共现概率 $P(e_1, e_2, \dots, e_q)$ 时， $(e_1, e_2, \dots, e_q)$ 的整体相关性越强，候选实体组 $e_1, e_2, \dots, e_q$ 的共现概率越大。如何有效度量候选实体组整体的相关性是目前的难点问题。为了削弱不相关实体对或者弱相关实体对对整体相关性的影响，并强调强相关实体对对整体相关性的贡献，本章定义了相关图和强相关序列概念。

定义10. 相关图：给定实体提及组的候选实体组 $(e_1, e_2, \dots, e_q)$ 及任意两个候

选实体之间的相关性 $R(e_i, e_j)$ 。 q 阶相关图是以候选实体组中所有实体作为节点，以任意两个实体之间的相关性作为实体间的边，连接形成的 q 阶无向完全图。

定义11. 相关序列：若相关图为 q 阶相关图，则满足三个条件的子图可以称为相关序列：（1）该子图具有 $q-1$ 个边；（2）该子图为连通图；（3）该子图为 q 阶相关图的生成子图。在相关图的所有相关序列中，累计相关性最大的相关序列称为强相关序列。

图5-3表示一个4阶相关图和它的两个相关序列，其中，红色的相关序列是所有相关序列中相关性最大的，称其为强相关序列。通过累计强相关序列上的相关性，得到强相关序列的相关性为2.4，即 $0.7+0.8+0.9=2.4$ 。根据相关序列的定义可知，相关序列并不一定是一条路径，还可能是一棵树，因此，强相关序列最终也可能是一棵树。例如，在图5-3中用蓝色实线表示的相关序列是一棵树。




图5-3 一个4阶相关图和其相关序列示例

Fig. 5-3 Examples of relatedness graph and relatedness sequences

基于强相关序列，本节构建了基于强相关序列的候选实体组整体相关性度量模型（strong-relatedness-sequence-based overall relatedness measurement model for candidate entity group, ORM-SRS）来估计候选实体组中所有实体的共现概率，如公式(5-8)所示。

$$P(e_1, e_2, \dots, e_q) = \sum_{(e_i, e_j) \in Tree(e_1, e_2, \dots, e_q)} R(e_i, e_j) \quad (5-8)$$

式中 $Tree_1(e_1, e_2, \dots, e_q)$ ——基于实体对的相关性得到的实体 $e_1, e_2, \dots, e_q$ 的强相关序列；

(e_i, e_j) ——强相关序列中的一条边；

$R(e_i, e_j)$ ——实体 e_i, e_j 的相关性。

在相关图中，存在多条相关序列，如何快速寻找到强相关序列是一个难点问题。如图5-4所示，一个4阶的相关图中存在多条相关序列，遍历所有的相关序列并计算其累计相关性需要消耗大量的计算资源。为了解决该问题，采用图论中的最大权重生成树算法来求解相关图的强相关序列。




图5-4 4阶相关图的相关性序列示例

Fig. 5-4 Relatedness sequences of a 4-order relatedness graph

为了验证强相关序列在捕捉候选实体组整体相关性的优势，将ORM-SRS和CFEL中的累计相关性来分别计算候选实体组的整体相关性。例如，在JH70发动机拆卸工艺知识图谱上实体链接时，通过ORM-SRS计算，候选实体组（回位弹簧座【启动轴】，徒手，弹性挡圈【启动轴】，卡簧钳）的整体相关性为3.3，而（回位弹簧座【启动轴】，小三叉套筒扳手，弹性挡圈【启动轴】，卡簧钳）的整体相关性为2.3。结果表明，实体提及组正确地链接到第一组候选实体，验证了通过强相关序列能够正确的实现集体实体链接。因此，强相关序列比累计相关性更能准确地度量候选实体组的整体相关性。

5.4.3 基于三种 2-hop 路径的实体相关性度量模型

ORM-SRS是基于候选实体对之间的相关性来建模的，实体对相关性度量精度直接影响了ORM-SRS的整体相关性度量精度。为了有效度量实体对之间的相关性，本节充分利用知识图谱中实体周围的信息，定义了三种2-hop路径并衡量每种2-hop路径对实体对相关性的贡献，建立了一种基于三种2-hop路径的实体相关性度量模型。

研究表明，实体的1-hop和2-hop路径能够很好的捕捉到实体之间的相关性信息，实体之间更长的路径会带来更多的噪声，反而减少了实体之间的相关性信息^[139]。CFEL模型在计算工艺实体对的相关性时，仅采用一种2-hop路径（有向2-hop），难以准确度量实体对的相关性。为了提升复杂装备拆卸工艺知识图谱中的信息利用率，本节将工艺知识图谱中的2-hop路径分为三种：第一种是指向共同的工艺实体；第二种是被共同的工艺实体指向；最后一种是两个工艺实体之间形成有向2-hop路径（即CFEL中使用的，已经在图5-5中用线框标出）。如

图5-5所示，实体 e_i 和 e_j 可能存在的三种2-hop路径。




图5-5 两个实体之间的2-hop路径

Fig. 5-5 Three types of 2-hop paths between two entities

如图5-6所示，在工艺实体“右侧盖【气缸头】”和“气缸头”之间真实存在三种2-hop路径。A中“右侧盖【气缸头】→螺栓【气缸左盖】←气缸头”是第一种2-hop路径，其关系为前序零件；B中“右侧盖【气缸头】←徒手→气缸头”是第二种2-hop路径，其关系为工具被使用；C中“气缸头→密封【气缸头右盖】→右侧盖【气缸头】”是第三种2-hop路径，其关系为前序零件。这三种路径对“右侧盖【气缸头】”和“气缸头”的相关性均有贡献。CFEL仅采用第三种2-hop路径，在计算“右侧盖【气缸头】”和“气缸头”的相关性时，忽略了“螺栓【气缸左盖】”和“徒手”对“右侧盖【气缸头】”和“气缸头”的相关性的影响，因此，难以准确度量工艺实体之间的相关性。

通常情况下，一方面，工艺实体之间的路径越短，工艺实体之间的相关性越大，工艺实体之间的路径越长，工艺相关性越小；另一方面，工艺实体之间包含的2-hop路径越多，工艺实体之间相关性越大。因此，本节提出采用三种2-hop路径和1-hop路径（即两个候选实体直接相连）来更准确地度量工艺实体之间的相关性。考虑到每种2-hop路径的数量以及每种2-hop路径对工艺实体相关性的重要度不同，本节建立了一种基于三种2-hop路径的实体相关性度量模型（entity pair relatedness measurement model based on three 2-hop paths, ERM-TTHP），如公式(5-9)所示。

$$R(e_i, e_j) = \begin{cases} 1 & \text{if } (e_i, r, e_j) \text{ or } (e_j, r, e_i) \\ R_2(e_i, e_j) & \text{otherwise} \end{cases} \quad (5-9)$$

$$R_2(e_i, e_j) = \frac{1}{l_{e_i, e_j}} \cdot \left(\frac{\beta \cdot (|B_{e_i, e_j}| + |T_{e_i, e_j}|) + (1 - \beta) \cdot |N_{e_i, e_j}|}{|N_{e_i}| + |T_{e_i, e_j}|} + \frac{\beta \cdot (|B_{e_j, e_i}| + |T_{e_j, e_i}|) + (1 - \beta) \cdot |N_{e_j, e_i}|}{|N_{e_j}| + |T_{e_j, e_i}|} \right)$$

式中 $R(e_i, e_j)$ ——工艺实体 e_i 和 e_j 的相关性度量函数；
 (e_i, r, e_j) ——在知识图谱中，工艺实体 e_i 和 e_j 之间存在关系；
 $R_2(e_i, e_j)$ ——基于 2-hop 路径的相关性度量函数；
 l_{e_i, e_j} ——工艺实体 e_i 到 e_j 的路径长度，本节中 $l_{e_i, e_j} = 2$ ；
 $|N_{e_i}|$ 、 $|N_{e_j}|$ ——分别为工艺实体 e_i 指向的工艺实体数量和 e_j 指向的工艺实体数量；
 $|B_{e_i, e_j}|$ 、 $|T_{e_i, e_j}|$ ——分别表示工艺实体 e_i 与 e_j 的第一种 2-hop 路径和第二种 2-hop 路径数量；
 $|N_{e_i, e_j}|$ ——工艺实体 e_i 到 e_j 的第三种 2-hop 路径数量；
 β ——一个衡量有向 2-hop 路径与其他 2-hop 路径重要度的超参数；




图5-6 JH70发动机拆卸工艺知识图谱中的三种2-hop路径

Fig. 5-6 Three types of 2-hop paths in knowledge graph of JH70 engine disassembly process

5.4.4 基于实体提及组和候选实体组的整体语义相似度模型

CFEL模型在计算 $P(m_1, m_2, \dots, m_q | e_1, e_2, \dots, e_q)$ 时，假设每个实体提及选择候选实体的概率是相互独立的，即 $P(m_1, m_2, \dots, m_q | e_1, e_2, \dots, e_q) = \prod_{i=1}^{|M|} P(m_i | e_i)$ 。然而，事实并非如此，在一段复杂装备拆卸工艺知识检索文本中各个实体提及的语义联系紧密。因此，实体提及组 $(m_1, m_2, \dots, m_q)$ 的整体语义相似度越强、候选实体组 $(e_1, e_2, \dots, e_q)$ 的整体语义相似度越强，则 $P(m_1, m_2, \dots, m_q | e_1, e_2, \dots, e_q)$ 越大。此外，给定候选实体 e_i 、实体提及 m_i 出现的概率越大时，则 $P(m_1, m_2, \dots, m_q | e_1, e_2, \dots, e_q)$ 越大。基于上述分析，本节建立基于实体提及组和候

选实体组的整体语义相似度模型来准确地估计 $P(m_1, m_2, \dots, m_q | e_1, e_2, \dots, e_q)$, 如公式(5-10)所示。

$$\begin{aligned} & P(m_1, m_2, \dots, m_q | e_1, e_2, \dots, e_q) \\ &= \prod_{i=1}^{|M|} P(m_i | e_i) \cdot Se(e_1, e_2, \dots, e_q) \cdot Se(m_1, m_2, \dots, m_q) \end{aligned} \quad (5-10)$$

式中 $|M|$ ——一段文本中实体提及的数量;

$Se(*)$ ——度量实体提及组 $(m_1, m_2, \dots, m_q)$ 和候选实体组 $(e_1, e_2, \dots, e_q)$ 的整体语义相似度函数;

$P(m_i | e_i)$ ——给定候选实体 e_i 下, 实体提及 m_i 出现的概率。

在集体实体链接过程中, 实体提及组通常是从一段已知文本中或者一句话中提取得到。因此, 实体提及组的语义相似度很强, 可以被视为1。在估计候选实体组的整体语义相似度时, 同样采用强相关序列的方法来估计候选实体组的整体语义相似度。进一步, 公式(5-10)被简化为公式(5-11)。

$$\begin{aligned} P(m_1, m_2, \dots, m_q | e_1, e_2, \dots, e_q) &= \prod_{i=1}^{|M|} P(m_i | e_i) \cdot Se(e_1, e_2, \dots, e_q) \\ &= \prod_{i=1}^{|M|} P(m_i | e_i) \cdot Tree_2(e_1, e_2, \dots, e_q) \\ &= \prod_{i=1}^{|M|} P(m_i | e_i) \cdot \sum_{(e_i, e_j) \in Tree_2(e_1, e_2, \dots, e_q)} S(e_i, e_j) \end{aligned} \quad (5-11)$$

式中 $S(e_i, e_j)$ ——实体 e_i 和实体 e_j 的语义相似度;

$Tree_2(e_1, e_2, \dots, e_q)$ ——基于实体对的语义相似度计算的强相关序列;

如何有效获取工艺实体 e_i 和工艺实体 e_j 的语义相似度是关键的问题。知识语义向量化表达方法能够有效学习到实体的上下文信息, 从而提取实体和关系的语义特征, 将实体的文本描述转换为语义向量。第2章建立的 ERTransH 模型能够有效学习到实体的语义信息。然而, 第2章是以拆卸工艺碎片化知识图谱库作为数据来训练 ERTransH 模型, 获得的工艺实体向量难以有效表征工艺实体在完整工艺知识图谱的语义信息。因此, 本章采用第4章构建的完整的复杂装备拆卸工艺知识图谱来重新训练 ERTransH 模型, 获得每个工艺实体的语义向量。

根据工艺实体的语义向量就可以通过余弦相似度或者欧氏距离量化任意两个工艺实体之间的语义相似度, 如公式(5-12)所示。例如, 经过ERTransH模型,

工艺实体“启动轴”的语义向量为 $[-0.17818, 0.13530, \dots, -0.00888, 0.23183]$, 工艺实体“曲轴连杆活塞组合”的语义向量为 $[-0.08544, 0.12662, \dots, -0.02125, 0.03360]$, 其余弦相似度为0.831, 即两个实体的语义相似度为0.831。

$$S(e_i, e_j) = \text{Sim}(\vec{e_i}, \vec{e_j}) \quad (5-12)$$

式中 $\vec{e_i}$ ——工艺实体 e_i 的语义向量;

$\text{Sim}(\vec{e_i}, \vec{e_j})$ ——计算工艺实体 $\vec{e_i}$ 和工艺实体 $\vec{e_j}$ 的语义相似度函数, 例如: 余弦相似度函数、欧氏距离的倒数;

为了能够准确估计 $P(m_1, m_2, \dots, m_q | e_1, e_2, \dots, e_q)$, 除了准确估计候选实体组的整体语义相似度和实体提及组的整体语义相似度, 还需要准确地估计给定候选实体 e_i 时实体提及 m_i 出现的概率, 即 $P(m_i | e_i)$ 。通过词频来计算 $P(m_i | e_i)$ 是一种有效的方法。然而, 我们无法获取所有与候选实体 e_i 和实体提及 m_i 相关的Web文档。一方面, 在网络世界中, 实体 e_i 和实体提及 m_i 的信息每时每刻都在发生变化; 另一方面, 由于复杂装备拆卸工艺知识的特性, 有些实体和实体提及的信息在网络中难以查询到。因此, 无法直接使用基于词语频率的方法来计算 $P(m_i | e_i)$ 。事实上, 拆卸工艺人员所输入的实体提及一般与正确的候选实体具有极大的表面相似度。因此, 本节假设实体提及 m_i 和候选实体 e_i 的表面相似度越大, $P(m_i | e_i)$ 越大。具体地, 采用编辑距离来计算实体提及 m_i 和候选实体 e_i 的表面相似度, 并用表面相似度来估计 $P(m_i | e_i)$, 如公式(5-13)所示。

$$\prod_{i=1}^{|M|} P(m_i | e_i) = \prod_{i=1}^{|M|} Lv(m_i, e_i) \quad (5-13)$$

$$Lv(m_i, e_i) = 1 - \frac{\text{lev}(m_i, e_i)}{\max(|m_i|, |e_i|)}$$

式中 $|m_i|$ 、 $|e_i|$ ——分别为实体提及 m_i 和候选实体 e_i 的字符数量;

$\text{lev}(m_i, e_i)$ ——实体提及 m_i 和候选实体 e_i 的编辑距离;

$Lv(m_i, e_i)$ ——实体提及 m_i 和候选实体 e_i 的表面相似度。

公式(5-13)表明只要存在 i , 使得 $S(m_i, e_i) = 0$, 则 $P(m_1, m_2, \dots, m_q | e_1, e_2, \dots, e_q)$ 就会等于0, 导致实体提及组 $(m_1, m_2, \dots, m_q)$ 链接到候选实体组 $(e_1, e_2, \dots, e_q)$ 的概率为0。若存在多个候选实体组被实体提及组链接到的概率均为0, 会导致实体提及组链接到不同候选实体组的链接概率难以被区分开。为了避免这种情况, 在计算实体提及与候选实体的表面相似度时, 添加一个大于0的超参数 γ , 如公

式(5-14)所示。

$$\prod_{i=1}^{|M|} P(m_i | e_i) = \prod_{i=1}^{|M|} (Lv(m_i, e_i) + \gamma) \quad (5-14)$$

5.4.5 细粒度集体实体链接方法

由于语义信息的获取也是基于知识图谱的结构，工艺实体的语义相似度和工艺实体的相关性通常难以有效区分。某种程度上，计算实体语义相似度的公式(5-14)和计算实体相关性的公式(5-9)可以互换。因此，根据实体相关性度量模型和实体语义相似度模型，提出了三种基于强相关序列的细粒度集体实体链接方法（strong-relatedness-sequence-based fine-grained collective entity linking, SRSCL），如公式(5-15)、公式(5-16)和公式(5-17)所示。

$$\begin{aligned} & \arg \max_{e_1 \in E_1, \dots, e_q \in E_q} P(e_1, e_2, \dots, e_q) \times Se(e_1, e_2, \dots, e_q) \cdot \prod_{i=1}^{|M|} P(m_i | e_i) \\ &= \arg \max_{e_1 \in E_1, \dots, e_q \in E_q} Tree_1(e_1, e_2, \dots, e_q) \times Tree_1(e_1, e_2, \dots, e_q) \cdot \prod_{i=1}^{|M|} (S(m_i, e_i) + \gamma) \end{aligned} \quad (5-15)$$

$$\begin{aligned} & \arg \max_{e_1 \in E_1, \dots, e_q \in E_q} P(e_1, e_2, \dots, e_q) \times Se(e_1, e_2, \dots, e_q) \cdot \prod_{i=1}^{|M|} P(m_i | e_i) \\ &= \arg \max_{e_1 \in E_1, \dots, e_q \in E_q} Tree_1(e_1, e_2, \dots, e_q) \times Tree_2(e_1, e_2, \dots, e_q) \cdot \prod_{i=1}^{|M|} (S(m_i, e_i) + \gamma) \end{aligned} \quad (5-16)$$

$$\begin{aligned} & \arg \max_{e_1 \in E_1, \dots, e_q \in E_q} P(e_1, e_2, \dots, e_q) \times Se(e_1, e_2, \dots, e_q) \cdot \prod_{i=1}^{|M|} P(m_i | e_i) \\ &= \arg \max_{e_1 \in E_1, \dots, e_q \in E_q} Tree_2(e_1, e_2, \dots, e_q) \times Tree_2(e_1, e_2, \dots, e_q) \cdot \prod_{i=1}^{|M|} (S(m_i, e_i) + \gamma) \end{aligned} \quad (5-17)$$

式中 $Tree_1(e_1, e_2, \dots, e_q)$ ——基于实体对的相关性得到的强相关序列；

$Tree_2(e_1, e_2, \dots, e_q)$ ——基于实体对的语义相似度得到的强相关序列。

5.5 复杂装备拆卸工艺知识图谱实体链接案例分析

为验证本章提出的面向复杂装备拆卸工艺知识图谱的细粒度集体实体链接方法的有效性，以 JH70 发动机实际拆卸工艺数据集作为实体链接样本，以第 4 章所构建的 JH70 发动机拆卸工艺知识图谱作为实体链接的知识库，进行实体链接实验。为验证提出的集体实体链接方法的泛化能力，以公开数据集 AIDA CoNLL-YAGO、ACE2004 和 AQUAINT 作为实体链接数据，以 YAGO-Core 中的部分数据作为实体链接的知识库，并在 YAGO-Core 上进行实体链接实验。

本章采用的 JH70 发动机实际拆卸工艺数据集 (engine disassembly process knowledge, EDPK) 是由 150 名学生实际拆卸发动机的工艺数据组成, 并且包括了学生多次拆卸发动机所得到的不同工艺数据。AIDA CoNLL-YAGO 是目前最大的手工标注实体链接数据集, 由马普研究所提供。该数据集共包含了 1393 篇与国家、政府、体育赛事等相关的文章。ACE 2004 由语言数据联盟开发, 包含各种类型的英语、中文和阿拉伯语文本数据。AQUANT 由三个来源的英文新闻文本数据组成: 新华社、纽约时报新闻社和美联社世界流新闻社。

公开数据集中已经完成了实体链接的手工标注过程，可以支持实体链接实验，如图 5-7 所示。在图 5-7 中，“B”表示实体提及的首个词语，“I”来表示组成实体提及的其他词语，“B”后面表示的是整个实体提及。若实体提及后面为“--NME--”，则表示其所链接的实体未知；否则，实体提及后面对应着其链接的实体，并且实体后面对应着实体在知识图谱中的唯一标识。



Fig. 5-7 Entity linking label for AIDA CoNLL-YAGO

然而，在 EDPK 中，工艺数据集中的实体提及与发动机拆卸工艺知识图谱中的实体名称完全一样，导致 EDPK 与实际情况不符，难以用于检验实体链接方法在实际应用中的有效性。一般地，拆卸人员在拆卸发动机或者检索相关知识时，可能会输入候选实体的同义词、部分关键字、缩写、错别字等。例如，拆卸人员在检索“T 型套筒扳手”时，可能输入“T 型加长套筒扳手”、“T 字扳手”、“丁字套筒扳手”、“T 型套筒扳子”、“T 形套筒扳子”等。基于上述分析，首先构建工艺实体的同义词词典；然后，通过随机将发动机实际拆卸工艺数据集中的实体提及替换为实体同义词词典中的实体提及，为发动机实际拆卸工艺数据集添加噪声，模拟拆卸人员在拆卸过程中实际检索情景。

此外，经过上述处理的数据集还未进行手工标注实体链接过程，因此，数据集难以用来支撑实体链接实验。为了解决该问题，采用公开数据集的实体链接标注过程，将包含实体提及的文本数据首先采用分词技术完成文本数据划分。

随后，分三步进行实体链接标注：（1）词语标识：将实体提及的首个词语标注为“B”，将实体提及的其他词语标注为“I”，将其他词语标注为“F”；（2）实体提及标注：为标识为“B”和“I”的词语标注实体提及；（3）为实体提及标注其所链接的实体：若不确定实体提及所链接的实体，则在实体提及后面标注为“--NME--”；若确定实体提及所链接的实体，则在实体提及后面标注其链接的实体。EDPK 的实体链接标注过程如图 5-8 所示。




图5-8 EDPK 的实体链接标注过程
Fig. 5-8 Entity linking label process for EDPK

实验所采用的数据集的详细信息如表 5-2 所示。具体地，表 5-2 中包含了每个数据集中所有的实体提及数量、所链接的实体在知识图谱中的实体提及数量以及具有候选实体的实体提及数量。实验中，以 EDPK 的所有数据作为 JH70 发动机拆卸工艺知识图谱上的实体链接实验。而在 YAGO 上的实体链接实验中，将所链接的实体在 YAGO 中的数据作为实验数据。这是因为 YAGO 规模庞大，受限于硬件条件，只截取了部分 YAGO 作为实体链接的知识库。

表5-2 实验数据
Table 5-2 Experiment datasets

数据集	实体提及数量	所链接的实体在知识库中的实体提及数量	具有候选实体的实体提及数量
EDPK	47576	47576	42907
AIDA CoNLL-YAGO	34929	20228	19716
AQUANT	727	186	180
ACE 2004	257	125	124

(2) 样本生成

通常情况下,集体实体链接需要设置滑动窗口的长度,将一个滑动窗口中的所有实体提及视为一个实体提及组或者一个样本。随后,计算实体提及组对应的候选实体组的整体相关性来实现集体实体链接。图 5-9 是在滑动窗口设置为 15 时提取 EDPK 中的一个实体提及组案例。如图 5-9 所示,第一个滑动窗口共包含了三个实体提及“定子总成”、“飞轮转子”和“十字螺钉-1”,这三个实体提及组成了一个实体提及组/样本。




图5-9 集体实体链接中实体提及组获取过程

Fig. 5-9 Entity mention group acquisition in collective entity linking

5.5.2 模型评估

实验中,采用精度、召回率和 F1 分数来评估实体链接方法在各数据集上的实体链接性能。

$$P = \frac{\text{correct_link}}{\text{processed_mentions}} \quad (5-18)$$

$$R = \frac{\text{correct_link_k}}{\text{total_mentions_k}} \quad (5-19)$$

$$F1 = \frac{2 \cdot P \cdot R}{P + R} \quad (5-20)$$

式中 correct_link ——正确的链接的实体提及数量;

processed_mentions —— 具有候选实体的实体提及数量。

total_mentions —— 所链接的实体在知识图谱中的实体提及数量

集体实体链接的重点是捕捉多个实体提及的候选实体组整体的相关性，然而，目前缺少集体实体链接方法在整体相关性方面的评估方法。本章基于滑动窗口包含的实体提及数量提出了一种 $M-k$ 评估方法，用来评估算法捕捉整体相关性的性能。在 $M-k$ 方法中，将具有候选实体的实体提及数量大于 k 的实体提及组（简称为 k 实体提及组）作为实验数据，评估其实体链接效果。这样由于实体提及的数量均大于 1，它们候选实体组整体的相关性都会被计算到。最后，使用精度、召回率和 F1 分数评估算法捕捉整体相关性的性能。

$$P = \frac{\text{correct_link_k}}{\text{processed_mentions_k}} \quad (5-21)$$

$$R = \frac{\text{correct_link_k}}{\text{total_mentions_k}} \quad (5-22)$$

$$F1 = \frac{2 \cdot P \cdot R}{P + R} \quad (5-23)$$

式中 *correct_link_k* —— 所有 k 实体提及组中正确链接的实体提及数量；
processed_mentions_k —— 所有 k 实体提及组中具有候选实体的实体提及数量；
total_mentions_k —— 所有 k 实体提及组中所链接的实体在知识图谱中的实体提及数量。

5.5.3 实验设置

根据公式(5-15)、公式(5-16)和(5-17)，SRSCl 方法有三种计算方式，分别命名为 SRSCl-10、SRSCl-11 和 SRSCl-12。在本节中，通过实验对提出的 SRSCl 方法的参数进行优化并对比三种 SRSCl 的实体链接效果。对模型精度影响较大的参数包括：候选实体数量、滑动窗口长度、衡量有向 2-hop 路径与其他 2-hop 路径重要度的参数 β 和避免实体链接概率为 0 的超参数 γ 。这些参数的默认值分别是：候选实体数量=10、滑动窗口=15、 $\beta=0.5$ 、 $\gamma=0.1$ 。下面采用 1/20 的 EDPK 探究 SRSCl 方法中各个参数对实体链接效果影响。

(1) β 和 γ 对 SRSCl 方法性能的影响

首先，设置候选实体的数量和滑动窗口为默认值。随后，根据经验知识，将 β 和 γ 的优化空间设置为： $\beta \in [0.3, 0.4, 0.5, 0.6, 0.7, 0.8]$ 和 $\gamma \in [0.1, 0.2, 0.3, 0.4, 0.5]$ 。采用设置的参数分别来优化 SRSCl-10、SRSCl-11 和 SRSCl-12，以对比三种 SRSCl 方法的实体链接效果，实验结果如表 5-3 所示。

表5-3 不同超参数范围下的实体链接性能

Table 5-3 The entity linking performance of the SRSCl with different hyperparameters

编号	β	γ	SRSCl-10			SRSCl-11			SRSCl-12		
			P(%)	R(%)	F1(%)	P(%)	R(%)	F1(%)	P(%)	R(%)	F1(%)
1	0.3	0.1	90.95	81.08	85.73	91.31	81.39	86.06	92.02	82.02	86.73
2	0.3	0.2	91.25	81.34	86.01	91.37	81.44	86.12	92.02	82.02	86.73
3	0.3	0.3	91.43	81.50	86.18	91.48	81.55	86.23	92.02	82.02	86.73
4	0.3	0.4	91.37	81.44	86.12	91.84	81.87	86.57	92.02	82.02	86.73
5	0.3	0.5	91.54	81.60	86.29	91.84	81.87	86.57	92.02	82.02	86.73
6	0.4	0.1	90.48	80.65	85.28	91.25	81.34	86.01	92.02	82.02	86.73
7	0.4	0.2	90.89	81.02	85.67	91.37	81.44	86.12	92.02	82.02	86.73
8	0.4	0.3	91.37	81.44	86.12	91.48	81.55	86.23	92.02	82.02	86.73
9	0.4	0.4	91.37	81.44	86.12	91.84	81.87	86.57	92.02	82.02	86.73
10	0.4	0.5	91.48	81.55	86.23	91.90	81.92	86.62	92.02	82.02	86.73
11	0.5	0.1	90.30	80.50	85.12	90.83	80.97	85.62	92.02	82.02	86.73
12	0.5	0.2	90.66	80.81	85.45	91.25	81.34	86.01	92.02	82.02	86.73
13	0.5	0.3	91.01	81.13	85.79	91.43	81.50	86.18	92.02	82.02	86.73
14	0.5	0.4	91.19	81.29	85.95	91.84	81.87	86.57	92.02	82.02	86.73
15	0.5	0.5	91.19	81.29	85.95	92.02	82.02	86.73	92.02	82.02	86.73
16	0.6	0.1	90.24	80.44	85.06	90.89	81.02	85.67	92.02	82.02	86.73
17	0.6	0.2	90.72	80.86	85.51	91.13	81.23	85.90	92.02	82.02	86.73
18	0.6	0.3	90.72	80.86	85.51	91.31	81.39	86.06	92.02	82.02	86.73
19	0.6	0.4	91.48	81.55	86.23	91.84	81.87	86.57	92.02	82.02	86.73
20	0.6	0.5	91.60	81.66	86.34	91.90	81.92	86.62	92.02	82.02	86.73
21	0.7	0.1	90.95	81.08	85.73	91.31	81.39	86.06	92.02	82.02	86.73
22	0.7	0.2	91.25	81.34	86.01	91.37	81.44	86.12	92.02	82.02	86.73
23	0.7	0.3	91.43	81.50	86.18	91.48	81.55	86.23	92.02	82.02	86.73
24	0.7	0.4	91.37	81.44	86.12	91.84	81.87	86.57	92.02	82.02	86.73
25	0.7	0.5	91.54	81.60	86.29	91.84	81.87	86.57	92.02	82.02	86.73
26	0.8	0.1	89.95	80.18	84.78	90.48	80.65	85.28	92.02	82.02	86.73
27	0.8	0.2	90.30	80.50	85.12	90.89	81.02	85.67	92.02	82.02	86.73
28	0.8	0.3	90.89	81.02	85.67	91.43	81.50	86.18	92.02	82.02	86.73
29	0.8	0.4	91.07	81.18	85.84	91.90	81.92	86.62	92.02	82.02	86.73
30	0.8	0.5	89.95	80.18	84.78	92.19	82.18	86.90	92.02	82.02	86.73

表 5-3 表明, SRSCl-12 在各参数下的结果不变, 这是因为 SRSCl-12 模型中没有包含参数 β 和 γ ; 当 $\beta = 0.6$ 并且 $\gamma = 0.5$ 时, SRSCl-10 取得了较好的实体链接精度、召回率以及 F1 分数; 当 $\beta = 0.8$ 并且 $\gamma = 0.5$ 时, SRSCl-12 在实体链接精度、召回率以及 F1 分数上取得了最好的值。注意到, β 是衡量有向 2-hop 路径与其他 2-hop 路径重要度的参数。在众多的参数中, 当 $\beta = 0.6$ 和 $\beta = 0.8$ 时, SRSCl-10 与 SRSCl-11 分别取得了最好的结果, 这说明了本章提出的另外两种 2-hop 路径在实体链接中具有一定的重要度, 验证了本章提出的三种 2-hop 路径的有效性。

如表 5-3 所示, 相比于 SRSCl-10 和 SRSCl-12, SRSCl-11 在精度、召回率和 F1 分数等指标上取得了最好的结果。具体地, 相比于 SRSCl-10, SRSCl-11 在精度、召回率和 F1 分数分别提升 0.59%、0.53%和 0.56%。SRSCl-11 和 SRSCl-10 的不同之处在于, 前者使用了语义向量来计算语义相似度, 后者使用三种 2-hop 路径来估计语义相似度。实验结果表明, 相比于三种 2-hop 路径, 知识语义向量化表达方法能有效捕捉实体的语义信息, 因而 SRSCl-11 的实体链接效果更好。相比于 SRSCl-12, SRSCl-11 在所有评估指标上均有所提升。SRSCl-11 和 SRSCl-12 的不同之处在于, 前者通过三种 2-hop 路径来估计实体对的相关性, 后者通过知识语义向量化表达方法来估计实体之间的相关性。实验结果表明, 相比于知识语义向量化表达方法, 三种 2-hop 路径能有效度量实体对的相关性。事实上, 语义相似度可能更注重实体在所有语境中所表示的含义, 相关性可能更注重实体之间的局部特征。因而, 采用三种 2-hop 路径能有效度量实体之间的相关性, 采用知识语义向量化表达方法能有效度量实体之间的语义相似度。实验分析表明, SRSCl-11 通过知识语义向量化表达方法能有效捕获实体的语义信息并通过三种 2-hop 路径能有效度量实体对的相关性。因此, 在三种 SRSCl 方法中, SRSCl-11 的实体链接效果最好。

下面在 $\beta=0.8$ 、 $\gamma=0.5$ 时, 探究候选实体数量与滑动窗口长度对 SRSCl-11 方法的实体链接效果影响。

(2) 候选实体数量对 SRSCl 方法性能的影响

在表 5-3 中的每组参数下, 将 SRSCl-11 的候选实体数量分别设置为 top-10、top-15 和 top-20 来探讨候选实体数量对 SRSCl 方法性能的影响。图 5-10 为 SRSCl-11 在候选实体数量不同时每组参数的实体链接精度、召回率和 F1 分数。在图 5-10 中, (a)表示不同候选实体数量时, SRSCl-11 的实体链接精度; (b)表示不同候选实体数量时, SRSCl-11 的实体链接召回率; (c)表示不同候选实体数量时, SRSCl-11 模型的实体链接 F1 分数。图 5-10 表明当候选实体数量从 top-10 变为 top-15 时, SRSCl-11 模型的实体链接精度、召回率和 F1 分数均下降; 当候选实体数量从 top-15 变为 top-20 时, SRSCl-11 的实体链接效果保持不变。结果表明随着候选实体数量规模的扩大, SRSCl-11 的精度、召回率和 F1 分数保持不变或者下降。这是由于随着候选实体规模的扩大, 引入了更多不相关的候选实体, 给实体链接带来了更多的噪声, 因而实体链接的精度保持不变或者下降。图 5-10 的结果侧面说明了本章候选实体生成方法的有效性, 即少量的候选实体也能取得好的实体链接精度。同时, 考虑到候选实体规模越多, 模型复杂度越高。因此, 设置候选实体数量设置为 top-10。




图5-10 SRSCl-11 在候选实体数量不同时的实体链接精度、召回率和 F1 分数
(在图(a)、图(b)、图(c)中 top-15 与 top-20 完全一样)

Fig. 5-10 The entity linking precisions, recall and F1 score of the SRSCl-11 with different sizes of candidate entity set (the results of top-15 and top-20 are identical in (a), (b), and (c))

(3) 滑动窗口长度对 SRSCl 方法性能的影响

采用控制变量法, 将其他参数固定来对 SRSCl-11 的滑动窗口长度进行调优。随后, 分别将滑动窗口的长度 (记作 l) 设置为 10、15、20 和 25 进行实验。SRSCl-11 在不同滑动窗口下的精度、召回率和 F1 分数如图 5-11 所示。

一般地, 随着滑动窗口增大, 一个滑动窗口的实体提及数量也增加。图 5-11 表明, 滑动窗口长度从 10 增加到 20 时, SRSCl-11 的精度、召回率和 F1 分数均为逐步递增。这说明了随着实体提及组规模的增大, SRSCl-11 能够有效地捕捉候选实体组的整体相关性。因而, 实体链接效果逐步提升。然而, 随着滑动窗口的长度从 20 增加到 25, 实体链接的精度、召回率和 F1 分数均为逐步递减。这可能与语言逻辑有关: 通常情况下, 对某一零部件拆卸时, 距离该零件

越近的相关操作或者相关零件，与该零件相关性越大；距离越远的相关操作或者相关零件，与该零件相关性越小。因此，滑动窗口中实体提及数量的继续增加，实体链接时引入了更多不相关的实体提及，导致了实体链接效果的下降。基于上述分析，在发动机拆卸工艺知识图谱上的实体链接中，本章将滑动窗口的长度设置为 20。




图5-11 不同滑动窗口下的 SRSCl-11 的实体链接结果

Fig. 5-11 Entity linking results of the SRSCl-11 under different sliding windows

综上所述，在发动机拆卸工艺知识图谱上的实体链接中，本章选择 SRSCl-11 作为最优的 SRSCl 方法与其他实体链接模型进行对比实验，并且实验中将滑动窗口长度设置为 20、候选实体的数量设置为 top-10、 β 设置为 0.8、 γ 设置为 0.5。

此外，本章还采用了公开数据集在 YAGO-Core 上的实体链接结果来验证本章所提出 SRSCl 方法的泛化性。重复上述实验过程，最终，在 YAGO-Core 上的实体链接中，选择 SRSCl-11 进行对比实验，并且将滑动窗口长度设置为 15、候选实体的数量设置为 top-10、 β 设置为 0.3、 γ 设置为 0.4。

5.5.4 对比实验

在本节中，为了验证所提出的 SRSCl 方法在 JH70 发动机拆卸工艺知识图谱上实体链接的有效性，以 EDPK 为实体链接的数据集，以所构建的发动机拆卸工艺知识图谱为知识库进行实体链接实验；同时，为了验证所提出的 SRSCl 方法的泛化性，将所提出的 SRSCl 方法应用在三个公共数据集上进行实体链接

实验。

实验中，将 SRSCl 方法与其他五种实体链接方法在上述数据集上进行对比，其他五种实体链接方法包括：经典的实体流行度模型（POP）、最新的集体实体链接方法 CFEL、EMDD、TTHP 和 CFELS。实体流行度模型通过实体的度信息来计算每个实体的流行度，并通过流行度对候选实体排序，从而获得实体提及最可能链接的候选实体。CFEL 通过实体之间的有向 2-hop 路径来计算实体的相关性，并以实体的相关性来表征实体的共现概率，最后通过一个概率模型来完成实体链接。在 CFEL 框架下，TTHP 使用三种 2-hop 路径来度量实体相关性；EMDD 使用语义向量度量实体对的相关性；而 CFELS 则引入了强相关序列以实现集体实体链接。

基于上述分析，本节对比实验共分为两个部分，第一部分为所提出的 SRSCl 在发动机拆卸工艺知识图谱上的对比实验；第二部分为所提出的 SRSCl 的泛化性验证实验。

（1）发动机拆卸工艺知识图谱上的实体链接对比实验

实验中，分别将 SRSCl 和其他五种实体链接方法应用在 EDPK 上进行实体链接，部分实验结果如表 5-4 所示。表 5-4 中的粗体表示链接正确的结果。

表 5-4 表明在部分的实验结果中，SRSCl 能够准确地完成实体链接。例如：在“套筒扳手”的链接中，只有 SRSCl 链接到了正确的实体。此外，POP 和 CFEL 模型的实体链接效果较差。例如：在“弹性挡圈【启动轴】”、“左边盖【气缸头】”和“挡圈弹簧【从动减速齿轮】”上的实体链接中，EMDD、TTHP、CFELS 和 SRSCl 均正确链接到了正确的实体，而 POP 和 CFEL 链接到错误的实体。

为了从全局度量各实体链接方法的实体链接效果，以精度、召回率和 F1 分数来评估上述六种实体链接方法/模型在 EDPK 上的实体链接的效果，实体链接结果如表 5-5 所示。

表 5-5 表明相比于其他五种模型，本章提出的 SRSCl 在 EDPK 上取得了最优的精度、召回率和 F1 分数。实验结果说明了所提出的 SRSCl 能够有效完成发动机拆卸工艺知识图谱上的实体链接任务，能有效支持拆卸工艺知识的检索。

在精度上，相比于其他实体链接方法，SRSCl 提升 0.75%-35.73%，平均提升 8.48%。此外，在召回率和 F1 分数上，SRSCl 显著优于其他五种实体链接方法。注意到，POP 是通过实体的邻接矩阵捕捉实体周围的特征，而其他实体链接方法均是采用 2-hop 路径或者知识语义向量化表达方法来度量工艺实体之间的相似度或者相关性。实验中，POP 取得了最差的实体链接效果，即在所有的评价指标上取得最低值。实验结果验证了 2-hop 路径和知识语义向量化表达方

法能有效地提取工艺实体的特征。除 POP 和 SRSCl 外, 其他模型采用知识语义向量化表达方法、2-hop 路径或者强相关序列中的一种或者两种来获得工艺实体的特征, 而 SRSCl 采用三种方法来捕获工艺实体周围的特征。实验结果验证了提出的 SRSCl 能有效提取工艺实体的特征。

表5-4 各实体链接方法在发动机拆卸工艺图谱上的部分实体链接结果

Table 5-4 Partial entity linking results of various entity linking methods on EDPK

实体提及	真实实体	实体链接方法所链接的实体					
		POP	CFEL	EMDD	TTHP	CFELS	SRSCl
套筒扳手	小三叉套筒扳手	T 型套筒扳手	T 型套筒扳手	T 型套筒扳手	T 型套筒扳手	T 型套筒扳手	小三叉套筒扳手
启动轴用回位弹簧	回位弹簧【启动轴】	回位弹簧座【启动轴】	弹簧【定位板】	弹簧【定位板】	弹簧【定位板】	弹簧【定位板】	回位弹簧【启动轴】
箱体定位销-1	定位销【箱体间】-1	定位板【变速鼓】	箱体密封	箱体密封	箱体密封	箱体密封	定位销【箱体间】-1
圆螺母扳手	圆螺母扳手	T 型套筒扳手	T 型套筒扳手	T 型套筒扳手	T 型套筒扳手	圆螺母扳手	圆螺母扳手
导油管【离合器】	通油管【离合器】	蝶形垫圈【离合器】	端盖【离合器】	端盖【离合器】	通油管【离合器】	通油管【离合器】	通油管【离合器】
主动轮【电机离合器】	主动齿轮【离合器】	齿轮外套【离合器】	齿轮外套【离合器】	齿轮外套【离合器】	主动齿轮【离合器】	主动齿轮【离合器】	主动齿轮【离合器】
离合器用套筒	套筒【离合器】	轴套【离合器】	轴套【离合器】	套筒【离合器】	套筒【离合器】	轴套【离合器】	套筒【离合器】
弹性挡圈【启动轴】	弹性挡圈【启动轴】	回位弹簧座【启动轴】	回位弹簧【启动轴】	弹性挡圈【启动轴】	弹性挡圈【启动轴】	弹性挡圈【启动轴】	弹性挡圈【启动轴】
左边盖【气缸头】	左侧盖【气缸头】	右侧盖【气缸头】	右侧盖【气缸头】	左侧盖【气缸头】	左侧盖【气缸头】	左侧盖【气缸头】	左侧盖【气缸头】
挡圈弹簧【从动减速齿轮】	弹性挡圈【从动减速齿轮】	回位弹簧座【启动轴】	回位弹簧座【启动轴】	弹性挡圈【从动减速齿轮】	弹性挡圈【从动减速齿轮】	弹性挡圈【从动减速齿轮】	弹性挡圈【从动减速齿轮】

除 POP 外, 其他五种实体链接方法隶属于同一个系列的方法。同时, EMDD、TTHP 和 CFELS 均是 CFEL 的改进方法, 它们分别采用本章提出的知识语义向量化表达方法、三种 2-hop 路径和强相关序列来进行实体链接。为了验证所提

出的 SRSCL 的有效性, 将 EMDD、TTHP、CFELS 和 SRSCL 分别与 CFEL 作对比。五个模型的实体链接精度、召回率和 F1 分数如图 5-12 所示。

表5-5 实体链接方法在 EDPK 上的对比实验结果

方法/模型	评估		
	<i>precision</i>	<i>recall</i>	<i>F1-score</i>
POP	55.42%	50.00%	52.58%
CFEL	88.61%	79.95%	84.06%
EMDD	89.87%	81.09%	85.25%
TTHP	90.40%	81.57%	85.76%
CFELS	89.72%	80.96%	85.11%
SRSCL	91.15%	82.24%	86.47%




图5-12 实体链接精度、召回率和 F1 分数对比

Fig. 5-12 The comparison results in entity linking precision, recall and F1 score

如图 5-12 所示, TTHP 在精度、召回率和 F1 分数上均优于 CFEL。TTHP 采用三种 2-hop 路径来度量工艺实体相关性, 而 CFEL 仅采用有向 2-hop 路径。结果验证了三种 2-hop 路径更能全面地表征工艺实体的特征, 从而能显著提升实体链接的效果。EMDD 在所有评估指标上优于 CFEL。实验结果表明相比于有向 2-hop 路径, 知识语义向量化表达方法能有效提取工艺实体的深层特征, 从而提升实体链接的效果。在精度、召回率和 F1 分数上, CFELS 的结果优于 CFEL, 验证了强相关序列能有效挖掘工艺实体之间的关联性信息, 从而显著提升实体链接的精度。

本章所提出的 SRSCL 中采用了三种 2-hop 路径来度量候选实体之间的相关性, 采用了知识语义向量化表达方法提取知识图谱的语义信息, 并采用强相关序列来计算候选实体组的整体相关性。理论上, 本章所提出的 SRSCL 的实体链

接效果最好。这与图 5-12 中实验结果一致，验证了本章提出的 SRSCl 在实体链接上的有效性。考虑到 SRSCl 的主要优势在于挖掘候选实体组的整体相关性，并且只有当滑动窗口中的实体提及数量大于 1 时，整体相关性才能够被计算。因此，下面采用 $M-k$ 方法评估 SRSCl 的性能。

POP、CFEL、EMDD、CFELS 和 SRSCl 等五种方法被用来进行候选实体组整体相关性捕捉对比实验。EDPK 的数据稀疏，一个滑动窗口中实体提及数量不多。因此，采用 $M-1$ 和 $M-2$ 来评估模型的性能，实验结果如表 5-6 所示。

表5-6 候选实体组相关性捕捉对比实验结果

Table 5-6 Comparison results in capturing the overall relatedness of candidate entity group

方法	$M-1$			$M-2$		
	<i>precision</i>	<i>recall</i>	<i>F1-score</i>	<i>precision</i>	<i>recall</i>	<i>F1-score</i>
POP	55.66%	52.66%	54.12%	59.75%	58.77%	59.26%
CFEL	88.22%	83.47%	85.78%	89.72%	88.24%	88.97%
EMDD	89.84%	85.00%	87.35%	92.68%	91.16%	91.91%
CFELS	89.68%	84.85%	87.20%	90.80%	89.31%	90.05%
SRSCl	91.19%	86.28%	88.67%	93.45%	91.92%	92.68%

如表 5-6 所示，在 $M-1$ - $M-2$ 上，SRSCl 取得了最好的实体链接精度、召回率和 F1 分数；EMDD 和 CFELS 获得了第二好和第三好的实体链接效果；CFEL 和 POP 模型分别取得了第三和第四好的结果。EMDD、CFELS 和 SRSCl 在 $M-1$ - $M-2$ 上的精度、召回率和 F1 分数显著优于 POP 和 CFEL。结果说明了在实体提及数量较多时，本章提出的 EMDD、CFELS 和 SRSCl 均能有效提取候选实体组的整体相关性。结果验证了本章提出的强相关序列、三种 2-hop 路径和知识语义向量化表达方法在捕捉候选实体组的整体相关性的有效性。

从表 5-6 中可以得出，五个实体链接方法的召回率和 F1 分数均与精度呈现正相关，即精度越高，召回率越高；精度越高，F1 分数越高。因此，在实验结果中，以精度代表评估指标来评估实体链接的效果。

与 CFEL 相比，EMDD 在 $M-1$ - $M-2$ 上的精度分别提升 1.26% 和 2.96%，结果表明知识语义向量化表达方法能够学习到实体的深层特征，从而能有效捕捉候选实体组的整体相关性。CFELS 显著提升 CFEL 的精度，结果表明 CFELS 能有效捕捉整体相关性。与 CFELS 相比，SRSCl 在 $M-1$ - $M-2$ 上的精度分别提升 1.51% 和 2.65%，证明了三种 2-hop 路径和知识语义向量化表达方法有助于捕捉整体相关性。与 CFEL 相比，SRSCl 在 $M-1$ - $M-2$ 上的精度显著提升，并且随着实体提及数量的增加，SRSCl 的精度提升越显著。

上述实验结果表明 SRSCl 能有效捕捉候选实体组的整体相关性，尤其是实体提及数量多时，SRSCl 的实体链接准确性突出。因此，SRSCl 方法能有效完成 JH70 发动机拆卸工艺知识图谱上的实体链接。

(2) SRSCl 泛化性验证实验

为了验证所提出的 SRSCl 的泛化性, 将 SRSCl 应用在公开数据集 AIDA CoNLL-YAGO、ACE2004 和 AQUAINT 上进行实体链接实验, 并采用 YAGO-Core 中的部分数据作为实体链接的知识库。采用精度、召回率和 F1 分数来评估方法的实体链接效果。六种方法在三个公共数据集的实体链接结果如表 5-7 所示。

表5-7 实体链接方法在三个公共数据集中的对比实验结果

Table 5-7 The entity linking results of various entity linking methods on three public datasets

方法		POP	CFEL	EMDD	TTHP	CFELS	SRSCl
AIDA CoNLL-YAGO	P(%)	74.99	80.21	79.96	81.93	80.21	82.23
	R(%)	71.39	76.36	76.12	78.00	76.36	78.29
	F1(%)	73.15	78.24	77.99	79.92	78.24	80.22
ACE2004	P(%)	83.87	89.52	89.52	90.32	89.52	90.32
	R(%)	83.87	89.52	89.52	90.32	89.52	90.32
	F1(%)	83.87	89.52	89.52	90.32	89.52	90.32
AQUAINT	P(%)	75.71	86.44	88.70	86.75	88.14	89.83
	R(%)	74.44	85.00	87.22	85.06	86.67	88.33
	F1(%)	75.07	85.71	87.96	85.90	87.40	89.08

表 5-7 表明相比于其他五种模型, 本章提出的 SRSCl 方法在三个数据集上均取得了最优的精度、召回率和 F1 分数。实验结果说明了所提出的 SRSCl 能够有效完成公共数据集的实体链接任务。验证了所提出的 SRSCl 泛化能力强, 能为其他领域和通用领域的实体链接提供借鉴意义。具体分析如下所示。

在 AIDA CoNLL-YAGO 的精度上, 相比于其他 5 种对比方法, SRSCl 提升 0.3%-7.24%, 平均提升 2.77%。同时, 在召回率和 F1 分数上, SRSCl 显著优于对比方法。在 AQUAINT 上, POP 在所有评估指标上取得了最差的结果, CFEL 取得了第二差的结果。而 SRSCl、EMDD、TTHP 和 CFELS 的结果显著优于 CFEL 的结果, 其中, SRSCl 取得了最好的结果。此外, SRSCl 的效果显著优于 POP 和 CFEL, 例如, SRSCl 的 F1 分数分别比 POP 和 CFEL 提升 14.01% 和 3.37%。ACE2004 上的实验结果显示, 由于 ACE2004 数据稀疏, 导致了多种模型在 ACE2004 上呈现相同的实体链接效果。POP 模型的实体链接效果最差, CFEL、EMDD、CFELS 均取得了第二好的效果, TTHP 和 SRSCl 均取得了最好的结果。实验结果验证了本章提出的 SRSCl 能有效完成公共数据集的实体链接, SRSCl 泛化能力强。

为了验证本章提出的强相关序列有效性, 在数据稠密的 AIDA CoNLL-YAGO 上采用 $M-k$ 来评估 POP、CFEL、CFELS 和 SRSCl 捕捉候选实体组的整体相关性的性能。具体地, 采用 $M-1$ 、 $M-2$ 、 $M-3$ 、 $M-4$ 、 $M-5$ 和 $M-6$ 来评估模型的性能, 结果如表 5-8 所示。

表5-8 捕捉候选实体组的整体相关性对比实验

Table 5-8 The performance comparison results in capturing the overall relatedness of candidate entity group

评价		$M-1$	$M-2$	$M-3$	$M-4$	$M-5$	$M-6$
POP(%)	P	74.85%	73.60%	72.53%	69.66%	66.58%	65.58%
	R	73.80%	72.84%	72.06%	69.21%	66.22%	65.28%
	F1	74.32%	73.22%	72.29%	69.44%	66.40%	65.43%
CFEL(%)	P	80.90%	80.64%	78.90%	74.48%	68.21%	62.56%
	R	79.76%	79.81%	78.39%	74.00%	67.84%	62.27%
	F1	80.32%	80.23%	78.64%	74.24%	68.02%	62.41%
CFELS(%)	P	81.25%	81.16%	79.12%	75.70%	69.84%	64.65%
	R	80.11%	80.32%	78.60%	75.21%	69.46%	64.35%
	F1	80.68%	80.74%	78.86%	75.46%	69.65%	64.50%
SRSCL(%)	P	84.25%	84.62%	83.53%	81.67%	77.17%	73.26%
	R	83.06%	83.75%	82.99%	81.14%	76.76%	72.92%
	F1	83.65%	84.19%	83.26%	81.40%	76.96%	73.09%

从表 5-8 中可以得出,四种实体链接方法的召回率和 F1 分数均与精度呈现正相关,即精度越高,召回率和 F1 分数越高。因此,在实验结果中,以精度来评估实体链接的效果。进一步,为了直观地对比所采用的的对比方法和 SRSCL 在 $M-k$ 上的实体链接效果,将各个模型的精度在图 5-13 中显示。




图5-13 候选实体组相关性捕捉精度

Fig. 5-13 The precision in capturing the overall relatedness of candidate entity group

如表 5-8 和图 5-13 所示, SRSCL 在 $M-1-M-6$ 上取得了最好的实体链接精度。CFELS 在 $M-1-M-6$ 上取得了次好的实体链接精度。CFEL 和 POP 模型分别取得了第三和第四好的结果。与 POP 模型相比, 在 $M-6$ 上, CFEL 模型的精度比 POP 低。结果说明了在实体提及数量较多时, CFEL 模型难以有效捕捉候选实体组的相关性, 反而是采用邻接矩阵的 POP 模型能有效捕捉实体提及组的

相关性。而 CFELS 和 SRSCl 在 $M-1-M-6$ 上显著优于 POP 和 CFEL，其中，SRSCl 精度最高。与 CFEL 相比，SRSCl 在 $M-1-M-6$ 上的精度分别提升 3.35%、3.98%、4.63%、7.19%、8.96% 和 10.70%。结果表明，随着滑动窗口中实体提及数量的增加，SRSCl 方法精度提升越显著，验证了提出的 SRSCl 能有效提取候选实体组的整体相关性。

综上所述，提出的 SRSCl 能有效完成 JH70 发动机拆卸工艺知识图谱上的集体实体链接任务。此外，SRSCl 的泛化性强，能够为通用领域和其他领域的实体链接任务提供借鉴。

根据本章的集体实体链接方法开发了面向复杂装备拆卸工艺知识图谱的语义检索系统。图 5-14 展示了 JH70 发动机“定子总成”的拆卸工艺知识检索过程。工艺人员在检索系统中实际输入为“定子总装”，输出的检索结果如图 5-14 所示。在检索结果中，点击中定子总成”跳转到“定子总成”的拆卸工艺知识图谱，如图 5-15 所示。“定子总装”与“定子”表达不同而语义相同，结果表明了本章提出的方法支持模糊语义检索。



图5-14 拆卸工艺知识语义检索系统

Fig. 5-14 Semantic retrieval system for disassembly process knowledge




图5-15 定子总成的拆卸工艺知识图谱

Fig. 5-15 Disassembly process knowledge graph of stator assembly

5.6 本章小结

为了能够准确地将工艺知识定位到复杂装备拆卸工艺知识图谱中，实现工艺知识的准确检索，本章提出了基于强相关序列的细粒度集体实体链接方法。受到自然语言逻辑特性的影响，该方法将一个滑动窗口中的实体提及及其候选实体视为一个整体，并建立强相关序列来有效度量候选实体组的整体相关性和整体语义相似度。为了能有效度量实体对的相关性并提取工艺实体的语义信息，该方法建立了基于三种 2-hop 路径的实体相关性度量模型并引入知识语义向量化表达方法，从而实现工艺知识的语义检索。最后，以 JH70 发动机实际拆卸工艺数据集和三个公共数据集进行实验，结果表明发动机拆卸工艺知识图谱上的实体链接精度提升至 91.15%，并且当滑动窗口中实体提及数量大于 6 时，所提出的方法在公共数据集上精度提升 10% 以上。实验结果表明所提出的方法能够有效完成复杂装备拆卸工艺知识图谱的实体链接任务和通用领域的实体链接任务，验证了该方法的有效性和泛化性。

结 论

复杂装备拆卸工艺知识图谱自动化构建与智能应用对于提高装备拆卸效率、降低复杂装备维修成本、避免拆卸事故发生等具有重要意义。本文针对该领域涉及的关键技术,研究了复杂装备拆卸工艺知识语义向量化表达方法、复杂装备拆卸工艺知识图谱的实体类别预测方法、装备拆卸工艺碎片化知识图谱相似度量与融合建模方法、面向复杂装备拆卸工艺知识图谱的细粒度集体实体链接方法,其成果对于提高复杂装备拆卸和装配的智能化水平具有一定的理论意义,同时对提高复杂装备厂商装备拆卸水平和拆卸工艺构建具有实用价值。本文主要研究工作如下:

(1) 针对复杂装备拆卸工艺碎片化知识图谱之间的工艺实体表达不统一、传统方法不能有效提取工艺实体和关系的语义信息问题,分析了复杂装备拆卸工艺知识图谱的复杂关系类型,建立了一种工艺实体和关系双投影超平面模型。模型为每个关系构建关系超平面和关系投影超平面,将工艺实体和关系的语义表示分别投影在关系超平面和关系投影超平面中,增大不同工艺实体和不同关系之间的语义距离,使得学习到的工艺实体和关系语义向量能够表征工艺实体和工艺关系的语义信息。利用 JH70 发动机拆卸工艺知识图谱和公共数据集进行工艺知识补全和链接预测实验,结果表明,所提出的模型能够更有效地提取拆卸工艺知识图谱中工艺实体和关系的语义信息,所学到的向量能够表征工艺实体和关系。

(2) 针对当前的机器学习方法难以同时提取工艺实体的层次结构特征和序列特征导致的实体类别预测不准问题,建立了样本自适应 LSTM 神经树预测模型。该模型将决策树与 LSTM 融合在一起,通过决策树来提取拆卸工艺实体的层次结构特征,通过 LSTM 来有效处理拆卸工艺实体的序列特征,提高了拆卸工艺实体的类别预测准确性。采用 JH70 发动机拆卸工艺数据对所构建的模型进行实验,结果表明,所构建的模型能够同时提取工艺实体的层次结构特征和序列特征,提升了工艺实体类别预测准确率。

(3) 为实现拆卸工艺知识图谱自动化构建,提出了装备拆卸工艺碎片化知识图谱相似度量与融合建模方法。论文建立了强化极大连通同归结构相似度模型,结合碎片化知识图谱中的路径相似、图结构相似以及拆卸工艺实体的权重信息,准确度量了碎片化知识图谱的相似度。在碎片化知识图谱融合过程中,论文综合考虑不同相似状态,通过实体融合、路径融合和插枝融合,在保证信息不丢失的情况下有效消除了冗余信息,实现了知识图谱的准确建模。采用

JH70 发动机拆卸工艺碎片化知识图谱库对所提出的方法进行实验, 结果表明, 所建立的相似度模型和提出的融合方法能有效实现 JH70 发动机拆卸工艺知识图谱的自动构建。

(4) 提出了基于强相关序列的细粒度集体实体链接方法, 能将查询文本准确链接到所构建的复杂装备拆卸工艺知识图谱中, 实现工艺知识精准推送。该方法考虑语言逻辑特性, 将一段拆卸工艺知识查询文本中多个实体提及对应候选实体视为一个整体。为准确度量候选实体组的整体相关性, 构建了三种 2-hop 路径的实体相关性度量模型来度量两个实体的相关性, 进而基于强相关序列度量整体相关性。为支持语义检索, 引入知识语义向量化表达方法, 并基于强相关序列度量候选实体组的整体语义相似度, 实现工艺知识的语义检索。以 JH70 发动机拆卸工艺知识图谱和 YAGO-Core 中部分数据作为实体链接知识库, 以 150 余人实际拆卸 JH70 发动机所产生的工艺数据集和几个公共数据集作为实体链接数据集进行实验, 证明了所提出的实体链接方法能有效完成拆卸工艺知识图谱的实体链接。

在完成上述研究工作的过程中, 取得了如下创新性成果:

(1) 提出了基于 ERTransH 的拆卸工艺知识语义向量化表达方法, 建立了工艺实体和关系双投影超平面模型, 该模型将实体和关系的语义表示分别投影在不同超平面中, 提取实体和关系语义信息, 实现了工艺实体和关系准确语义向量化表达。

(2) 建立了样本自适应 LSTM 神经树实体类型预测模型。该模型以决策树为框架, 通过 LSTM 定义树模型的节点, 能同时提取工艺实体的层次结构特征和序列特征, 实现了工艺实体类别信息的有效补全。

(3) 建立了面向碎片化知识图谱的强化极大连通同归结构相似度量模型, 定义了极大连通同归结构概念, 基于极大连通同归结构和拆卸工艺实体的重要度建立了碎片化知识图谱的相似度模型, 实现了碎片化知识图谱的准确相似度量。

(4) 提出了基于强相关序列的细粒度集体实体链接方法。该方法将一段工艺检索文本中的多个实体提及对应的候选实体视为一个整体, 建立了基于强相关序列的模型来度量候选实体组的相关度, 实现工艺知识的模糊检索与语义检索。

在本文研究工作的基础上, 还可以在以下方面开展进一步研究:

(1) 在复杂装备拆卸工艺知识图谱自动构建方面, 本文并未对文本形式的数据进行知识图谱建模, 将文本形式的数据抽取为碎片化知识图谱对于扩充知识图谱的规模和提升装备拆卸工艺知识图谱的实际应用具有重要的理论意义。

（2）在知识图谱应用方面，利用本文完善的拆卸工艺知识图谱，研究拆卸装配序列规划技术也是本文所提方法工程化的重要方向。

参考文献

- [1] 张栋豪, 刘振宇, 郑维强, 等. 知识图谱在智能制造领域的研究现状及其应用前景综述[J]. 机械工程学报, 2021, 57(5): 90-113.
- [2] 韩智, 周法国. 基于知识图谱的高铁动车设备检测系统的本体框架构建与维护[J]. 现代电子技术, 2018, 41(6): 11-14.
- [3] Zhang G, Cao X, Zhang M. A knowledge graph system for the maintenance of coal mine equipment[J]. Mathematical Problems in Engineering, 2021, 2021: 1-13.
- [4] Zhang X, Liu X, Li X, et al. MMKG: An approach to generate metallic materials knowledge graph based on DBpedia and Wikipedia[J]. Computer Physics Communications, 2017, 211: 98-112.
- [5] Mrdjenovich D, Horton M K, Montoya J H, et al. Propnet: a knowledge graph for materials science[J]. Matter, 2020, 2(2): 464-480.
- [6] Feng Y , Zhai F , Li B , et al. Research on intelligent fault diagnosis of power acquisition based on knowledge graph[C]// 2019 3rd International Conference on Electronic Information Technology and Computer Engineering (EITCE). IEEE, 2019: 1737-1740.
- [7] Liang K, Zhou B, Zhang Y, et al. PF2RM: a power fault retrieval and recommendation model based on knowledge graph[J]. Energies, 2022, 15(5): 1810.
- [8] Wang X Q, Yang S K. A tutorial and survey on fault knowledge graph[C]//Cyberspace Data and Intelligence, and Cyber-Living, Syndrome, and Health: International 2019 Cyberspace Congress, CyberDI and CyberLife, Beijing, China, December 16–18, 2019, Proceedings, Part II 3. Springer Singapore, 2019: 256-271.
- [9] 刘瑞宏, 谢国强, 苑宗港, 等. 基于知识图谱的智能故障诊断研究[J]. 邮电设计技术, 2020(10): 30-35.
- [10] Hubauer T, Lamparter S, Haase P, et al. Use cases of the industrial knowledge graph at siemens[C]//ISWC (P&D/Industry/BlueSky). 2018.
- [11] Schmid S, Henson C, Tran T. Using knowledge graphs to search an enterprise data lake[C]//The Semantic Web: ESWC 2019 Satellite Events: ESWC 2019 Satellite Events, Portorož, Slovenia, June 2–6, 2019, Revised Selected Papers 16. Springer International Publishing, 2019: 262-266.
- [12] Zhao Y, Liu Q, Xu W. Open industrial knowledge graph development for intelligent manufacturing service matchmaking[C]// 2017 International

- Conference on Industrial Informatics - Computing Technology, Intelligent Technology, Industrial Information Integration (ICIICII). IEEE Computer Society, 2017: 194-198.
- [13]袁芳怡. 面向制造业的知识图谱表示模型与构建技术研究[D]. 哈尔滨: 哈尔滨工业大学, 2019.
- [14]He L, Jiang P. Manufacturing knowledge graph: a connectivism to answer production problems query with knowledge reuse[J]. IEEE Access, 2019, 7: 101231-101244.
- [15]Lu Y C, Wen Y J, Xuan L. Exploration of the construction and application of knowledge graph in equipment failure[J]. DEStech Transactions on Computer Science and Engineering, (smce), 2017: 147-152.
- [16]Li X, Zhang S, Huang R, et al. Structured modeling of heterogeneous CAM model based on process knowledge graph[J]. The International Journal of Advanced Manufacturing Technology, 2018, 96: 4173-4193.
- [17]李秀玲, 张树生, 黄瑞, 黄波, 王思佳. 面向工艺重用的工艺知识图谱构建方法[J]. 西北工业大学学报, 2019, 37(06): 1174-1183.
- [18]凡天娣. 船舶焊接工艺知识建模及工艺规划技术研究[D]. 镇江: 江苏科技大学, 2020.
- [19]段阳, 侯力, 冷松. 金属切削加工知识图谱构建及应用[J]. 吉林大学学报: 工学版, 2021, 51(1): 12.
- [20]顾星海. 基于知识图谱的复杂产品装配工艺智能设计方法[D]. 上海: 东华大学, 2022.
- [21]陈新元, 谢晟祎, 陈庆强, 等. 结合平移关系嵌入和 CNN 的知识图谱补全[J]. 中文信息学报, 2021, 35(1): 54-63..
- [22]王维美, 陈恒, 史一民, 等. 基于卷积神经网络的知识图谱补全方法研究[J]. 计算机应用与软件, 2021, 38(4): 250-255.
- [23]Niu H, He H, Feng J, et al. Knowledge graph completion based on GCN of multi - information fusion and high-dimensional structure analysis weight[J]. Chinese Journal of Electronics, 2022, 31(2): 387-396.
- [24]Wu X, Tang Y, Zhou C, et al. An Intelligent Search Engine Based on Knowledge Graph for Power Equipment Management[C]//2022 5th International Conference on Energy, Electrical and Power Engineering (CEEPE). IEEE, 2022: 370-374.
- [25]张天杭, 李婷婷, 张永刚. 基于知识图谱嵌入的多跳中文知识问答方法[J]. 吉林大学学报 (理学版), 2022, 60(1): 119-0126.
- [26]Yin C, Zhang B, Liu W, et al. Geographic knowledge graph attribute normalization: improving the accuracy by fusing optimal granularity clustering

- and co-occurrence analysis[J]. ISPRS International Journal of Geo-Information, 2022, 11(7): 360.
- [27]Bharadwaj A G, Starly B. Knowledge graph construction for product designs from large CAD model repositories[J]. Advanced Engineering Informatics, 2022, 53: 101680.
- [28]Ye Q, Hsieh C Y, Yang Z, et al. A unified drug–target interaction prediction framework based on knowledge graph and recommendation system[J]. Nature communications, 2021, 12(1): 6775.
- [29]Xie L, Hu Z, Cai X, et al. Explainable recommendation based on knowledge graph and multi-objective optimization[J]. Complex & Intelligent Systems, 2021, 7: 1241-1252.
- [30]Bordes A, Weston J, Collobert R, et al. Learning structured embeddings of knowledge bases[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2011, 25(1): 301-306.
- [31]Socher R, Chen D, Manning C D, et al. Reasoning with neural tensor networks for knowledge base completion[J]. Advances in Neural Information Processing Systems, 2013, 26: 1-10.
- [32]Bordes A, Glorot X, Weston J, et al. A semantic matching energy function for learning with multi-relational data: Application to word-sense disambiguation[J]. Machine Learning, 2014, 94: 233-259.
- [33]Bordes A, Glorot X, Weston J, et al. Joint learning of words and meaning representations for open-text semantic parsing[C]//Artificial Intelligence and Statistics. PMLR, 2012: 127-135.
- [34]Jenatton R, Roux N, Bordes A, et al. A latent factor model for highly multi-relational data[J]. Advances in Neural Information Processing Systems, 2012, 25.
- [35]Sutskever I, Tenenbaum J, Salakhutdinov R R. Modelling relational data using bayesian clustered tensor factorization[J]. Advances in Neural Information Processing Systems, 2009, 22: 1-8.
- [36]Yang B, Yih W, He X, et al. Embedding entities and relations for learning and inference in knowledge bases[J]. arXiv preprint arXiv:1412.6575, 2014: 1-12.
- [37]Nickel M, Tresp V, Kriegel H P. A three-way model for collective learning on multi-relational data[C]//ICML. 2011, 11(10.5555): 3104482.3104584.
- [38]Nickel M, Tresp V, Kriegel H P. Factorizing yago: scalable machine learning for linked data[C]//Proceedings of the 21st International Conference on World Wide Web. 2012: 271-280.
- [39]Mikolov T, Sutskever I, Chen K, et al. Distributed representations of words and phrases and their compositionality[J]. Advances in Neural Information Processing Systems, 2013, 26: 1-9.
- [40]Mikolov T, Chen K, Corrado G, et al. Efficient estimation of word representations

- in vector space[J]. arXiv preprint arXiv:1301.3781, 2013: 1-12.
- [41]Fu R, Guo J, Qin B, et al. Learning semantic hierarchies via word embeddings[C]//Proceedings of the 52nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2014: 1199-1209.
- [42]Bordes A, Usunier N, Garcia-Duran A, et al. Translating embeddings for modeling multi-relational data[J]. Advances in Neural Information Processing Systems, 2013, 26: 1-9.
- [43]Wang Z, Zhang J, Feng J, et al. Knowledge graph embedding by translating on hyperplanes[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2014, 28(1): 1112-1119.
- [44]Lin Y, Liu Z, Sun M, et al. Learning entity and relation embeddings for knowledge graph completion[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2015, 29(1): 2181-2187.
- [45]Ji G, He S, Xu L, et al. Knowledge graph embedding via dynamic mapping matrix[C]//Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing (volume 1: Long papers). 2015: 687-696.
- [46]Xiao H, Huang M, Hao Y, et al. TransA: An adaptive approach for knowledge graph embedding[J]. arXiv preprint arXiv:1509.05490, 2015: 1-7.
- [47]Xiao H, Huang M, Hao Y, et al. TransG: A generative mixture model for knowledge graph embedding[J]. arXiv preprint arXiv:1509.05488, 2015: 1-7.
- [48]He S, Liu K, Ji G, et al. Learning to represent knowledge graphs with gaussian embedding[C]//Proceedings of the 24th ACM International on Conference on Information and Knowledge Management. 2015: 623-632.
- [49]Lei Z, Sun Y, Nanekaran Y A, et al. A novel data-driven robust framework based on machine learning and knowledge graph for disease classification[J]. Future Generation Computer Systems, 2020, 102: 534-548.
- [50]Jia Y, Wang Y, Jin X, et al. Path-specific knowledge graph embedding[J]. Knowledge-Based Systems, 2018, 151: 37-44.
- [51]Yaghoobzadeh Y, Adel H, Schütze H. Noise mitigation for neural entity typing and relation extraction[J]. arXiv preprint arXiv:1612.07495, 2016: 1-12.
- [52]Zhang R, Kong F, Wang C, et al. Embedding of hierarchically typed knowledge bases[C]//Thirty-Second AAAI Conference on Artificial Intelligence. 2018: 2046-2053.
- [53]Jain P, Kumar P, Chakrabarti S. Type-sensitive knowledge base inference without explicit type supervision[C]//Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers). 2018: 75-80.
- [54]Hajishirzi H, Zilles L, Weld D S, et al. Joint Coreference Resolution and Named-

-
- Entity Linking with Multi-Pass Sieves[C]//EMNLP. 2013: 289-299.
- [55]Durrett G, Klein D. A joint model for entity analysis: Coreference, typing, and linking[J]. Transactions of the Association for Computational Linguistics, 2014, 2: 477-490.
- [56]Gupta N, Singh S, Roth D. Entity linking via joint encoding of types, descriptions, and context[C]//Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing. 2017: 2681-2690.
- [57]Chen S, Wang J, Jiang F, et al. Improving entity linking by modeling latent entity type information[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2020, 34(05): 7529-7537.
- [58]Diefenbach D, Singh K, Maret P. Wdaqua-core1: a question answering service for rdf knowledge bases[C]//Companion Proceedings of the The Web Conference 2018. 2018: 1087-1091.
- [59]Elsahar H, Gravier C, Laforest F. Zero-shot question generation from knowledge graphs for unseen predicates and entity types[J]. arXiv preprint arXiv:1802.06842, 2018: 1-11.
- [60]Balog K, Neumayer R. Hierarchical target type identification for entity-oriented queries[C]//Proceedings of the 21st ACM International Conference on Information and Knowledge Management. 2012: 2391-2394.
- [61]Wang X, He X, Cao Y, et al. Kgat: Knowledge graph attention network for recommendation[C]//Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2019: 950-958.
- [62]Yogatama D, Gillick D, Lazic N. Embedding methods for fine grained entity type classification[C]//Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing (Volume 2: Short Papers). 2015: 291-296.
- [63]Shimaoka S, Stenetorp P, Inui K, et al. An attentive neural architecture for fine-grained entity type classification[J]. arXiv preprint arXiv:1604.05525, 2016: 1-6.
- [64]Melo A, Paulheim H, Völker J. Type prediction in rdf knowledge bases using hierarchical multilabel classification[C]//Proceedings of the 6th International Conference on Web Intelligence, Mining and Semantics. 2016: 1-10.
- [65]Chen B, Gu X, Hu Y, et al. Improving distantly-supervised entity typing with compact latent space clustering[J]. arXiv preprint arXiv:1904.06475, 2019: 1-11.
- [66]Sekine S. Extended named entity ontology with attribute information[C]//Proceedings of the Sixth International Conference on Language Resources and Evaluation (LREC'08). 2008: 52-57.
- [67]Melo A, Völker J, Paulheim H. Type prediction in noisy RDF knowledge bases using hierarchical multilabel classification with graph and latent features[J]. International Journal on Artificial Intelligence Tools, 2017, 26(02): 1760011.

-
- [68]Zahera H M, Heindorf S, Ngomo A C N. ASSET: A Semi-supervised Approach for Entity Typing in Knowledge Graphs[C]//Proceedings of the 11th on Knowledge Capture Conference. 2021: 261-264.
- [69]Paulheim H, Bizer C. Improving the quality of linked data using statistical distributions[J]. International Journal on Semantic Web and Information Systems (IJSWIS), 2014, 10(2): 63-86.
- [70]Kliegr T, Zamazal O. LHD 2.0: A text mining approach to typing entities in knowledge graphs[J]. Journal of Web Semantics, 2016, 39: 47-61.
- [71]Lin T, Etzioni O. No noun phrase left behind: detecting and typing unlinkable entities[C]//Proceedings of the 2012 Joint Conference on Empirical Methods in Natural Language Processing and Computational Natural Language Learning. 2012: 893-903.
- [72]Biswas R, Sofronova R, Alam M, et al. Do judge an entity by its name! entity typing using language models[C]//The Semantic Web: ESWC 2021 Satellite Events: Virtual Event, June 6–10, 2021, Revised Selected Papers 18. Springer International Publishing, 2021: 65-70.
- [73]Lee C, Hwang Y G, Oh H J, et al. Fine-grained named entity recognition using conditional random fields for question answering[J]. Lecture notes in computer science, 2006, 4182: 581-587.
- [74]Paulheim H, Bizer C. Type inference on noisy RDF data[C]//The Semantic Web—ISWC 2013: 12th International Semantic Web Conference, Sydney, NSW, Australia, October 21-25, 2013, Proceedings, Part I 12. Springer Berlin Heidelberg, 2013: 510-525.
- [75]LaValley M P. Logistic regression[J]. Circulation, 2008, 117(18): 2395-2399.
- [76]Lin C J, Weng R C, Keerthi S S. Trust region newton methods for large-scale logistic regression[C]//Proceedings of the 24th International Conference on Machine Learning. 2007: 561-568.
- [77]Belgiu M, Drăguț L. Random forest in remote sensing: A review of applications and future directions[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2016, 114: 24-31.
- [78]Rigatti S J. Random forest[J]. Journal of Insurance Medicine, 2017, 47(1): 31-39.
- [79]Suykens J, Vandewalle J. Least Squares Support Vector Machine Classifiers[J]. Neural Processing Letters, 1999, 9(3): 293-300.
- [80]Mikolov T, Karafiát M, Burget L, et al. Recurrent neural network based language model[C]//Interspeech. 2010, 2(3): 1045-1048.
- [81]Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in Neural Information Processing Systems, 2012, 25: 1097-1105.
- [82]Van Houdt G, Mosquera C, Nápoles G. A review on the long short-term memory

- model[J]. Artificial Intelligence Review, 2020, 53: 5929-5955.
- [83]Hovda J A B, Garigliotti D, Balog K. NeuType: A Simple and Effective Neural Network Approach for Predicting Missing Entity Type Information in Knowledge Bases[J]. arXiv preprint arXiv:1907.03007, 2019: 1-4.
- [84]Biswas R, Sofronova R, Alam M, et al. Entity type prediction in knowledge graphs using embeddings[J]. arXiv preprint arXiv:2004.13702, 2020: 1-7.
- [85]Zahera H M, Heindorf S, Ngomo A C N. ASSET: A Semi-supervised Approach for Entity Typing in Knowledge Graphs[C]//Proceedings of the 11th on Knowledge Capture Conference. 2021: 261-264.
- [86]Neelakantan A, Chang M W. Inferring missing entity type instances for knowledge base completion: New dataset and methods[J]. arXiv preprint arXiv:1504.06658, 2015: 1-11.
- [87]Zhao Y, Zhang A, Feng H, et al. Knowledge graph entity typing via learning connecting embeddings[J]. Knowledge-Based Systems, 2020, 196: 105808.
- [88]Zhao Y, Li Z, Deng W, et al. Learning entity type structured embeddings with trustworthiness on noisy knowledge graphs[J]. Knowledge-Based Systems, 2021, 215: 106630.
- [89]庄严, 李国良, 冯建华. 知识库实体对齐技术综述[J]. 计算机研究与发展, 2016, 53(1): 165-192.
- [90]Naumann F, Bilke A, Bleiholder J, et al. Data fusion in three steps: resolving schema, tuple, and value inconsistencies[J]. IEEE Data Eng. Bull., 2006, 29(2): 21-31.
- [91]Elmagarmid A K, Ipeirotis P G, Verykios V S. Duplicate record detection: a survey[J]. IEEE Transactions on Knowledge and Data Engineering, 2006, 19(1): 1-16.
- [92]Jukes E. Encyclopedia of machine learning and data mining[J]. Reference Reviews, 2018, 32(7/8): 3-4.
- [93]Hu W, Bai W Y, Qu Y Z. Research on resolving object coreference on the semantic web[J]. Journal of Software, 2012, 23(7): 1729-1744.
- [94]焦文欢, 冯兴杰. 一种改进的字符串匹配模型研究[J]. 计算机仿真, 2022, 3(39): 319-324.
- [95]李华锋, 曾崇, 胡海青, 等. 基于机器学习的航行通告文本分类研究[J]. 民航学报, 2022, 4(6): 6-9.
- [96]王振振, 何明, 杜永萍. 基于 LDA 主题模型的文本相似度计算[J]. 计算机科学, 2013, 40(12): 229-232.
- [97]Cumin D. Longest Common Subsequence[J]. Similarity String Lcs Data, 2013.
- [98]Ta T T, Shieh Y K, Lu C L. Computing a longest common almost-increasing subsequence of two sequences[J]. Theoretical Computer Science, 2021, 854: 44-

- 51.
- [99] Qiu D, Jiang H, Chen S. Fuzzy information retrieval based on continuous bag-of-words model[J]. *Symmetry*, 2020, 12(2): 225.
- [100] Li D, Li J, Fan Y, et al. Printed label defect detection using twice gradient matching based on improved cosine similarity measure[J]. *Expert Systems with Applications*, 2022, 204: 117372.
- [101] Batzelis E, Blanes J M, Toledo F J, et al. Noise-scaled euclidean distance: a metric for maximum likelihood estimation of the PV model parameters[J]. *IEEE Journal of Photovoltaics*, 2022, 12(3): 815-826.
- [102] Iofciu T, Zhou X, Giesbers B, et al. State of the art report in knowledge sharing, recommendation and Latent Semantic Analysis[J]. *Cooper Consortium Deliverable*, 2006, 3.
- [103] Sharma C, Sharma S. Latent DIRICHLET allocation (LDA) based information modelling on BLOCKCHAIN technology: a review of trends and research patterns used in integration[J]. *Multimedia Tools and Applications*, 2022, 81(25): 36805-36831.
- [104] 侯爱民. 图同构的一个充分必要条件[J]. *计算机工程与应用*, 2009, 45(30): 57-61.
- [105] Hu Y, Tang Y, Huang H, et al. A graph isomorphism network with weighted multiple aggregators for speech emotion recognition[J]. *arXiv preprint arXiv: 2207.00940*, 2022: 1-5.
- [106] Yu W, Richards G T, Vogeley M S, et al. Examining AGN UV/Optical Variability beyond the Simple Damped Random Walk[J]. *The Astrophysical Journal*, 2022, 936(2): 132.
- [107] Ma K, Shao W, Zhu Q, et al. Kernel based statistic: identifying topological differences in brain networks[J]. *Intelligent Medicine*, 2022, 2(01): 30-40.
- [108] 吴江宁, 刘巧凤. 基于最大公共子图的文本相似度算法研究[J]. *情报学报*, 2010, 29(5): 787-791.
- [109] Kim J B, Park R H, Kim H I. A comprehensive analysis and evaluation to unsupervised binary hashing method in image similarity measurement[J]. *Iet Image Processing*, 2017, 11(8): 633-639.
- [110] Koch I. Enumerating all connected maximal common subgraphs in two graphs[J]. *Theoretical Computer Science*, 2001, 250(1-2): 1-30.
- [111] Kawabata T. Build-up algorithm for atomic correspondence between chemical structures[J]. *Journal of chemical information and modeling*, 2011, 51(8): 1775-1787.
- [112] Oliveira I L, Fileto R, Speck R, et al. Towards holistic entity linking: Survey and directions[J]. *Information Systems*, 2021, 95: 101624.

- [113] Pershina M, He Y, Grishman R. Personalized page rank for named entity disambiguation[C]//Proceedings of the 2015 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. 2015: 238-243.
- [114] Le P, Titov I. Distant learning for entity linking with automatic noise detection[J]. arXiv preprint arXiv:1905.07189, 2019: 1-11.
- [115] Fang Z, Cao Y, Li Q, et al. Joint entity linking with deep reinforcement learning[C]//The World Wide Web Conference. 2019: 438-447.
- [116] Ganea O E, Hofmann T. Deep Joint Entity Disambiguation with Local Neural Attention (EMNLP 2017)[C]//Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, 2017: 2619-2629.
- [117] Wu L, Petroni F, Josifoski M, et al. Scalable Zero-shot Entity Linking with Dense Entity Retrieval[C]//Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2020: 6397-6407.
- [118] Fabian M, Gjergji K, Gerhard W. Yago: A core of semantic knowledge unifying wordnet and wikipedia[C]//16th International World Wide Web Conference, WWW. 2007: 697-706.
- [119] Shen W, Wang J, Han J. Entity linking with a knowledge base: Issues, techniques, and solutions[J]. IEEE Transactions on Knowledge and Data Engineering, 2014, 27(2): 443-460.
- [120] Zhang W, Tan C L, Su J, et al. I2R-NUS-MSRA at TAC 2011: Entity Linking[C]//TAC. 2011: 1-6.
- [121] Wang H, Zheng J G, Ma X, et al. Language and domain independent entity linking with quantified collective validation[C]//Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing. 2015: 695-704.
- [122] Onoe Y, Durrett G. Fine-grained entity typing for domain independent entity linking[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2020, 34(05): 8576-8583.
- [123] Hoffart J, Seufert S, Nguyen D B, et al. KORE: keyphrase overlap relatedness for entity disambiguation[C]//Proceedings of the 21st ACM International Conference on Information and Knowledge Management. 2012: 545-554.
- [124] Daiber J, Jakob M, Hokamp C, et al. Improving efficiency and accuracy in multilingual entity extraction[C]//Proceedings of the 9th International Conference on Semantic Systems. 2013: 121-124.
- [125] Cao Y, Hou L, Li J, et al. Neural Collective Entity Linking[C]//Proceedings of the 27th International Conference on Computational Linguistics. 2018: 675-686.

-
- [126] Liu M, Gong G, Qin B, et al. A Multi-View–Based Collective Entity Linking Method[J]. *ACM Transactions on Information Systems (TOIS)*, 2019, 37(2): 1-29.
- [127] Sevgili Ö, Shelmanov A, Arkhipov M, et al. Neural entity linking: A survey of models based on deep learning[J]. *Semantic Web*, 2022 (Preprint): 1-44.
- [128] Chong W H, Lim E P, Cohen W. Collective entity linking in tweets over space and time[C]//*Advances in Information Retrieval: 39th European Conference on IR Research, ECIR 2017, Aberdeen, UK, April 8-13, 2017, Proceedings 39*. Springer International Publishing, 2017: 82-94.
- [129] Xia Y, Wang X, Gu L, et al. A collective entity linking algorithm with parallel computing on large-scale knowledge base[J]. *The Journal of Supercomputing*, 2020, 76(2): 948-963.
- [130] Vrandečić D, Krötzsch M. Wikidata: a free collaborative knowledgebase[J]. *Communications of the ACM*, 2014, 57(10): 78-85.
- [131] Lehmann J, Isele R, Jakob M, et al. Dbpedia—a large-scale, multilingual knowledge base extracted from wikipedia[J]. *Semantic web*, 2015, 6(2): 167-195.
- [132] Zhao G, Wu J, Wang D, et al. Entity disambiguation to Wikipedia using collective ranking[J]. *Information Processing & Management*, 2016, 52(6): 1247-1257.
- [133] Liu M, Gong G, Qin B, et al. A multi-view–based collective entity linking method[J]. *ACM Transactions on Information Systems (TOIS)*, 2019, 37(2): 1-29.
- [134] E. Rama-Maneiro E, Vidal J C, Lama M. Collective disambiguation in entity linking based on topic coherence in semantic graphs[J]. *Knowledge-Based Systems*, 2020, 199: 105967.
- [135] Zhou X, Miao Y, Wang W, et al. A recurrent model for collective entity linking with adaptive features[C]//*Proceedings of the AAAI Conference on Artificial Intelligence*. 2020, 34(01): 329-336.
- [136] Shen W, Han J, Wang J. A probabilistic model for linking named entities in web text with heterogeneous information networks[C]//*Proceedings of the 2014 ACM SIGMOD International Conference on Management of Data*. 2014: 1199-1210.
- [137] Shen W, Han J, Wang J, et al. Shine+: A general framework for domain-specific entity linking with heterogeneous information networks[J]. *IEEE Transactions on Knowledge and Data Engineering*, 2017, 30(2): 353-366.
- [138] Wang G, Yang J, Xu J. Granular computing: from granularity optimization to multi-granularity joint problem solving[J]. *Granular Computing*, 2017, 2: 105-120.

- [139] Li J, Bu C, Li P, et al. A coarse-to-fine collective entity linking method for heterogeneous information networks[J]. Knowledge-Based Systems, 2021, 228: 107286.
- [140] Myles A J, Feudale R N, Liu Y, et al. An introduction to decision tree modeling[J]. Journal of Chemometrics: A Journal of the Chemometrics Society, 2004, 18(6): 275-285.

附录

附表 1 文本实验所用的三元组
Schedule 1 Triples used in the experiments

头实体	关系	尾实体	头实体	关系	尾实体
螺栓[左箱]-4	前序零件	链轮[二次传动]	端盖[离合器]	前序零件	十字螺钉[离合器]-3
六角螺栓[传动链轮]-1	功能	用于固定二次传动链轮	定位板[变速鼓]	前序零件	螺栓[变速鼓]-1
螺栓[左箱]-7	前序零件	弹簧[定位板]	螺栓[左箱]-5	前序零件	链轮[二次传动]
十字螺钉[离合器]-3	使用工具	十字螺丝刀	螺栓[左箱]-4	前序零件	回位弹簧[启动轴]
包括轴承等	类别	功能	导向销轴[气缸体]	类别	轴系零件
气缸头盖罩	前序零件	普通垫片-2	螺栓[左箱]-3	前序零件	定子总成
圆螺母[离合器]	类别	连接零件	螺栓[正时从动链轮]-2	使用工具	小三叉套筒扳手
离合器	功能	内含离合器离合器上板、弹性挡圈、离合器下板、主动盘、离合器外罩、离合器弹簧等	螺栓[变速鼓]-2	使用工具	大三叉套筒扳手
气缸体	属性	圆柱度	圆柱度	正常范围	小于 0.25mm

头实体	关系	尾实体	头实体	关系	尾实体
螺栓[左箱]-5	使用工具	T 型套筒扳手	箱体组合[中右侧]	前序零件	螺栓[左箱]-2
十字螺栓[缸体连接]-1	类别	连接零件	圆螺母[离合器]	使用工具	圆螺母扳手
螺栓[左箱]-6	前序零件	换挡摇臂-1	螺栓[左箱]-3	类别	连接零件
推杆[离合器]	使用工具	徒手	定位销[箱体间]-1	使用工具	徒手
气缸体	制造单位	宁波缸套厂有限公司	螺栓[右箱]-8	类别	连接零件
齿轮外套[离合器]	类别	传动零件	螺栓[正时从动链轮]-3	类别	连接零件
螺栓[左箱]-7	前序零件	定子总成	螺栓[气缸右盖]-2	使用工具	小三叉套筒扳手
用于与飞轮转子配合发电	类别	功能	气缸体	生产日期	2013.01.02
气缸体	使用工具	徒手	普通垫片-4	功能	用于增大接触面积,减小压力,防止松动,保护零件等
从动减速齿轮	前序零件	主动齿轮[离合器]	螺栓[右箱]-6	功能	用于连接右侧箱体, 注意螺栓长度与孔的对应关系
螺栓[变速鼓]-1	前序零件	从动减速齿轮	螺栓[正时从动链轮]-3	使用工具	小三叉套筒扳手
普通垫片-1	前序零件	圆头螺帽-1	轴套[离合器]	类别	轴系零件
气缸体	失效日期	2023.05.06	时规链条	材质	碳钢

头实体	关系	尾实体	头实体	关系	尾实体
弹性挡圈[启动轴]	功能	用于固定零部件的轴向运动 (一般安装于槽轴上)	箱体组合[中右侧]	前序零件	定子总成
定位板[变速鼓]	功能	用于支持变速鼓定位	箱体组合[中右侧]	前序零件	螺栓[左箱]-5
箱体组合[左侧]	前序零件	曲轴连杆活塞组合	圆头螺帽-1	类别	连接零件
用于离合器通油	类别	功能	螺栓[左箱]-3	前序零件	弹簧[定位板]
螺栓[变速鼓]-1	使用工具	大三叉套筒扳手	圆头螺帽-2	使用工具	大三叉套筒扳手
用于连接气缸头右 盖、气缸头、气缸头 左盖	类别	功能	螺栓[左箱]-1	功能	用于连接左侧箱体，注意螺栓 长度与孔的对应关系
螺栓[左箱]-5	前序零件	回位弹簧[启动轴]	气缸体	功能	用于提供活塞运动空间
定子总成	前序零件	十字螺钉[定子总成]-2	螺栓[左箱]-5	功能	用于连接左侧箱体，注意螺栓 长度与孔的对应关系
右侧盖[气缸头]	功能	用于封闭气缸头	螺栓[变速鼓]-2	前序零件	箱体密封
气缸头盖罩	类别	其他零件	用于支持变速鼓定位	类别	功能
曲轴连杆活塞组合	功能	发动机的重要组成部分，精 度要求较高，加工比较困 难，拆装不容易，一般不轻 易拆卸	用于压紧变速鼓定位 板	类别	功能
蝶形垫圈[离合器]	使用工具	徒手	螺栓[左箱]-2	前序零件	回位弹簧[启动轴]

头实体	关系	尾实体	头实体	关系	尾实体
十字螺钉[离合器]-1	功能	用于连接离合器端盖	定位销[箱体间]-1	前序零件	箱体组合[中右侧]
链轮[二次传动]	前序零件	链轮固定装置	螺栓[右箱]-1	功能	用于连接右侧箱体，注意螺栓长度与孔的对应关系
时规链条	类别	传动零件	箱体组合[中右侧]	前序零件	螺栓[左箱]-1
螺栓[变速鼓]-2	功能	用于固定变速鼓螺栓	用于密封箱体	类别	功能
箱体组合[右侧]	前序零件	螺栓[右箱]-2	六角螺栓[传动链轮]-1	类别	连接零件
用于张紧杆组所用弹簧。	类别	功能	变速机构	前序零件	螺栓[变速鼓]-2
离合器	类别	组合零件	右侧盖[气缸头]	使用工具	徒手
十字螺栓[缸体连接]-2	功能	用于连接气缸体与箱体	螺栓[左箱]-5	前序零件	箱体组合[右侧]
螺栓[左箱]-7	前序零件	换挡摇臂-1	螺栓[左箱]-3	前序零件	时规链条
定位销[箱体间]-2	类别	其他零件	螺栓[左箱]-7	前序零件	箱体组合[右侧]
用于固定变速鼓螺栓	类别	功能	气缸头	功能	内含气门、弹簧、摇臂、凸轮轴等
螺栓[箱底]	类别	连接零件	用于固定二次传动链轮	类别	功能

附录

头实体	关系	尾实体	头实体	关系	尾实体
普通垫片-4	类别	其他零件	螺栓[正时从动链轮]-1	类别	连接零件
螺母[飞轮转子]	功能	用于锁紧磁电机飞轮转子	时规链条	使用工具	徒手
箱体组合[左侧]	前序零件	定位销[箱体间]-2	箱体组合[左侧]	前序零件	箱体密封
箱体组合[中右侧]	前序零件	螺栓[左箱]-4	气缸头盖罩	功能	用于封闭气缸头
箱体组合[左侧]	前序零件	启动轴	箱体组合[右侧]	前序零件	螺栓[右箱]-8
弹簧[张紧]	前序零件	螺栓[箱底]	螺栓[右箱]-8	使用工具	T 型套筒扳手
气缸头	前序零件	密封[气缸头右盖]	张紧杆组件[张紧链轮]	使用工具	徒手
用于启动轴回位	类别	功能	用于安装正时从动链轮	类别	功能
蝶形垫圈[离合器]	前序零件	垫圈[离合器]	螺栓[左箱]-2	前序零件	链轮[二次传动]
垫圈[离合器]	类别	其他零件	密封[气缸头右盖]	类别	其他零件
回位弹簧[启动轴]	功能	用于启动轴回位	十字螺钉[离合器]-3	功能	用于连接离合器端盖
气缸头	使用工具	徒手	导向销轴[气缸体]	功能	用于定位链条导向滚轮
十字螺栓[缸体连接]-1	使用工具	十字螺丝刀	螺栓[右箱]-1	使用工具	T 型套筒扳手
螺栓[正时从动链轮]-2	功能	用于安装正时从动链轮	圆头螺帽-3	使用工具	大三叉套筒扳手

头实体	关系	尾实体	头实体	关系	尾实体
圆头螺帽-2	类别	连接零件	用于操控离合器	类别	功能
气缸头	前序零件	十字螺栓[缸体连接]-1	密封[气缸头盖罩]	类别	其他零件
换挡摇臂-1	使用工具	橡胶锤	螺栓[左箱]-3	前序零件	链轮[二次传动]
用于提供活塞运动空间	类别	功能	螺栓[右箱]-1	类别	连接零件
气缸头	前序零件	螺栓[气缸左盖]-1	螺栓[右箱]-4	类别	连接零件
螺栓[左箱]-2	前序零件	弹簧[定位板]	时规链条	功能	用于连接正时主动轮与正时从动轮
启动轴	前序零件	回位弹簧[启动轴]	垫圈[离合器]	前序零件	圆螺母[离合器]
螺栓[左箱]-7	前序零件	回位弹簧[启动轴]	回位弹簧座[启动轴]	前序零件	弹性挡圈[启动轴]
主动齿轮[离合器]	功能	离合器主动齿轮	右侧盖[气缸头]	前序零件	螺栓[气缸左盖]-1
螺栓[正时从动链轮]-2	类别	连接零件	用于支持反冲启动	类别	功能
螺栓[气缸左盖]-1	类别	连接零件	齿轮外套[离合器]	前序零件	离合器
螺栓[左箱]-2	前序零件	时规链条	垫圈[离合器]	功能	用于固定离合器
螺栓[气缸右盖]-1	类别	连接零件	六角螺栓[传动链轮]-2	使用工具	小三叉套筒扳手
张紧杆组件[张紧链轮]	前序零件	弹簧[张紧]	螺栓[变速鼓]	类别	连接零件

附录

头实体	关系	尾实体	头实体	关系	尾实体
时规链条	前序零件	气缸体	定子总成	功能	用于与飞轮转子配合发电
气缸头	前序零件	链轮[正时从动]	链轮[正时从动]	使用工具	徒手
用于固定零部件的轴向运动（一般安装于槽轴上）	类别	功能	螺栓[右箱]-3	功能	用于连接右侧箱体，注意螺栓长度与孔的对应关系
螺栓[左箱]-3	前序零件	换挡摇臂-1	箱体组合[左侧]	前序零件	定位销[箱体间]-1
螺栓[左箱]-5	前序零件	套筒[离合器]	换挡摇臂-2	使用工具	徒手
轴套[离合器]	使用工具	徒手	螺栓[左箱]-5	类别	连接零件
圆头螺帽-4	使用工具	大三叉套筒扳手	螺栓[右箱]-2	使用工具	T 型套筒扳手
螺栓[气缸右盖]-1	使用工具	小三叉套筒扳手	箱体组合[右侧]	功能	包括右侧箱体及附件
十字螺钉[定子总成]-2	功能	用于连接定子总成与箱体	端盖[离合器]	前序零件	十字螺钉[离合器]-4
圆头螺帽-4	类别	连接零件	箱体密封	功能	用于密封箱体
六角螺栓[传动链轮]-2	类别	连接零件	箱体组合[中右侧]	前序零件	时规链条
普通垫片-2	前序零件	圆头螺帽-2	用于连接左侧箱体，注意螺栓长度与孔的对应关系	类别	功能

头实体	关系	尾实体	头实体	关系	尾实体
十字螺钉[离合器]-1	使用工具	十字螺丝刀	张紧杆组件[张紧链轮]	功能	用于张紧链轮
用于固定离合器	类别	功能	十字螺钉[离合器]-4	类别	连接零件
定位板[变速鼓]	使用工具	徒手	螺栓[箱底]	使用工具	大三叉套筒扳手
离合器用轴套	类别	功能	换挡摇臂-1	前序零件	换挡摇臂-2
螺栓[右箱]-6	类别	连接零件	十字螺钉[定子总成]-1	使用工具	十字螺丝刀
用于连接气缸体与箱体	类别	功能	换挡摇臂-1	功能	用于支持变速机构换挡。
导向销轴[气缸体]	使用工具	小三叉套筒扳手	左侧盖[气缸头]	类别	其他零件
右侧盖[气缸头]	前序零件	螺栓[气缸右盖]-2	换挡摇臂	类别	组合零件
螺栓[右箱]-7	类别	连接零件	定位销[箱体间]-2	使用工具	徒手
通油管[离合器]	前序零件	推杆[离合器]	螺栓[左箱]-2	使用工具	T 型套筒扳手
时规链条	前序零件	张紧杆组件[张紧链轮]	十字螺钉[定子总成]-2	前序零件	飞轮转子
飞轮转子	前序零件	螺母[飞轮转子]	普通垫片-2	类别	其他零件
内含气门、弹簧、摇臂、凸轮轴等	类别	功能	箱体组合[右侧]	前序零件	螺栓[右箱]-6
链轮固定装置	功能	用于固定二次传动链轮	轴套[离合器]	前序零件	主动齿轮[离合器]

附录

头实体	关系	尾实体	头实体	关系	尾实体
飞轮转子	使用工具	徒手	换挡摇臂-1	使用工具	徒手
用于连接正时主动轮 与正时从动轮	类别	功能	包括卡簧、外棘轮端 齿、启动齿轮等	类别	功能
螺栓[右箱]-5	类别	连接零件	链轮[二次传动]	类别	传动零件
左侧盖[气缸头]	使用工具	徒手	启动轴	前序零件	箱体组合[中右侧]
启动轴	类别	组合零件	螺栓[右箱]-3	类别	连接零件
箱体组合[中右侧]	使用工具	徒手	密封[气缸头盖罩]	前序零件	气缸头盖罩
螺栓[右箱]-2	功能	用于连接右侧箱体，注意螺 栓长度与孔的对应关系	螺栓[左箱]-1	使用工具	T 型套筒扳手
螺栓[左箱]-2	前序零件	套筒[离合器]	螺栓[左箱]-3	前序零件	回位弹簧[启动轴]
弹簧[定位板]	类别	其他零件	弹性挡圈[从动减速齿 轮]	功能	用于固定零部件的轴向运动 (一般安装于槽轴上)
定位销[箱体间]-2	功能	用于拆装时箱体间定位	螺栓[右箱]-7	功能	用于连接右侧箱体，注意螺栓 长度与孔的对应关系
圆头螺帽-1	使用工具	大三叉套筒扳手	螺栓[正时从动链轮]- 1	使用工具	小三叉套筒扳手
换挡摇臂-2	功能	用于支持变速机构换挡	箱体组合[左侧]	前序零件	箱体组合[中右侧]
用于连接定子总成与 箱体	类别	功能	端盖[离合器]	类别	其他零件

头实体	关系	尾实体	头实体	关系	尾实体
圆螺母[离合器]	功能	用于固定离合器	回位弹簧座[启动轴]	使用工具	徒手
回位弹簧[启动轴]	前序零件	回位弹簧座[启动轴]	螺栓[左箱]-5	前序零件	换挡摇臂-1
十字螺钉[离合器]-1	类别	连接零件	螺栓[左箱]-6	使用工具	T 型套筒扳手
六角螺栓[传动链轮]-1	使用工具	小三叉套筒扳手	螺栓[正时从动链轮]-3	功能	用于安装正时从动链轮
螺栓[左箱]-1	前序零件	回位弹簧[启动轴]	张紧杆组件[张紧链轮]	类别	组合零件
圆头螺帽-3	功能	用于连接气缸头盖罩、垫片与气缸头等	螺栓[左箱]-6	前序零件	套筒[离合器]
回位弹簧[启动轴]	使用工具	徒手	箱体组合[中右侧]	前序零件	螺栓[左箱]-7
曲轴连杆活塞组合	使用工具	徒手	用于支持变速机构换挡	类别	功能
定子总成	类别	组合零件	螺栓[右箱]-6	使用工具	T 型套筒扳手
螺栓[左箱]-3	前序零件	套筒[离合器]	螺栓[左箱]-3	使用工具	T 型套筒扳手
主动齿轮[离合器]	使用工具	徒手	十字螺钉[离合器]-4	功能	用于连接离合器端盖
螺栓[左箱]-6	前序零件	定子总成	螺栓[气缸右盖]-2	类别	连接零件
链轮[二次传动]	功能	用于向外传递动力	用于张紧链轮	类别	功能
螺栓[左箱]-1	前序零件	链轮[二次传动]	十字螺钉[离合器]-4	使用工具	十字螺丝刀
导向滚轮[链条]	使用工具	徒手	箱体组合[右侧]	前序零件	螺栓[右箱]-1

附录

头实体	关系	尾实体	头实体	关系	尾实体
螺栓[气缸左盖]-1	功能	用于连接气缸头右盖、气缸头、气缸头左盖	主动齿轮[离合器]	前序零件	齿轮外套[离合器]
螺栓[左箱]-1	前序零件	定子总成	气缸头盖罩	前序零件	普通垫片-1
普通垫片-1	类别	其他零件	弹性挡圈[启动轴]	使用工具	卡簧钳
箱体组合[中右侧]	前序零件	螺栓[左箱]-6	箱体密封	前序零件	箱体组合[中右侧]
启动轴	使用工具	徒手	用于配合张紧杆组， 位于曲轴箱体底部	类别	功能
左侧盖[气缸头]	功能	用于封闭气缸头	气缸头盖罩	前序零件	普通垫片-4
离合器	前序零件	蝶形垫圈[离合器]	用于封闭气缸头	类别	功能
导向滚轮[链条]	类别	传动零件	螺栓[左箱]-4	前序零件	时规链条
螺栓[左箱]-4	前序零件	套筒[离合器]	螺栓[左箱]-6	前序零件	链轮[二次传动]
螺栓[左箱]-5	前序零件	弹簧[定位板]	螺栓[左箱]-7	类别	连接零件
导向滚轮[链条]	前序零件	导向销轴[气缸体]	包括轴承、张紧轮、 机油泵传递链轮组件 等	类别	功能
普通垫片-1	功能	用于增大接触面积,减小压力,防止松动,保护零件等	链轮[二次传动]	使用工具	徒手
普通垫片-2	功能	用于增大接触面积,减小压力,防止松动,保护零件等	螺栓[右箱]-8	功能	用于连接右侧箱体，注意螺栓 长度与孔的对应关系

头实体	关系	尾实体	头实体	关系	尾实体
十字螺栓[缸体连接]-1	前序零件	左侧盖[气缸头]	用于链条导向	类别	功能
定位板[变速鼓]	类别	其他零件	普通垫片-1	使用工具	徒手
弹簧[定位板]	前序零件	定位板[变速鼓]	圆头螺帽-4	功能	用于连接气缸头盖罩、垫片与气缸头等
螺栓[右箱]-5	功能	用于连接右侧箱体，注意螺栓长度与孔的对应关系	套筒[离合器]	功能	离合器用套筒
通油管[离合器]	功能	用于离合器通油	左侧盖[气缸头]	前序零件	螺栓[气缸左盖]-1
齿轮外套[离合器]	功能	离合器齿轮外套	螺栓[左箱]-4	使用工具	T 型套筒扳手
定位销[箱体间]-1	类别	其他零件	螺栓[左箱]-6	前序零件	时规链条
定子总成	前序零件	十字螺钉[定子总成]-1	密封[气缸头右盖]	功能	用于密封气缸头右盖
螺栓[左箱]-1	前序零件	换挡摇臂-1	气缸体	前序零件	导向滚轮[链条]
回位弹簧[启动轴]	类别	其他零件	圆螺母[离合器]	前序零件	端盖[离合器]
从动减速齿轮	类别	传动零件	通油管[离合器]	使用工具	徒手
蝶形垫圈[离合器]	使用工具	尖嘴钳	通油管[离合器]	类别	其他零件
十字螺钉[离合器]-2	类别	连接零件	螺栓[左箱]-4	前序零件	箱体组合[右侧]
弹簧[张紧]	使用工具	徒手	箱体组合[右侧]	类别	箱体零件
定位销[箱体间]-2	前序零件	箱体组合[中右侧]	弹簧[定位板]	使用工具	徒手
气缸头盖罩	前序零件	普通垫片-3	螺栓[左箱]-7	使用工具	T 型套筒扳手

附录

头实体	关系	尾实体	头实体	关系	尾实体
端盖[离合器]	使用工具	徒手	箱体组合[右侧]	使用工具	徒手
气缸头	前序零件	密封[气缸头盖罩]	垫圈[离合器]	使用工具	徒手
螺栓[变速鼓]-1	功能	用于锁紧变速鼓定位板	普通垫片-3	类别	其他零件
弹簧[定位板]	功能	用于压紧变速鼓定位板	用于向外传递动力	类别	功能
螺栓[左箱]-1	前序零件	箱体组合[右侧]	用于将动力传递给配 气机构摇臂	类别	功能
螺栓[左箱]-4	功能	用于连接左侧箱体，注意螺 栓长度与孔的对应关系	链轮[正时从动]	功能	用于将动力传递给配气机构摇 臂
螺栓[左箱]-2	前序零件	箱体组合[右侧]	启动轴	功能	包括卡簧、外棘轮端齿、启动 齿轮等
用于连接气缸头与气 缸体连接	类别	功能	箱体组合[右侧]	前序零件	螺栓[右箱]-5
用于密封气缸头右盖	类别	功能	套筒[离合器]	使用工具	徒手
箱体组合[中右侧]	类别	其他零件	箱体密封	使用工具	徒手
螺栓[左箱]-6	类别	连接零件	十字螺钉[定子总成]- 1	前序零件	飞轮转子
用于拆装时箱体间定 位	类别	功能	包括右侧箱体及附件	类别	功能

头实体	关系	尾实体	头实体	关系	尾实体
螺栓[右箱]-4	使用工具	T 型套筒扳手	普通垫片-3	功能	用于增大接触面积,减小压力,防止松动,保护零件等
变速机构	前序零件	箱体组合[中右侧]	螺栓[左箱]-3	功能	用于连接左侧箱体, 注意螺栓长度与孔的对应关系
弹性挡圈[从动减速 齿轮]	前序零件	箱体组合[右侧]	普通垫片-4	使用工具	徒手
十字螺栓[缸体连接]- 1	功能	用于连接气缸头与气缸体连接	螺栓[左箱]-6	前序零件	弹簧[定位板]
箱体组合[右侧]	前序零件	螺栓[右箱]-4	蝶形垫圈[离合器]	类别	其他零件
密封[气缸头右盖]	前序零件	右侧盖[气缸头]	箱体组合[左侧]	前序零件	变速机构
变速机构	使用工具	徒手	箱体组合[左侧]	前序零件	换挡摇臂-1
箱体组合[左侧]	使用工具	徒手	弹性挡圈[启动轴]	类别	其他零件
十字螺钉[定子总成]- 1	类别	连接零件	十字螺钉[定子总成]- 2	类别	连接零件
弹性挡圈[从动减速 齿轮]	类别	其他零件	箱体组合[中右侧]	前序零件	通油管[离合器]
气缸头盖罩	使用工具	徒手	螺栓[左箱]-5	前序零件	定子总成
链轮[正时从动]	前序零件	螺栓[正时从动链轮]-1	用于连接离合器端盖	类别	功能
密封[气缸头盖罩]	使用工具	徒手	弹性挡圈[启动轴]	前序零件	箱体组合[右侧]

头实体	关系	尾实体	头实体	关系	尾实体
螺栓[左箱]-4	类别	连接零件	用于连接气缸头右盖 与气缸头	类别	功能
曲轴连杆活塞组合	类别	组合零件	端盖[离合器]	功能	其上装有轴承
十字螺钉[离合器]-3	类别	连接零件	螺栓[左箱]-3	前序零件	箱体组合[右侧]
用于锁紧磁电机飞轮 转子	类别	功能	普通垫片-3	使用工具	徒手
螺栓[左箱]-4	前序零件	弹簧[定位板]	十字螺栓[缸体连接]- 2	类别	连接零件
变速机构	类别	组合零件	曲轴连杆活塞组合	前序零件	箱体组合[中右侧]
普通垫片-3	前序零件	圆头螺帽-3	气缸体	前序零件	十字螺栓[缸体连接]-2
发动机的重要组成部分， 精度要求较高， 加工比较困难，拆装 不容易，一般不轻易 拆卸	类别	功能	螺栓[左箱]-2	前序零件	定子总成
时规链条	使用工具	尖嘴钳	气缸头	类别	箱体零件
定子总成	使用工具	一子螺丝刀	右侧盖[气缸头]	前序零件	螺栓[气缸右盖]-1
螺母[飞轮转子]	使用工具	大三叉套筒扳手	螺栓[正时从动链轮]- 1	功能	用于安装正时从动链轮

头实体	关系	尾实体	头实体	关系	尾实体
用于密封气缸头盖罩	类别	功能	密封[气缸头右盖]	使用工具	徒手
十字螺钉[离合器]-2	功能	用于连接离合器端盖	飞轮转子	类别	其他零件
螺栓[左箱]-1	前序零件	弹簧[定位板]	端盖[离合器]	前序零件	通油管[离合器]
用于定位链条导向滚轮	类别	功能	定位销[箱体间]-1	功能	用于拆装时箱体间定位
六角螺栓[传动链轮]-2	功能	用于固定二次传动链轮	链轮[正时从动]	类别	传动零件
导向滚轮[链条]	功能	用于链条导向	螺栓[左箱]-6	功能	用于连接左侧箱体，注意螺栓长度与孔的对应关系
齿轮外套[离合器]	使用工具	徒手	从动减速齿轮	前序零件	弹性挡圈[从动减速齿轮]
箱体组合[中右侧]	功能	包括轴承等	套筒[离合器]	前序零件	轴套[离合器]
螺栓[左箱]-1	类别	连接零件	用于锁紧变速鼓定位板	类别	功能
蝶形垫圈[离合器]	功能	用于固定离合器	螺栓[左箱]-7	前序零件	时规链条
曲轴连杆活塞组合	前序零件	套筒[离合器]	螺栓[左箱]-7	前序零件	套筒[离合器]
用于增大接触面积，减小压力，防止松动，保护零件等	类别	功能	端盖[离合器]	前序零件	十字螺钉[离合器]-1
链轮固定装置	类别	其他零件	螺栓[气缸右盖]-2	功能	用于连接气缸头右盖与气缸头

附录

头实体	关系	尾实体	头实体	关系	尾实体
螺栓[气缸右盖]-1	功能	用于连接气缸头右盖与气缸头	用于承接离合器传递的传动，并将动力传递给变速机构	类别	功能
弹簧[张紧]	类别	组合零件	用于连接气缸头盖罩、垫片与气缸头等	类别	功能
十字螺钉[定子总成]-2	使用工具	十字螺丝刀	从动减速齿轮	使用工具	徒手
链轮固定装置	使用工具	徒手	螺栓[左箱]-2	功能	用于连接左侧箱体，注意螺栓长度与孔的对应关系
回位弹簧座[启动轴]	功能	用于支持反冲启动	普通垫片-4	前序零件	圆头螺帽-4
其上装有轴承	类别	功能	螺母[飞轮转子]	类别	连接零件
离合器用套筒	类别	功能	回位弹簧座[启动轴]	类别	其他零件
变速机构	功能	包括凸爪齿轮、空套齿轮等，通过拨叉进行齿轮滑移来实现变速	十字螺钉[离合器]-2	使用工具	十字螺丝刀
螺栓[左箱]-6	前序零件	回位弹簧[启动轴]	圆头螺帽-2	功能	用于连接气缸头盖罩、垫片与气缸头等
箱体组合[左侧]	功能	包括轴承、张紧轮、机油泵传递链轮组件等	螺栓[气缸左盖]-1	使用工具	小三叉套筒扳手

头实体	关系	尾实体	头实体	关系	尾实体
螺栓[左箱]-1	前序零件	套筒[离合器]	离合器主动齿轮	类别	功能
链轮[正时从动]	使用工具	一子螺丝刀	螺栓[右箱]-4	功能	用于连接右侧箱体，注意螺栓长度与孔的对应关系
端盖[离合器]	前序零件	十字螺钉[离合器]-2	套筒[离合器]	类别	轴系零件
螺栓[右箱]-2	类别	连接零件	定子总成	使用工具	徒手
螺栓[左箱]-4	前序零件	换挡摇臂-1	用于支持变速机构换挡。	类别	功能
螺栓[左箱]-7	前序零件	链轮[二次传动]	推杆[离合器]	功能	用于操控离合器
链轮固定装置	前序零件	六角螺栓[传动链轮]-1	螺栓[左箱]-2	前序零件	通油管[离合器]
螺栓[右箱]-7	使用工具	T 型套筒扳手	箱体组合[左侧]	类别	箱体零件
箱体组合[中右侧]	前序零件	螺栓[左箱]-3	圆头螺帽-3	类别	连接零件
气缸体	类别	箱体零件	螺栓[右箱]-3	使用工具	T 型套筒扳手
螺栓[左箱]-2	前序零件	换挡摇臂-1	圆头螺帽-1	功能	用于连接气缸头盖罩、垫片与气缸头等
密封[气缸头盖罩]	功能	用于密封气缸头盖罩	螺栓[左箱]-5	前序零件	时规链条
螺栓[左箱]-7	功能	用于连接左侧箱体，注意螺栓长度与孔的对应关系	螺栓[左箱]-2	类别	连接零件
螺栓[右箱]-5	使用工具	T 型套筒扳手	十字螺钉[定子总成]-1	功能	用于连接定子总成与箱体

附录

头实体	关系	尾实体	头实体	关系	尾实体
十字螺栓[缸体连接]-2	使用工具	十字螺丝刀	螺栓[左箱]-4	前序零件	定子总成
换挡摇臂-2	前序零件	箱体组合[右侧]	弹簧[张紧]	功能	用于张紧杆组所用弹簧。
离合器齿轮外套	类别	功能	推杆[离合器]	前序零件	箱体组合[右侧]
普通垫片-2	使用工具	徒手	推杆[离合器]	类别	其他零件
用于与定子总成配合发电	类别	功能	螺栓[左箱]-6	前序零件	箱体组合[右侧]
螺栓[左箱]-1	前序零件	时规链条	离合器	使用工具	徒手
用于连接右侧箱体， 注意螺栓长度与孔的 对应关系	类别	功能	主动齿轮[离合器]	类别	传动零件
飞轮转子	使用工具	磁电机拿子 用于承接离合器传递的传 动，并将动力传递给变速机 构	箱体组合[右侧]	前序零件	螺栓[右箱]-3
从动减速齿轮	功能	其他零件	飞轮转子	功能	用于与定子总成配合发电
右侧盖[气缸头]	类别	其他零件	轴套[离合器]	功能	离合器用轴套
弹性挡圈[从动减速 齿轮]	使用工具	卡簧钳	箱体组合[右侧]	前序零件	螺栓[右箱]-7