

DOI: 10.3901/JME.2021.05.090

知识图谱在智能制造领域的研究现状 及其应用前景综述*

张栋豪¹ 刘振宇¹ 郑维强^{1,2} 刘 惠¹ 谭建荣¹

(1. 浙江大学计算机辅助设计与图形学国家重点实验室 杭州 310027;

2. 信雅达系统工程股份有限公司浙江省重点大数据研究院 杭州 310053)

摘要: 数据和知识是新一代信息技术与智能制造深度融合的基础。然而, 当前产品设计、制造、装配和服务等过程中, 数据及知识的存储大多以传统关系型数据库为基础, 这导致了数据及知识的冗余性和搜索及推理的低效性。近年来, 知识图谱技术飞速发展起来, 它本质上是基于语义网络的思想, 可以实现对现实世界的事物及其相互关系的形式化描述。该技术为智能制造领域数据及知识的关联性表达和相关性搜索推理问题的解决带来了可能性, 因此其在智能制造的实现过程中扮演着越来越重要的角色。为了给知识图谱在智能制造领域的应用提供理论支撑, 总结了知识图谱领域的研究进展; 同时探索了知识图谱在智能制造领域的 3 大类应用方向, 共 15 小类应用前景, 分析了在各个应用前景上与传统方法的不同之处, 应用过程中所需要使用的知识图谱相关技术以及实施过程中所待突破的关键技术, 希望可以为进一步展开针对知识图谱在智能制造领域的研究提供启发, 同时为相关企业针对知识图谱的实际应用提供参考; 最后以数控机床故障分析为案例, 验证了知识图谱在智能制造领域应用的有效性。

关键词: 知识图谱; 研究综述; 语义网络; 智能制造

中图分类号: TP301

A Review on Knowledge Graph and Its Application Prospects to Intelligent Manufacturing

ZHANG Donghao¹ LIU Zhenyu¹ JIA Weiqiang^{1,2} LIU Hui¹ TAN Jianrong¹

(1. State Key Laboratory of CAD&CG, Zhejiang University, Hangzhou 310027;

2. Key Research Institute for Big Data of Zhejiang Province, Sunyard System Engineering Co., Ltd., Hangzhou 310053)

Abstract: Data and knowledge are the basis for the deep integration of new-generation information technology and intelligent manufacturing. However, the storage of data and knowledge in the processes of product design, manufacturing, assembly and service is mostly based on relational database, which brings data redundancy and inefficiency of searching and reasoning. Recently, knowledge graph technology, based on the idea of semantic network, has developed rapidly. It can achieve the description of real-world things and their relationships, which provides a mean for the correlation representation of data and knowledge, and a solution of the relevance searching and reasoning problem in the area of intelligent manufacturing. Therefore, it plays an increasingly important role in the realization of intelligent manufacturing. In order to provide the theoretical support for the application of knowledge graph, a review about the research status of knowledge graph is provided. At the same time, three major applications of knowledge graph in the area of intelligent manufacturing are explored, including a total of 15 small application prospects. Among them, the differences compared with traditional methods, the knowledge graph technology to be introduced and the key technologies to be breakthrough are detailed. It is hoped that it can provide inspiration for researchers to further carry out study on the knowledge graph in the area of intelligent manufacturing, and provide reference for mechanical companies on the application of knowledge graph. Finally, a case

* 国家自然科学基金(51935009, 51805473)和浙江省重点研发计划(2021C01008) 资助项目。20200315 收到初稿, 20200918 收到修改稿

about the lathe failure analysis is used to verify the superiority of the knowledge graph in the area of intelligent manufacturing.

Key words: knowledge graph; literature review; semantic network; intelligent manufacturing

0 前言

物联网、云计算、人工智能等新一代信息技术的迅猛发展,带来了制造业的新一轮突破,推动着制造系统向智能化方向发展,驱动着未来制造模式的创新^[1]。其中数据和知识是实现制造业与新一代信息技术融合的基础,是实现智能制造的保障。一方面,产品在其生命周期的各个阶段将会产生海量工业数据和知识^[2];另一方面,工业数据和知识是制造领域的信息化进程的必备资源,其中蕴含了大量有用的模式。然而,当前制造领域产品设计、制造、装配、服务等生命周期过程中数据以及知识的存储大多以传统关系型数据库为基础,冗余性较高、分布分散、关联性较弱且储量相对较小,强调对数据以及知识的检索却较少从语义层面研究数据以及

知识的关联、认知、理解与推理。因此,如何从冗余的数据与知识文本中抽取有用信息,如何有效表达数据之间的内在关联与知识之间的内在关联,如何有效利用数据的关联性与知识的关联性实现高效的信息检索与信息推理,是当前实现智能制造目标的核心瓶颈之一。

知识图谱(Knowledge graph, KG)来源于谷歌下一代智能语义搜索引擎技术。其本质上基于语义网络的思想,是一种有向图结构的语义知识库,用于以符号形式描述物理世界中的概念及其相互关系^[3],其应用服务架构如图 1 所示。在知识图谱内部,数据和知识的存储结构为三元组,形如 $\langle s, p, o \rangle$ 或 $p(s, o)$, 其中 s 和 o 为知识图谱中的节点,分别代表了主语实体知识和宾语实体知识, p 为知识图谱中的边,代表了从 s 指向 o 的关系知识(谓语)。




图 1 基于知识图谱的应用服务架构

知识图谱具有如下 3 种特点：① 数据及知识的存储结构为有向图结构。有向图结构允许知识图谱有效地存储数据和知识之间的关联关系；② 具备高效的数据和知识检索能力。知识图谱可以通过图匹配算法，实现高效的数据和知识访问；③ 具备智能化的数据和知识推理能力。知识图谱可以自动化、智能化地从已有的知识中发现和推理多角度的隐含知识。

目前,知识图谱技术已经在互联网领域如搜索

引擎、智能问答等发挥了重要作用,同时也已经在多个领域进行初步应用,比如:金融、电商、医疗等^[4]。许多国际著名企业也已经开始探索知识图谱的应用,比如谷歌、微软、IBM、苹果等。与此同时,在智能制造领域,西门子于 2018 年提出了他们在知识图谱领域的规划^[5];博世公司于 2019 年构建了底盘系统控制相关数据的大型知识图谱,以提供有效地数据访问^[6]。然而国内的机械行业针对知识图谱的探索却有些许不足。在研究过程中以及与多

家机械相关企业的交流中发现,当前知识图谱在智能制造领域应用过程还存在以下不足。

(1) 缺乏对知识图谱理论的深入认识。目前知识图谱相关理论与技术在迅速发展,但是智能制造领域的专家大多对该技术缺乏深入的了解,无法有效管理和应用知识图谱中的数据及知识。

(2) 知识图谱相关技术在智能制造领域的优势不明晰。目前知识图谱在智能制造领域的应用处于起步阶段,针对产品设计、制造、装配、服务等过程所带来的优势不是很明确,且在知识图谱应用于智能制造领域过程中可能遇到的问题尚不明确。

(3) 知识图谱相关技术在智能制造领域的应用场景模糊。当前企业对知识图谱在智能制造领域的应用前景有所疑问,不确定知识图谱技术在产品设计、制造、装配和服务等过程的切入点和切入方式。

(4) 知识图谱在智能制造领域落地所需要的技术不明确。目前在通用领域上的知识图谱的研究角度十分广泛,但是针对智能制造领域各个应用场景,所需要使用的知识图谱相关技术类别却还不是很明晰。

(5) 智能制造领域相关数据缺乏。目前基于深度学习的知识图谱相关技术需要构建一定量的有标签数据集,目前通用领域的相关数据集比较多,而智能制造领域的相关数据却比较缺乏。

针对以上问题,本文总结了可以应用于智能制造领域的知识图谱技术的研究进展。同时从应用出发,探索了知识图谱在智能制造领域的 3 大类应用方向,共 15 小类应用前景,分析了在各个应用前景上与传统方法的不同之处,应用过程中所需要的知识图谱技术以及实施过程中所待突破的关键技术,为后续知识图谱在智能制造领域的进一步落地提供理论支撑和方法参考。

1 智能制造领域知识图谱研究进展

谷歌在 2012 年最早提出了知识图谱的概念^[7],当时主要用于从多来源数据中增强搜索引擎的结果。与传统的关键词匹配搜索相比,基于知识图谱的语义搜索可以更好地理解用户的问题,提供更加简明的搜索结果^[8],如图 2 中所示的谷歌关于“3D 打印”的搜索结果。图中可以看到,搜索界面不止返回了与 3D 打印相关的页面链接,更重要的是在知识图谱的帮助下在侧边栏显示了各个打印技术的发明时间、3D 打印公司以及 3D 打印材料等关联信息。用户可以根据这些信息快速定位到自己的

搜索目标,同时也可以拓展了解技术的更多相关信息。自从知识图谱提出以后,各种基于知识图谱的知识库迅速发展,如 Freebase^[9]、Wikidata^[10]、DBpedia^[11]等。但是上述这些知识库中所存储的均是通用领域的知识,当前针对智能制造领域的知识图谱型知识库依然十分缺乏。




图 2 关于 3D 打印技术的谷歌搜索结果

智能制造领域的知识图谱型知识库可以用于表达智能制造领域数据和知识的属性以及数据和知识之间的内在关联。智能制造领域知识图谱与通用领域知识图谱在架构上基本相同,不同之处在于其还具有以下 4 点特性:① 存储智能制造领域数据与知识:其中存储了产品设计过程、工艺过程、加工过程等产品全生命周期的数据与知识;② 面向智能制造领域应用场景和问题:以提高产品设计和生产过程的效率和质量为目标,处理产品全生命周期遇到的问题;③ 可解释性及精度要求高:可解释性要求便于人类专家对其推理结果进行验证和理解,而其精度影响了企业各个制造任务的运作效率和质量;④ 资源少且专属性强:难以从网上获取大量的数据及知识,主要根据制造企业的特点及企业自身积累的数据与知识,构建专属的知识图谱。

由于知识图谱具有强大的知识表示和推理能力,该技术在提出后迅速获得学术界和业界的广泛关注。当前智能制造领域知识图谱的相关研究主要集中在五大方面,分别是:智能制造领域知识的形式化表达方法、智能制造领域知识图谱的自动构建技术、智能制造领域知识推理技术、智能制造领域问答技术及智能制造领域个性化推荐技术。下面将简要介绍上述技术的研究进展,为后续智能制造领域应用前景的探索提供参考。

1.1 智能制造领域知识的形式化表达方法

将知识图谱技术应用到智能制造领域中,首先

需要实现领域知识的形式化表达,即在多模态数据要求下实现机器可以理解的知识表达方式。在智能制造领域知识的形式化表达方向中,所涉及的关键技术手段包含了谓词逻辑知识表示方法^[12]、框架式知识表示方法^[13]、基于语义网络的知识表示方法^[14]、基于本体的知识表示方法^[15]等。相比较而言,基于本体的知识表示方法能够保证知识传递和共享过程中知识理解的唯一性,可以满足知识类型多样、语义关系复杂的要求,已成为智能制造领域知识表示的主要方法之一^[16]。知识图谱作为本文的重点分析对象,也是以本体作为模式层的知识表达与存储方法,其利用本体所定义的概念和关系的形式化描述,表征实例化后实体的类型与实体之间的关系。

目前基于本体的智能制造领域知识表示方法的代表性工作有:针对产品设计过程知识和制造过程知识,CHHIM 等^[17]发展了联合两类知识的本体,并尝试将其应用于知识重用过程;针对工艺设计知识,郭鑫等^[15]考虑工艺知识特点及领域范围,提出基于本体的工艺知识管理逻辑架构;针对制造业领域全生命周期知识,刘航等^[18]基于本体提出多层次、多维度的知识表达模型,实现制造业领域知识结构化、维度化的表示;针对协同设计知识,BOCK 等^[19]探索了结合本体和基于模型技术进行协同设计的方法。

可以看出,当前基于本体的智能制造领域知识表示方法获得了广泛的研究,研究范围涉及到了设计过程、制造过程等多维度的本体的创立,为后续知识图谱的自动构建提供了基础。在企业实际应用中,可以以现有学者构建的本体作为基础,以提高企业知识本体构建的效率。然而,现有研究中所构建的本体往往细节度不高,应用过程需根据实际的企业需求进行拓展。

1.2 智能制造领域知识图谱的自动构建技术

在智能制造领域知识图谱自动构建过程中,所涉及到的关键技术有:命名实体识别、关系抽取、实体对齐等。其中命名实体识别用于从智能制造领域非结构化的文本中抽取到预定义的本体所实例化的实体;而关系抽取用于抽取智能制造领域非结构化文本中所蕴含的实体对在本体中定义的关系类别。通过上述两个技术方法,可以自动化地以管道式的方式构建智能制造领域知识图谱三元组。然而由于实际智能制造领域知识图谱的构建过程很可能会产生多个知识图谱(如产品设计知识图谱、设备故障知识图谱、工艺过程知识图谱等),为了实现多个知识图谱之间的融合推理,还需要引入实体对齐技

术。下面将简要介绍这三个细分领域的常见步骤以及代表方法,以为后续企业应用过程中选择合适的方法提供参考。

1.2.1 命名实体识别

基于深度学习的命名实体识别方法一般而言,首先使用词嵌入算法^[20],将语句中的词组表示为低维稠密矢量;而后使用深度神经网络编码语句的上下文信息;最终解码上下文信息获取每一个词组的序列标签。

其中具有代表性的工作有:HUANG 等^[21]提出了使用双向长短期记忆网络(Bidirectional long short term memory, Bi-LSTM)编码语句的上下文信息,而后使用条件随机场(Conditional random field, CRF),限制输出序列的连接形式,其模型结构如图 3 所示(图中采用 BIO 标注方法);QIU 等^[22]使用空洞卷积加强模型对语句上下文信息的编码能力,同时提升模型的运行速度;YAN 等^[23]改进 Transformer 模型,引入相对距离驱动的注意力机制,提高 Transformer 模型在命名实体识别中的表现。在智能制造领域,刘宇飞等^[24]将迁移学习技术应用至数控系统领域专业文献的命名实体识别过程,解决了专利文献少标注的问题。




图 3 Bi-LSTM-CRF 模型

可以看出,该领域已经取得了一定的进展,且已经在多种语言和多种场景上进行应用,这将有助于后续实现精确化的智能制造领域知识图谱的自动构建以及用户问句的语义解析。然而智能制造领域相关数据缺乏,需要更加深入地发展基于无监督学习、半监督学习与迁移学习的命名实体识别技术。

1.2.2 关系抽取

目前基于深度学习的关系抽取技术中,研究最广泛的便是基于远程监督假设的关系抽取技术。远程监督假设最早是由 MINTZ 等^[25]提出,它假设当两个实体存在关系,则同时包含这两个实体的语句均表征了该实体对的该关系的部分信息。因此,可以使用所有包含这两个实体的文本语句来学习该关

系的内在模式。基于远程监督假设的关系抽取技术能够以很小的成本获得大量的关系抽取数据,可以限制关系类别空间,还能够降低部分数据噪声。

该类型方法的代表性工作有: ZENG 等^[26]提出使用卷积神经网络获取词汇与语句级别的信息,而后实现实体之间关系类别的预测,图 4 展示了文中上下文信息的编码方式; SOROKIN 等^[27]使用了长短期记忆网络联合编码一个句子中的多个实体对之间的关系,实现多实体对的关系预测;为了引入多粒度的语言信息以及外部的语言知识, LI 等^[28]提出了多粒度晶格框架,实现了中文文本的关系抽取任务;为了强化上下文信息的编码过程, BILAN 等^[29]将自注意力机制引入到关系抽取任务。在智能制造领域, LENG 等^[30]依据大量制造关系的社交交互上下文,帮助决策者抓住跨企业制造业需求能力匹配的决策支持信息。




图 4 卷积神经网络上下文信息编码

可以看出,目前存在大量学者在该领域研究,以提高模型在该任务上的表现或拓展该领域的应用场景。当前该领域已经获得了一定的进步,为后续知识图谱自动构建与用户意图分析打下了良好的基础。然而智能制造领域对关系抽取的精确性要求以及相关数据集标注成本,对现有研究中的数据噪声^[31]、长尾关系^[32]等问题的解决提出了更高的要求。

1.2.3 实体对齐

当前基于深度学习的实体对齐技术主要为基于知识图谱嵌入的实体对齐技术,该技术可以同时考虑实体表面字符串的相似度、知识图谱中实体的分布相似度以及实体在多语境情况下的语义相似度。

其中代表性的工作有: CHEN 等^[33-34]首先为每个知识图谱计算嵌入,然后使用一组对齐实体的较小种子集来计算多语言知识图谱的过渡矩阵,为每个嵌入的跨语言对应对象提供过渡; ZHU 等^[35]提出了一种通过联合嵌入进行实体对齐的迭代方法,将实体和各个关系编码到统一的低维语义空间,其对齐计算方式如图 5 所示; SUN 等^[36]提出了一种基于嵌入的实体对齐的自举方法,迭代地将可能的实体对齐标记为训练数据,以学习面向对齐的知识图谱

嵌入; CAO 等^[37]将图卷积神经网络与注意力机制引入实体对齐任务中,用于获取表征知识图谱中实体分布的相连实体的重要性权重。




图 5 统一低维语义空间实体对齐方法

可以看出,当前基于深度学习的实体对齐技术主要关注于多语言环境下知识图谱的实体对齐技术,对多领域环境下知识图谱的实体对齐技术研究相对较少。而在智能制造领域知识图谱的构建与融合过程中,更加常见的是多领域环境的情况。相比于多语言环境,多领域环境下实体的分布将更加多变,对实体对齐技术提出了更高的要求。

1.3 智能制造领域知识推理技术

目前大部分的知识图谱都是由人工或者半自动方式构建,知识图谱内无法包含所有的知识,大量实体之间的隐含关系没有被充分挖掘出来^[38]。与此同时,知识图谱中还隐式表征了实体关系之间所具有的逻辑规则。为了充分挖掘和利用智能制造领域知识图谱结构数据中所蕴含的隐式知识,智能制造领域知识推理技术逐步发展起来。该技术包含了知识图谱补全技术以及逻辑规则推理技术,旨在根据已有的知识推理出新的知识或识别错误的知识^[39]。

1.3.1 知识图谱补全

由于从智能制造领域非结构化文本中抽取得到的知识图谱存在实体或关系缺失现象,知识图谱补全技术迅速发展起来。知识图谱补全涉及到链接预测与节点分类^[38]。如图 6 所示,链接预测技术主要用于依据实体在智能制造领域知识图谱中的分布情况,推断两个实体之间存在的隐含关系;而节点分类主要用于给定智能制造领域知识图谱中的主语实体与关系,推断出在知识图谱中对应的宾语实体。在实际操作中,链接预测与节点分类的方法十分类似,通常将头尾实体和关系嵌入到一个低维的向量空间,而后使用深度神经网络训练一个评分模型,给出每个三元组在该知识图谱中出现的置信度。




图6 链接预测技术实例

目前知识图谱补全的代表性工作有：BORDES等^[40]提出了 TransE 算法，它通过对实体的低维嵌入进行转换来对关系进行建模，可以扩展到非常大的数据库；针对 TransE 算法无法处理自反、一对多、多对一和多对多映射关系，WANG 等^[41]提出了 TransH 算法，将关系建模为超平面；KIPF 等^[42]提出一种基于变分自动编码器的无监督学习图结构化数据的框架，能够学习无向图的可解释潜在表示，而后使用图卷积网络编码器和简单的内积解码器实现链接预测；CAI 等^[43]引入了对抗性学习框架，使用一个知识图嵌入模型作为负样本生成器来协助训练所需模型。在智能制造领域，陈继文等^[44]综合利用本体概念自身的语义和概念间的层次结构，研究基于本体语义块相似性匹配的设计知识更新方法。

从上述文献可以看出，知识图谱补全技术的相关研究已经取得了一定的进展，可以应用于智能制造领域的知识发现、知识更新等过程。然而，智能制造领域对新知识的可验证性和领域知识图谱的动态更新要求，需要知识图谱补全技术继续发展其可解释性^[42]和可扩展性^[45]。

1.3.2 逻辑规则推理

逻辑规则推理主要用于推理出智能制造领域知识图谱中实体之间的关系逻辑规则传递方式，其目的是发现知识图谱中蕴含的规则、推断新的三元组或验证已有三元组的正确性。一般而言，逻辑规则推理技术推理出的知识图谱中的每个规则包含了一个头(H)和一个体(B)，其表示了体中的原子(原子表示知识图谱中的一个三元组，其中两个实体的位置使用变量代替)联合起来($B = \wedge_i B_i(\cdot, \cdot)$)可以推理出头中的原子($B \Rightarrow H$)，比如“子部件(p, c) $\wedge$ 连接于(p, s) $\Rightarrow$ 连接于(c, s)”，表示若 p 是 c 的子部件且 p 连接于 s ，则 c 连接于 s 。在实际使用规则时，需要将规则进行实例化。

目前该领域的代表性工作主要有：GALÁRRAGA 等^[46]提出了不完整证据下的关联规则挖掘系统，并在后续工作中对此方法进行优化，使其适应于大规模的知识图谱^[47]；TANON 等^[48]针对不完整知识图谱的规则挖掘，引入了表征知识

图谱中事实数目的元数据，用于学习知识图谱中边的数量规则；在后续工作中，他们引入了知识图谱嵌入以及文本语料库来迭代拓展知识图谱产生的规则^[49]；YANG 等^[50]提出了神经逻辑编程框架，实现了端到端的一阶逻辑规则的参数和结构学习；SADEGHIAN 等^[51]也提出了一种完全可微的模型来同时学习知识图谱中的逻辑规则结构以及规则结构相关的置信度得分。

可以看出，当前逻辑规则推理的研究已经取得一定的进展，可以应用于智能制造领域的知识发现、知识验证等过程。然而，当前针对完全可微的逻辑规则推理系统的研究才刚刚起步，而且针对高阶逻辑规则的推理技术还是一个未知的领域。

1.4 智能制造领域问答技术


智能制造领域问答技术以自然语言问句为输入，从智能制造领域知识图谱中查询到相应的答案，并以文本的形式返回给用户^[52]。目前该领域的方法可以分为两类：基于信息检索的问答技术^[53-54]与基于语义解析的问答技术^[55-56]。虽然存在部分学者探索基于信息检索的问答技术，尝试以端到端的方式实现自然语言问句到目标答案实体的推断，但是该技术目前难以处理多约束、多类型的复杂问句，因此主要综述基于语义解析的问答技术。

基于语义解析的问答技术是一种管道式的方法。首先需要对用户的查询问句进行语义解析，获取查询对象、对象约束与用户意图，而后根据查询对象、约束之间的关联关系形成查询图。最后使用查询图与知识图谱进行匹配和推理，获取并推送给用户所需要的知识。其中涉及到的关键技术有：命名实体识别(用于获取查询对象以及约束对象的字符串表达)、实体链接、语义解析、图匹配算法(用于将查询图与知识图谱进行匹配，获取最终答案实体)、文本生成算法(以答案实体、知识图谱与用户问句作为条件，生成易于理解的文本返回给用户)。其中命名实体识别技术已经在前面介绍，图匹配算法目前主要依据语义解析后生成的 SPARQL 语句进行实现，文本生成算法对获取知识的准确性没有影响，因此本章节主要介绍实体链接技术以及语义解析技术。

1.4.1 实体链接

如图7所示，实体链接技术用于将语句中的实体的字符串表达映射到知识图谱中的形式化表达。由于每个实体都可能存在多种字符串表达，同时多个实体可能含有相同的字符串表达，因此在映射过程中不能只考虑字符串的相似度，还需要从语义、

上下文、知识图谱中实体的分布等多种角度考虑。



该技术的代表性工作有：MILNE 等^[57]使用词意的普适性、上下文关系和上下文质量这三种特征训练一个分类器，用于给候选集中的实体排序；VALENTIN 等^[58]构建了一个标志了相关实体对的词典，而后使用了实体相关文本、概念以及维基百科的链接实现实体链接；YANG 等^[59]将实体链接建模成结构学习任务，并提出了结构化多元加性回归树模型用于结构预测，最终获得了最优的实体链接结果。在智能制造领域，任朝淦等^[60]提出了基于注意力机制的编码器-解码器问句实体链接模型，将实体文本表述链接到汽车领域知识图谱中的实体。

可以看出，当前实体链接技术获得了广泛的研究。在应用至智能制造领域的基于知识图谱的问答系统的构建时，可以选用召回率高的算法，初步减少推理路径的搜索空间，而后在语义解析过程中获得精确的预测结果。然而实体链接的准确率是智能制造领域问答系统的准确率的基础，因此如何利用知识图谱中的更加详细的信息(如实体类型信息、隐关系信息^[61]等)将成为其后续的研究方向之一。

1.4.2 语义解析

语义解析主要用于分析语句中实体之间的关系，集成实体的约束以及聚合函数，形成查询图，以便于后续的答案的搜索。

该类型技术是目前应用比较广泛的基于知识图谱的问答技术，其中代表性的工作有：BAO 等^[62]提出了一种基于约束的复杂问句问答系统，通过识别查询语句中的预先设定的约束类型，生成查询图(图 8 展示了智能制造领域某一问句的查询图，其中问句为“CJK6130 数控车床中的最大直径的齿轮所连接的法兰的型号是多少？”， x 为答案变量， y_1 、 y_2 和 y_3 为中间变量。)，而后使用一些相似度评估方法获得最佳查询图；HU 等^[63]提出了一种基于状态转移的复杂问句问答系统，根据定义的状态转移条件以及对应的状态转移动作迭代获得查询图，以最大化一个奖励函数，获得查询图的实体或关系候选集；ABUJABAL 等^[64]提出了一种基于模板的复杂问

句问答系统，实现了复杂问句查询模板的迭代更新。在智能制造领域，徐荣振等^[65]对其所构建的产品设计案例本体进行解析，建立数据库关系模式与本体之间的映射关系，并利用该映射关系自动生成数据库查询语句，对源数据库进行查询。




图 8 问句语义解析得到的查询图

从中可以看出，当前基于语义解析的问答技术已经展开一定的研究，这些研究有助于后续智能制造领域的面向用户、面向专家、面向管理的问答系统的构建，以更好地利用企业积累下来的产品信息知识、设计知识、企业条例知识等数据及知识。然而智能制造领域问答系统所要求处理的数据及知识查询问句十分复杂，需要在后续研究中更加关注多模态、多约束、多类型、多跳问答系统的构建技术。

1.5 智能制造领域个性化推荐技术

将知识图谱引入智能制造领域推荐系统可以获得更多的语义信息，可以更深层的挖掘用户兴趣与产品相关性，同时可以为推荐过程提供可解释性，从而提高用户对推荐结果的满意度和接受度。当前基于知识图谱的个性化推荐技术主要分为三大类：基于特征的个性化推荐技术、基于路径的个性化推荐技术以及基于知识图谱嵌入的个性化推荐技术。其中基于特征的个性化推荐技术^[66]主要从知识图谱中抽取一些用户和产品的属性及相关性特征，而后送入机器学习模型中进行训练。该方法无法深入的挖掘知识图谱的三元组结构所带来的图结构数据的优势，无法高效利用用户实体和产品实体的关系传递路径、实体节点分布等所蕴含的隐式信息。因此，此处主要综述基于路径的个性化推荐技术以及基于知识图谱嵌入的个性化推荐技术。

1.5.1 基于路径的个性化推荐技术

基于路径的个性化推荐技术将知识图谱视为一个异构信息网络，而后构建用户与物品实体之间的链接路径，从而获得用户与物品之间的相关性度量。

其中的代表性工作有：YU 等^[67]提出了个性化实体推荐模型，引入了元路径的概念，用于表征知识图谱中两个实体之间的潜在关系模式；相比于元路径对两个实体之间结构的序列限制，ZHAO 等^[68]引入了元图的概念，其对两个实体之间的连接结构不做限制，可以获得知识图谱中更加丰富的语义信息；朱桂明等^[69]以用户在知识图谱中的历史访问项

目为偏好起点,通过知识图谱中实体间的关系链接传播用户偏好,学习用户的潜在偏好。

可以看出,基于路径的个性化推荐技术需要手动设计元路径或元图,在实践中很难获得最优的表现,且模型的领域之间的泛化能力也很有限。

1.5.2 基于知识图谱嵌入的个性化推荐技术

基于知识图谱嵌入的个性化推荐技术主要利用知识图谱嵌入的信息,自动学习知识图谱中实体与关系的特征矢量,随后进一步结合推荐系统中的用户矢量与物品矢量,实现精确化推荐。

该类型技术的代表性工作有:WANG 等^[70]提出了依次学习的架构,首先使用知识图谱特征学习得到实体矢量和关系矢量,然后将这些低维矢量引入推荐系统,使用卷积神经网络融合多通道的矢量,学习得到用户矢量和物品矢量;ZHANG 等^[71]提出了联合学习的架构,将结构化知识学习、文本知识学习与图像知识学习的目标函数与推荐系统协同过滤的目标函数相结合,使用端到端的方法进行联合学习;类似地,WANG 等^[72]沿用联合学习的架构,模拟了用户兴趣以历史记录中的实体为中心向外扩散且逐渐衰减的过程,从而实现多跳响应的计算;WANG 等^[73]在后续工作中又提出了交替学习的架构,将知识图谱嵌入学习和推荐算法视为两个分离但又相关的任务,使用多任务学习的框架进行交替学习,以利用两个任务的互补信息。

可以看出,如何更好地引入知识图谱中的知识到推荐系统中为目前的主要研究方向。同时该技术的应用领域还比较局限,主要应用于电商、旅游等领域,还需要研究人员将该领域的技术拓展到更加多样化的应用场景中,如智能制造、医疗等领域。

2 知识图谱在智能制造领域应用探索

基于上述知识图谱的理论研究总结,本章节将进一步探索知识图谱在智能制造领域的应用前景,并分析其与传统方法的不同之处、应用过程中所需要使用的知识图谱技术以及实施过程中待突破的关键技术等,尝试为知识图谱在智能制造领域的应用提供参考和启发。

2.1 面向企业客户的智能制造知识图谱应用

面向企业客户的智能制造知识图谱应用是指针对企业客户提供服务的知识图谱应用。此处探索了 2 种该类型的应用:基于知识图谱的产品推荐和基于知识图谱的专家检索。

2.1.1 基于知识图谱的产品推荐

产品推荐是指利用用户的属性信息、历史点击购买评价信息、产品的属性信息等数据,分析目标用户的兴趣点,并按照用户的兴趣实现个性化产品推荐,以实现制造企业产品与用户群的精确匹配,提高企业产品的销售量。与传统的推荐系统相比,基于知识图谱的产品推荐可以建立用户之间、产品之间、用户与产品之间的关联,一方面易于挖掘相似度高的用户群体与产品群体,实现精确推送;另一方面便于处理系统冷启动的情况。

基于知识图谱的产品推荐系统的结构与流程如图 9 所示。与传统产品推荐相比,基于知识图谱的产品推荐主要有以下几点转变。




图 9 基于知识图谱的产品推荐系统的结构与流程

① 信息完备度:基于知识图谱的产品推荐可以引入传统产品推荐系统所不具备或需要深入挖掘的关键知识,比如:用户之间的关系、产品之间的关系、产品介绍文本中包含的实体信息等;② 用户和产品的矢量表达:基于知识图谱的产品推荐可以通过分析知识图谱中每个实体的分布情况和语义信息,产生表达用户和产品的低维稠密矢量,从而降低由于矢量维度过高而造成的数据需求量大的情况,且更有助于模型的学习过程;③ 推荐矫正:当用户对系统推荐的产品标注感兴趣或不感兴趣时,系统可以自主推断出该产品相关联的其他产品,以更加精准地向用户扩展推荐关联产品或停止推荐关联产品。

现有的知识图谱相关研究可以尝试应用于基于知识图谱的产品推荐过程,比如:智能制造领域知识图谱的自动构建技术以及智能制造领域个性化推荐技术。主要应用于构建用户信息、产品信息以及相互之间的关联关系的产品推荐知识图谱,以及基于知识图谱的用户与产品的精确匹配。

然而,基于知识图谱的产品推荐尚需在以下几

个方面进行突破:① 图嵌入算法:包括融入除分布以外的多种信息(如实体类别、约束信息)的图嵌入算法,以及引入知识图谱结构随时间变化的动态图嵌入算法;② 社区发现算法:用于发现知识图谱中联系紧密的节点,有助于发现具有相似特征的用户群与相似特征的产品群;③ 多模态知识图谱的推荐系统:在推荐过程中引入产品的图片信息、视频信息等多模态信息,以提高产品推荐的准确度。

2.1.2 基于知识图谱的专家检索

专家检索是指针对用户对产品的售前或售后问句,匹配到合适的专家人员予以解答,以提高用户的满意度。基于知识图谱的专家检索一方面可以对用户的问句进行语义解析,预测问句所需的专业技能;另一方面使用知识图谱描述专家的属性信息与关联关系,易于推理用户问句所匹配的专家集合。

基于知识图谱的专家检索系统的结构与流程如图 10 所示。与传统专家检索相比,基于知识图谱的专家检索主要有以下几点转变:① 自主性:用户可以根据检索出的相关专家以及可视化展示的专家之间的关系和专业技能,自主地进行选择;② 问题处理效率:相比于传统售前或售后人工服务,基于知识图谱的专家检索系统可以根据用户的文本问题个性化匹配具有相关领域知识的专家,以更有效率地解答用户的问句;③ 专家积极性:基于知识图谱的专家检索系统可以更加透明化地向用户展示专家的评价情况与工作状态,激励专家提供更好地服务。




图 10 基于知识图谱的专家检索系统的结构与流程

现有的知识图谱相关研究可以尝试应用于基于知识图谱的专家检索过程,比如:智能制造领域知识图谱的自动构建技术、智能制造领域问答技术以及智能制造领域个性化推荐技术。主要应用于构建专家信息知识图谱、针对用户问句的语义解析以及基于专家信息知识图谱和解析后的问句的专家搜索。

然而,基于知识图谱的专家检索尚需在以下几个方面进行突破:① 多社区资源整合:包括企业内部专家信息整合以及公共社区论坛专家信息整合,以提供给用户多种选择;② 细粒度情感分析算法:

针对用户的评价,分析用户对产品、专家的服务、问题解答效率等方面的情感状态,帮助企业更好地把控市场和评估员工;③ 多模态文本的语义解析:针对用户所提出的问题中包含图片的情况,实现图片与产品实体的对齐以及用户问句的多模态解析。

2.2 面向领域专家的智能知识图谱应用

面向领域专家的智能知识图谱应用是指为智能制造领域专家提供服务的知识图谱应用。此处探索了 10 种该类型的应用:基于知识图谱的知识发现、基于知识图谱的知识重用、基于知识图谱的设计方案生成、基于知识图谱的过程监控、基于知识图谱的质量分析、基于知识图谱的故障分析、基于知识图谱的数字孪生、基于知识图谱的人机协同与交互、基于知识图谱的物流配送、基于知识图谱的智慧工厂。

2.2.1 基于知识图谱的知识发现

知识发现有两层含义:一方面指从非结构化文本数据中提炼出潜在的有效新知识;另一方面指在已有知识基础上,挖掘出以往未得到的新知识。与传统知识发现相比,基于知识图谱的知识发现系统主要应用知识发现相关技术实现知识图谱的自动构建、知识更新以及知识推理。由于基于知识图谱的知识发现系统中知识的结构为图数据结构,因此该系统可以统一知识表达形式,可以便捷地根据知识实体之间的关系,自主推理出新的知识,还可以应用逻辑规则以及三元组置信度评估知识的合理性。

基于知识图谱的知识发现系统的结构与流程如图 11 所示。与传统知识发现相比,基于知识图谱的知识发现主要有以下几点转变:① 驱动方式:传统的知识发现主要由专家经验驱动,而基于知识图谱的知识发现转化为基于知识数据驱动;② 数据管理:数据由杂乱的非结构化文本数据转化为结构化的三元组数据,从而简化数据管理方式;③ 新知识类型多样化:基于知识图谱的知识发现不仅可以提炼非结构化文本数据中具有的知识,还可以挖掘知识实体之间的新的关系,以及知识图谱所蕴含的逻辑规则。




图 11 基于知识图谱的知识发现系统的结构与流程

现有的知识图谱相关理论研究可以尝试应用于基于知识图谱的知识发现过程,比如:智能制造领域知识图谱的自动构建技术以及智能制造领域知识推理技术。主要应用于从非结构化文本数据中抽取智能制造领域知识图谱构建过程所需要的知识实体与关系,智能制造领域知识图谱的知识实体之间缺失关系的补全以及智能制造领域知识图谱内逻辑规则的推理。

然而,基于知识图谱的知识发现尚需在以下几个方面进行突破:① 全流程知识管理:包括知识提炼、知识存储、知识图谱补全、逻辑规则推理、知识更新、知识的可视化展示;② 知识重要性评估:包含了关键知识的识别、关键知识的信息更新与推理以及无用知识的过滤;③ 半监督式的知识图谱构建技术以及基于知识图谱的半监督式的推理技术:可以用来降低智能制造领域数据集标注成本,同时规范化模型输出结果的搜索范围;④ 数据噪声:针对包括文本数据噪声以及知识图谱数据噪声的削弱与处理,以提高知识图谱的质量。

2.2.2 基于知识图谱的知识重用

由于同类产品的设计过程具有极大的相似性,设计过程知识通常可以在设计中直接进行复用^[74],类似地,工艺规划过程、维修过程等过程获取的知识也可以在后续相似过程中进行复用或指导。具体而言,知识重用通过分析评估当前设计需求、工艺规划、维修状态等与以往同类过程的相似度,进而利用以往同类相似度高的过程所积累的知识为当前过程提供服务,以提高当前过程的实现效率,并降低当前过程的成本。在传统知识重用过程中,知识的存储是使用非结构化的文本数据、表格、图片等数据,相比较而言,基于知识图谱的知识重用更加强调知识的存储结构为图结构。

基于知识图谱的知识重用系统的结构与流程如图12所示。与传统知识重用相比,基于知识图谱的知识重用主要有以下几点转变:① 多源数据融合:智能制造领域中,设计、制造和装配等过程的知识与数据往往存储在不同数据库中,数据的格式也不尽相同。知识图谱的引入,规范了各个数据库中的格式,同时在数据库之间建立了接口;② 多约束多类型非结构化文本语句查询:传统知识重用系统使用关键字搜索相关文本知识,知识的组织杂乱而没有关联性,且不易引入关键字的约束。知识图谱的引入,允许了针对多约束多类型非结构化文本语句查询的语义解析过程,同时增加了查询知识之间的关联关系展示,有助于专家更好地理解知识;③ 知

识获取高效性:传统的知识重用系统使用的是非结构化的文本数据存储相应的知识,这便要求专家人员自行规划查询的关键词。而知识图谱的引入,允许专家人员提供模糊的查询对象,而后通过知识之间的关联关系获取目标知识;④ 交互方式:传统的知识重用系统只可以展示使用关键词搜索得到的知识,而知识图谱的引入能以可视化的方式帮助专家获取当前知识的关联知识,从而协助专家以某一路径获得目标知识。




图12 基于知识图谱的知识重用系统的结构与流程

现有的知识图谱相关理论研究可以尝试应用于基于知识图谱的知识重用过程,比如:智能制造领域知识的形式化表达方法、智能制造领域知识图谱的自动构建技术、智能制造领域问答技术、智能制造领域个性化推荐技术。主要应用于智能制造领域知识图谱的自动构建、知识查询与问答以及知识的个性化推荐。

然而,基于知识图谱的知识重用尚需在以下几个方面进行突破:① 多源知识的形式化表达与存储:包括设计、工艺规划以及维修等过程产生的来自于不同数据仓库的数据及知识的统一表达、本体构建、命名实体识别、关系抽取以及实体对齐;② 多阶段设计过程知识的多粒度推送:包括概念设计阶段、方案设计阶段、详细设计阶段的针对不同阶段专家的不同粒度的设计知识推送;③ 模糊设计意图的语义解析:包括隐式设计意图以及复杂组合设计意图的语义解析过程;④ 复杂查询语句的语义解析:包括多约束查询语句、多类型查询语句以及多跳推理查询语句。

2.2.3 基于知识图谱的设计方案生成

设计方案生成是指是从用户需求出发寻求设计结果的问题求解过程^[75]。目前存在多种理论和方法

可以应用于产品设计方案生成,比如:公理化设计方法^[76]、质量功能展开方法^[77]、配置设计方法^[78]、产品族与模块化设计方法^[79]等。但已有的研究大多采用传统关系型数据库作为产品方案创新设计的基础,知识分布分散、关联性较弱且储量相对较小,强调对知识的检索却较少从语义层面研究知识的关联、认知、理解与推理。因此,需要发展基于知识图谱的设计方案生成技术。

基于知识图谱的设计方案生成系统的结构与流程如图13所示。与传统设计方案生成相比,基于知识图谱的设计方案生成主要有以下几点转变:①数据质量:传统的设计方案生成系统所依赖的数据存在不一致性和冗余性,而基于知识图谱的设计方案生成系统实现了设计知识的统一表达;②约束构建方式:传统设计方案主要依靠分布在电子表格中的历史产品配置信息,而配置之间的约束关系未知。基于知识图谱的设计方案生成系统可以以图结构的方式充分考虑产品配置之间的约束关系;③缺失约束信息识别:基于知识图谱的设计方案生成系统可以根据设计知识图谱中实体之间的连接约束关系,搜索需求文档中未定义的约束,让设计专家人员进行填充;④可解释性:基于知识图谱的设计方案生成系统可以通过设计方案生成过程的推理路径,向设计专家展示解决方案的推理流程。




图13 基于知识图谱的设计方案生成系统的结构与流程

现有的知识图谱相关理论研究可以尝试应用于基于知识图谱的设计方案生成过程,比如:智能制造领域知识的形式化表达方法、智能制造领域知识图谱的自动构建技术、智能制造领域问答技术。主要应用于设计知识图谱的自动构建、需求文档的语义解析、设计知识图谱的约束构建以及设计方案推理。

然而,基于知识图谱的设计方案生成尚需在以下几个方面进行突破:①全流程设计方案知识图谱构建:包括需求、功能、结构、配置等设计阶段的全流程知识图谱的构建;②数字离散推理^[80]:包括需求文档中的数字相关信息提取技术以及基于设

计知识图谱的数字离散推理技术;③设计方案的迭代优化:包括设计方案的性能评估,以及基于上一步生成的设计方案的迭代优化;④性能约束反求:将产品出厂时需满足的性能需求反求为产品在全生命周期中需要满足的性能需求与配置需求。

2.2.4 基于知识图谱的过程监控

过程监控是指依据生产过程中传感器数据的变化,对传感器进行关联分析,以合适地调整控制单元数值,达到降低生产过程产品的质量波动的目标。现有的过程监控方法使用多变量统计方法^[81]确定各工序的工艺参数控制范围。然而该类型方法随着变量数目的增加,会出现维度爆炸的情况。而基于知识图谱的过程监控可以将每个物理实体的传感器和控制单元数据,集成到知识图谱中,编码数据变量之间的依赖关系,从而缩小搜索空间,实现有效的过程监控。

基于知识图谱的过程监控系统的结构与流程如图14所示。与传统过程监控相比,基于知识图谱的过程监控主要有以下几点转变:①工艺变量与控制单元变量关联定义:基于知识图谱的过程监控系统使用图结构定义工艺变量、控制变量之间的关联关系;②异常搜索方式:基于知识图谱的过程监控可以依据知识图谱中定义的传感器之间的依赖关系,快速搜索定位异常工艺参数变量的所处位置;③控制粒度:基于知识图谱的过程监控可以精细化描述控制变量对工艺参数的影响,降低可控粒度,提高控制精度。




图14 基于知识图谱的过程监控系统的结构与流程

现有的知识图谱相关理论研究可以尝试应用于基于知识图谱的过程监控技术,比如:智能制造领域知识的形式化表达方法以及智能制造领域知识推理技术。主要应用于传感器和控制单元本体构建、过程监控知识图谱构建以及异常工艺参数搜索与推理。

然而，基于知识图谱的过程监控技术尚需在以下几个方面进行突破：① 边界评估：以知识图谱为核心，引入基于无监督学习的异常检测算法或基于监督学习的分类算法，以寻找精确鲁棒的正常样本边界；② 成本控制：合理评估调整控制变量所需成本与产品质量下降所造成的成本损失，以在两者之间谋求平衡；③ 控制变量预测算法：根据过程变量的时序变化以及控制变量的时序变化，使用深度学习的方法预测控制变量需调整的值的大小，以最小化对产品质量的影响。

2.2.5 基于知识图谱的质量分析

质量分析是指综合考虑生产过程中所记录的数据，实现产品的加工质量分析与预测；同时在出现质量问题时，可以追溯其加工中每个环节，找出原因，从而改进加工工艺、控制加工质量^[82]。基于知识图谱的质量分析通过知识图谱建模了产品生产过程中所经过的各个工序及工序依赖关系，并记录了各个工序的切削力误差、定位精度等属性数据，可以实现产品加工质量的预测、分析与溯源。

基于知识图谱的质量分析系统的结构与流程如图15所示。与传统质量分析相比，基于知识图谱的质量分析主要有以下几点转变：① 数据建模：统一工序与产品信息的表达空间，通过产品经过的工序来表征产品与工序之间的关联性；② 依赖表达：使用有向图的方式表达产品、工序之间的依赖关系，便于实现质量追溯与瓶颈工序推理；③ 验证手段：基于知识图谱的质量分析，可以通过可视化手段形象地展示产品工序之间的依赖关系以及产品的质量追溯推理过程，以便于专家验证推理过程的合理性。




图15 基于知识图谱的质量分析系统的结构与流程

现有的知识图谱相关理论研究可以尝试应用于基于知识图谱的质量分析技术，比如：智能制造领域知识的形式化表达方法、智能制造领域知识推理技术。主要应用于工序属性和产品信息的相关本体构建、质量分析知识图谱构建以及产品生产过程中的质量追溯与瓶颈工序推理。

然而，基于知识图谱的质量分析技术尚需在以下几个方面进行突破：① 工序与产品信息表达方法：包括变产品、变工序情况下工序与产品信息的有效、统一表达；② 质量预测技术：发展针对变产品、变工序情况下，可以编码产品工序之间的依赖关系的深度学习质量预测技术^[83]；③ 误差传播技术：发展针对变产品、变工序情况下，产品加工误差传播技术，推理每个工序对产品最终质量的影响。

2.2.6 基于知识图谱的故障分析

故障分析是指诊断故障设备或产品的故障机理、影响、发展变化规律和发生概率等内容。传统的故障分析方法通常是基于故障树实现的^[84]，可以用来了解系统失效的原因，定位系统失效位置，并且找到最好的方式降低风险，或是通过统计分析的方法确定某一安全事故或是特定系统失效的发生率。而基于知识图谱的故障分析可以拓展故障事件以及故障部件的描述形式，以图结构的方式更加灵活地表达事件与部件之间的关联关系，以更加精准地定位系统失效部位、原因以及处理方案。

基于知识图谱的故障分析系统的结构与流程如图16所示。与传统故障分析相比，基于知识图谱的故障分析主要有以下几点转变：① 故障知识语义关系模式：传统的故障分析方法只能以树结构的方式分析事件之间的传递方式，而基于知识图谱的故障分析可以通过图结构的数据存储方法，可以描述事件与部件之间更加丰富的语义关系；② 故障推理能力：传统的故障分析方法使用人工经验在故障树上进行故障事件的推理，而基于知识图谱的故障分析可以结合事件推理与部件推理，实现更加精确的故障分析；③ 故障范围分析：基于知识图谱的故障分析不止可以定位当前系统的失效部位，还可以分析现有故障对其他部件的影响；④ 故障多层次分析：基于知识图谱的故障分析可以分析系统失效部位的层次结构，同时实现模糊定位与精确定位。

现有的知识图谱相关理论研究可以尝试应用于基于知识图谱的故障分析过程，比如：智能制造领域知识图谱的自动构建技术、智能制造领域问答技术。主要应用于故障相关知识图谱的构建、故障事件描述文本的实体与语义解析、故障部位的精确定

位、故障路径解析、故障原因以及处理方案搜索。




图 16 基于知识图谱的故障分析系统的结构与流程

然而，基于知识图谱的故障分析尚需在以下几个方面进行突破：① 多态、组合失效行为分析：实际系统中存在的时序性、相关性、顺序性等动态特性，要求故障知识图谱中存储故障相关属性，同时具有动态解析能力；② 概率知识图谱的构建与解析：包括事件实体之间的关联概率和事件实体与部件实体之间的关联概率的计算与存储，以及概率知识图谱的解析，以分析某一安全事故或是特定系统失效的发生概率；③ 故障知识动态更新：包括故障知识的事件、部件、故障属性实体及相应关系的实时动态增加、删减以及修改；④ 预见性维护：在系统中集成基于深度学习的故障预测方法^[85]，同时通过故障知识图谱精确定位一段时间内可能发生的系统的故障部位、原因以及处理方案。




图 17 基于知识图谱的数字孪生系统的结构与流程

现有的知识图谱相关研究可以尝试应用于基于知识图谱的数字孪生技术，比如：智能制造领域知识的形式化表达方法以及智能制造领域知识推理技术。主要应用于数字孪生知识图谱的本体的构建、数字孪生知识图谱的更新与补全。

然而，基于知识图谱的数字孪生技术尚需在以下几个方面进行突破：① 动态实时更新：数字孪生技术要求知识图谱具备对物理实体每个阶段的动态实时更新能力；② 仿真融合：数字孪生技术要求知识图谱融合包括机械、电气等多领域，静力学场、

2.2.7 基于知识图谱的数字孪生

数字孪生技术用于实现物理世界与信息世界的交互与共融，其是以数字化方式创建物理实体的虚拟模型，借助数据模拟物理实体在现实环境中的行为，通过虚实交互反馈、数据融合分析、决策迭代优化等手段，为物理实体增加或扩展新的能力^[82]。目前该技术已经获得了广泛的关注，存在很多著名企业探索该技术在产品设计、制造和服务等方面的应用。基于知识图谱的数字孪生技术可以应用于数字孪生技术中的数字孪生体构建与更新、孪生数据融合与分析过程，从而为用户提供更加智能化、个性化的服务应用。

基于知识图谱的数字孪生系统的结构与流程如图 17 所示。与传统数字孪生相比，基于知识图谱的数字孪生主要有以下几点转变：① 物理信息融合方式：基于知识图谱的数字孪生系统针对物理样机产生的数据，使用图结构的存储方式，包含了物理信息之间的关联关系；② 物理信息与虚拟信息的交互方式：物理信息与虚拟信息可以分别构成两个子知识图谱，同时连接两个子知识图谱之间的相关实体组合而成数字孪生知识图谱，实现虚实融合；③ 虚拟样机管理：基于知识图谱的数字孪生可以通过更新物理信息知识图谱中每个节点的值，来更新相关联的虚拟信息知识图谱中的节点的值。

动力学场等多物理场，以及宏观尺度、微观尺度等多尺度的仿真数据；③ 可控变量优化：包括挖掘物理可控变量对每一个物理信息的影响，同时基于仿真数据和深度学习方法，优化物理实体中的可控制变量。

2.2.8 基于知识图谱的人机协同与交互

人机协同与交互是指工业机器人的配置，工业机器人与环境的交互以及工业机器人与操作人员的协同与交互，以实现高效的产品生产与加工。基于知识图谱的人机协同与交互可以描述机器人传感

器、控制单元、环境、机器人结构以及连接部件的关联关系,并以可视化的方式更加直观地向操作人员展示当前机器人的状态以及操作方法。

基于知识图谱的人机协同与交互系统的结构与流程如图 18 所示。与传统人机交互相比,基于知识图谱的人机协同与交互主要有以下几点转变:① 操作难度:基于知识图谱的人机协同与交互允许构建操作知识图谱,代表了操作人员的使用机器人的方式以及机器人上连接件的安装与连接方法,提高操作人员的学习效率;② 协作性:操作人员可以通过知识图谱便捷地对机器人进行配置,实现更高效的人机协作;③ 自适应性:基于知识图谱的人机协同与交互可以将感知环境的传感器的数据输入至知识图谱中,便于分析环境数据所影响的其他变量的变化,并进行相应的调整。




图 18 基于知识图谱的人机协同与交互系统的结构与流程

现有的知识图谱相关理论研究可以尝试应用于基于知识图谱的人机协同与交互技术,比如:智能制造领域知识的形式化表达方法、智能制造领域知识推理技术以及智能制造领域问答技术。主要应用于机器人传感器、控制单元、外部环境和机器人结构本体构建、人机交互知识图谱和操作知识图谱构建、人机交互知识图谱推理以及操作知识图谱知识查询与问答。

然而,基于知识图谱的人机协同与交互技术尚需在以下几个方面进行突破:① 传感器与感知技术:包括温度、力、触觉等传感器的测量精度以及对应的数据处理算法;② 决策优化算法:根据传感器数据变化以及传感器在知识图谱中的依赖关系,使用强化学习方法优化机器人控制单元参数;③ 有序知识图谱:当操作人员查询机器人使用方式或机器人部件安装方式时,需要考虑操作顺序或部件安装的顺序,此时需要知识图谱内部可以实现实体的

顺序定义与有序推理。

2.2.9 基于知识图谱的物流配送

生产物流包括企业内部物流和企业外部物流,是保证企业正常生产、提高生产效率、降低产品成本的关键^[82]。基于知识图谱的物流配送可以将车辆信息与物流目标地点之间的距离信息嵌入到知识图谱内部,进而将物流配送问题转化为图最短路径搜索问题以及组合优化问题。

基于知识图谱的物流配送系统的结构与流程如图 19 所示。与传统物流配送相比,基于知识图谱的物流配送主要有以下几点转变:① 建模方法:使用知识图谱构建车辆信息与物流目标地点的关联关系,可以便捷、快速地将问题建模为图搜索问题;② 约束推理:可以根据知识图谱中包含的配送车辆的属性信息、物料的属性信息、环境的属性信息以及车间/企业的属性信息与依赖信息,便捷地推理出配送过程所需满足的联合约束;③ 物流透明化:可以通过知识图谱实时追踪当前的车辆信息的状态以及物料配送情况。




图 19 基于知识图谱的物流配送系统的结构与流程

现有的知识图谱相关理论研究可以尝试应用于基于知识图谱的物流配送技术,比如:智能制造领域知识的形式化表达方法、智能制造领域知识图谱的自动构建技术以及智能制造领域知识推理技术。主要应用于车辆信息与物流目标地点本体的构建、物流配送知识图谱的构建以及配送过程的约束推理。

然而,基于知识图谱的物流配送技术尚需在以下几个方面进行突破:① 智能调度优化算法:包括考虑配送过程的多物流车辆、多目标地点、多优化目标的分配优化,实现多物流设备协同运输;② 高效的图算法:包括有向有权图的最短路径搜索、单源最短路径算法、拓扑排序算法以及图聚类算法;

③ 物流车辆的自主控制: 设置每个车辆都可以作为一个控制单元, 共享物流配送知识图谱, 实时调整任务分配, 实现自组织、自适应控制。

2.2.10 基于知识图谱的智慧工厂

智慧工厂是以数字化信息形式的工厂模型为基础, 以实现制造系统离线分析设计和实际生产系统运行状态在线监控^[86]。智慧工厂要求建立工厂中作业对象的数字化模型, 以监控生产状态。其中作业对象包括车间、过程单元、生产单元、生产线、作业单元、人员、设备、工艺、产品等。基于知识图谱的智慧工厂可以更加有效地建立各个单元之间的关联关系与影响。

基于知识图谱的智慧工厂系统的结构与流程如图 20 所示。与传统智慧工厂相比, 基于知识图谱的智慧工厂主要有以下几点转变: ① 多作业单元统一描述: 基于知识图谱的智慧工厂可以实现设备、人

员、资源、产品等的统一描述与管理, 以真正实现工厂所有单元的数字化建模; ② 作业单元关联模式发现: 传统工厂建模需要专家人员分析各个作业单元的关联模式, 而基于知识图谱的智慧工厂可以使用启发式的规则定义关联模式; 可以从历史故障记录文本中抽取故障影响的作业单元的关联关系; 还可以根据不完整知识图谱补全作业单元之间的依赖关系; ③ 多作业单元的关联分析: 基于知识图谱的智慧工厂可以分析一个作业单元出现故障后所影响的所有作业单元, 实现敏捷地故障分析。

现有的知识图谱相关理论研究可以尝试应用于基于知识图谱的智慧工厂技术, 比如: 智能制造领域知识的形式化表达方法以及智能制造领域知识推理技术。主要应用于作业单元本体构建、工厂建模知识图谱构建以及作业单元关联依赖关系补全和推理。




图 20 基于知识图谱的智慧工厂系统的结构与流程

然而, 基于知识图谱的智慧工厂技术尚需在以下几个方面进行突破: ① 丰富本体的表达模式: 包括本体的层级关系、类别关系、约束关系; ② 工厂建模知识图谱的融合技术: 包括工厂布局、工艺和产品信息的相关知识图谱的融合, 尤其涉及到工艺与产品信息知识图谱更新频率较高的情况; ③ 增量式的知识图谱更新: 包括工厂建模知识图谱中表征工厂元素的实体与关系的增量式扩充、删减以及修改; ④ 云计算: 使用更加稳定高效的云计算来实现数据的存储与运算, 还可以使用弹性计算来提高计算资源的利用率, 均衡计算资源的负载。

2.3 面向企业管理的智能制造知识图谱应用

面向企业管理的智能制造知识图谱应用是指针对智能制造企业管理者提供服务的知识图谱应用。此处探索了 3 种该类型的应用: 基于知识图谱的潜

在客户识别、基于知识图谱的企业风险分析、基于知识图谱的企业条例管理。

2.3.1 基于知识图谱的潜在客户识别

潜在客户识别是指根据用户的社交情况、消费行为等数据, 分析客户的需求、购买力和决策权, 搜寻企业的潜在客户。其中潜在客户是对企业的某类产品存在需求且具备购买能力的待开发客户, 这类客户与企业存在着销售合作机会。传统的潜在客户识别依赖销售管理人员在网页进行大量的检索, 而基于知识图谱的潜在客户识别可以使用知识图谱表征用户自身的属性特征以及用户之间的复杂关系, 从而实现更加精准的潜在客户识别。

基于知识图谱的潜在客户识别系统的结构与流程与第 2.1.1 节中所示的基于知识图谱的产品推荐

系统相似,不过重点强调潜在客户的识别。与传统潜在客户识别相比,基于知识图谱的潜在客户识别主要有以下几点转变:① 用户画像的表达方式:基于知识图谱的潜在客户识别使用知识图谱表达每一个用户的用户画像,表征每个用户的属性;② 用户画像的关联分析:传统的潜在客户识别依据的是分散的表征用户关系的文本数据,而基于知识图谱的潜在客户识别将用户关系集成在知识图谱内部;③ 多元信息分析:基于知识图谱的潜在客户识别是基于用户属性与用户之间的关系的融合语义信息与知识图谱结构信息的多角度的潜在客户识别。

现有的知识图谱相关理论研究可以尝试应用于基于知识图谱的潜在客户识别技术,比如:智能制造领域知识的形式化表达方法、智能制造领域知识图谱的自动构建技术以及智能制造领域知识推理技术。主要应用于用户画像实体类别与关系集合定义、用户画像知识图谱构建与补全以及基于知识图谱的潜在客户推理分析。

然而,基于知识图谱的潜在客户识别技术尚需在以下几个方面进行突破:① 多平台信息融合:在知识图谱中融合用户活跃的多平台信息,以更全面地分析用户的特征;② 用户画像补全:包括用户属性补全与用户之间的关系补全;③ 目标客户群的分层划分:包括潜在客户的评分方式以及目标客户群的等级划分方法。

2.3.2 基于知识图谱的企业风险分析

企业风险分析是指剖析未来可能发生的不确定性事件对企业实现其经营目标的影响。传统的企业风险分析依赖于大量企业管理人员分析文本类型数据中蕴含的风险事件,难以挖掘风险事件更加深入的关联关系。而基于知识图谱的企业风险分析可以建立客户、企业和行业间的知识图谱,从行业关联的角度预测行业或企业面临的风险,为管理者的决策提供帮助。

基于知识图谱的企业风险分析系统的结构与流程如图 21 所示。与传统企业风险分析相比,基于知识图谱的企业风险分析主要有以下几点转变:① 透明度:可以通过知识图谱便捷地查询公司之间的关系,提高公司之间的透明度,助于建立公平的竞争环境;② 风险推理能力:基于知识图谱的企业风险分析可以通过基于知识图谱的推理技术,挖掘更深层次的风险关系,识别依靠人力难以识别的风险;③ 辅助效益:基于知识图谱的企业风险分析能够以可视化的手段展示风险推理过程,指导专家进行进一步地分析工作。




图 21 基于知识图谱的企业风险分析系统的结构与流程

现有的知识图谱相关理论研究可以尝试应用于基于知识图谱的企业风险分析技术,比如:智能制造领域知识的形式化表达方法、智能制造领域知识图谱的自动构建技术以及智能制造领域知识推理技术。主要应用于表征客户、企业和行业间关联关系的知识图谱的构建、以及基于知识图谱的企业风险分析与推理。

然而,基于知识图谱的企业风险分析技术尚需在以下几个方面进行突破:① 高敏捷度的风险分析:考虑到风险对企业的有害影响,敏捷度越高的风险分析系统可以让企业更快地规避损失;② 基于图数据的风险评估:包括基于知识图谱的不一致性验证、组团欺诈、异常分析等企业风险评估方法与规则;③ 风险规避策略生成:现阶段基于知识图谱的企业风险分析主要是辅助人类发现企业可能面临的风险,而无法获取处理风险的最优决策。

2.3.3 基于知识图谱的企业条例管理

企业条例是指企业为了管理员工、项目、资源等而制定的规章制度。主要包括了条目式的规范(如员工守则)以及流程式的规范(如项目申报流程)。传统的企业条例管理要求每一位员工阅读文本规范,同时针对流程式的规范容易出现遗漏审批的情况,严重降低了工作的效率。而基于知识图谱的企业条例管理能够以可视化的方式指引员工规范自身行为以及完成流程式审批,提高企业的运作效率。

基于知识图谱的企业条例管理系统的结构与流程如图 22 所示。与传统企业条例管理相比,基于知识图谱的企业条例管理主要有以下几点转变:① 友好性:企业条例知识图谱可以以路径的方式展示员工为了完成任务所需的流程,便于员工理解和执行,提高员工满意度与执行效率;② 高效性:基于知识图谱的企业条例管理可以允许员工使用非结构文本查询,同时可以通过知识图谱返回更加精确的条例,减少过程违规而造成的损失。

现有的知识图谱相关理论研究可以尝试应用于

基于知识图谱的企业条例管理技术,比如:智能制造领域知识的形式化表达方法、智能制造领域知识图谱的自动构建技术以及智能制造领域问答技术。主要应用于企业条例知识图谱构建、员工企业条例查询以及企业条例的可视化。




图 22 基于知识图谱的企业条例管理系统的结构与流程

然而,基于知识图谱的企业条例管理技术尚需在以下几个方面进行突破:① 基于文本的问答技术与基于知识图谱的问答技术相结合:由于企业条例知识图谱总会存在不完备性,当企业条例知识图谱中无法查询到员工所需条例时,可以结合文本数据,如历史相似问题处理方式等,给予员工参考;② 不可回答的问题判断:针对员工查询的在企业条例中不存在答案的问题,系统应给出员工提示;③ 融合员工信息:将企业条例知识图谱内融合员工信息相关知识,以实现流程负责人的快速查询,同时尝试构建员工的自动评价系统。

3 应用案例:数控车床的故障分析

数控车床是机械产品制造过程中常见的加工设备,主要用于轴类零件或盘类零件的内外圆柱面、任意锥角的内外圆锥面、复杂回转内外曲面和圆柱、圆锥螺纹等切削加工,并能进行切槽、钻孔、扩孔、铰孔及镗孔等。由于数控车床具有高质量、高精度的特点,其在产品加工过程占据了很关键的地位。因此很有必要对数控车床中发生和可能发生故障的系统及其组成单元进行分析,鉴别其故障模式、故障原因,估计该故障模式对系统可能产生的何种影响,以便采取措施提高其可靠性,降低其对生产过程的影响。

为了高效准确地帮助专家针对数控车床进行故障分析,展示知识图谱技术在机械领域应用的有效性,此处建立了在第 2.2.6 节中描述的基于知识图谱的故障分析系统。

针对故障分析知识图谱的构建过程,本文从企

业设备故障记录文本、以及数控车床设备信息与设备故障相关网页、书籍和文献中抽取到所需的数控车床结构知识、故障模式知识、故障机理知识、故障应对措施知识。最终构建的部分故障分析知识图谱的实体与关系如图 23 所示。基于该知识图谱可实现的主要故障分析方式如下所示。

(1) 灵活的信息查询格式。基于知识图谱的故障分析系统可以利用命名实体识别技术和语义解析技术,实现非结构化文本式的故障分析。如员工输入“数控车床主轴振动”便可以解析出话语中所包含的部件实体有:“数控车床”和“主轴”,事件实体有:“振动”,进而便可以在知识图谱中实现进一步的搜索和推理。

(2) 故障原因、处理措施推理。故障原因与处理措施推理对故障分析十分关键,指引着专家对故障的解决方式。与传统关键词检索不同,基于知识图谱的故障分析,通过对语句的实体与关系分析找到答案,如针对(1)中的语句与解析结果,可以在知识图谱中通过图 24 所示的路径,推理出员工所提出的故障现象的原因和处理措施的存储编号(图中为原因 22 与措施 22,而后可以自动根据该存储编号检索故障原因和处理措施的详细内容。

(3) 故障影响范围推理。在故障分析知识图谱中,耦合了数控车床中各个部件的连接关系以及部件的层级关系,因此可以用于推理故障部件所影响的其他部件。比如,从知识图谱中可以得到主轴部件的故障可能会影响其相连的轴承、挡圈等部件的工作情况,以提示操作人员进行进一步的检查。

(4) 隐式故障模式推理。操作人员往往只能观察到故障发生时带来的表面的现象,而不确定该故障现象对应的实际的故障现象描述,因此需要指引操作人员进一步探索真正的故障原因。基于知识图谱的故障分析系统实现了这一目标。在知识图谱内部可以耦合故障现象之间的关联关系,比如部件的“发热”故障事件可能是由于“磨损”、“振动”、“短路”等事件造成的,而“振动”事件还可能导致“噪声”、“断裂”等事件。当相关现象链接到知识图谱中的事件实体后,可以实现隐式事件的挖掘以及事件可能造成的后续影响的提示。如员工输入“驱动装置发热”,经过知识图谱的事件关系推理后,可以得出可能的故障模式是短路或负载高等,从而进一步可以推理更精确的故障原因、处理措施等。



图 23 数控车床故障分析知识图谱

(5) 交互式故障检测。由于数控机床的结构是层级结构，由很多系统组成，而各个系统由包含了许多子系统。因此操作人员描述故障现象时，容易描述故障对象的范围较大。而故障分析知识图谱内部结合了数控机床的结构信息，可以指引用户进行逐层故障检查。如员工输入“导向机构发热”，经知识图谱提示，导向机构内包含了导柱、导套等可能出现发热现象的部件，于是员工可以进一步检查定位，发现最终故障原因是导柱的磨损。

(6) 多层次故障分析。在数控车床中存在很多同类别部件，比如多种齿轮或多种电动机等，其所遇到的故障处理方法往往很接近。在故障分析知识图谱中耦合了这种模式，一方面可以去除冗余数据，降低数据存储空间，另一方面可以实现故障的多层次分析。比如员工输入“传动零部件振动”和“齿轮箱齿轮振动”可以获得相同的故障处理方法，但是针对“齿轮箱齿轮振动”可以获得具体化的故障机理推理。实现了多层次的故障分析，满足了员工

的多层次需求。




图 24 故障原因及处理措施的软件界面推理结果

可以看出, 基于知识图谱的故障分析彻底改变了传统的故障分析方法, 实现了更加全面化、深入化的知识推理, 更加高效化、智能化的故障分析, 以及更加友好化、个性化的服务应用。

4 结论

本文首先总结了智能制造领域知识图谱相关技术的研究进展, 为后续应用过程提供理论支撑。其次探索了知识图谱在智能制造领域的面向企业客户的 2 类应用前景、面向领域专家的 10 类应用前景以及面向企业管理的 3 类应用前景。在各个应用前景中, 分析了引入知识图谱的方法与传统方法的不同之处, 应用过程中所需要的智能制造领域知识图谱相关技术以及实施过程中所待突破的关键技术等。希望可以为进一步展开对知识图谱在智能制造领域的研究提供启发, 同时为相关企业针对知识图谱的实际应用提供参考。最后, 使用一个数控车床故障分析的案例展现了知识图谱的有效性。

参 考 文 献

- [1] 张映锋, 郭振刚, 钱成, 等. 基于过程感知的底层制造资源智能化建模及其自适应协同优化方法研究[J]. 机械工程学报, 2018, 54(16): 1-10.
ZHANG Yingfeng, GUO Zhengang, QIAN Cheng, et al. Investigation on process-aware based intelligent modeling of bottom layer manufacturing resources and self-adaptive collaborative optimization methodology[J]. Journal of Mechanical Engineering, 2018, 54(16): 1-10.
- [2] 王少杰, 侯亮, 方奕凯, 等. 考虑产品运行大数据的装载机变速箱优化设计[J]. 机械工程学报, 2018, 54(22):

218-232.

- WANG Shaojie, HOU Liang, FANG Yikai, et al. Optimization design of wheel loader gearbox considering product operational big data[J]. Journal of Mechanical Engineering, 2018, 54(22): 218-232.
- [3] 徐增林, 盛泳潘, 贺丽荣, 等. 知识图谱技术综述[J]. 电子科技大学学报, 2016, 45(4): 589-606.
XU Zenglin, SHENG Yongpan, HE Lirong, et al. Review on knowledge graph techniques[J]. Journal of University of Electronic Science and Technology of China, 2016, 45(4): 589-606.
- [4] WANG Q, MAO Z, WANG B, et al. Knowledge graph embedding: A survey of approaches and applications[J]. IEEE Transactions on Knowledge and Data Engineering, 2017, 29(12): 2724-2743.
- [5] HUBAUER T, LAMPARTER S, HAASE P, et al. Use cases of the industrial knowledge graph at siemens[C]// International Semantic Web Conference (P&D/Industry/BlueSky). Monterey, USA, 2018;
- [6] SCHMID S, HENSON C, TRAN T. Using knowledge graphs to search an enterprise data lake[C]// European Semantic Web Conference. Portoroz, Slovenia, 2019: 262-266.
- [7] SINGHAL A. Introducing the knowledge graph: Things, not strings[J/OL]. Official Google Blog, 2012, 5. <http://googleblog.blogspot.pt/2015/05/introducing-knowledge-graph-things-nit.html>.
- [8] WU T, QI G, LI C, et al. A survey of techniques for constructing chinese knowledge graphs and their applications[J]. Sustainability, 2018, 10(9): 3245-3270.
- [9] BOLLACKER K, EVANS C, PARITOSH P, et al. Freebase: A collaboratively created graph database for structuring human knowledge[C]// Proceedings of the 2008 ACM SIGMOD international conference on Management of data. Vancouver, Canada, 2008: 1247-1250.
- [10] VRANDEČIĆ D, KRÖTZSCH M. Wikidata: A free collaborative knowledgebase[J]. Communications of the ACM, 2014, 57(10): 78-85.
- [11] LEHMANN J, ISELE R, JAKOB M, et al. DBpedia: A large-scale, multilingual knowledge base extracted from wikipedia[J]. Semantic Web, 2015, 6(2): 167-195.
- [12] 龚晶, 刘检华, 赵柏萱, 等. 基于知识的管路布局自动评价技术[J]. 计算机集成制造系统, 2014, 20(10): 2522-2531.

- GONG Jing, LIU Jianhua, ZHAO Boxuan, et al. Knowledge-based automatic evaluating method for pipe routing[J]. *Computer Integrated Manufacturing Systems*, 2014, 20(10): 2522-2531.
- [13] 邹慧君, 王石刚. 基于多层推理机制的机械产品概念设计[J]. *计算机辅助设计与图形学学报*, 1997, 9(6): 548-553.
- ZOU Huijun, WANG Shigang. Mechanical product conceptual design based on multilevel reasoning[J]. *Journal of Computer Aided Design & Computer Graphics*, 1997, 9(6): 548-553.
- [14] 蔡鸿明, 何援军, 刘胡瑶. 基于分层语义网络的设计资源库建模及实现[J]. *计算机集成制造系统*, 2005, 11(1): 73-78.
- CAI Hongming, HE Yuanjun, LIU Huyao. Modeling and implementation of design resource base based on hierarchy semantics networks[J]. *Computer Integrated Manufacturing Systems*, 2005, 11(1): 73-78.
- [15] 郭鑫, 赵武, 王杰, 等. 面向创新设计的工艺设计知识模型及检索方法研究[J]. *机械工程学报*, 2017, 53(15): 80-86.
- GUO Xin, ZHAO Wu, WANG Jie, et al. A study of knowledge modeling and retrieval methods oriented towards innovative design of manufacturing planning[J]. *Journal of Mechanical Engineering*, 2017, 53(15): 80-86.
- [16] 李长杰, 明新国, 邱坤华, 等. 基于本体的飞机工装设计知识表示方法[J]. *中国机械工程*, 2014, 25(19): 2614-2619.
- LI Changjie, MING Xinguo, QIU Kunhua, et al. Knowledge representation method for aircraft tooling design based on ontology[J]. *China Mechanical Engineering*, 2014, 25(19): 2614-2619.
- [17] CHHIM P, CHINNAM R B, SADAWI N. Product design and manufacturing process based ontology for manufacturing knowledge reuse[J]. *Journal of Intelligent Manufacturing*, 2019, 30(2): 905-916.
- [18] 刘航, 杜江, 白瑀. 基于多维度本体的制造业领域知识语义建模研究[J]. *制造技术与机床*, 2019(9): 140-146.
- LIU Hang, DU Jiang, BAI Yu. Research on semantic modeling based on multi-dimension ontology for manufacturing domain knowledge[J]. *Manufacturing Technology & Machine Tool*, 2019(9): 140-146.
- [19] BOCK C, ZHA X, SUH H, et al. Ontological product modeling for collaborative design[J]. *Advanced Engineering Informatics*, 2010, 24(4): 510-524.
- [20] MIKOLOV T, SUTSKEVER I, CHEN K, et al. Distributed representations of words and phrases and their compositionality[C]// *Advances in Neural Information Processing Systems*. Nevada, USA, 2013: 3111-3119.
- [21] HUANG Z, XU W, YU K. Bidirectional LSTM-CRF models for sequence tagging[J]. *arXiv preprint arXiv: .01991*, 2015.
- [22] QIU J, WANG Q, ZHOU Y, et al. Fast and accurate recognition of chinese clinical named entities with residual dilated convolutions[C]// *2018 IEEE International Conference on Bioinformatics and Biomedicine (BIBM)*. Madrid, Spain, 2018: 935-942.
- [23] YAN H, DENG B, LI X, et al. TENER: Adapting transformer encoder for name entity recognition[J]. *arXiv preprint arXiv: .04474*, 2019.
- [24] 刘宇飞, 尹力, 张凯, 等. 基于深度迁移学习的技术术语识别——以数控系统领域为例[J]. *情报杂志*, 2019, 38(10): 168-175.
- LIU Yufei, YIN Li, ZHANG Kai, et al. Deep transfer learning for technical term extraction: A case study in computer numerical control system[J]. *Journal of Intelligence*, 2019, 38(10): 168-175.
- [25] MINTZ M, BILLS S, SNOW R, et al. Distant supervision for relation extraction without labeled data[C]// *Proceedings of the Joint Conference of the 47th Annual Meeting of the ACL and the 4th International Joint Conference on Natural Language Processing of the AFNLP: Volume 2-Volume 2*. Suntec, Singapore, 2009: 1003-1011.
- [26] ZENG D, LIU K, LAI S, et al. Relation classification via convolutional deep neural network[C]// *Proceedings of COLING 2014, the 25th International Conference on Computational Linguistics: Technical Papers*. Dublin, Ireland, 2014: 2335-2344.
- [27] SOROKIN D, GUREVYCH I. Context-aware representations for knowledge base relation extraction[C]// *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing*. Copenhagen, Denmark, 2017: 1784-1789.
- [28] LI Z, DING N, LIU Z, et al. Chinese relation extraction with multi-grained information and external linguistic knowledge[C]// *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*. Florence, Italy, 2019: 4377-4386.
- [29] BILAN I, ROTH B. Position-aware self-attention with

- relative positional encodings for slot filling[J]. arXiv preprint arXiv: .03052, 2018.
- [30] LENG J, JIANG P. A deep learning approach for relationship extraction from interaction context in social manufacturing paradigm[J]. Knowledge-Based Systems, 2016, 100: 188-199.
- [31] WU Y, BAMMAN D, RUSSELL S. Adversarial training for relation extraction[C]// Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing. Copenhagen, Denmark, 2017: 1778-1783.
- [32] SOARES L B, FITZGERALD N, LING J, et al. Matching the blanks : Distributional similarity for relation learning[C]// Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. Florence, Italy, 2019: 2895-2905.
- [33] CHEN M, TIAN Y, YANG M, et al. Multilingual knowledge graph embeddings for cross-lingual knowledge alignment[C]// Proceedings of the 26th International Joint Conference on Artificial Intelligence. Melbourne, Australia, 2017: 1511-1517.
- [34] CHEN M, ZHOU T, ZHOU P, et al. Multi-graph affinity embeddings for multilingual knowledge graphs[C]// Proceedings of NIPS Workshop on Automated Knowledge Base Construction. CA, USA, 2017:
- [35] ZHU H, XIE R, LIU Z, et al. Iterative entity alignment via joint knowledge embeddings[C]// Proceedings of the 26th International Joint Conference on Artificial Intelligence. Melbourne, Australia, 2017: 4258-4264.
- [36] SUN Z, HU W, ZHANG Q, et al. Bootstrapping entity alignment with knowledge graph embedding[C]// Proceedings of the 27th International Joint Conference on Artificial Intelligence. Stockholm, Sweden, 2018: 4396-4402.
- [37] CAO Y, LIU Z, LI C, et al. Multi-channel graph neural network for entity alignment[C]// Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. Florence, Italy, 2019: 1452-1461.
- [38] 张仲伟, 曹雷, 陈希亮, 等. 基于神经网络的知识推理研究综述[J]. 计算机工程与应用, 2019, 55(12): 8-19. ZHANG Zhongwei, CAO Lei, CHEN Xiliang, et al. Survey of knowledge reasoning based on neural network[J]. Computer Engineering and Applications, 2019, 55(12): 8-19.
- [39] 官赛萍, 靳小龙, 贾岩涛, 等. 面向知识图谱的知识推理研究进展[J]. 软件学报, 2018, 29(10): 74-102. GUAN Saiping, JIN Xiaolong, JIA Yantao, et al. knowledge reasoning over knowledge graph: A survey[J]. Journal of Software, 2018, 29(10): 74-102.
- [40] BORDES A, USUNIER N, GARCIA-DURAN A, et al. Translating embeddings for modeling multi-relational data[C]// Advances in neural information processing systems. Nevada, USA, 2013: 2787-2795.
- [41] WANG Z, ZHANG J, FENG J, et al. Knowledge graph embedding by translating on hyperplanes[C]// Proceedings of the Twenty-Eighth AAAI Conference on Artificial Intelligence. Québec, Canada, 2014: 1112-1119.
- [42] KIPF T N, WELLING M. Variational graph auto-encoders[J]. arXiv preprint arXiv: .07308, 2016.
- [43] CAI L, WANG W Y. KBGAN: Adversarial learning for knowledge graph embeddings[C]// Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics : Human Language Technologies, Volume 1 (Long Papers). New Orleans, Louisiana, 2018: 1470-1480.
- [44] 陈继文, 杨红娟, 董明晓, 等. 基于本体语义块相似匹配的设计知识更新[J]. 机械工程学报, 2014, 50(7): 161-167. CHEN Jiwen, YANG Hongjuan, DONG Mingxiao, et al. Design knowledge updating method based on similarity matching of ontology semantic block[J]. Journal of Mechanical Engineering, 2014, 50(7): 161-167.
- [45] CAI H, ZHENG V W, CHANG K C-C. A comprehensive survey of graph embedding: Problems, techniques, and applications[J]. IEEE Transactions on Knowledge Data Engineering, 2018, 30(9): 1616-1637.
- [46] GALÁRRAGA L A, TEFLIOUDI C, HOSE K, et al. AMIE : Association rule mining under incomplete evidence in ontological knowledge bases[C]// Proceedings of the 22nd international conference on World Wide Web. Rio de Janeiro, Brazil, 2013: 413-422.
- [47] GALÁRRAGA L, TEFLIOUDI C, HOSE K, et al. Fast rule mining in ontological knowledge bases with AMIE+[J]. The VLDB Journal—The International Journal on Very Large Data Bases, 2015, 24(6): 707-730.
- [48] TANON T P, STEPANOVA D, RAZNIEWSKI S, et al. Completeness-aware rule learning from knowledge graphs[C]// International Semantic Web Conference. Vienna, Austria, 2017: 507-525.
- [49] HO V T, STEPANOVA D, GAD-ELRAB M H, et al.

- Rule learning from knowledge graphs guided by embedding models[C]// International Semantic Web Conference. CA, USA, 2018: 72-90.
- [50] YANG F, YANG Z, COHEN W W. Differentiable learning of logical rules for knowledge base reasoning[C]// Advances in Neural Information Processing Systems. CA, USA, 2017: 2319-2328.
- [51] SADEGHIAN A, ARMANDPOUR M, DING P, et al. DRUM: End-to-end differentiable rule mining on knowledge graphs[C]// Advances in Neural Information Processing Systems. BC, Canada, 2019: 15321-15331.
- [52] 曹明宇, 李青青, 杨志豪, 等. 基于知识图谱的原发性肝癌知识问答系统[J]. 中文信息学报, 2019, 33(6): 88-93.
- CAO Mingyu, LI Qingqing, YANG Zhihao, et al. A question answering system for primary liver cancer based on knowledge graph[J]. Journal of Chinese Information Processing, 2019, 33(6): 88-93.
- [53] CHEN Y, WU L, ZAKI M J. Bidirectional attentive memory networks for question answering over knowledge bases[C]// Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers). Minneapolis, Minnesota, 2019: 2913-2923.
- [54] SAHA A, ANSARI G A, LADDHA A, et al. Complex program induction for querying knowledge bases in the absence of gold programs[J]. Transactions of the Association for Computational Linguistics, 2019, 7: 185-200.
- [55] YIH W-t, CHANG M-W, HE X, et al. Semantic parsing via staged query graph generation: Question answering with knowledge base[C]// Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). Beijing, China, 2015: 1321-1331.
- [56] LI F-L, CHEN W, HUANG Q, et al. AliMe KBQA: Question answering over structured knowledge for e-commerce customer service[J]. arXiv Preprint arXiv: .05728, 2019.
- [57] MILNE D, WITTEN I H. Learning to link with wikipedia[C]// Proceedings of the 17th ACM conference on Information and knowledge management. California, USA, 2008: 509-518.
- [58] SPITKOVSKY V I, CHANG A X. A cross-lingual dictionary for english wikipedia concepts[C]// Proceedings of the Eighth International Conference on Language Resources and Evaluation (LREC-201 ②). Istanbul, Turkey, 2012: 3168-3175.
- [59] YANG Y, CHANG M-W. S-MART: Novel tree-based structured learning algorithms applied to tweet entity linking[C]// Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). Beijing, China, 2015: 504-513.
- [60] 任朝淦, 杨燕, 贾真, 等. 基于注意力机制的问句实体链接[J]. 模式识别与人工智能, 2018, 31(12): 69-75.
- REN Chaogan, YANG Yan, JIA Zhen, et al. Attention mechanism based question entity linking[J]. Pattern Recognition and Artificial Intelligence, 2018, 31(12): 69-75.
- [61] LE P, TITOV I. Improving entity linking by modeling latent relations between mentions[C]// Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Melbourne, Australia, 2018: 1595-1604.
- [62] BAO J, DUAN N, YAN Z, et al. Constraint-based question answering with knowledge graph[C]// Proceedings of COLING 2016, the 26th International Conference on Computational Linguistics: Technical Papers. Osaka, Japan, 2016: 2503-2514.
- [63] HU S, ZOU L, ZHANG X. A state-transition framework to answer complex questions over knowledge base[C]// Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing. Brussels, Belgium, 2018: 2098-2108.
- [64] ABUJABAL A, SAHA ROY R, YAHYA M, et al. Never-ending learning for open-domain question answering over knowledge bases[C]// Proceedings of the 2018 World Wide Web Conference. Lyon, France, 2018: 1053-1062.
- [65] 徐荣振, 高琦, 邵祖光, 等. 基于本体填充的设计案例获取方法研究[J]. 组合机床与自动化加工技术, 2019, (7): 125-129.
- XU Rongzhen, GAO Qi, SHAO Zuguang, et al. Research on a method of case requirement based on ontology population[J]. Modular Machine Tool & Automatic Manufacturing Technique, 2019, (7): 125-129.

- [66] RENDLE S. Factorization machines with libfm[J]. ACM Transactions on Intelligent Systems Technology, 2012, 3(3): 57-78.
- [67] YU X, REN X, SUN Y, et al. Personalized entity recommendation: A heterogeneous information network approach[C]// Proceedings of the 7th ACM International Conference on Web Search and Data Mining. NY, USA, 2014: 283-292.
- [68] ZHAO H, YAO Q, LI J, et al. Meta-graph based recommendation fusion over heterogeneous information networks[C]// Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. NS, Canada, 2017: 635-644.
- [69] 朱桂明, 宾辰忠, 古天龙, 等. 基于知识图谱的用户偏好神经建模框架[J]. 模式识别与人工智能, 2019, 32(7): 661-668.
- ZHU Guiming, BIN Chenzhong, GU Tianlong, et al. Neural user preference modeling framework based on knowledge graph[J]. Pattern Recognition and Artificial Intelligence, 2019, 32(7): 661-668.
- [70] WANG H, ZHANG F, XIE X, et al. DKN: Deep knowledge-aware network for news recommendation[C]// Proceedings of the 2018 World Wide Web Conference. Lyon, France, 2018: 1835-1844.
- [71] ZHANG F, YUAN N J, LIAN D, et al. Collaborative knowledge base embedding for recommender systems[C]// Proceedings of the 22nd ACM SIGKDD international Conference on Knowledge Discovery and Data Mining. San Francisco, USA, 2016: 353-362.
- [72] WANG H, ZHANG F, WANG J, et al. Ripplenet: Propagating user preferences on the knowledge graph for recommender systems[C]// Proceedings of the 27th ACM International Conference on Information and Knowledge Management. Torino, Italy, 2018: 417-426.
- [73] WANG H, ZHANG F, ZHAO M, et al. Multi-task feature learning for knowledge graph enhanced recommendation [C]// The World Wide Web Conference. CA, USA, 2019: 2000-2010.
- [74] 傅柱, 王曰芬, 丁绪辉. 面向知识重用的设计过程知识语义表示研究[J]. 数据分析与知识发现, 2019, 3(6): 21-29.
- FU Zhu, WANG Yuefen, DING Xuhui. Semantic representation of design process knowledge reuse[J]. Data Analysis and Knowledge Discovery, 2019, 3(6): 21-29.
- [75] 毕鲁雁, 焦宗夏, 范圣韬. 基于本体映射的产品概念设计
方案生成新方法[J]. 北京航空航天大学学报, 2009, 35(7): 895-898.
- BI Luyan, JIAO Zongxia, FAN Shengtao. New product conceptual design scheme generation method based on ontology mapping[J]. Journal of Beijing University of Aeronautics and Astronautics, 2009, 35(7): 895-898.
- [76] KULAK O, CEBI S, KAHRAMAN C. Applications of axiomatic design principles: A literature review[J]. Expert Systems with Applications, 2010, 37(9): 6705-6717.
- [77] JIA W, LIU Z, LIN Z, et al. Quantification for the importance degree of engineering characteristics with a multi-level hierarchical structure in QFD[J]. International Journal of Production Research, 2016, 54(6): 1627-1649.
- [78] 谭建荣, 李涛, 戴若夷. 支持大批量定制的产品配置设计系统的研究[J]. 计算机辅助设计与图形学学报, 2003, 15(8): 931-937.
- TAN Jianrong, LI Tao, DAI Ruoyi. Research on configuration design system supporting mass customization[J]. Journal of Computer Aided Design & Computer Graphics, 2003, 15(8): 931-937.
- [79] 郑维强, 刘振宇, 刘达新, 等. 基于模糊关联的复杂产品模块化设计方法及其应用[J]. 机械工程学报, 2015, 51(5): 130-142.
- JIA Weiqiang, LIU Zhenyu, LIU Daxin, et al. Modular design method and application for complex product based on fuzzy correlation analysis[J]. Journal of Mechanical Engineering, 2015, 51(5): 130-142.
- [80] RAN Q, LIN Y, LI P, et al. NumNet: Machine reading comprehension with numerical reasoning[C]// Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP). Hong Kong, China, 2019: 2474-2484.
- [81] DU W, ZHANG Y, ZHOU W. Modified non-gaussian multivariate statistical process monitoring based on the gaussian distribution transformation[J]. Journal of Process Control, 2020, 85: 1-14.
- [82] 陶飞, 刘蔚然, 刘检华, 等. 数字孪生及其应用探索[J]. 计算机集成制造系统, 2018, 24(1): 1-18.
- TAO Fei, LIU Weiran, LIU Jianhua, et al. Digital twin and its potential application exploration[J]. Computer Integrated Manufacturing Systems, 2018, 24(1): 1-18.
- [83] LIU Z, ZHANG D, JIA W, et al. An adversarial bidirectional serial-parallel LSTM-based QTD

- framework for product quality prediction[J]. Journal of Intelligent Manufacturing, 2020: 1-19.
- [84] 姚成玉, 饶乐庆, 陈东宁, 等. T-S 动态故障树分析方法[J]. 机械工程学报, 2019, 55(16): 17-32.
- YAO Chengyu, RAO Leqing, CHEN Dongning, et al. T-S dynamic fault tree analysis method[J]. Journal of Mechanical Engineering, 2019, 55(16): 17-32.
- [85] LIU H, LIU Z, JIA W, et al. A novel deep learning-based encoder-decoder model for remaining useful life prediction[C]// 2019 International Joint Conference on Neural Networks (IJCNN). Budapest, Hungary, 2019: 1-8.
- [86] 里鹏, 史海波, 尚文利, 等. 基于 SP95 标准的工厂模型设计与建模方法研究[J]. 计算机集成制造系统, 2009, 15(3): 458-462.
- LI Peng, SHI Haibo, SHANG Wenli, et al. Design of plant model and its modeling method based on SP95 standard[J]. Computer Integrated Manufacturing Systems, 2009, 15(3): 458-462.
-
- 作者简介:** 张栋豪, 男, 1995 年出生, 博士研究生。主要研究方向为知识图谱、自然语言处理、基于深度学习的数据挖掘、质量预测、复杂装备健康管理等。
E-mail: dhz@zju.edu.cn
- 刘振宇(通信作者), 男, 1974 年出生, 博士, 教授, 博士研究生导师。主要研究方向为复杂装备数字化设计与制造、复杂装备健康管理等。
E-mail: liuzy@zju.edu.cn
- 郑维强, 男, 1986 年出生, 博士。主要研究方向为知识图谱、自然语言处理、基于深度学习的数据挖掘等。
E-mail: wqjia@zju.edu.cn; weiq.jia@sunyard.com
- 刘惠, 男, 1994 年出生, 博士研究生。主要研究方向为传感器数据分析、基于深度学习的故障预测、复杂装备健康管理等。
E-mail: liuhui2017@zju.edu.cn
- 谭建荣, 男, 1954 年出生, 博士, 教授, 博士生导师, 中国工程院院士, 中国机械工程学会副理事长。主要研究方向为复杂装备数字化设计与制造、机械设计及理论、复杂装备健康管理等。
E-mail: egi@zju.edu.cn